AIハーネスの実行制御を検証する

品質を保ちながら、仕事の完了までに使う全担当の総トークンを減らす。

分担・情報共有・作業状態の引き継ぎを、
同じモデルと計算予算でどう設計するか。

今回の報告	実験の区切り	研究期限
目的・構成・実測・考察	基準方式 + Ansible初回	2027年12月

測れる基盤はできた。再編の利益はこれから確かめる

実装・運用の成果と、学術的に証明できたことを分ける。

できたこと

大型モデルの実機運用
単一 / 固定2担当の実行
全呼び出しの費用記録
最終成果物の独立評価

今回観測したこと

P3：2課題 × 2方式
同じ課題で合格 / 未解決
P4：調査は進んだが
修正パッチを作れず

まだ言えないこと

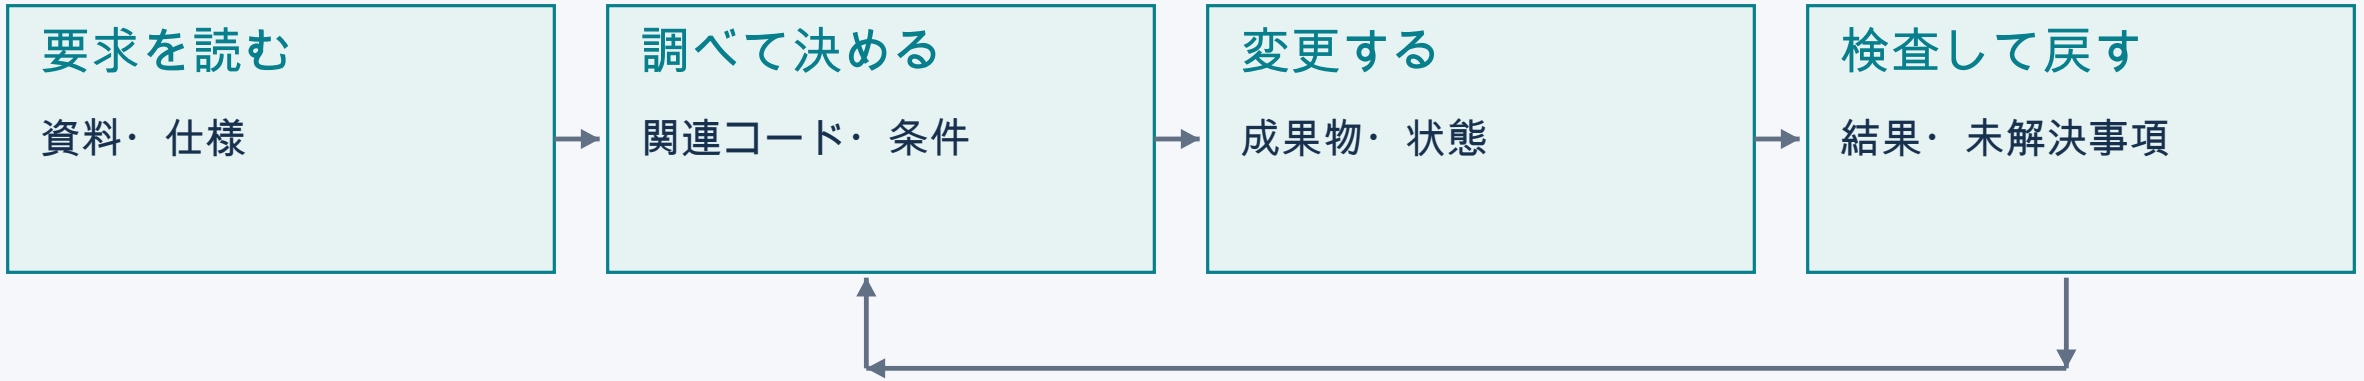
品質を保った費用削減
分担や集約の一般的優位
新規性の確定
別領域への一般化

次の一歩：構成を変える価値がある局面を、強い基準方式から探す。

出典 S1–S4：研究仕様、P3/P4測定・考察。各課題・方式は1試行。

仕事全体の整合性を、モデルの外側で支える

対象は一回の回答より長い、調査・実装・検査・修正の連続。



分担で扱う範囲を小さくする

担当ごとの調査・判断・文脈を整理する。

分担後にも整合が必要

前提の共有、変更の往復、履歴の再入力。

出典 S1。下図は問題設定の説明であり、観測済みの因果関係ではない。

品質を条件に、仕事全体の総トークンを減らす

節約だけを目的にせず、未完了や失敗も含めて評価する。

最小化：E [C全担当・ 全制御]

制約：品質が基準方式から許容差 δ を超えて下がらない

測る量	今回の定義
費用 C	すべての入力 + 出力。キャッシュ対象の入力も含む。
品質 Q	凍結した最終成果物の独立評価。未完了は成功にしない。
補助指標	実時間、メモリ、往復修正、移管費用、不要な変更。

品質許容差 δ・必要課題数・確認用課題は未確定。非有意差は同等性ではない。

出典 S1・S8：研究仕様と確認評価の検討。式は目標の定式化で、達成済みではない。

現象を観測してから、再編と選択器を作る

自動集約を先に完成させると、本当に必要な機構を見失う。

01

基盤・評価器

状態 / 費用 / 成果物

実施済み

02

単一・固定分担

失敗と調整の観察

実施中

03

同一状態の分岐

整理 / 調整 / 移管

これから

04

対応の自動選択

利益と費用を予測

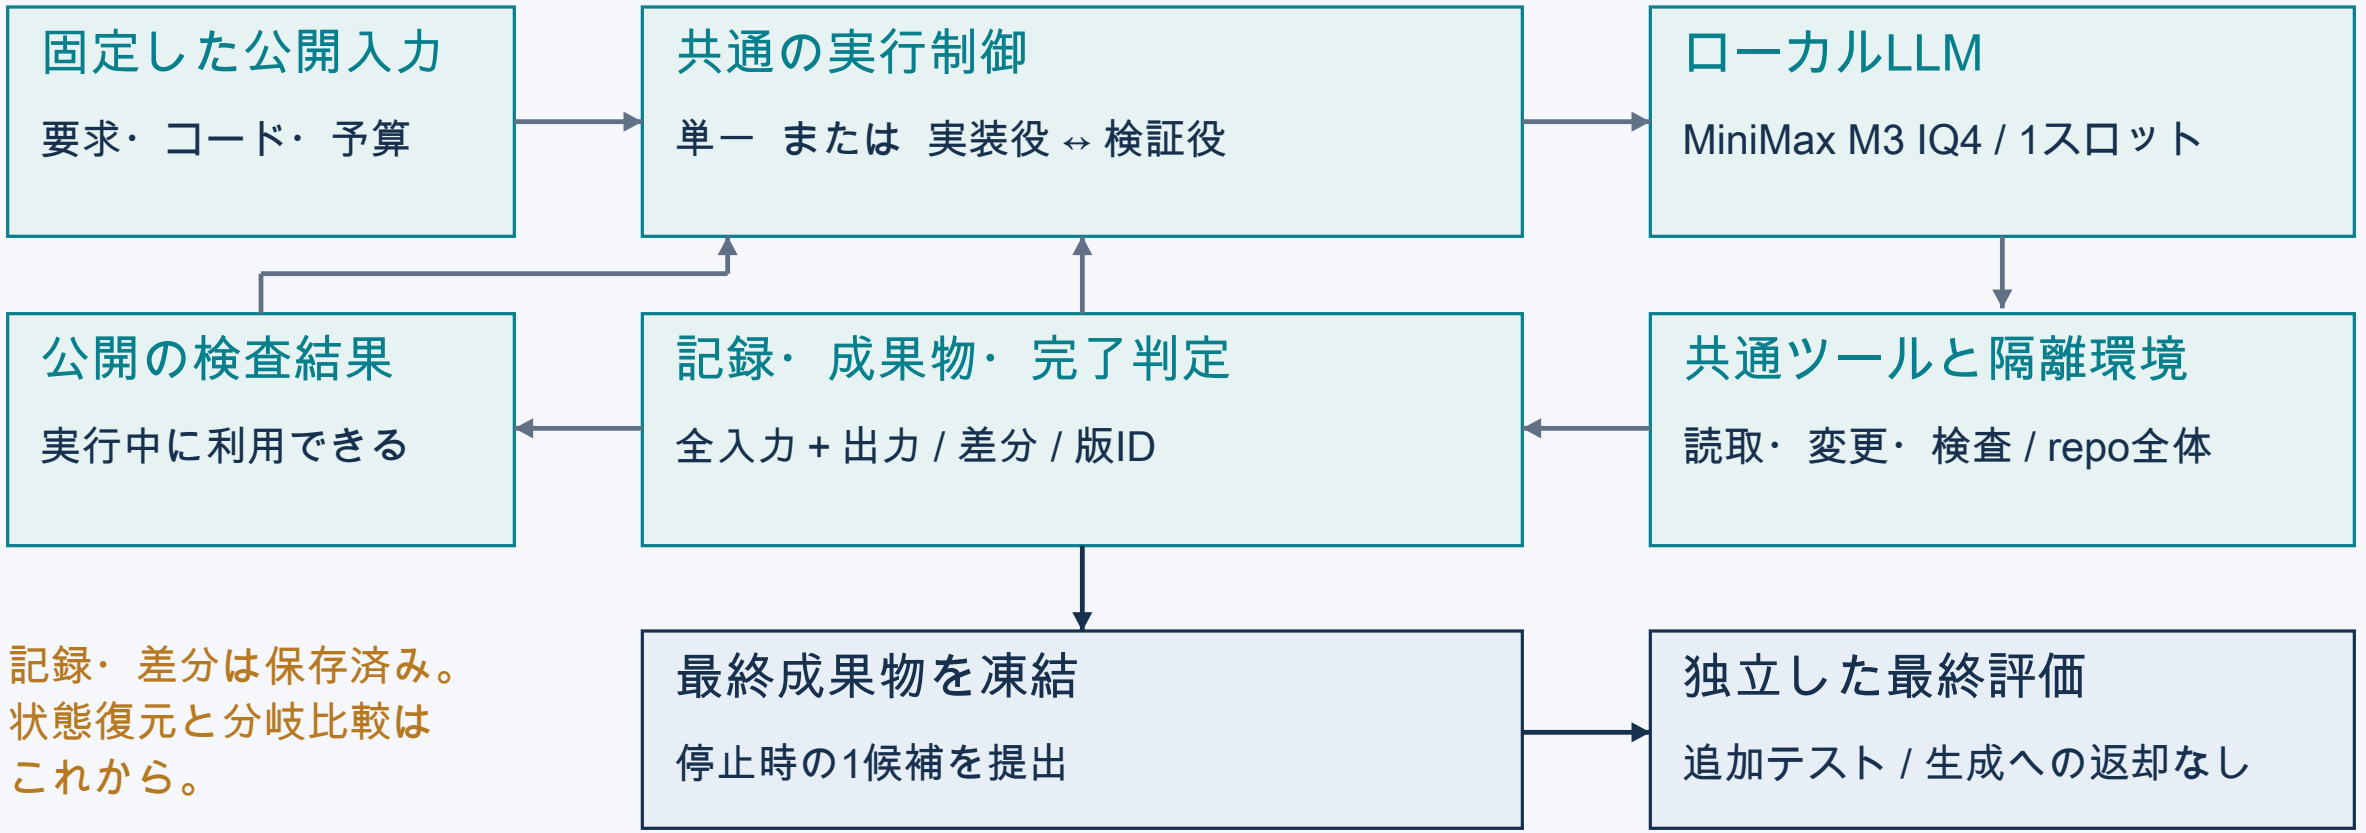
効果があれば

今は「構成比較に適した課題と、切り分け可能な失敗」を確認している。

出典 S1・S5：研究仕様と作業ボード。青緑 = 実施、黄 = 未実証 / 今後。

1つのモデルを、単一または固定2担当で共有する

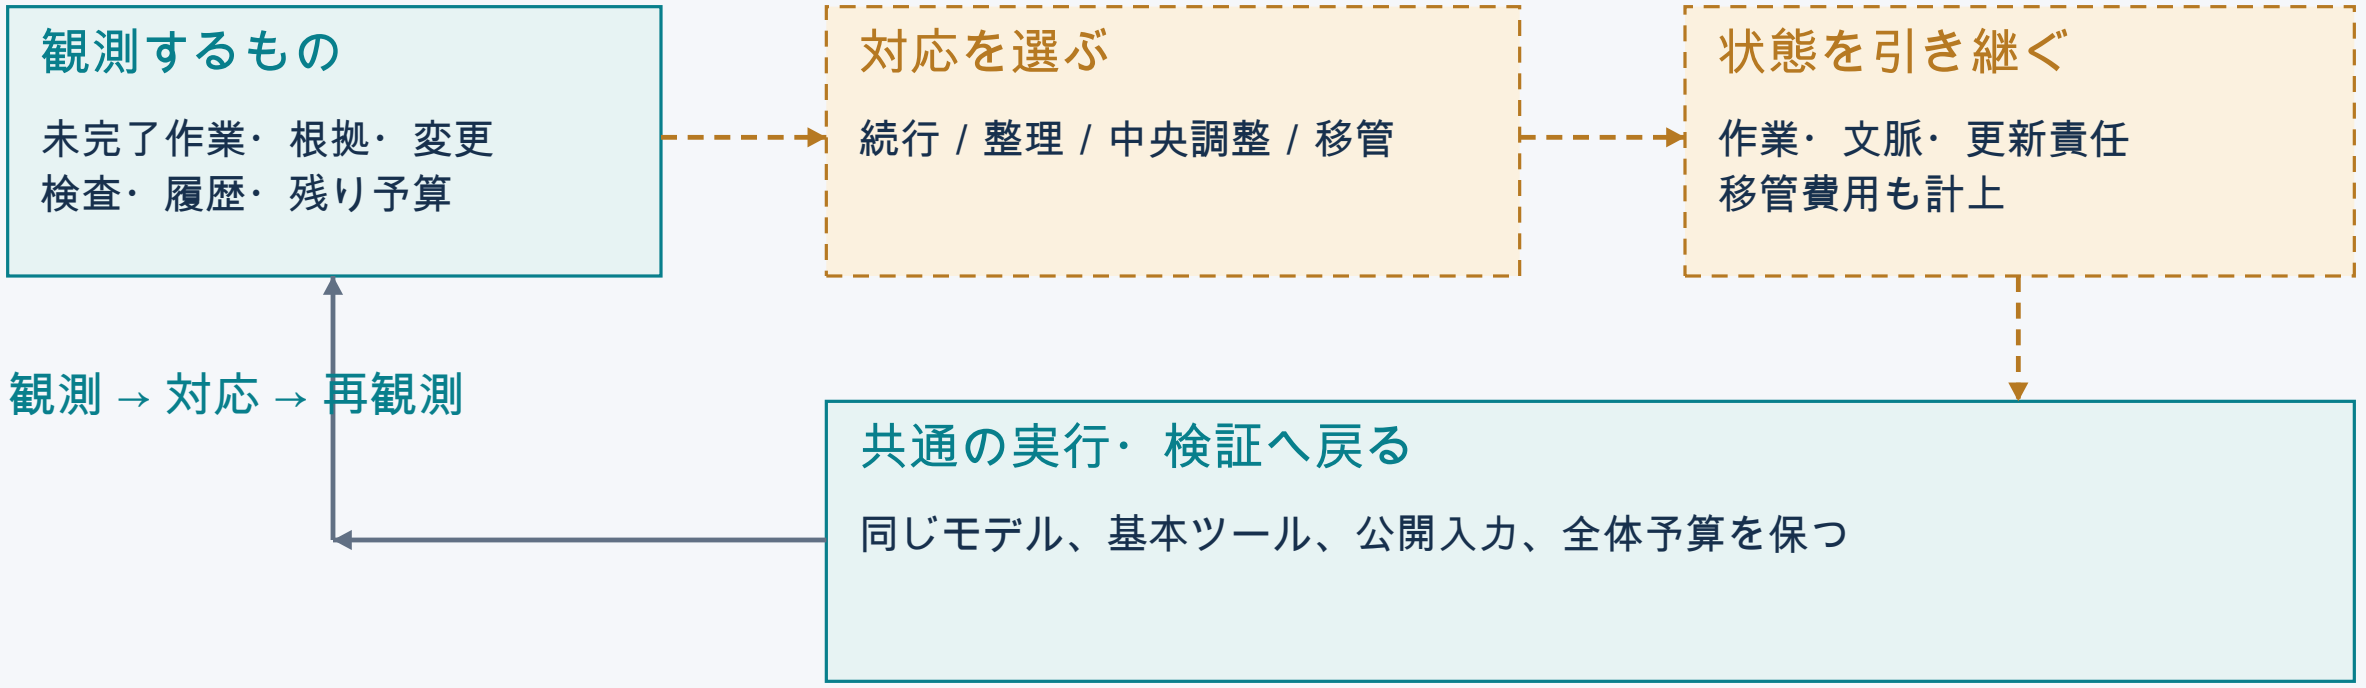
実験条件・全体予算・成果物の版を、共通の実行器で管理する。



出典 S6：run_fixed_comparison.py / run_pro_pilot.py / artifact_capture.py / experiment_state.py

実行中の状態から、次の対応を選ぶハーネスへ

黄の部分は計画段階。自動再編の効果を示す実験はまだ行っていない。



学習器は、状態によって有効な対応が変わり、単純規則では足りない場合に検討。

出典 S1・S7：研究仕様と四条件分岐タスク。モデル重みの融合ではない。

情報を整理する効果と、実行単位を変える効果を分ける

同じ会話・ファイル・環境・成果物・残予算を保存して分岐する。

分岐	変えるもの	保つもの
A 継続	変更なし	現在の担当・文脈・更新範囲
B 情報整理	必要根拠と現在状態を整理	担当・更新範囲
C 中央調整	共同方針を決めて返す	元の担当が実行
D 作業移管	関連する判断と実行を集める	モデル・ツール・総予算

DがB・Cを超えた場合にだけ、実行単位を変える追加価値を検討する。

出典 S7。四条件比較は設計段階。中央調整と移管が機能的に同じなら差分を主張しない。

大型モデルを1つ共有し、担当ごとの履歴を切り替える

実機の256GiBはメモリ。保存領域の容量とは別に測定した。

項目	採用中の開発条件
Mac Studio	M3 Ultra / CPU 28 / メモリ 256GiB
モデル	MiniMax M3 IQ4_XS / 重み 213.91GiB
推論	llama.cpp b11669 / KV q8_0 / 入力枠 65,536
複数担当	同じモデルへ逐次入力。重みを担当数倍にしない。
P4の実測	サーバーRSS最大約219.9GiB / 観測swap 0

複数担当の検証は可能。ただし、この構成から物理並列の高速化は主張しない。

出典 S9・S3：モデル選定、実機記録、P4の5秒間隔サンプル。GiB = 2^30バイト。

モデルの大きさより、必要な入力長で測定できること

大型・非Flashという希望と、実際の容量・接続・実課題の結果を合わせた判断。

候補	確認結果・優先順位の理由
M3 IQ4_XS + q8 KV	64Kとツール往復が動作。P3/P4の共通モデルとして採用。
同じIQ4 + f16 KV	64KでMetalメモリ不足。失敗記録を保ち別設定に分離。
M3 Q3_K_L	動作済み。比較記録を保持。Q3対IQ4はKV条件も異なる。
M3 Q4_K_M	重みだけで約243GiB。長い入力と作業領域の余裕が小さい。
別系列・小型モデル	比較候補として残す。今はハーネス条件を先に固定する。

本実験のモデルは未確定。2課題の成績や量子化名だけで一般的な優位は決めない。

出典 S9。未測定の候補を劣ると判断した表ではない。一般的な最強モデルの選定でもない。

実行基盤の検証から、構成差の観察へ進んだ

条件が異なる段階を一つの成功率にまとめない。

段階	目的	実行規模	到達点
P0 / E0 / P1	接続・評価・単一基準	P1：2モデル×2課題	公開 / 独立評価を分離
P2 Q3	大型モデルの実行適合	2課題 / 53呼出	独立評価0/2
P2 IQ4/q8	容量と開発課題品質	2課題 / 58呼出	独立評価1/2
P3	単一と固定2担当	2課題×2方式 / 105呼出	両方式で同じ成否
P4	広い依存候補の単一観察	Ansible 1課題 / 38呼出	未解決・修正差分なし

ここまでの成果は、方法の改善率ではなく、比較の基盤と失敗の観測記録。

出典 S10・S2–S4。呼び出し数は実問題の当該試行のみ。校正・失敗した導入は別記録。

モデル・ツール・総予算をそろえ、工程分担を比べた

同じDjangoの開発2課題を、単一 / 固定2担当で各1回。

単一エージェント

1つの履歴で調査・実装・検査
外部ツールと全リポジトリを利用
完了判定と費用を共通管理

固定2担当

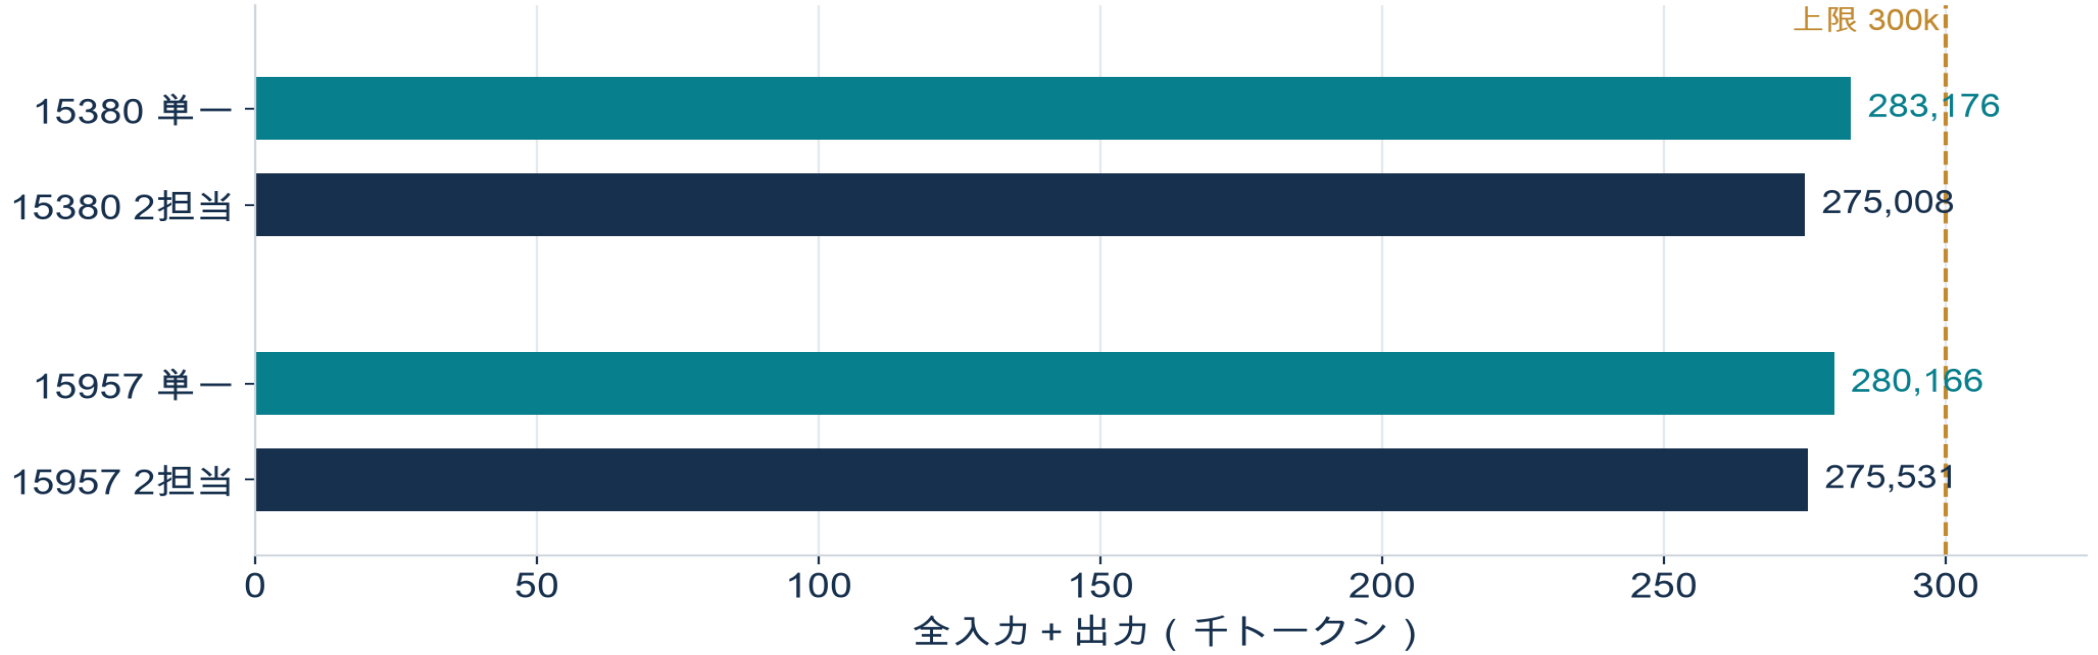
実装役と検証役の別履歴
交互に実行し、同じ作業ツリーを共有
排他的な責任の移管は行わない

共通上限：30呼び出し / 300,000入力 + 出力 / 3,600秒 / 同じM3 IQ4/q8

出典 S2：P3固定計画・測定。両担当とも全作業ツリーを読取・変更できる。

総トークンは近いが、全件が予算停止だった

15380は両方式合格、15957は両方式未解決。各棒は1試行。

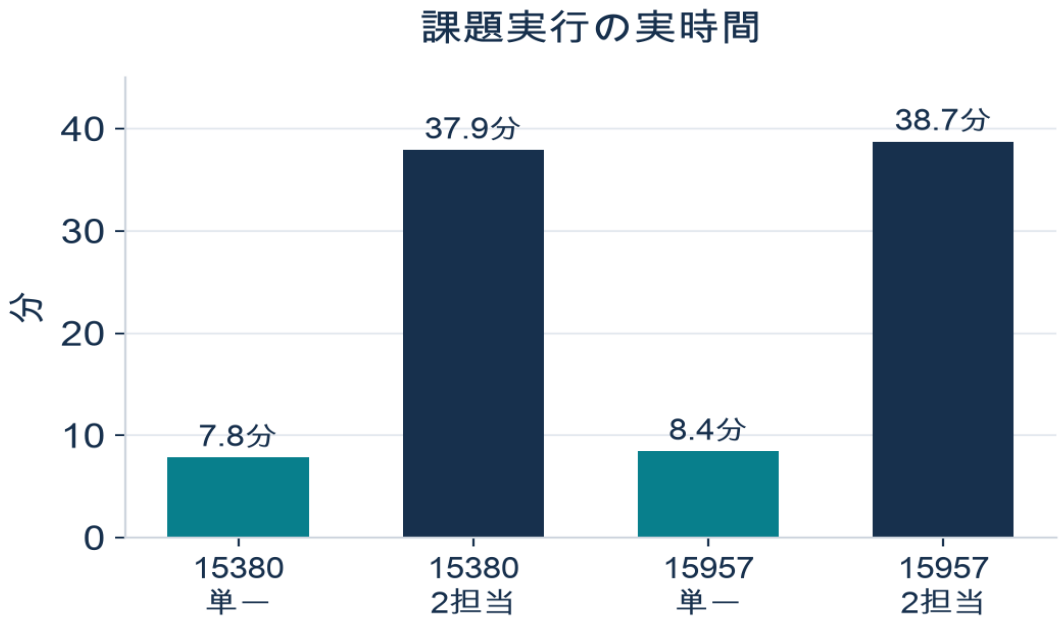


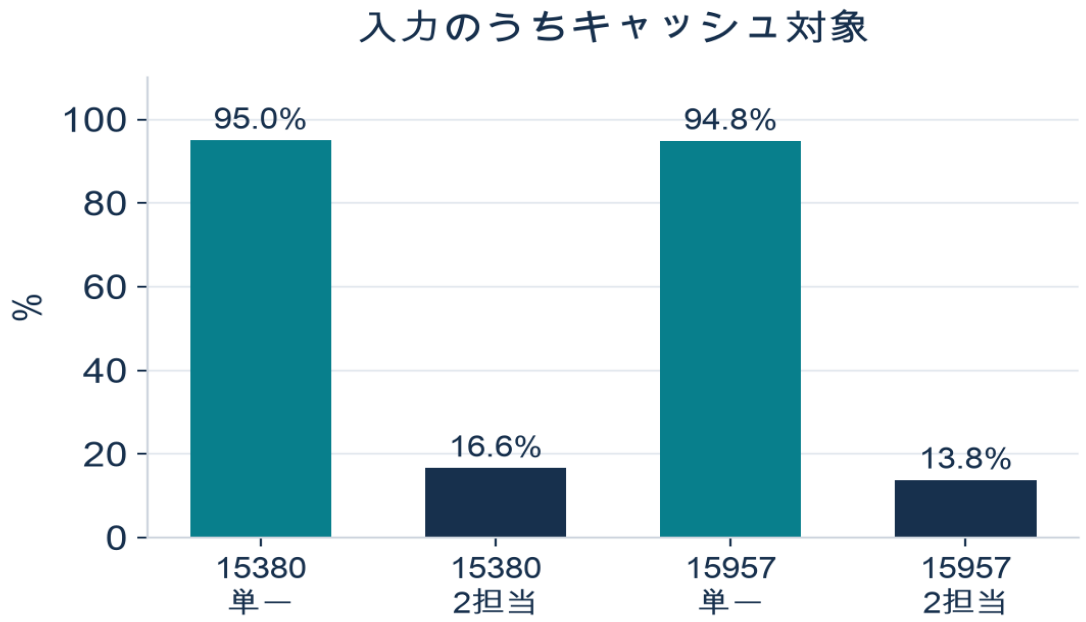
少し少ない消費を「品質を保った費用削減」とは扱わない。完了宣言は全4件0回。

出典 S2・P3_data.csv。バーは0起点。反復がないため誤差棒や有意差は示さない。

論理トークンが近くても、実時間は大きく違った

単一履歴と交互の2履歴で、キャッシュの利用条件も違う。





2担当が常に遅いとは言えない。物理構成とキャッシュを含む、この実行条件での観測。

出典 S2· P3_data.csv。一つの物理スロットで逐次実行。キャッシュは入力の内数。

解けない原因を、分担や受け渡しのせいにしない

成果物と操作を調べ、次の研究へ使える観測か判断した。

課題	単一	固定2担当
15380 同時改名	機能修正 / 合格 857バイトの差分	機能修正 + テスト / 合格 2,678バイトの差分
15957 prefetchの制限	修正差分なし / 未解決 公開既存検査は合格	再現テストのみ / 未解決 追加検査に3エラー

両方式で機能修正に至らない失敗はある。
この結果だけでは、更新責任を集める必要性を特定できない。

出典 S2：P3_findings.md。局所修正の成功を大規模・相互依存作業の実証にしない。

正解の変更箇所を使わず、公開要求から候補を選ぶ

大きなリポジトリであることと、複数作業の依存が強いことは別。

最初の12候補

6リポジトリ × 2件
公開要求を先に固定抽出
局所修正が中心だった
主課題の採用は保留

Proの追加12候補

604候補から規則で抽出
3候補の21ファイル確認
メール復号・YAML等の
関係を公開コードで検討

Ansibleを先に導入

YAML・信頼情報・vault
の条件を扱う実行候補
固定基点と評価器を確認
正式な主課題採用は未定

小課題を不自然に分割して、集約が必要な状況を作らない。

出典 S11：公開課題選定・Pro候補・基点コードの確認。すべて開発用の閲覧台帳に記録。

未修正は落ち、参照修正は通ることを先に確かめた

モデルの失敗と、評価基盤の失敗を区別するための正負対照。

投入した成果物	要求を確認する4テスト	既存動作の21テスト
空の差分（負対照）	0合格 / 4不合格	21合格 / 0不合格
参照修正（正対照）	4合格 / 0不合格	21合格 / 0不合格
P4の凍結成果物	0合格 / 4不合格	21合格 / 0不合格

導入時の3失敗と、終了コード1を基盤エラーにした誤判定も保存。
残した出力から訂正し、元の結果は上書きしなかった。

出典 S12・S3：PRO_ENV_05 / P4独立評価。参照修正・追加テストの内容は生成側へ渡さない。

YAML処理の複数の条件を、単一方式でまず観察する

Ansible 1開発課題・1試行。P3から課題と上限が変わるため、直接の手法比較にはしない。

YAMLの入口・出口

from_yaml / from_yaml_all
to_yaml / to_nice_yaml

→

保持すべき情報

信頼情報・由来情報
文字列・コンテナ

→

暗号化とテンプレート

vaultの出力条件
未定義値等の扱い

上限 60呼び出し / 600,000トークン / 3,600秒

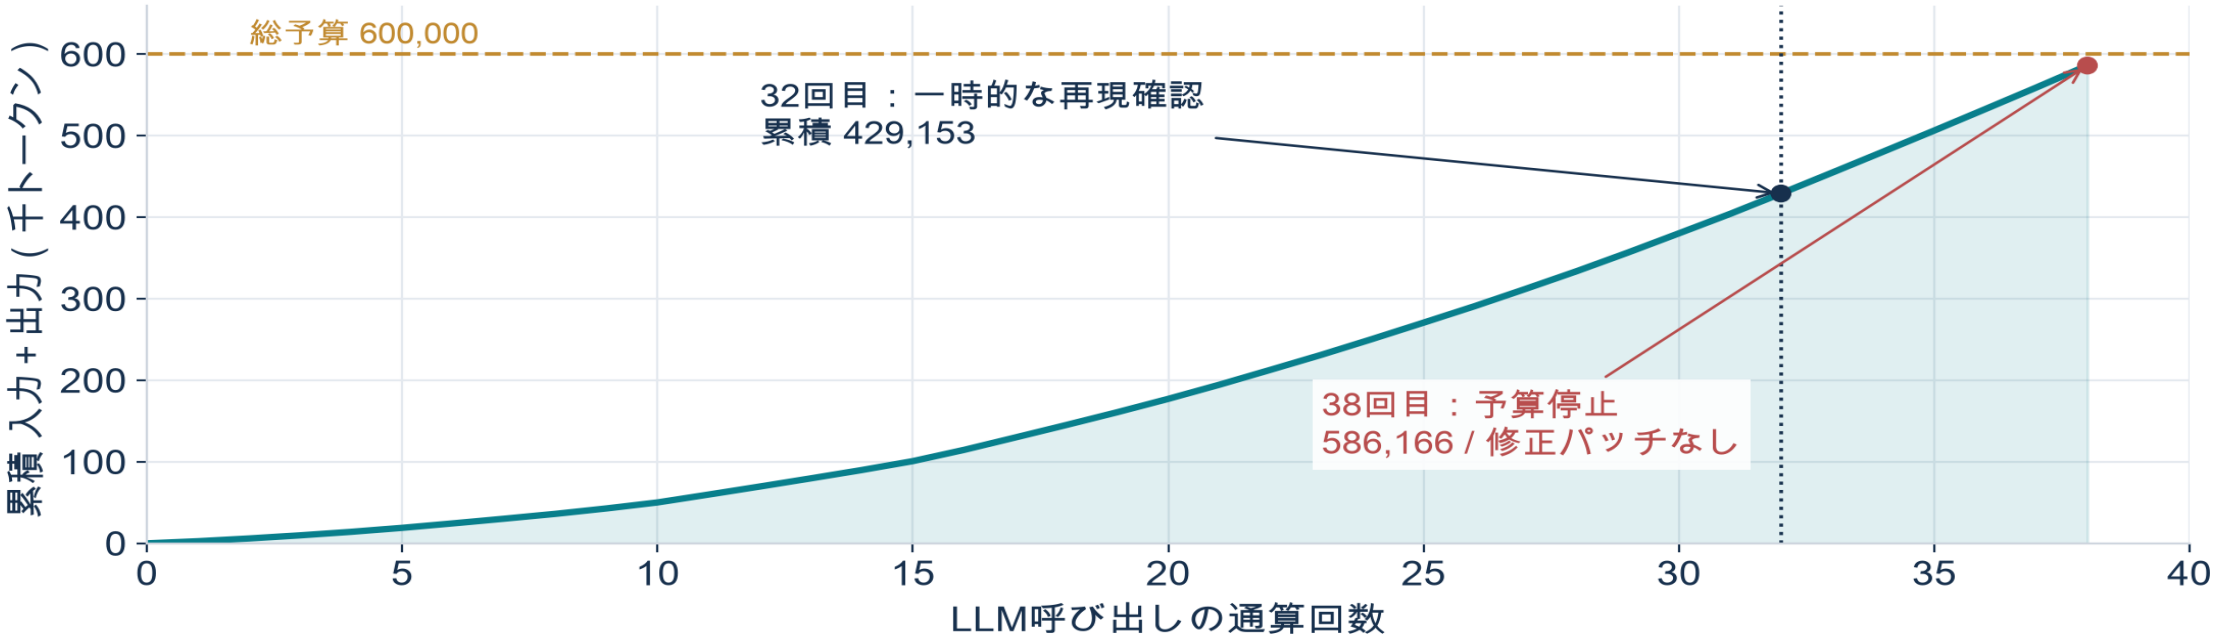
公開要求3項目をすべて入力。19ソースと条件を実行前に固定。

情報が不足した設定にせず、公開要求を保ったまま挙動を測る。

出典 S3・S4。下図は公開要求に登場する関係で、実証済みの因果グラフではない。

調査から再現確認へ進んだが、修正には届かなかった

最初の再現確認より前に404,067トークンを使用。修正成果物は最後まで0バイト。

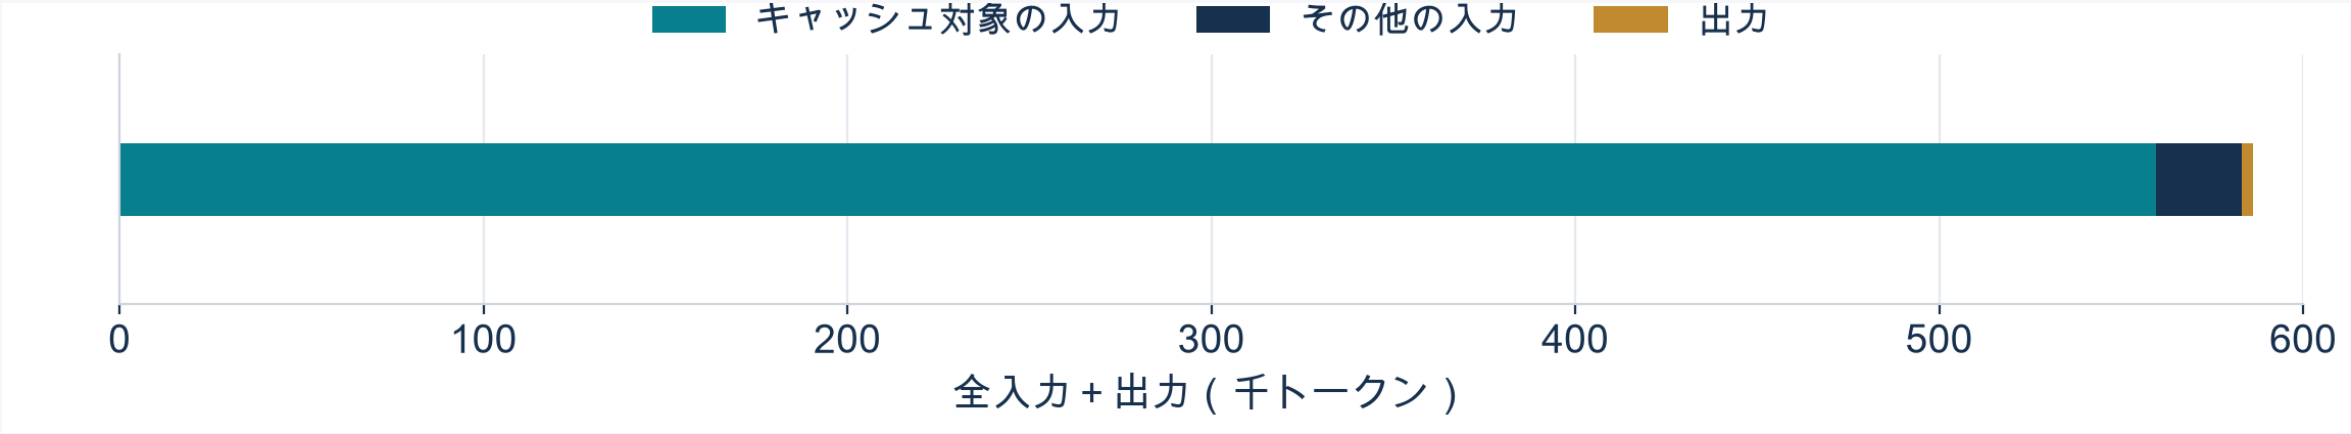


読む作業を一律に無駄とは判定しない。調査から変更へ移る条件は、次の検証候補。

出典 S3・S4・P4_timeline.csv。一時領域の再現スクリプトは操作記録に保存。

入力の繰り返しが総トークンの大半を占めた

実行 448.53秒 / 38呼び出し / 586,166総トークン



入力	出力	最終成果物	独立評価
583,040	3,126	0バイト	未解決：要求0/4

公開既存131件の合格、再現スクリプトの終了0だけでは要求を満たしたとは言えない。

出典 S3。キャッシュ対象559,572は入力583,040の内数。課金額や実計算量とは別の指標。

分かったことと、原因として未確認のこと

失敗も費用へ含め、実装の問題と研究仮説を混ぜない。

観測できたこと

同じモデルで両構成を測れる
公開検査と独立評価が食い違う
P4は予算停止で機能修正なし
計測欠損・形式エラーはなかった

これから切り分けること

基準方式の調査・停止方針の影響
本当に必要な作業間の調整
情報整理だけで改善できる範囲
実行単位変更の固有の追加価値

単一の失敗を、複数担当や集約の必要性の証拠へ読み替えない。

出典 S2–S4。内部推論文から原因を断定する分析は行っていない。

「動的に担当を変える」だけでは、既に研究がある

本文と固定コードを照合中。完全再現と新規性の確定は未完了。

近接研究	既に扱われていること	今回さらに検証したいこと
MaAS / ICML 2025	課題に応じた構成・費用配分	全工程の品質条件と費用
TDAG / NN 2025	動的な分解・担当生成	進行した作業状態の移管
Flow / ICLR 2025	実行中の作業・担当更新	共有・中央調整を超える効果
Puppeteer / NeurIPS 2025	状態に応じた担当選択	移管の利益と費用を含む比較

狙うのは有効条件と機構の説明。再編・分岐実験・利益予測そのものを世界初としない。

出典 L1–L4・S13。各研究の原理の要約であり、同条件の性能比較ではない。

分担の観察 → 同一状態の対照 → 必要なら自動選択

前段で現象が残らなければ、次の複雑な機能へ進まない。

順序	行うこと	進める条件
1	同条件の工程分担· 強い基準の点検	観測可能な調整· 状態不整合がある
2	同一状態から継続 / 整理 / 調整 / 移管	復元と予算の比較が成立する
3	単純規則と利益予測を比べる	局面により有効な対応が変わる
4	未使用課題· 別モデルで確認する	品質条件· 主要指標· 必要件数を固定

並行して決める：主課題、依存の分類、品質許容差、必要件数、最も近い比較実装。

出典 S1· S5· S7。後続の具体的な試行条件は、開始前に別計画として固定する。

2027年夏の初回投稿を目標に、段階ごとに判断する

12月は修論・成果物の完成期限。採録時期は査読に依存する。

時期	重点	残す成果物
2026年10–12月	主課題・基準方式・現象の確認	選定理由、条件、失敗分析
2027年1–4月	同一状態の比較・機構の分析	分岐データ、効果と費用
2027年5–6月	確認評価と論文の主張を固定	主要図表、限界、再現手順
2027年7–8月	執筆・初回投稿	IEICE論文誌を主候補に原稿
2027年9–12月	追加検証・査読対応・修論	コード、設定、最終発表

再編が効かない場合も記録する。ただし、否定結果だけで論文化できるとは保証しない。

出典 S1・S5：研究の現方針を基にした予定。結果により手法と件数を見直す。

どの状態に、どの構成が必要かを説明できる研究へ

到達目標は、平均スコアの上昇だけではない。

学術的な成果

情報整理で十分な条件
中央調整が有効な条件
移管が役立つ / 害になる条件
品質と費用の根拠

技術的な成果

状態を扱う共通ハーネス
同じ途中状態の比較基盤
費用を含む選択規則
再実行できる記録と設定

現在の課題

強い基準でも残る現象
近接研究との差分
主課題と確認評価
一般化できる範囲

「誰に何を渡し、どこで判断・実行をまとめるか」を、実測に基づいて決める。

P3の4試行を比較するためのデータ

下記は開発観察。入力キャッシュは全入力の内数で、費用から差し引かない。

課題・方式	呼出	入力	出力	合計	秒	評価
15380 単一	26	277,892	5,284	283,176	469.70	合格
15380 2担当	27	269,358	5,650	275,008	2274.54	合格
15957 単一	25	274,364	5,802	280,166	506.82	未解決
15957 2担当	27	270,474	5,057	275,531	2324.12	未解決

全4試行が予算停止。合計105呼び出し・1,113,881トークン。独立な課題数は2。

出典 S2・materials/20261020/P3_data.csv。完全な集計はreports/に保存。

固定したものと、原記録のたどり方

公開可能な集計・コードと、実験機上に保持するデータを区別する。

対象	固定版 / 記録
推論基盤	llama.cpp 620d2225… / mini-swe-agent 04d809ce…
P3計画	configs/P3_development_plan_v01.json / ce33553f…
P4計画	configs/P4_pro_single_plan_v01.json / 64701ea1…
Proデータ・実行環境	HF 2d52cb3d… / V2 image sha256:2ee62346…
公開するもの	集計・理由・設定・図表CSV・資料生成コード
ローカルに保持	モデル重み・完全な履歴・独立評価の追加テスト

GitHubの変更先はAI-のみ。Issueと専用Projectに状態を継続記録する。

出典 S6・S14。下記は短縮表記。完全なSHA-256・コミットは設定とdata_sources.jsonへ。

数値・図表・判断の出典

資料の数値は記録済みの集計から生成。詳細は各リンクと発表者ノートへ。

S1	研究の目的・評価の基準 ↗
S2	P3比較の実測と考察 ↗
S3–S4	P4実測・公開操作の分析 ↗
S5–S7	作業ボード・実装・分岐計画 ↗
S8–S10	品質条件・モデル選定・以前の実測 ↗
S11–S12	主課題選定と評価器の校正 ↗
S13–S14	先行研究比較と固定計画 ↗

新規性の確認に使っている主な文献

下記の正式掲載研究と著者実装を比較。方法全体の再現はまだ行っていない。

L1 MaAS: Multi-agent Architecture Search via Agentic Supernet ↗

ICML 2025 / PMLR 267

L2 TDAG: Dynamic Task Decomposition and Agent Generation ↗

Neural Networks 185, 107200 (2025)

L3 Flow: Modularized Agentic Workflow Automation ↗

ICLR 2025

L4 Multi-Agent Collaboration via Evolving Orchestration ↗

NeurIPS 2025

本文・実装の確認範囲と未確認事項はdocs/related_work_matrix.mdに記録。