品質を保って総トークンを減らすための検証

独自手法を決める前に、
既存方式で起きた失敗の機構を確かめる。

全履歴、先行研究に基づく保持方式、対象台帳を比較。
完了率だけでなく、実行情報の誤記憶と
保持判断・入力再処理の費用を分けて調べた。

得られたのは失敗条件と次の比較。新しいアルゴリズムはまだ選んでいない。

担当再編を前提にせず、必要な機構を選び直す

目標：同じモデルで必要な品質を満たし、全入力＋出力トークンを減らす。

出発点

大規模な仕事を分担し、
途中で仕事・状態を
引き継ぐ研究を検討。
既存方式との重複を確認。

見直した理由

開発実験では担当間の
変更衝突を確認できず、
再編の固有利益を
裏づけられなかった。

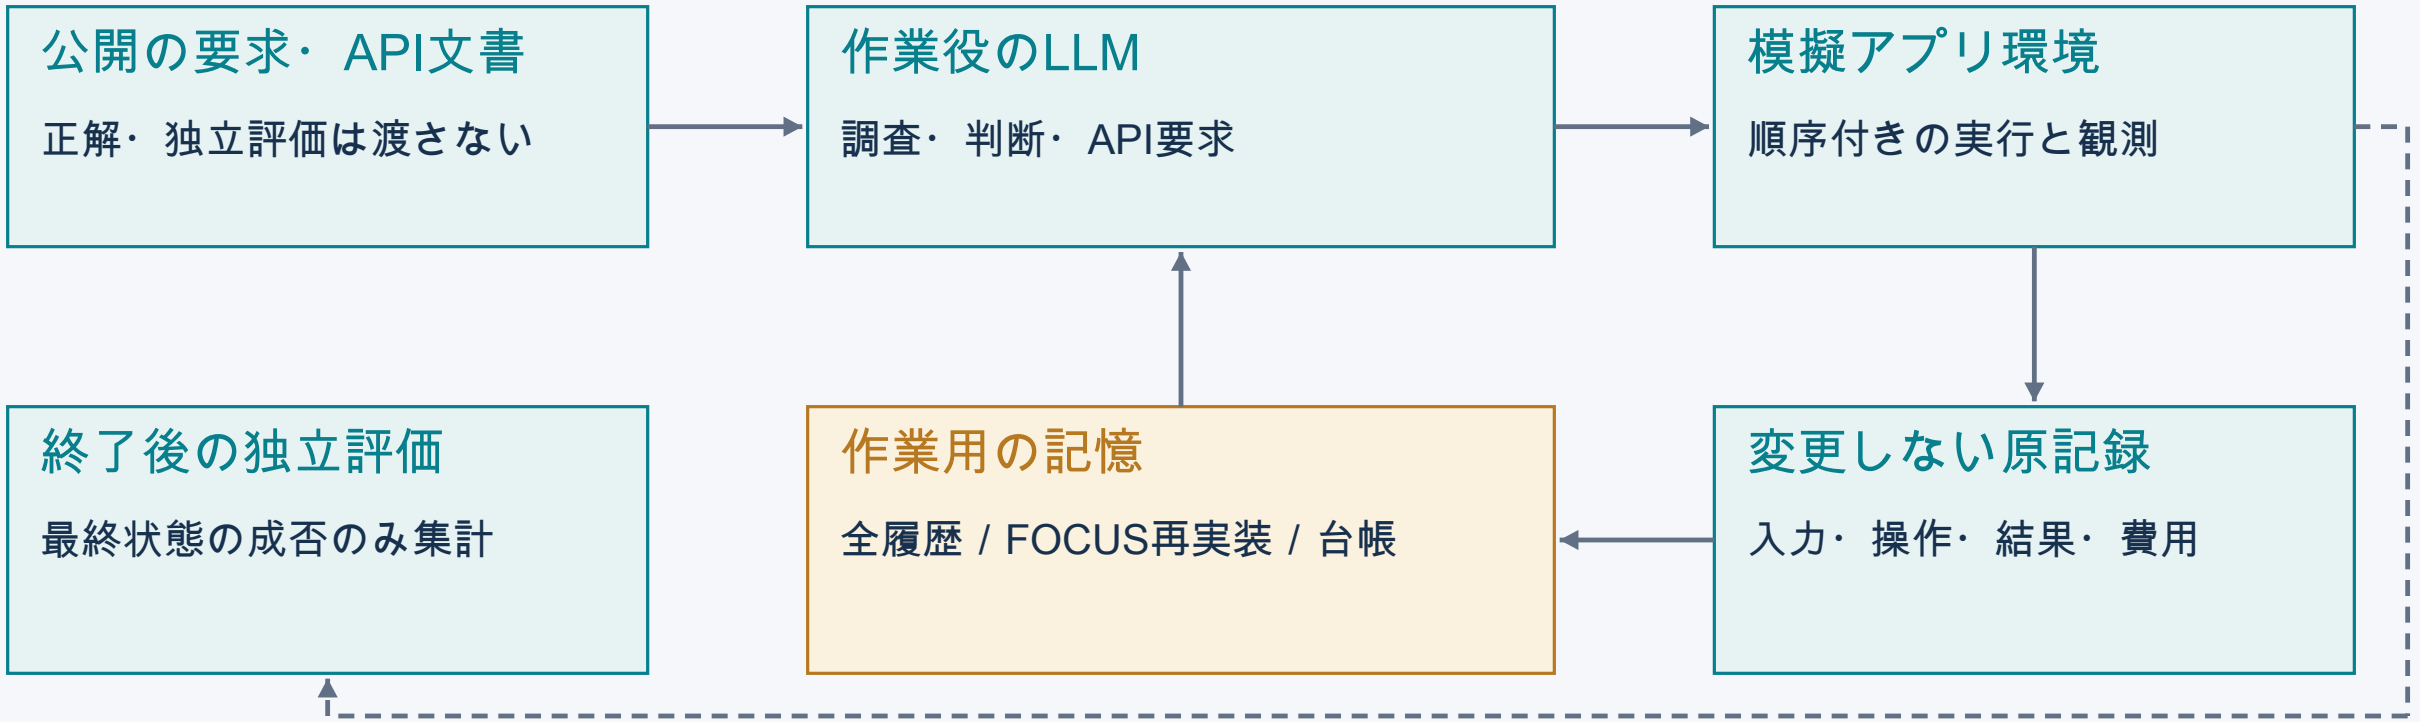
現在の検証

情報をどう保持・更新し、
行動へ渡すかを比較。
既存の単純方式で足りる
可能性も検証する。

モデルの外側にある情報・状態・実行制御が対象。ハーネス研究として継続する。

記憶の更新と、環境で実際に行った操作を分離する

同じモデル・公開ツール・予算で、作業用の記憶だけを切り替える。



記憶の生成文、操作の実行、最終タスク成功は、それぞれ別の記録で確認する。

少数の開発課題で、方式を校正する段階

AppWorldの公開train入力から2課題を選択。各方式・各課題1回。

条件	固定した内容
モデル	MiniMax M3 IQ4_XS・64K・KV q8_0・同じ推論基盤
全履歴	原記録を全て作業用入力へ。過去の参照も可能
FOCUS再実装	将来計画の参照 + 防御的保持。原著者の性能再現ではない
対象台帳	対象・条件・進捗・根拠IDを更新。意味の正しさは未保証
共通上限	80呼び出し・45万トークン・30分・出力4,096 / 回

全担当・記憶生成・再読込を計上。大規模本実験や一般化の証明とは区別する。

成功と費用を同時に見る

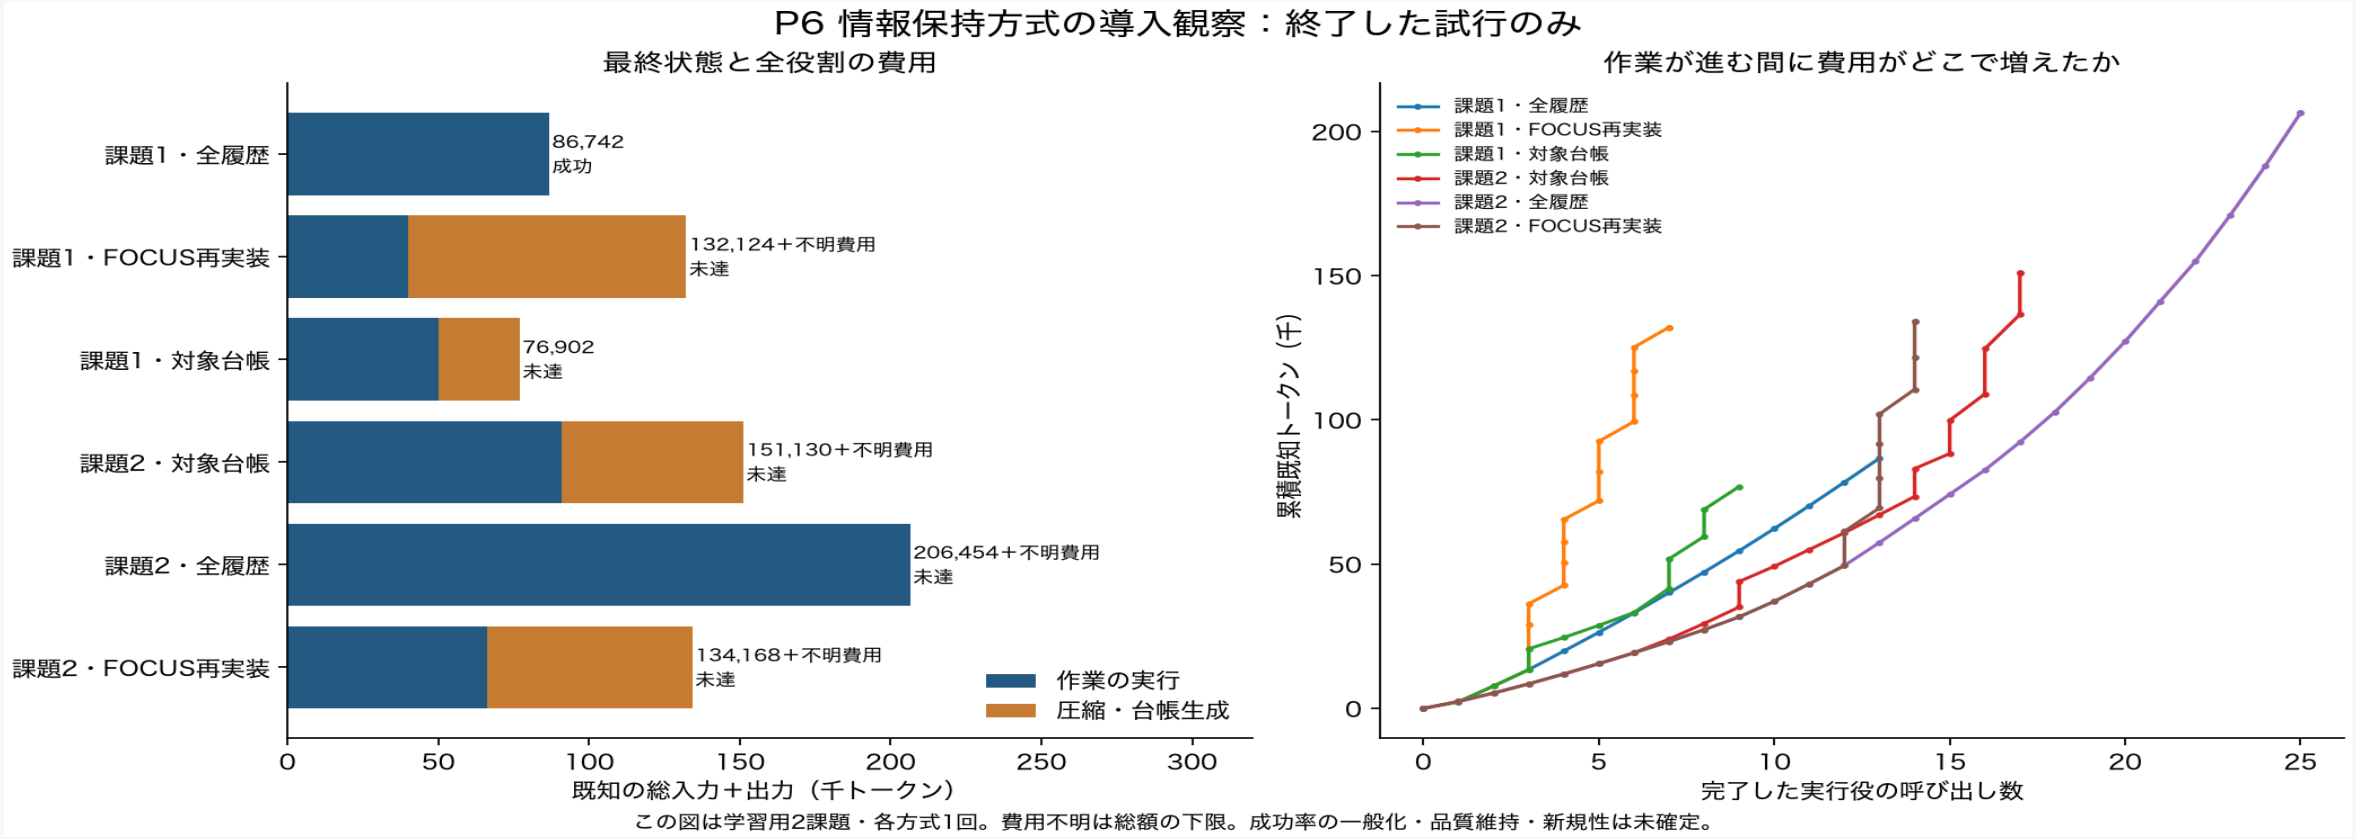
費用不明の中断呼び出しは0とせず、「＋不明」として残す。

課題	方式	呼出	既知トークン	評価	停止理由
1	全履歴	13	86,742	成功	完了宣言
1	FOCUS再実装	19	132,124＋不明	未達	時間上限
1	対象台帳	12	76,902	未達	完了宣言
2	対象台帳	23	151,130＋不明	未達	時間上限
2	全履歴	26	206,454＋不明	未達	時間上限
2	FOCUS再実装	21	134,168＋不明	未達	時間上限

少ないトークンで失敗した結果を「品質を保った削減」とは呼ばない。

記憶を小さくする判断にも計算が必要

記憶生成の費用を除かず、元の実行記録から集計。



失敗したという事実だけでは、原因は決まらない

推論文の自己説明を、そのまま原因の証明に使わない。

保持判断の負担

FOCUSの計8更新試行。
履歴を除いた記録は0回。
形式不備・生成上限・費用を
忘却の効果と混ぜない。

台帳の誤った完了

課題1では送信されなかった
不正な操作を根拠に、
更新をdoneとした。
IDの存在だけでは不十分。

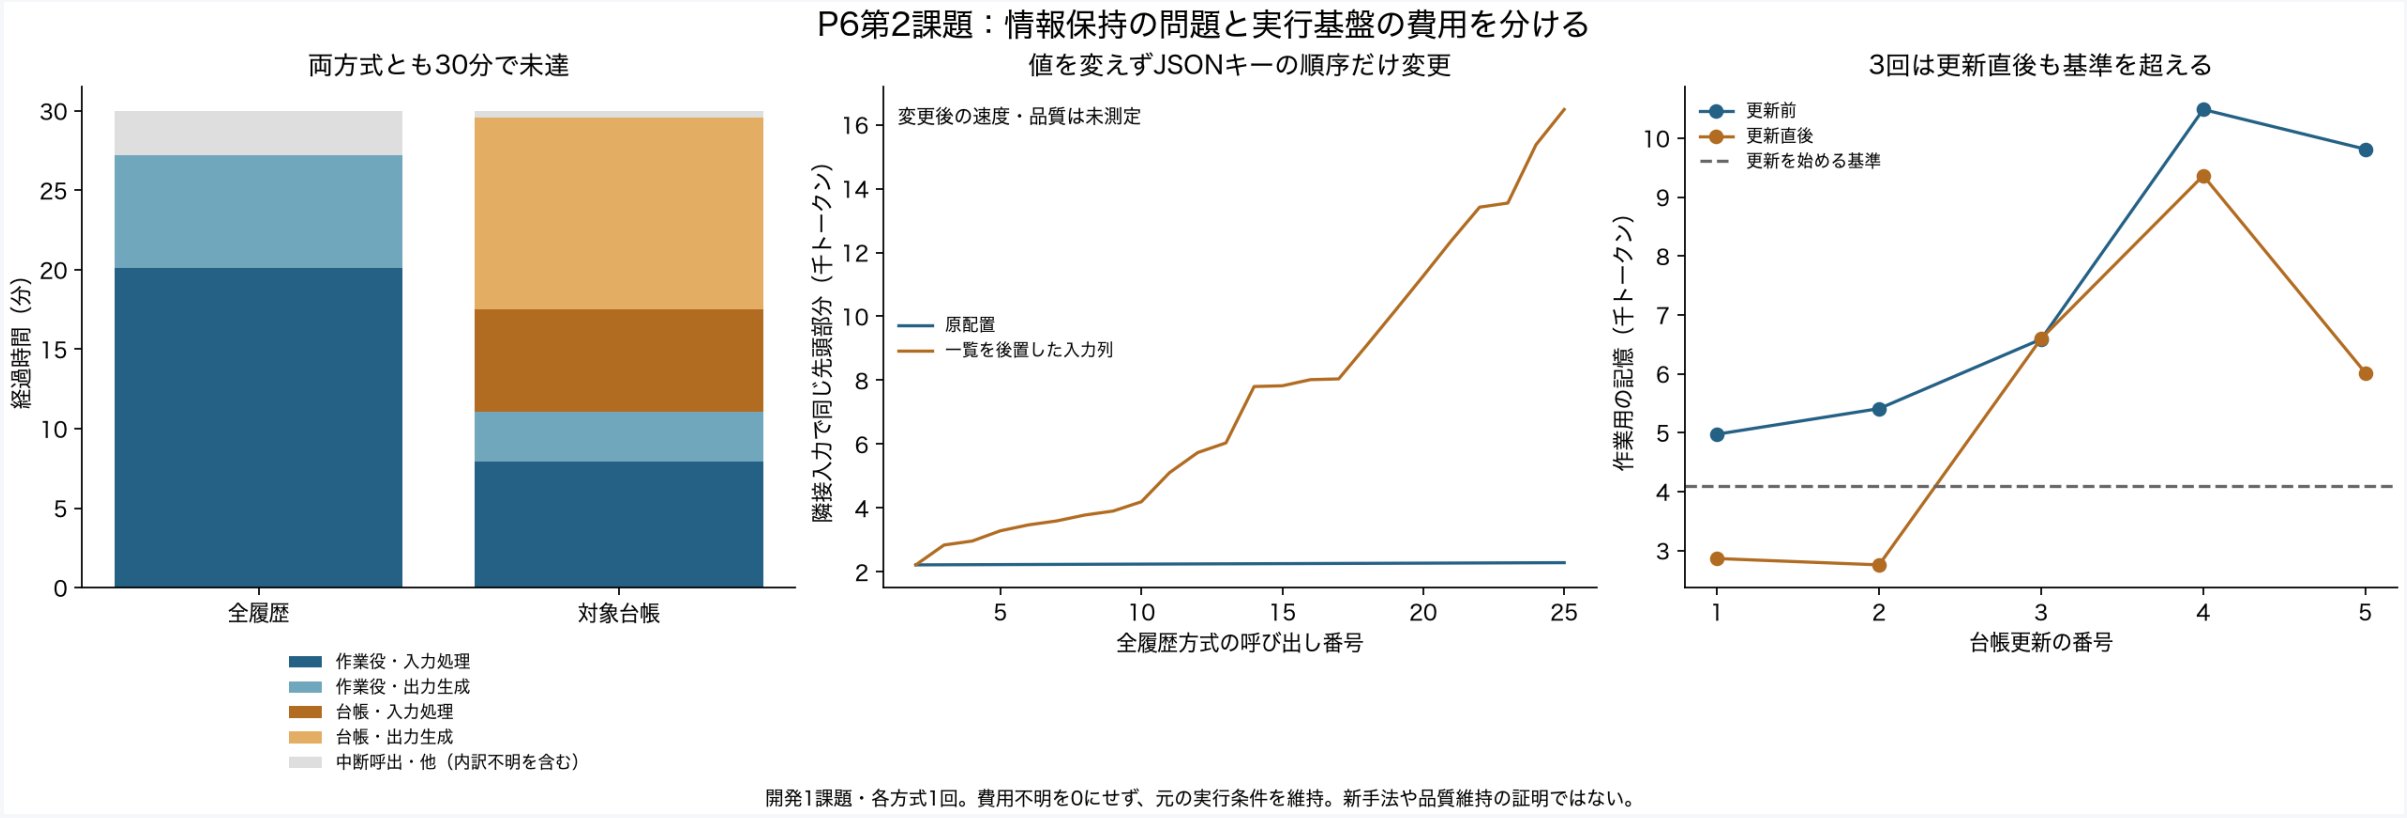
比較基盤の負担

課題2の全履歴では
入力再処理に約20分。
台帳更新には約18分半。
同じ時間上限でも
費用の内訳が異なる。

いずれも少数例の観測。新機構の必要性は、単純な対照を超えるかで判断する。

情報を捨てる前に、実行基盤の無駄を測る

中央は入力列の一致の測定。変更後の実時間と品質はまだ測っていない。



開発1課題・各方式1回。費用不明を0にせず、元の実行条件を維持。新手法や品質維持の証明ではない。

異なる原因を、別の実験で切り分ける

P6終了後に順番に実行。以下は計画であり、この資料の結果には含めない。

実験	変えるもの	測るもの
P7：同じ記憶入力	原入力 / 未実行部分の退避 / 未実行記録	完了主張と公開の実行証拠
P8：強いAPI基準	API別スキーマ・複数操作・公開探索	最終状態・全費用・形式失敗
P9：同じ隣接入力	情報は保持し、入力配置だけ変更	入力再処理量と実時間

P7・P9は課題成功を測らない。P8は複数の変更を含み、単一要因の効果ではない。

既存方式をつないだだけで終えないための判定

現在の成果と、研究の完成時に必要な成果を分ける。

ここまでの成果

再現可能な比較・全費用の記録。
誤完了の記憶、保持判断の負担、
入力再処理という原因候補の切り分け。
選ばなかった案と失敗も公開記録へ。

これから必要な成果

強い既存方式でも残る機構上の問題。
その問題を扱う具体的な更新・制御規則。
同じ予算で単純な対照を超える効果。
別課題・別モデルでの成立条件と限界。

単純な対策で足りれば独自機構を追加しない。次の結果から研究の中核を絞る。

実験条件・結果・理由をGitHubからたどれる

この資料の数値はP6終了時点の集計。完全な実行履歴・認証情報は公開しない。

P6の条件と再実装の範囲

全6試行の結果と次の判断

台帳の誤完了と公開操作の再生

第2課題の費用・入力配置の診断

独自の技術的中核を選び直した理由