比較基準を直し、形式と意味の限界を分けた

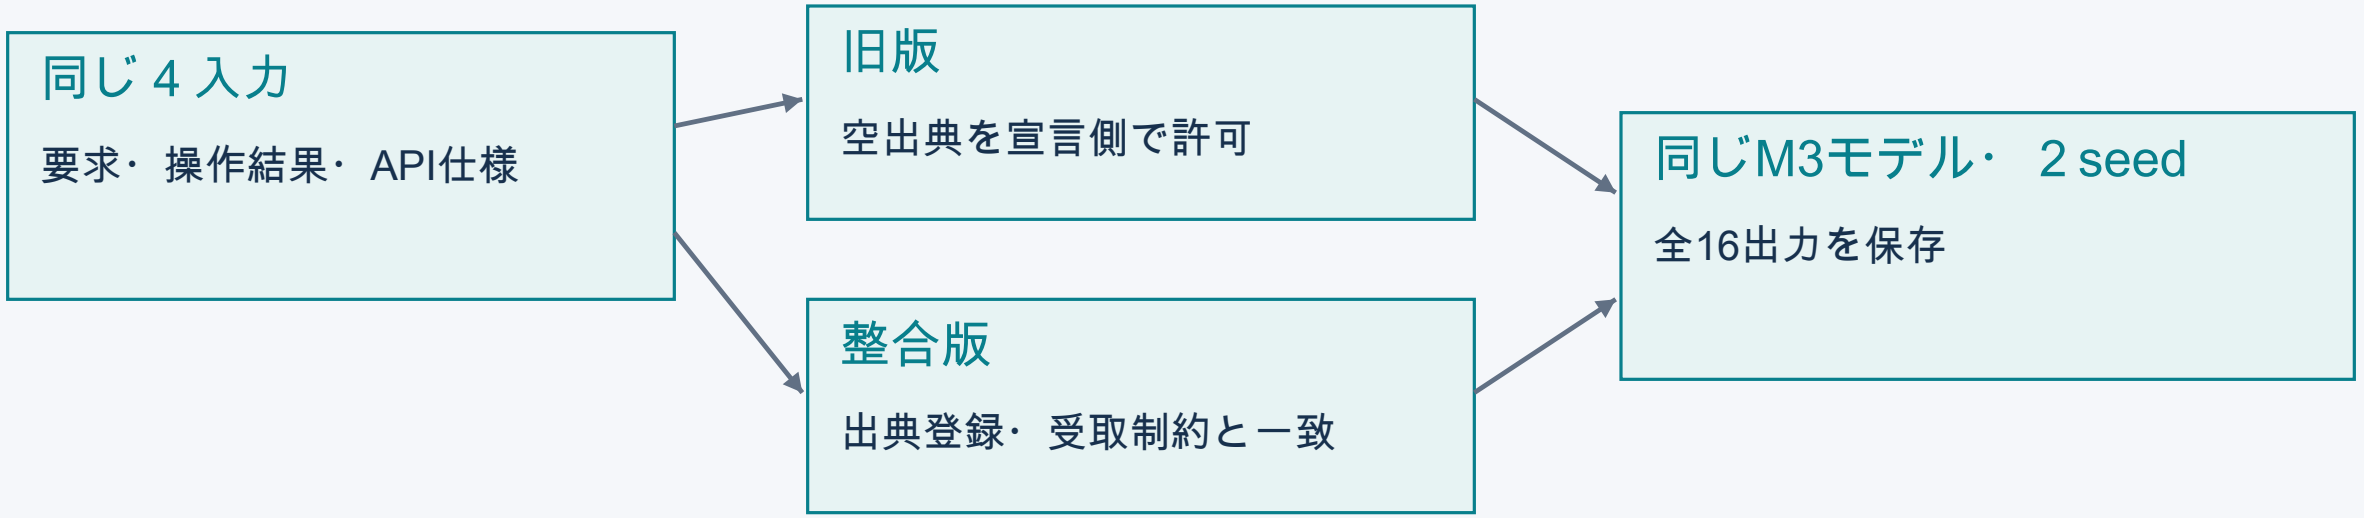
整合版は８ / ８出力が形式適合。
ただし、内容の正しさを保証する結果ではない。

全16生成、317,357トークン、不明０。
適合15出力の全140項目を、元の記録と照合した。
曖昧な全体完了と、不十分な引用が残った。

この修正は自作基準の不備への対応。独自方式の発見や性能改善とは区別する。

情報・予算をそろえ、台帳の契約だけを校正

モデルに許す形式と、実行器が受け取る形式を一致させる。



終了後：原入力・費用の監査 → 方式名を伏せて全項目を照合
→ ラベル固定 → 方式とseedを開いて集計。追加の環境操作は０。

要求文は「何を頼まれたか」の根拠であり、「実行したか」の証拠にはならない。

形式不適合は減ったが、意味の優位性は示せない

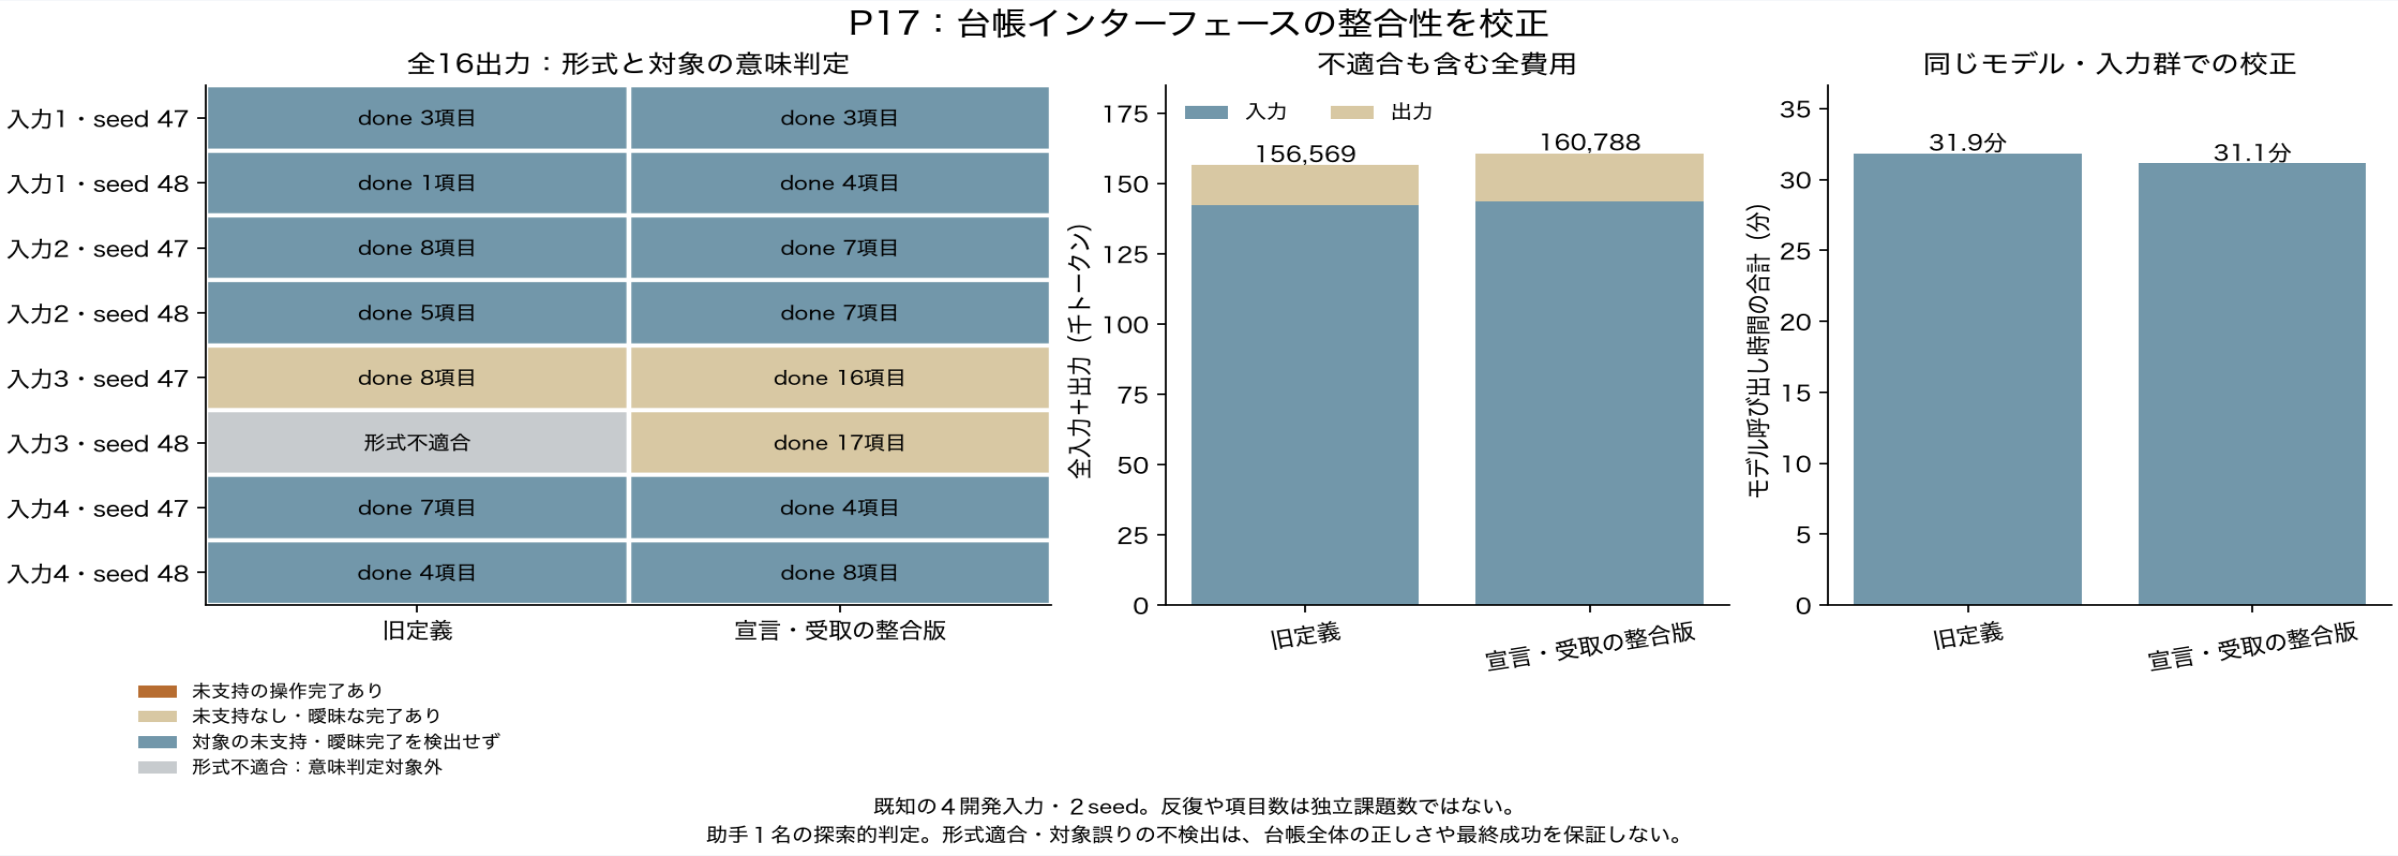
反復・台帳項目を独立した課題数に数えない。助手 1 名の探索的照合。

指標	旧版	整合版
形式適合	7 / 8	8 / 8
未支持操作完了を検出した適合出力	0 / 7	0 / 8
曖昧な完了を含む適合出力	1 / 7	2 / 8
曖昧な完了項目	1	3
不適合も含む全生成トークン	156,569	160,788

旧版の 1 不適合は空出典。未支持 0 件は一般的な安全性の証明ではない。
曖昧な項目を未支持側へ含めても、整合版の意味上の優位は示せない。

16出力の成否・曖昧さ・費用をすべて残す

成功した出力だけで比較しない。最終タスク成功は、この実験では測っていない。



既知の４開発入力・２seed。反復や項目数は独立課題数ではない。
助手１名の探索的判定。形式適合・対象誤りの不検出は、台帳全体の正しさや最終成功を保証しない。

個々の操作が成功しても、対象全体の確認は別

曖昧な全体完了： 4 項目

調べたページは時刻の降順だった。
しかしAPI説明に全体の順序保証がない。
個別 4 件の操作成功は確認できても、
対象を全て調べたことまでは
証明したと扱わない。

要求側だけの引用： 3 項目

taskのみ 2 件、要求取得との併用 1 件。
うち 2 件は引用外の同じ前半記録に
実際の成功返却があった。
引用不足と、前半全体にも根拠がない
誤完了は分けて記録する。

形式の整合は保持する。意味上も安全な台帳としての採用条件は未達。

一つの追加機構を、強い単純対照に対して検証する

2 段組 4 ページ。10/23に主要実験・あらまし、10/31に投稿完了が目標。

研究の目的：仕事の品質を保ちながら、状態共有・再取得を含む総費用を減らす。
現在の成果：比較基盤、費用の観測、見送り判断、基準の修正。新規性は未確定。
次の実行：P18の別 4 課題を同じ全履歴基準で実行し、自然な失敗を切り分ける。
確認用12シナリオは未閲覧。機構と比較条件を固定するまで保留する。

P17：全結果・採否・限界

P18： 4 課題の事前仕様

4 ページの原稿構成

少数評価で主張できる範囲