出力方式の比較と、生成上限の制約

直接CSVは２ / ３、計算コードは１ / ３が完全な書出。
残り３件は上限停止。コード方式の優位性は示せない。

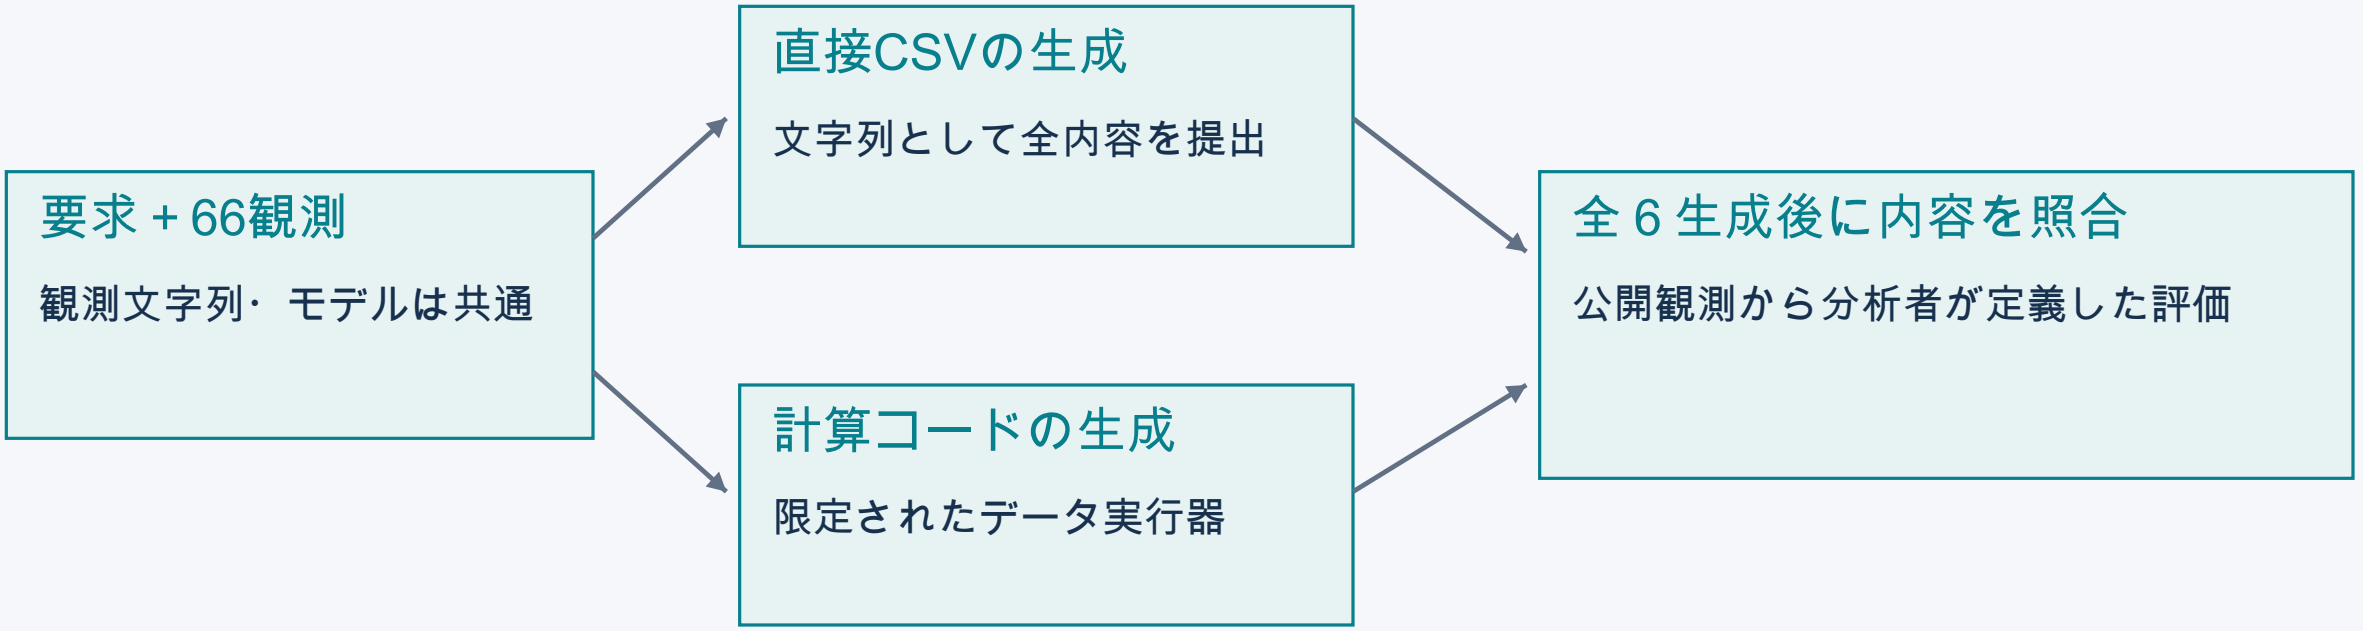
P20：提出 0/6、完全な書出 0/6、総 80,367 トークン

P21：提出 3/6、完全な書出 3/6、総 100,107 トークン

目的：通常の計算で足りるかを確認し、追加のハーネス機構が必要か判断する。

両方式へ同じ取得済み観測を渡す

P18のCSVや欠落行、正解件数、隠し評価を生成側へ渡さない。



P20は4,096出力、P21は8,192出力。両方式を等しく変更。
seed・指示・入力は固定。思考と提出物の生成を含む全費用を記録する。

提出の有無と、提出内容の正しさを分ける

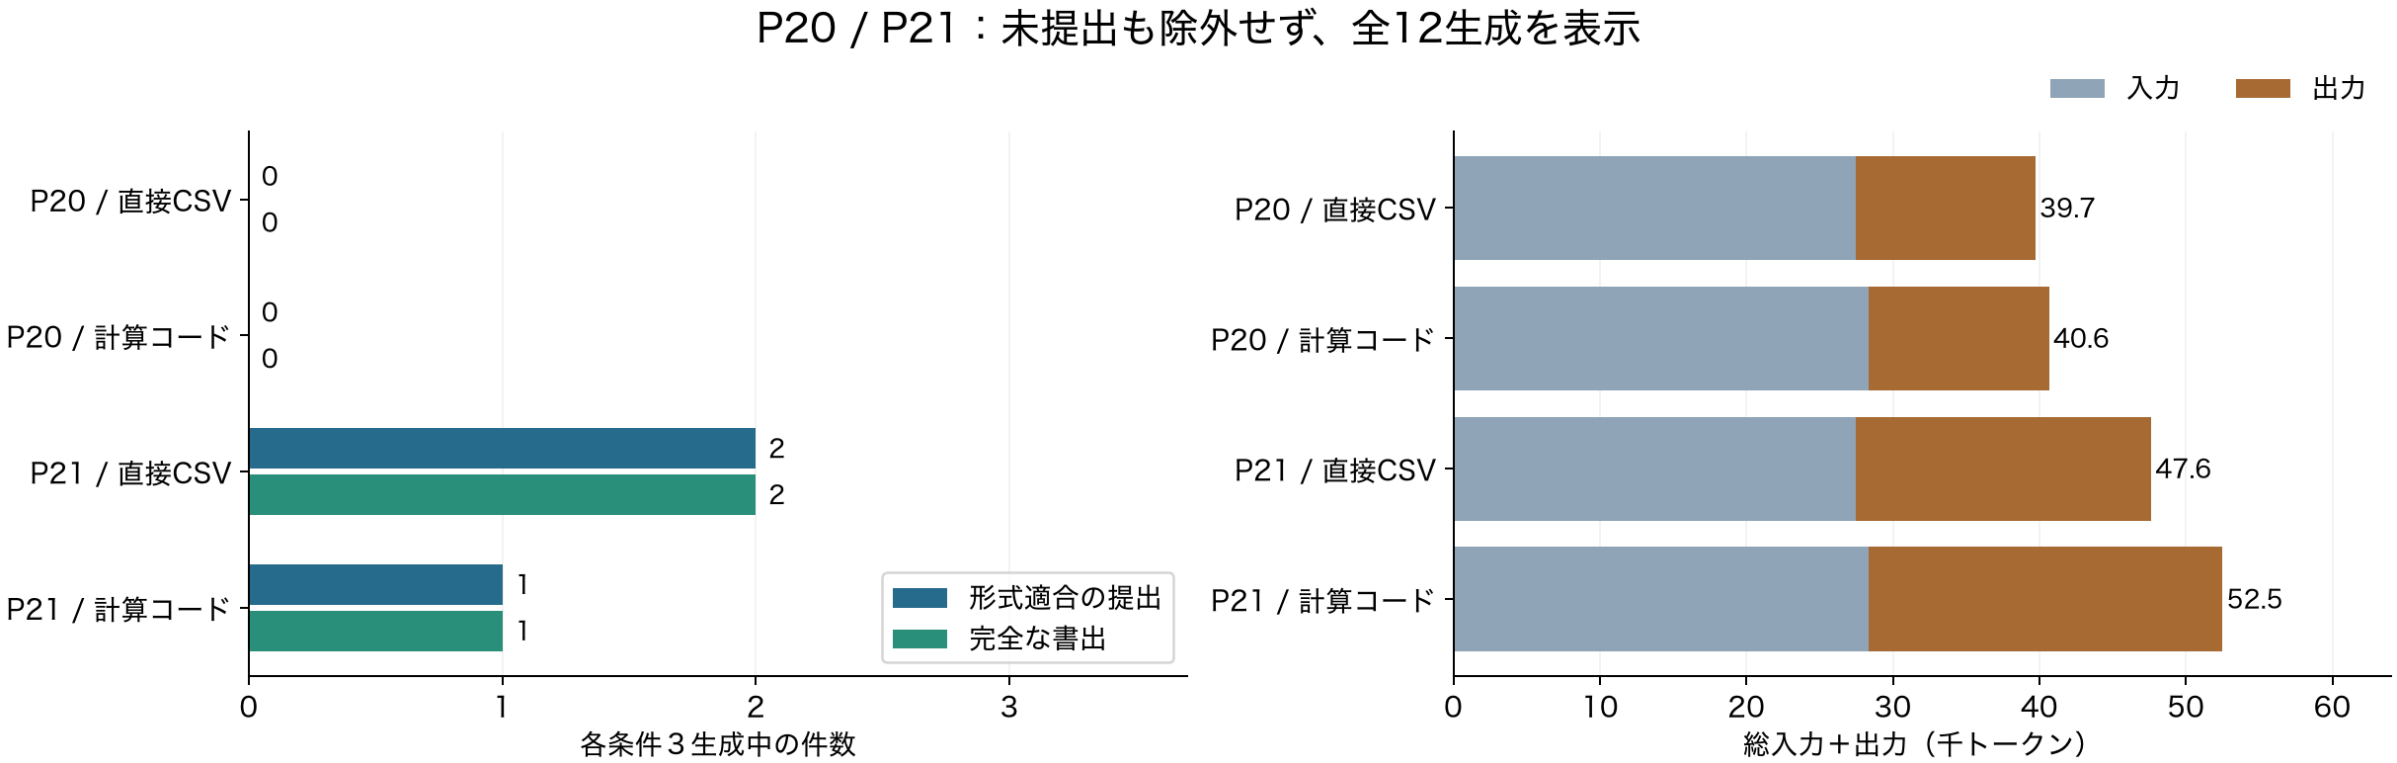
3 seedは同じ入力の反復。課題数を水増ししない。

実験	方式	出力上限	提出	完全書出	総トークン
P20	直接CSV	4,096	0/3	0/3	39,720
P20	計算コード	4,096	0/3	0/3	40,647
P21	直接CSV	8,192	2/3	2/3	47,616
P21	計算コード	8,192	1/3	1/3	52,491

未提出・打切りは成功に数えない。CSVが存在しない場合、
欠落行数や余分な行数は「評価対象なし」であり、0 件の正解ではない。

全12生成を残し、予算変更の効果を分ける

計算コードを使うだけで新規性が得られるとは扱わない。



１つの既知開発状態の反復。提出なしの場合は内容の品質差を判断しない。
出力には推論過程も含む。使用量不明０。

１入力での正解を、一般的な正しさへ広げない

提出コードの補助評価：対象１件。
４変換すべてに適合１件。追加モデル呼出し０。
固定CSVには適用しない。検査対象なしを合格とは数えない。

提出できた３件は、公開観測から求めた72行と一致。
唯一の提出コードは４つの入力変換にも適合した。
残る失敗は未提出であり、言語制限による実行失敗ではない。
１つの開発状態の反復から、一般性能や新規性は主張しない。

補助検査は既存の検査原理を利用。自律的な仕様生成や新機構の実績ではない。

４ページの原稿に載せる主張を、実測で絞る

10/23主要実験・あらまし、10/31投稿完了。採録は査読に依存する。

この１件で上限拡張や指示調整を繰り返さない。
予約した別の６開発課題を、既存の全履歴基準で観察する。
通常構成でも残る失敗から、必要な変更規則を一つ絞る。
確認用12シナリオは、方式の固定まで未閲覧で残す。

P20：全結果と上限を増やした理由

P21：全結果・解釈・採らない案

既存研究との機能の重なり

確認群を残した追加開発課題の準備