追加 6 課題で、次に検証すべき問題を絞る

6 件中 2 件成功。観測の欠落だけでは説明できない。
通常の指示で残る問題を見極め、新技術の対象を絞る。

全履歴基準：2/6 成功。全 6 件を評価・監査。
65生成、1,087,194既知トークン、202 API。
使用量不明 1件。失敗・打切りも費用に含める。

到達点は基準の観察。既存対照を超える固有の機構と効果は、別の比較で示す。

仕事を正しく終えるための状態・実行制御を研究する

背景と目的

情報が複数の取得・操作へ分散する仕事では、
途中の正しさだけで最終完了は決まらない。
同じモデル・情報・予算で、
ハーネスのどの制御が品質と費用を
変えるかを測る。

P22で確かめること

強い単純対照でも問題が残るかを調べる前に、
別の要求で全履歴基準の実行を観察する。
集約・台帳・検査器はまだ追加しない。
この６件は方式選定の開発用になり、
未調整の確認群として再利用しない。

求める成果：具体的な失敗条件 → 状態・更新規則の変更 → 同予算の対照との効果と限界。

凍結した実行器から、模擬アプリを操作する

M3 IQ4_XS、64K、全履歴、同じ公開API。物理的な並列推論は行わない。

事前選定の 6 課題

要求を見る前にID・順序を固定

→

単一の実行ループ

モデル → 公開API → 観測

→

模擬環境と成果物

操作順・費用・境界状態を保存

各課題：45万総トークン、80モデル呼出し、80 API、30分。
独立評価は後続モデルへ返さず、全 6 件終了後に内容を分析する。
80 APIは研究側の追加上限。公式の応答回数とは異なる。
現基準は残予算を逐次提示しない。上限停止だけから新機構を正当化しない。

全結果を同じ表へ残す

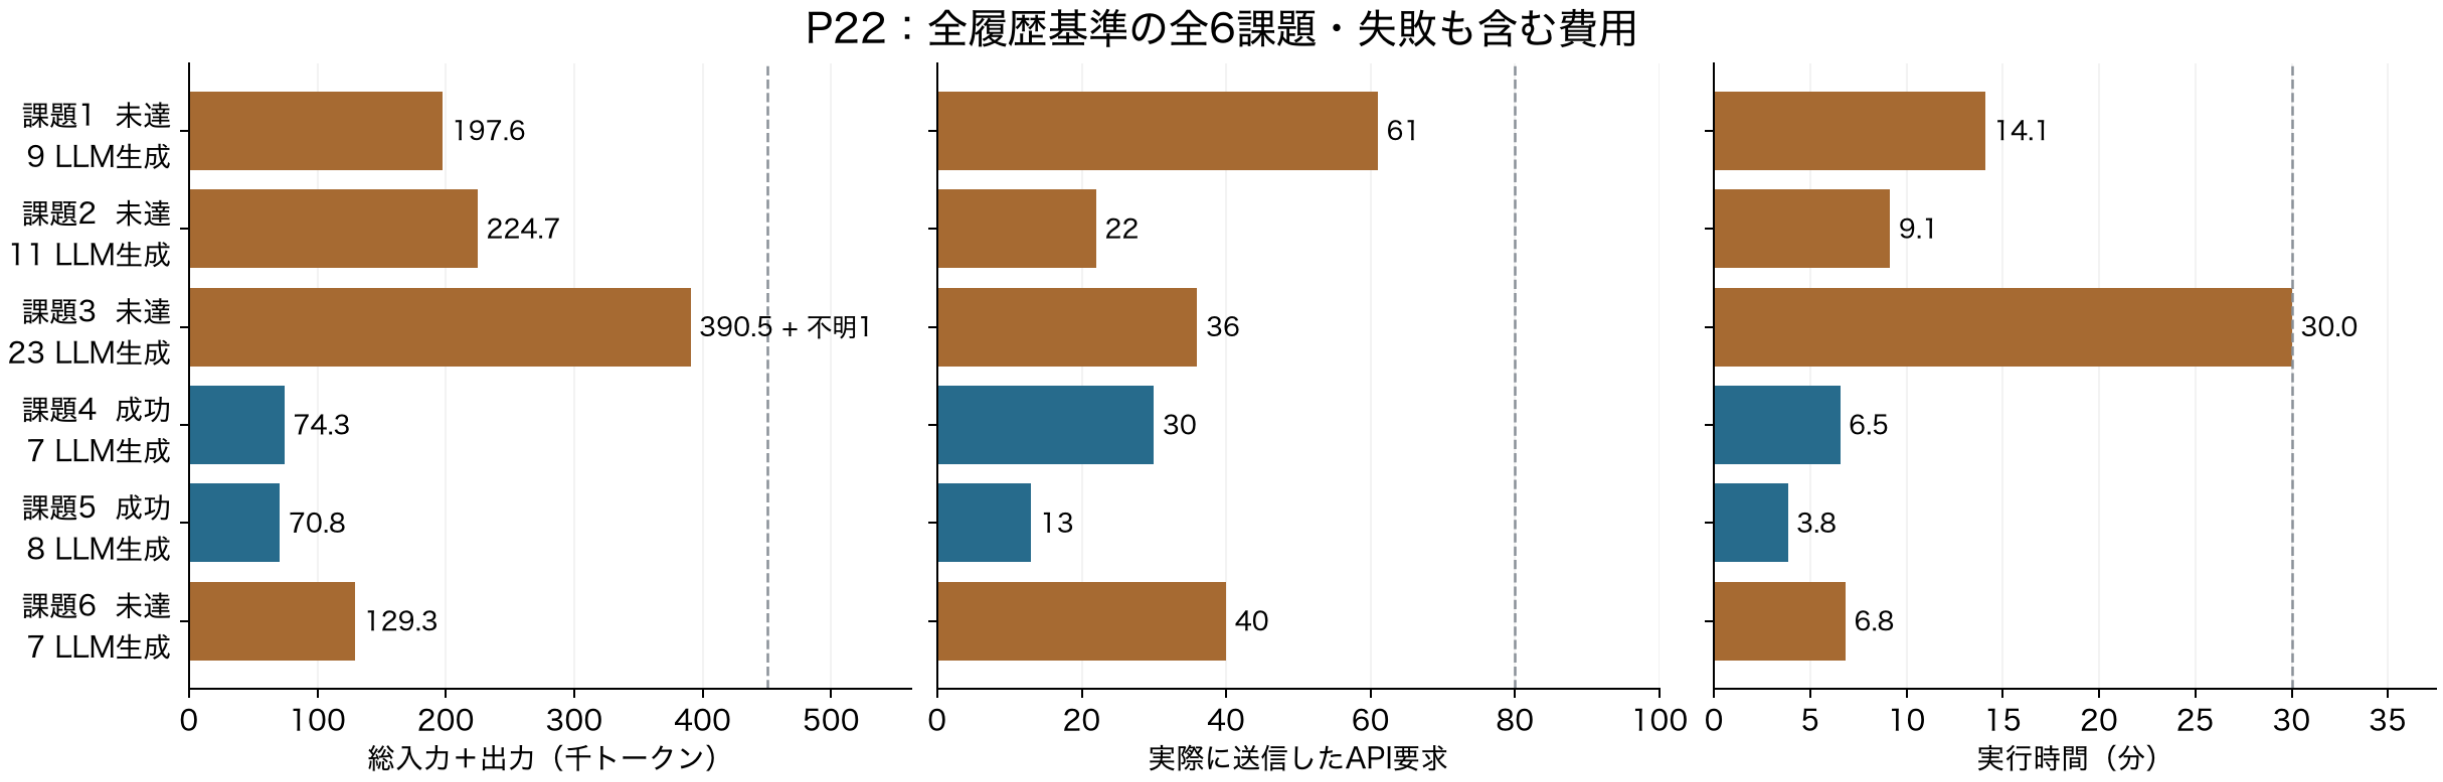
課題が違うP11・P18との成否差を、方式改善の効果とは扱わない。

課題	結果・終了条件	既知トークン	送信API
1 条件付き評価更新	未達・完了宣言	197,557	61
2 支払要求の承認	未達・完了宣言	224,688	22
3 年間請求の集計	未達・生成中の時間上限	390,485	36
4 指定元の連絡削除	成功・完了宣言	74,335	30
5 保存物の圧縮・整理	成功・完了宣言	70,784	13
6 候補群の最大値選択	未達・完了宣言	129,345	40
合計	2/6 成功	1,087,194	202

使用量不明 1件。監査不一致 0 。完了宣言と独立評価を区別する。

成功・未達の両方にかかった量を示す

破線は各課題の上限。既知トークンは使用量不明がある場合には下限。



破線は各上限。各課題 1 試行。API上限・トークン予約・時間制限を区別する。
新方式との比較ではなく、自然な実行上の制約を調べる開発実験。

観測事実と、まだ検証していない原因を分ける

集合が正しいか / 全部見たか

課題1：選んだ27曲の処理は全件実行。
要求に合う集合かは未確定。
課題6：観測した35曲の最大値は正しい。
ただし一覧は先頭５件だけで、
次ページの確認がなかった。
取得後の記憶不足とは断定できない。

既知のAPI規則と成功例

課題2：観測内の対象10件を全件承認。
質問でないのに回答引数を付けた。
課題3：時刻APIを呼ばず時間上限へ。
課題4・５：対象操作と独立評価は成功。
公式の一般指示にある案内を補い、
６件を同じ予算で比較する。

原因は未確定。公式の一般指示を補うP24は、既存基準の校正であり新手法ではない。

既存指示で改善する分を、新規性から分ける

目標：２段組４ページ、10/23主要実験・あらまし、10/31投稿完了。

P24：同じ６件に、時刻取得・全ページ・完了形式等の一般規則を追加。
モデル・ツール・全履歴・予算は維持し、成功例も全て残す。
通常PythonのP23全体比較は未実施。今回の問題に合う対照を先にする。
12確認シナリオは未閲覧。具体的な機構と比較計画を固定してから使う。
現時点では、新規性・提案方式の有効性・投稿準備完了を主張できない。

P22：全結果・採否・代案

同じ予算での既存対照の位置づけ

原稿と新規性の現在地

４ページで主張できる評価範囲