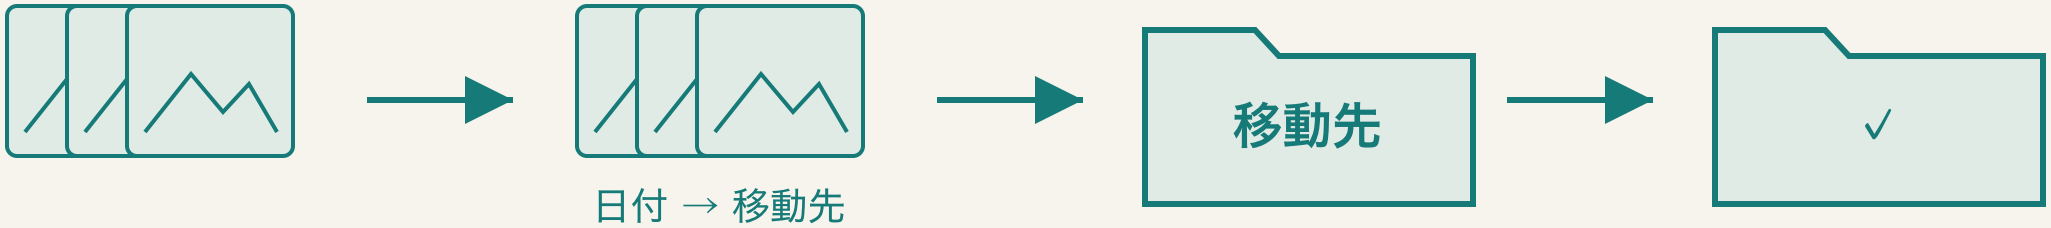
AIハーネスにおける
作業状態の引き継ぎと継続実行

AIに、調査から実際の処理まで任せたい

たとえば写真整理では、方法を答えるだけでなく、
対象を調べて移動し、要求どおりに終えたか確かめる必要がある。

例：写真を撮影日ごとのフォルダーへ整理する



一覧を取得
何が対象か

撮影日を確認
どこへ移すか

写真を移動
実際に変更

完了を確認
要求を満たしたか

この間に、取得した値・判断・操作済みの内容をつなぐ必要がある。

作業が進むほど、引き継ぐ情報も増える

過去の応答や取得結果を毎回入力すると、入力が長くなる。
一部を省けば、作業の続きに必要な情報まで見えなくなる可能性がある。

説明用の場面：途中で会話履歴を短くして再開する

「一覧を取得した。撮影日で分類した。
次は、未処理の写真を移動する」



再開したAIに見えるのは直近の結果だけ
「残っている一覧は何に使うもの？」

値が残ること　　≠　　用途・作業の続きが伝わること

想定される支障：調べ直す／計算し直す／処理を抜かす／重複して処理する

AIの作業状態は、三つの場所に分かれる

「履歴が残る」「変数が残る」「操作の結果が残る」は、それぞれ違う。

① 会話履歴

AIの過去の応答

ツールが返した結果

次の入力としてAIに見せる

今回、全部／直近に変える

② Pythonの変数

取得した一覧や計算結果

実行環境にある値

コードで再利用できる

今回、保持／初期化に変える

③ アプリの状態

移動済みのファイル

送信済みの依頼や返金

すでに実行した操作の結果

全条件で同じ状態から開始

変数を消しても、すでに移動した写真は元に戻さない。

変数を残せば、会話履歴は減らせるか

期待する利点

取得・計算した値を再利用すれば、長い過去の会話を毎回渡す費用を減らせるかもしれない。

確かめる必要がある点

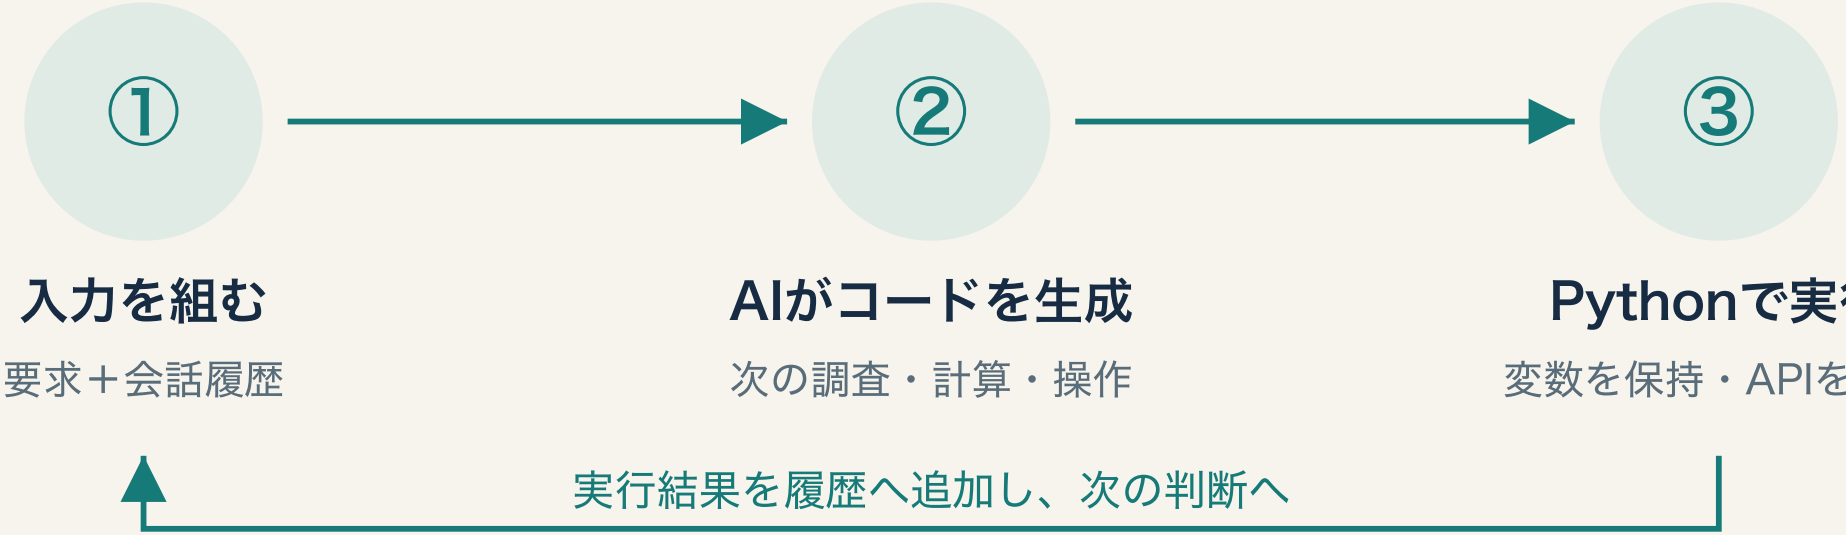
値だけでは、その用途、未完了の作業、使うAPIが伝わらず、調べ直しが増えるかもしれない。

> 目的：継続に必要な状態を特定し、完了率と総費用の関係を明らかにする。

ハーネスが、入力と作業状態を管理する

同じAIにPythonコードを生成させ、模擬アプリを操作する。
今回変更するのは、再開時に渡す会話と、Python状態の保持方法。

利用者の要求 → **ハーネス：次の入力と実行手順を管理するプログラム**



まず、引き継ぐ状態の影響を切り分ける

研究全体の目標

仕事の依存に応じて
担当・作業範囲を組み替える

再編には、会話や変数、未完了作業の引き継ぎが伴う。

現在の実験

担当は固定し、
残す会話と変数だけ変える

再編後の差を、単なる情報の欠落や整理の効果と取り違えないため。

> 現在測っているもの：一つの作業役が途中から再開するときの、状態保持の効果。

復元できる模擬アプリで、四つの仕事を行う

AppWorldの既知の開発課題を使用。要求を読ませ、ツールで実際に操作させる。

仕事	必要な工程	最後に確認すること
写真整理	一覧取得 → 日付確認 → 移動	指定どおりの配置になったか
共有・依頼	文書・連絡先・日付の確認 → 依頼	要求された処理を完了したか
誤請求への返金	請求・履歴・対象の確認 → 返金	対象の処理が正しいか
曲一覧の書出	複数の一覧取得 → 統合 → CSV作成	出力内容が要求を満たすか

モデル・要求・アプリ状態・継続予算を固定する

そろえる条件	この比較での設定
AIとツール	同じMiniMax-M3量子化モデル・同じPython／API
要求とアプリ状態	同じ要求、同じ地点まで操作済みの模擬環境
再開後の上限	16回のAI応答・12万トークン・８分のいずれかまで
API操作の上限	写真整理160回、他80回。共通の前半も数える
成功の判定	終了後に別の評価器で判定。結果をAIへ戻さない

同じ途中地点から、四条件で続きを実行する

最初から別々に走らせると、取得した情報も変わる。
そこで、４回目の応答と操作が終わった地点を共通の出発点にする。

共通の前半

1 → 2 → 3 → 4

AIの応答 → ツール実行 を４回

この時点で会話・変数・環境を保存

成功・失敗を見て地点を選ばない

- **A 全履歴＋保持** → 継続 → 評価
- **B 直近＋保持** → 継続 → 評価
- **C 全履歴＋初期化** → 継続 → 評価
- **D 直近＋初期化** → 継続 → 評価

４課題 × ４条件 × 各１回 ＝ 16実行。独立した課題数は４件。

会話の量と、変数の保持を別々に変える

	会話を全部残す 前半４回の応答＋ツール結果	会話は直近だけ 最後の１回の応答＋ツール結果
Pythonの変数を残す	A 全履歴＋保持	B 直近＋保持
Pythonを一度初期化	C 全履歴＋初期化	D 直近＋初期化

最初の要求は全条件で残す。アプリは同じ状態。

過去の取得記録は、全条件でツールから再読できる。

一つずつ変えないと、何が効いたか分からない

A と B を比較

変数を残したまま、会話だけ減らす。

保持した値があれば、履歴を減らしても継続できるか。

C と D も比較し、初期化した場合との違いを見る。

A と C を比較

同じ会話の量で、変数の保持だけ変える。

過去の会話があっても、値を残す追加価値があるか。

B と D も比較し、会話が少ない場合との違いを見る。

> 評価：予算内に仕事を終えたか ＋ 最後までに使った入力・出力と操作の量。

変数を残しても、会話短縮を補えなかった

A と B では、同じ変数を保持している。変えたのは再開時の会話の量。

課題	A 全履歴＋保持	B 直近＋保持	C 全履歴＋初期化	D 直近＋初期化
写真整理	○ **成功**	— 未達	— 未達	— 未達
共有・依頼	— 未達	— 未達	— 未達	— 未達
返金	○ **成功**	— 未達	○ **成功**	○ **成功**
曲一覧の書出	— 未達	— 未達	— 未達	— 未達
成功した課題数	**2 / 4**	**0 / 4**	**1 / 4**	**1 / 4**

> 今回の４課題・この予算では、「変数を残すから会話を減らせる」とは言えない。

入力を短くして始めても、総費用は増えた

A と B の比較。直近だけにすると最初の入力は短くなるが、継続全体では逆転した。

再開直後の入力

４課題の最初の１入力の合計

A 全履歴＋保持



25,528

B 直近＋保持



12,767

最初の入力は約半分

終了までの総トークン

４課題の全入力＋全出力の合計

A 全履歴＋保持



332,236

B 直近＋保持



416,022

継続全体では 25.2% 増加

単位：トークン。左右は別の尺度。実行準備の再生費用は別記。

短い履歴では、過去の情報を取り直す動きがあった

観測できたこと

前半と同じAPI要求

A 全履歴＋保持：**1回**

B 直近＋保持：**11回**

BではAPI説明・接続情報の再取得が中心。

４課題の継続部分を合計。

次に確かめる仮説

値と、値を使うための情報が結びついていない可能性

残る変数、利用できるAPI、次の作業を示すと、再取得と未達を減らせるか。

> 観測と仮説を分ける。現段階では、失敗原因も解決策の有効性も確定していない。

独自性を狙うのは、引き継ぐ情報の選び方

既存研究にある機能	今回の位置づけ
CodeAct：コード実行と状態の保持	比較基準として実装。これ自体は新提案にしない
CaveAgent等：実行状態と履歴の分離・通知	変数一覧や通知も、既存の対照として比べる必要
文脈圧縮：残す情報と費用の評価	入力削減だけでなく、後の再取得費用まで測る

狙う成果：作業状態と次の処理に応じて、残す履歴を選ぶ規則。

現状：その規則の実装・既存方式を上回る効果は、まだ確立していない。

まず、作業が進んだ地点でも確かめる

1

８回目から再開

同じ４課題・四条件を、後の地点で比較する。

追加実験を実行中

2

通常の通知と比較

変数一覧やAPI案内だけで十分か。追加する情報を一つずつ分ける。

次の比較候補

3

規則を固定して確認

効果が残る場合に選択規則を作り、未調整課題で比較する。

未実施

> 同じ課題で失敗を直せたことと、未調整の仕事でも通用することを分けて確認する。

確認できたのは、少数課題での引き継ぎの弱点

ここまでの成果

同じ途中状態から比較できる基盤。
会話と変数を分けた16実行。
入力短縮と総費用が逆転した事例。

まだ不足する証拠

既知４課題・１モデル・各１回。
独自の選択規則と、その改善効果。
未調整課題・担当再編への適用。

> 研究の狙い：何を残せば、何を省いても仕事を継続できるかを説明する。

10月23日に、論文の主張と主要結果を絞る

10/23

主要結果・あらまし

追加比較を閉じ、既存との差を一つに絞る。

10/25

確認実験を終了

不足する対照と未調整課題の確認を優先する。

10/29–30

４ページ原稿

本文・図・引用・公式様式・著者情報を確認する。

10/31

投稿完了が目標

新規性と追加結果の成立が、現在の日程上の制約。

> 今優先すること：説明可能な一つの結果と、既存方式に対する追加価値を固める。

同じモデル・同じ環境で、構成差を比較する

計算機	Mac Studio / M3 Ultra 256 GiB RAM
モデル	MiniMax-M3 / IQ4_XS 重み約229.7 GB・版固定
推論	llama.cpp / 64K context KV q8・1スロット

環境	AppWorld 0.1.3.post1 復元可能な模擬アプリ
全体実行の上限	45万token・80生成・30分
引き継ぎ後の上限	12万token・16生成・8分
評価	終了後の別プロセス 正解をモデルへ戻さない

同じ途中状態から、全16分岐を評価する

	会話：全部	会話：直近だけ
変数を保持	● ○ ● ○ 2/4 332,236 token ／ 187 API	○ ○ ○ ○ 0/4 416,022 token ／ 196 API
変数を初期化	○ ○ ● ○ 1/4 316,491* token ／ 176 API	○ ○ ● ○ 1/4 392,787* token ／ 144 API

● 成功 ／ 淡色 未達。各 4 既知課題・1 seed。数値は後続のみ。＊：使用量不明あり（全体で 2 呼出）。表示は既知分。

> 履歴と作業状態の組合せを観測。新しい選択方式の有効性は別の検証が必要。

同じ４課題の全結果を、成功と費用で見る

課題	初期接続	関数説明を補足	説明＋変数保持
写真整理	成功 ／ 187,189	成功 ／ 134,387	成功 ／ 209,299
共有・依頼	成功 ／ 258,270	成功 ／ 218,993	成功 ／ 224,588
返金	成功 ／ 341,481	成功 ／ 81,974	成功 ／ 84,818
曲情報の書出	未達 ／ 177,249	未達 ／ 183,028	未達 ／ 121,330
成功数 / 全費用	**3/4 ／ 964,189**	**3/4 ／ 618,382**	**3/4 ／ 640,035**

数値＝全入力＋全出力トークン。各 1 seedの開発比較。未集計は未実行・実行中・監査待ちを含む。

> 追加の仕組みが必要かを決めるため、通常方式を十分にした状態で比べる。

P27の全比較 ／ P28の全比較 ／ P29の全比較

写真整理の残り15件は、追加操作で完了した

上限80：未達

80 API / 185,739 token



27/42

上限160：成功

97 API / 361,169 token



42/42

■ 移動の返却あり　　淡色：移動の返却なし

同じ成果物でも、完了APIの形式で合否が変わった

記録済み前半の再生	回答文あり	回答文を省略
一般指示を補う前の操作系列	未達	成功
一般指示を補った後の操作系列	未達	成功

４条件とも、完了直前のDBは同一

公開返却と保存状態のハッシュを照合。
LLM追加０、模擬API要求118。

公開仕様に沿った影響

行動依頼では回答文を省く規則がある。
評価器の不具合や独自手法の効果とはしない。