AIハーネスにおける
入力削減と実行費用の分析

目的：最終品質を保ち、不要な処理を減らす

ハーネスが、AIへ渡す情報・ツール実行・状態・検証・停止を制御する。

減らしたい負担

同じ長い出力の再入力。
省略した情報の再取得。
それに伴う追加のAI呼出し。

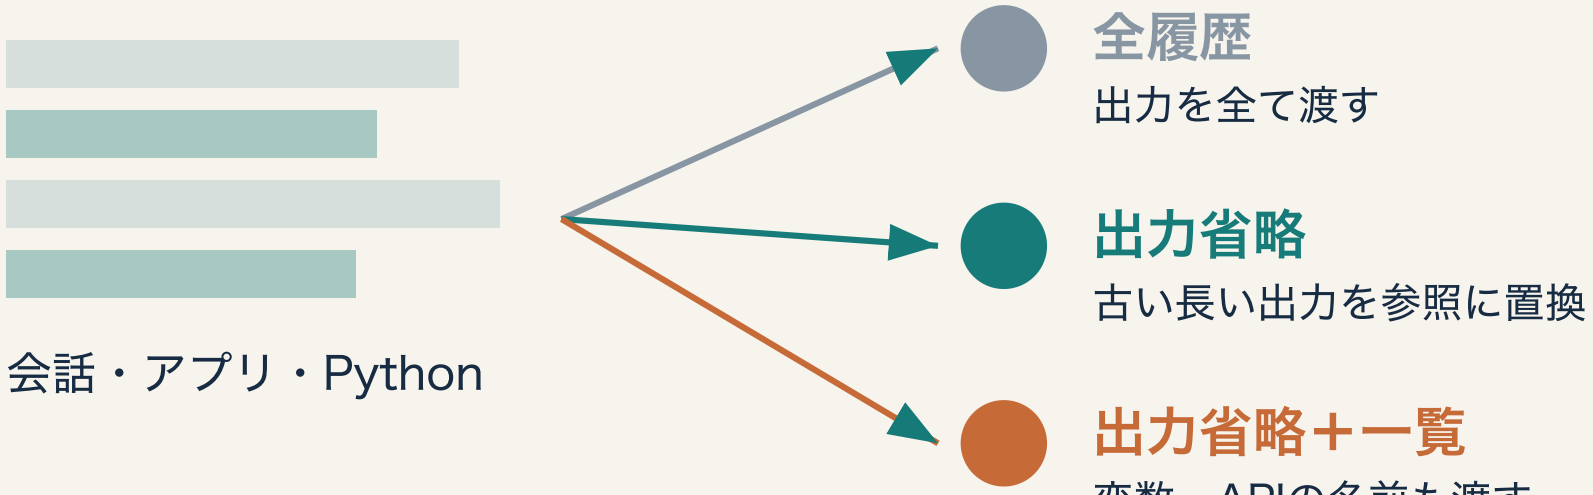
残す必要があるもの

要求・操作・失敗の記録。
必要な値と元資料へのアクセス。
要求を満たす最終成果。

> 今回の問い：操作の手掛かりを残せば、長い出力を省けるか。

実験：同じ途中状態から、３条件を比べる

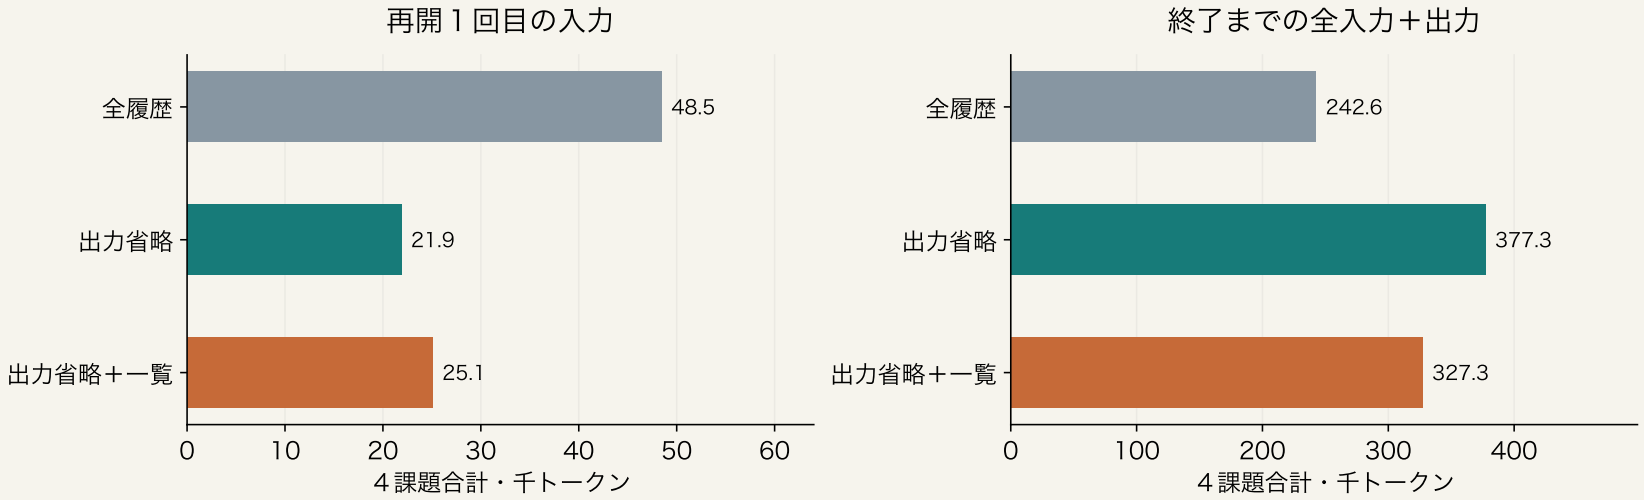
同じ４課題の８応答後



Python状態・原記録の再読・モデル・後続予算は共通

後続上限：16生成・12万総トークン・480秒。元のAPI上限と共通前半を計上。
４既知課題×３条件×各１試行。全履歴の対照も新しく実行。整理・一覧の費用も含める。

結果：初回の短縮と総費用を分ける



条件	最終成功	AI呼出し	後続API	使用量不明
全履歴	2/4	18	162	0呼出
出力省略	2/4	39	133	0呼出
出力省略＋一覧	2/4	29	150	0呼出

P33_comparison.json ／ P33_cost_profile.json

品質：成功件数だけでは判断しない

課題	全履歴	出力省略	出力省略＋一覧
写真整理	**成功**	**成功**	**成功**
共有・依頼	未達	未達	未達
返金	**成功**	**成功**	**成功**
曲一覧の書出	未達	未達	未達

出力省略：対照の成功を落とした課題 0件。総トークン差 +134,632。

出力省略＋一覧：対照の成功を落とした課題 0件。総トークン差 +84,629。

書出は全履歴がAPI上限、他２方式がトークン上限で未達。
早く打ち切られた低費用を、効率よく完了した結果とは扱わない。

> ４件各１回の結果。品質維持の一般的な証明にはならない。

考察：通常方式の効果と、独自の差を分ける

今回の２つの省略条件は、開発用の採否基準を満たさなかった。

出力省略と変数一覧は既存の仕組み。
結果が良くても、それだけを新規性とはしない。

値との照合だけで省略を選ぶ候補（P34）は、対象23出力中１出力にしか適用できず、追加のモデル比較を見送った。

次は、コードが参照した情報とAPI返却の対応を、保存記録の再生で調べる。読み取りの記録がないことを、不要だとは判定しない。

> 月末投稿へ向けた独自の主張と、未調整課題での確認は未完了。

補足：入力トークンと実際の処理量

条件	総入力	キャッシュ入力	新規入力処理	出力
全履歴	233,888	176,340	57,548	8,752
出力省略	366,134	322,808	43,326	11,138
出力省略＋一覧	315,583	264,881	50,702	11,686

総入力には、再利用されたキャッシュ部分も含む。
小さい入力、少ないAPI、短い実時間は別の指標。

使用量が不明な呼出しは、この内訳の外にある。
再構成、制御、失敗を含む詳細は元の集計とCSVへ残した。