AIハーネスによる
不要な情報取得の削減に向けた検証

背景：仕事を完了するまでに、処理が積み重なる

AIに任せる対象は、回答生成だけでなく、調査・操作・確認を伴う仕事。



情報を集める

文書・要求・観測

処理して変更する

コード・API・ファイル

完了を確かめる

要件と最終状態

ハーネス＝AIへ渡す情報、ツール実行、状態管理、検証、停止を制御する外側の仕組み。

目的：必要な情報を残して、仕事全体の費用を減らす

起こり得る無駄

すでに取得した値を、別のAPIから再取得する。
情報を省きすぎて、調べ直しや追加生成が増える。

今回、測ること

最終課題を完了できたか。
開始から終了まで何回呼び出したか。
全入力・出力と追加処理にいくらかかったか。

> 一部の入力・API回数だけが減っても、研究目的の達成とはしない。

なぜこの実験か：入力の省略だけでは総費用が増えた

直前の４既知課題では、初回入力を減らしても、全体のトークンは増えた。

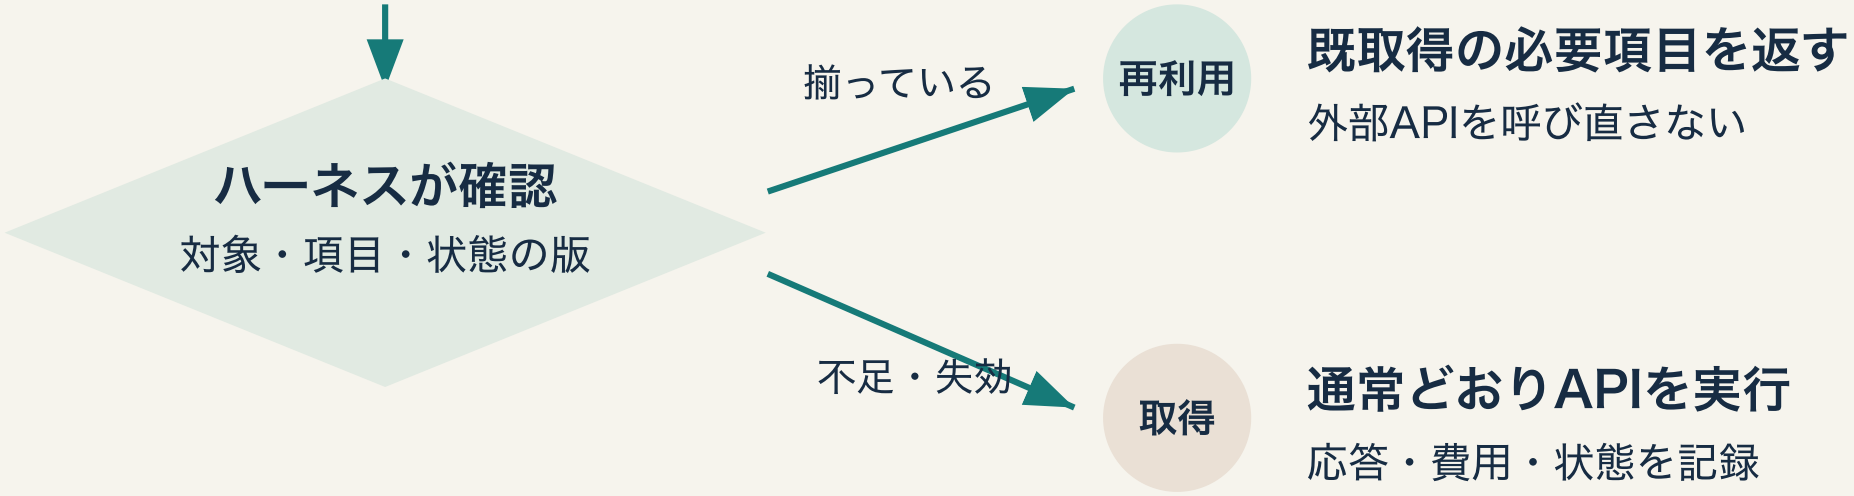
入力の構成	成功	総トークン
全履歴	2/4	242,640
古い長い出力を省略	2/4	377,272
省略＋変数・API一覧	2/4	327,269

次は、情報を消す前に「すでにある必要項目で、取得を省けるか」を調べる。

実装：要求された項目を、状態を確かめて再利用する

AIがコードで「対象」と「必要項目」を指定

例：曲のタイトル・アーティスト名を読む



未知の操作が送信されたら失効。元APIの全項目返却は変えない。

実験の前提：同じ仕事・途中状態から、３方式を比較

曲情報を書き出す既知１課題。８応答後の会話・Python・アプリ状態を復元。

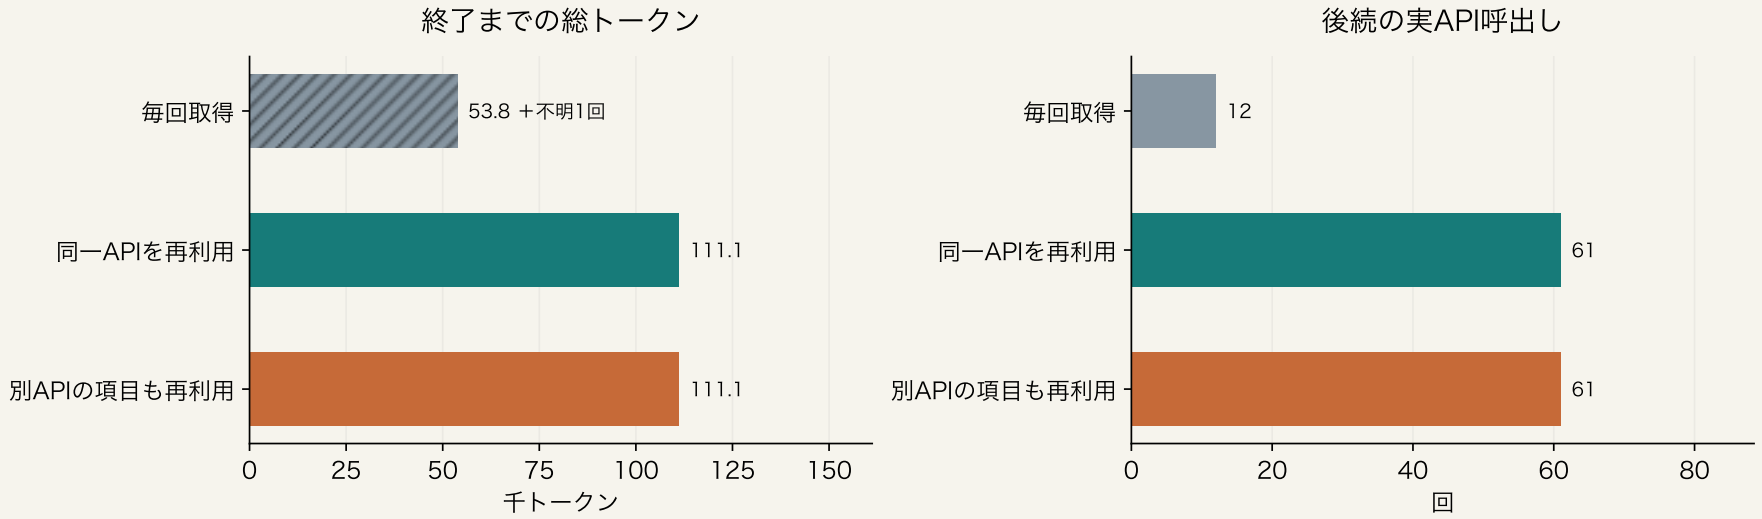
方式	何を再利用できるか
毎回取得	必要項目の読取も、その都度APIを呼ぶ
同一APIを再利用	同じAPI・引数の過去の全返却
別APIの項目も再利用	上記に加え、意味と状態を確認した必要項目

全方式で、説明・初回入力13,552 token・モデル・権限が同じ。

後続上限：16生成、12万token、480秒。APIは共通前半を含め80回。

MiniMax M3 IQ4_XS・入力上限65,536。各１回。対象は開発後に選んだ機構利用の確認用。

結果：最終成否と、実際に使われた再利用を確認



方式	最終結果	AI呼出し	同一API再利用	別API再利用
毎回取得	未達	4	0	0
同一APIを再利用	未達	6	0	0
別APIの項目も再利用	未達	6	0	0

reports/P38_comparison.json / reports/P38_runtime_costs.json

考察：再利用の対象と、次に必要な対象が違った

前半で保持していた値

12対象

曲一覧から取得済み。
後続の無効化は０回。

後続の項目読取

60要求

全て、候補キャッシュでは未観測。
前半の12対象への要求は０。

この要求列では、無効化を緩めても不足している値は作れない。

検証：再利用の正しさと、課題の正しさは別

実験終了後に、別の隔離環境で同じ操作列を再生。
今回は再利用０件のため、通常応答の再現を確認した。

方式	照合した通常応答	再利用値の実取得照合	最終DB
毎回取得	30	0	一致
同一APIを再利用	79	0	一致
別APIの項目も再利用	79	0	一致

監査用の追加API：188回。追加AI・最終評価器：０回。
値が一致しても、仕事を最後まで達成できた証明にはならない。

既存との差：部品の実装だけでは、新規性にならない

内容	現在の位置づけ
同じ結果をキャッシュする	既存技術。対照として必要。
別の問い合わせの一部を再利用する	意味的キャッシュに先行研究がある。
状態・履歴・由来を確認する	ツールキャッシュ等と重なる。
AIの仕事全体で品質と費用を制御する	研究目的。独自の制御と追加価値は未確立。

現在は、採用候補を測定して絞る段階。新しい名前を付けて新手法とはしない。

次の判断：局所の節約を、成果の改善につなげられるか

今回：成功 0/3、別APIの項目再利用 0回。
1 既知課題・各 1 回で、一般的な品質維持と総費用削減は未確立。

次に確かめること

残った失敗は取得費用か、処理の進め方か。
既存の通常方式では説明できない改善余地があるか。

進めないこと

成功するまで上限を増やす。
結果を見て確認用課題を調整する。
再利用回数だけで論文の主張にする。