AIハーネスの仕様表示と仕事を終えるまでの費用

目的：最終品質を保ちながら、不要な処理を減らす

入力を短くするだけでは、仕事全体が安くなるとは限らない。

これまで

一律の出力省略では
初回入力は短くても総tokenが増加。
省略した情報の扱いを見直した。

今回

作業データと見出しを残し、
照合できたAPI仕様返却だけを省略。
最終結果と全継続費用を比較する。

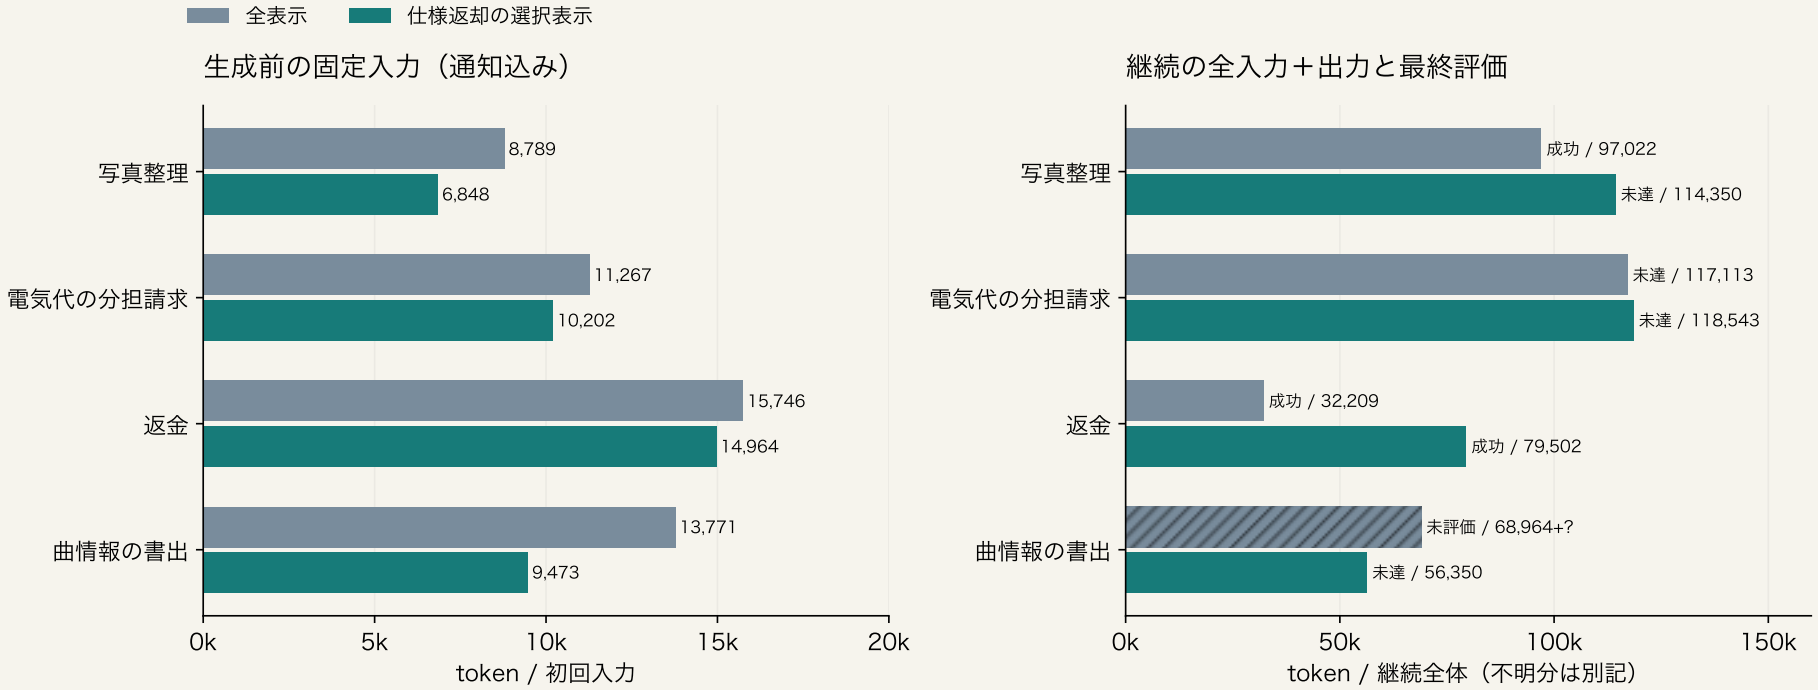
> 通常の選択的省略を評価する対照実験。独自方式の成立は主張しない。

条件：同じ途中状態から、全４課題を各１回ずつ

比較する差	両条件で共通のもの
全表示	４既知課題・８応答後の環境とPython状態 残予算通知・残量に応じた出力枠 初回cacheなしを実測照合、以後は再利用可
仕様返却の選択表示	
保持する情報	操作・作業データ・見出し・最新出力・原文への参照
各条件の上限	16生成／120,000 token／480秒／元課題のAPI枠

> 未知使用量・復元不一致・実行や評価の故障で停止。置換試行や上限延長をしない。

初回入力と、終了までの費用を分けて読む



k＝1,000 token。左右の横軸の範囲は異なる。右側は失敗を含む全継続費用。不明分は別記。

全予定条件を残し、未評価と未実行も示す

課題	条件	最終	継続token	AI	API
写真整理	全表示	成功	97,022	7	94
写真整理	仕様返却の選択表示	未達	114,350	10	48
電気代の分担請求	全表示	未達	117,113	9	9
電気代の分担請求	仕様返却の選択表示	未達	118,543	10	7
返金	全表示	成功	32,209	2	2
返金	仕様返却の選択表示	成功	79,502	5	3
曲情報の書出	全表示	未評価	68,964 ＋不明	5	60
曲情報の書出	仕様返却の選択表示	未達	56,350	5	62

> 評価済 7/8、実行済み未評価 1、未実行 0。

制御や復元の費用も記録する

費用・観測	全表示	選択表示
継続の既知token	315,308	368,745
使用量不明の呼出し	1	0
継続の経過秒	1385.585	1218.854
表示構築の秒	0.004	0.021
入力計数の秒	1.001	1.306
原文再読／参照選択	0 / 0	0 / 0
復元API／復元秒	51 / 10.46	51 / 9.39

表示構築と計数は継続秒の内数。計数秒は既知分の和、時間不明0件。未完遂バッチの合計を優劣の比較に使わない。

局所比較を、仕事全体の費用と混同しない

費用の区間	全表示	選択表示
共通前半（各条件に 1 回加算）	210,380	210,380
今回の継続	315,308 ＋不明1回	368,745
前半＋継続の論理的な全仕事	525,688 ＋不明1回	579,125

元の前半を各条件へ 1 回ずつ加える。
新しい全体実行を行った値ではない。
実験用の復元とモデルロードは別の実測費用として残す。

> 途中状態からの比較では、共通前半・復元・継続を分けて示す。

判断と、まだ主張できないこと

今回の判断

比較は未完遂で採用条件に届かない。評価済みの対に成功喪失もあり、この形の省略を採用しない。

基準：全８件・既知使用量・監査合格、
成功課題の喪失０、継続総token減少。

次に進める作業

既公開の仕様と送信前の拒否を照合し、修復に必要な再取得・AI呼出しを絞る。

４既知課題・１seed。
多担当の通信費や再編効果は未測定。
新規性と投稿の中心的主張は未確立。

> 失敗や欠測を残し、入力の短さを最終品質・総費用へ置き換えない。