状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用原稿・著者情報未設定

あらまし　状態保持型 LLM エージェントの情報保持と実行制御を評価する．既知 4 課題で API 説明省略, 推論保持, 失敗通知を比較し, 費用と品質の採用基準は未達だった．終了手続きと例外前の経路差を診断し, 局所的な費用差の解釈限界を示す.

キーワード　ハーネスエンジニアリング, LLM エージェント，情報保持，実行制御，費用評価

1　目的と検証する問い

ハーネスエンジニアリングは，LLM の外側で情報提供，実行，検証，停止を設計する．必要情報と最終品質を保つ効率化には，取得から終了までの費用評価が必要である．**状態を保持したまま情報提示や実行制御を変えると，全仕事費用と成否はどう変わり，その差をどこまで介入に帰属できるか**を調べる．既知 4 課題の全 24 表示条件，終了診断，通常終了制御，推論保持，失敗通知を扱い，全結果と不明使用量を残す.

2　関連研究と本稿の範囲

圧縮と成否・費用の反復比較 [1]，再取得費用 [2]，推論圧縮と後続行動 [3] は既出である．CodeAct[4] のコード行動，CaveAgent[5] の持続状態，HD-Gist[6] の API 表現，Tool Search Tool[7] の定義展開，段階的開示 [8] も関連する．同一状態からの返却比較 [9]，作用・方針・課題指標の分離 [10]，ECT[11] と AgentLoop[12] の終了・反復制御，ハーネス依存の検証費用 [13] も踏まえる．本稿は具体的な表示・保持・通知の全件比較であり，圧縮の一般論，例外処理，既知文型の手書き検査を新手法とはしない.

3　費用の定義

仕事全体の論理トークンを

$$T_{\mathrm{work}} = T_{\mathrm{prefix}} + \sum_{j=1}^{n} (I_j + O_j) \tag{1}$$

とする．共通前半の実測値を各条件へ一度加え，開始時からの比較では前半を 0 とする．キャッシュ入力も I_j へ含める．継続だけの値も示し，初回短縮量を全体の節約量へ，論理 token を請求額・計算量・時間へ換算しない．API，時間，実験用復元，評価，推論器のロード・常駐は別記し，重なる時間を足さない．評価器単独の時間は表示比較では未計測で，稼働時間の残差からは求めない.

4　表示比較の方法

継続点の状態を会話履歴 H，Python 名前空間 P，操作先環境 E，残予算 $\mathcal{B}$，初期公開分を含む取得済み公開スキーマの集合 V とする．登録された全公開 API の集合を $\mathcal{A}$ とし，$V \subseteq \mathcal{A}$ である．文書取得必須の接続は V，公開名接続は $\mathcal{A}$ に属する API を呼び出せる．後者でも，未取得のスキーマや具体的な引数値を追加表示するわけではない．未登録名・未知の引数名はハーネスで拒否し，型・必須引数は元の API 側で検査する．認証，予算，完了後・作用不明後の停止も共通である.

全表示 F，古い詳細のみ省略 D，同じ詳細と古い一覧を省略 B を比較する．保存した公開 API 返却と表示処理から出自を照合できる区間のみを変更し，操作コード，リテラル，混合出力，エラー，最新応答を保持する．D/B で詳細の省略集合と印をそろえ，P, E, V と原文参照経路を維持する．表示省略は保存情報の消去や呼出し権限の縮小とは異なる.

既知 4 課題の第 8 応答後から各条件を 1 回ずつ実行する．文書取得必須 G（P55）の結果を保存し，公開名 N（P71）の比較を後に固定した．P71 では全 3 条件に同じ能力説明とツール説明を与え，前半の行動と返却は変更しない．前半は元の文書取得必須条件で生成されたもので，そのときの拒否も履歴へ残す．公開名接続を適用するのは継続部分であり，初期状態からの通常実行の比較ではない．各比較内で D 対 F と D 対 B を評価する．P55 と P71 の間では説明文と実行時点も異なるため，その差を呼出し制約だけの因果効果とはしない．両比較は同じ既知課題と前半を使い，独立した 8 課題の確認評価ではない.

各条件 16 生成，継続 120,000 token，480 秒を上限とし，全入力を計数して残予算内に出力枠を収める．初

回入力はキャッシュを再利用しない．MiniMax-M3 の IQ4_XS 版と llama.cpp b11669 を用い, context 65,536, 温度 1.0，top-p 0.95，最大出力 4,096 とした．seed は 50 から生成ごとに 1 増やし，順序は課題ごとに FDB, DBF，BFD，FBD とする．API 上限は前半込みで写真 160，他 80 である．使用量不明の生成は実行も再試行もせず当該条件を終了し，作用・片付け・推論器の待機を確認できた場合だけ保存状態を評価して次へ進む．不明費用，未評価，未実行を補完しない．

両比較で Python 出力，公開返却，保存ファイルを継続前に照合するが，ヒープ・乱数状態の完全複製や生成の決定性は主張しない．返金 D/B は追加で省く一覧がなく基礎入力が同じである．残時間通知と数値実装の揺らぎは残るため，そこでの差を一覧保持の効果とはしない． 会話履歴 H は公開 content・呼出し・観測であり，全表示 F を含む全条件でモデルが返した推論は再投入しない．したがって，表 2・3 の結果は推論保持を含む通常対照へ一般化できない．

AppWorld[14] の写真整理，電気代精算，返金，曲一覧の書出を用いる．過去の失敗・入力計数を見た方式探索であり，未閲覧 12 シナリオは使わない．D/B の詳細省略は課題順に 7・2・3・7 返却で一致し，B の追加一覧省略は 1・1・0・3 返却だった．表 1 は共通の予算通知と省略印を含む初回短縮量である．

表 1　D の初回入力短縮 token（対 F）

接続	写真	精算	返金	曲書出し
文書必須	1,447	258	782	1,629
公開名	1,447	258	782	1,629

4.1　採用基準と欠測

全 12 評価・全使用量既知・監査合格の下，D が F/B 双方の成功を失わず，合計 T_{work} が F 未満・B 以下なら局所採用候補とする．一覧の価値には入力が異なる D 成功・B 失敗の対も要求し，同数成功を非劣性とはしない．不明使用量は既知分と分け，ゼロや上限で補わず，確定費用差を求めない．API 作用・復元・実行・片付け・評価・推論器版の不一致では全体を停止する．結果で seed・条件・予算を変えず，未実行の成否も補完しない．

5　費用と成否の全結果

両接続の全 12 条件を評価した（表 2）．D の既知費用は F より G で 43,083，N で 22,524 token 多かった．N の D の写真・書出しは時間上限で使用量不明となった．未達の早期停止を完成効率とはしない．

表 2　全 24 予定条件の成否・仕事 token

接続	課題	F	D	B
G	写真	未達 145,850	成功 120,935	未達 165,015
	精算	未達 163,918	未達 161,225	未達 154,720
	返金	成功 85,697	成功 117,223	成功 117,305
	書出	未達 117,100	未達 156,265+?	未達 126,734
N	写真	成功 156,754	未達 121,357+?	成功 129,261
	精算	未達 161,694	未達 162,725	未達 154,222
	返金	成功 85,975	成功 100,527	成功 100,527
	書出	未達 96,460	未達 138,798+?	未達 173,238

G：文書必須，N：公開名で継続．+? は別に使用量不明がある値．

不明生成を含む確定費用差は求めず，両 D の採用条件は未達とする（表 3）．G の D は初回入力が短くても継続生成が 22 回から 26 回へ増えた．返金も全条件成功だが D の全費用は F より大きい．

表 3　全 4 課題合計の費用と実行量

指標	F	D	B
文書取得必須（P55）			
成功／評価	1/4	2/4	1/4
仕事・既知 token	512,565	555,648+?	563,774
継続・既知 token	302,185	345,268+?	353,394
継続生成／不明	22/0	26/1	29/0
継続／復元 API	173/51	162/51	122/51
公開名（P71）			
成功／評価	2/4	1/4	2/4
仕事・既知 token	500,883	523,407+?	557,248
継続・既知 token	290,503	313,027+?	346,868
継続生成／不明	21/0	25/2	27/0
継続／復元 API	204/51	138/51	148/51

API は実送信数で，拒否と原文参照は別記する．G/N の推論器全稼働 4,112.859/3,724.097 秒は復元と評価も含む．回数減だけを不要取得の削減とはしない．

6　成否差と終了手続きの診断

G の写真 F/D は各 42 移動で非 supervisor 保存ファイルが一致したが，公式成否は未達／成功，通知は 0／1 件だった．まず G の写真 F/B を別環境で再現し，元 D と同じ空引数の完了通知なし／1 回追加の 4 条件を固定した．次に N の全 12 条件のうち，成否によらず完了 API 未送信の全 7 状態（既知 3 課題）を選び，同じ 2 条件の計 14 ケースを固定した．N の通知は元写真 B で観測した `status="success"`だけとした．全ケースで送信済み公開 API の返却と介入前の全 13 保存ファイルを元状態と照合し，無介入は元の成否を再現した．

表 4　完了通知だけの介入（全 18 ケース）

再現した元状態	通知なし	通知 1 回
G 写真 F	未達	成功
G 写真 B	未達	未達
N 写真 D	未達	成功
N 精算 F	未達	未達
N 精算 D	未達	未達
N 精算 B	未達	未達
N 書出し F	未達	未達
N 書出し D	未達	未達
N 書出し B	未達	未達

G の写真 F と N の写真 D だけが未達から成功へ変わり，それぞれ元 G の D，元 N の B と最終 13 保存ファイルも一致した．非 supervisor 保存ファイルは全ケースで介入前後不変だった．残り 7 状態は通知後も未達で，完了宣言を一律に足す根拠にはならない．G の診断は 346 API・4 評価・23.927 秒（評価 8.541 秒），N は 702 再送＋7 通知＝ 709 API・14 評価・64.318 秒（評価 19.503 秒）だった．両診断とも生成 0 で，元の成否と不明費用は変更しない．N の不明 2 生成は最後の未実行応答に限り，全 API 作用が既知であることを別に照合した．同じ既知写真の事後診断であり，独立した別課題の追認ではない．G の写真では分類に必要な現在年の成功した公開時計応答がなく，通知による公式判定の変化は公開証拠だけで要求を全て検証できたことを意味しない．

7　公開証拠による通常終了制御の追加点検

既知写真を開始から文書必須・公開名の各接続で実行する別対照を用いた．モデル・seed・案内・予算をそろえ，各 80 生成・450,000 token・1,800 秒・160 API とした．全プログラム実行後の公開記録で，元集合・元日時・現在年・移動先・名前保持が支持されれば完了 API を 1 回送る．不明なら通常継続し，追加案内・未来応答・評価器は使わない．

表 5　別条件の写真課題：全体 token

接続	通常終了	終了制御	減少率
文書取得必須	130,439	91,116	30.1%
公開名	151,664	112,233	26.0%

全 4 実行が成功し，制御では各 2 生成・4 API を省いた．各対の最終 13 保存ファイルと制御までの公開 API 記録は一致したが，ID 差で要求・モデル入力の全文一致基準は不成立だった．制御 25 生成の使用量は全て既知で，25 検査・記録ダイジェストの 0.028224 秒を全体時間に含めた．減少 78,754 token の 66,720 は cached input で，金額・時間の同率削減ではない．既知書出しでは正しい CSV 作成後の退会を要求し，API 上限を 80 として各 1 回比較した．両方 8 生成・219,126 token・80 API で未達，書出し・退会 0 回だった．8 検査 0.004080 秒で通知・削減・使用量不明は 0．最終 13 保存ファイルは一致し，ID 差の全文不一致は残った．この ID 差を別途点検し，固定 runtime で保存 66 入力と 3 対照を再構成した．元 batch は原文と正規化後のテンプレートの末尾改行 1 byte 差で停止したため，保存出力を事後に読み取った．写真 13・12 対，書出し 8 対の全 33 対で文章・全 token 列・生成制約が一致し，元 66 入力の実測数とも一致した．未変更と ID 変更の対照は一致，本文変更では文章・token 列が変化した．69 入力の再構成・計数を含む処理 5.543 秒，事前照合 1.859 秒，事後読取 0.254 秒で，新規生成・API・評価は 0 だった．過去の GPU・乱数器状態は復元せず，元の全文不一致判定は変更しない． これらは API の意味を信頼した既知文型の通常制御であり，表 2・3 へ合算しない．実装・固定条件・全件集計を公開する[*1]．

8　推論履歴を保持する通常対照

同じ既知 4 課題の 8 応答後から，公開履歴のみ（P）と返却推論も全て保持（R）を各 1 回比較した．両条件は公開履歴・持続 Python・公開名接続・予算を共通にし，過去と以後の推論の投入だけを変えた．各 16 生成・120,000 token・480 秒で，最初の生成は cache を使わない．共通前半は推論を再投入せず生成しており，最初からの方針比較ではない．

推論保持比較の全 8 条件：成否・仕事 token

課題	P：公開履歴のみ	R：推論も保持
写真	成功 156,754	成功 118,184
精算	未達 160,878	未達 164,322
返金	成功 85,720	成功 88,001
書出	未達 134,971+?	未達 100,425+?
成功／評価	2/4	2/4
既知 token 合計	538,323+?	470,932+?

R の初回入力は課題順に 291・189・1,116・361 token 増えた．全 8 予定条件のうち 8 条件を評価し，使用量不明は 2 生成だった．欠測を補完せず，採用判定に用いる確定費用差は求めない．課題別の R − P の仕事 token 差は，写真 -38,570 ／精算 +3,444 ／返金 +2,281 ／書出し 未確定だった．全 8 評価・全使用量既知・少なくとも 1 対成功・成功喪失 0 ・全体費用減少という局所採用条件は満たさなかった．新規継続は 43 生成・既知 588,495 token ＋使用量不明 2 生成，継続 306・復元 102 API だった．推論器全稼働 2,662.086 秒に復元・評価も含め，重複加算しない．保持は通常の比較条件であり，新規手

[*1] https://github.com/sophiria1225/AI-

法や一般的な非劣性の実証とはしない．表 2・3 の過去条件は変更しない．

9　API 失敗通知の通常対照

同じ 4 課題を開始から各 1 回，実 API 例外を文字列値で返す V と Python 例外で通知する E を比較した．型付き正常値，最初からの推論保持，持続 Python，公開名と予算は共通である．各 80 生成・450,000 token・1,800 秒，API は写真 160・他 80 とし，過去比較の再現とはしない．

失敗通知の全 8 条件：成否・仕事 token

課題	V：文字列	E：例外	実例外 V/E
写真	成功 184,501	成功 181,555	1/1
精算	成功 214,306	成功 213,504	3/3
返金	成功 186,960	成功 119,442	0/0
書出	未達 84,946	未達 277,203	0/1
合計	670,713	791,704	4/5

両方 3/4 成功, 全使用量既知で, E−V は +120,991 token だった．全件評価・監査・費用既知の下，実例外と双方成功があり，成功を失わず E の合計費用が減る採用条件は未達だった．初回の実送信要求は全対一致した．参照 ID だけをそろえた事後照合では，写真・精算は第 3 回の例外後，第 4 回に入力が分かれた．返金・書出しは第 6 回に残時間通知だけが 1 秒異なり，公開出力も分かれた．返金には実例外がなく，書出し E の最初の例外は第 19 回だった．ID 置換後の JSON 照合に限り，通知前の差を通知方法の効果にしない．残時間 1 秒の因果効果も未特定である．全 137 生成・448 API・8 評価，推論器全稼働 4,390.281 秒を記録した．

10　解釈と結論

既知 4 課題・1 モデル・各条件 1 回の開発比較で，18 診断は 3 課題 9 状態の事後介入である．保存した上記 2 入力の残時間を元値／＋ 1 秒とし各 3 回，計 12 生成した．全回 cache 0 で同じ通知の公開出力は一致，通知間は両課題で異なった（99,966 token，推論器 1,010.160 秒, API・評価 0）．元の再利用状態は未再現で, 成否・費用の効果は未特定である． B にも API 名が写真 8/26・精算 10/26 残る（過去コード等）．

表示省略・推論保持・失敗通知は全体採用条件未達だった．通常終了制御の局所改善を一般化せず，全仕事費用・実作業・介入発生・終了手続きを分けて評価する．

参考文献

[1] R. Satish, P. Sinha, A. Kawada, and N.J. Yadwadkar, “Beyond token savings: a systematic study of context compression in LLM agents,” arXiv:2609.32961v1, Sept. 2026.

[2] S. Liu, “What does context compression cost an agent? Interaction costs unrevealed by task-completion metrics,” arXiv:2608.16370v1, Aug. 2026.

[3] M. Wang, F. Luo, B. Wang, G. Yao, Y. Guo, C. Ning, H. Chen, Y. Ma, and J. Han, “When can agents forget their reasoning? ICLR for long-horizon agent context compression,” arXiv:2609.29875v1, Sept. 2026.

[4] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[5] M. Ran, Z. Wan, C. Lin, Y. Zhang, H. Xin, H. Fan, Y. Xu, B. Luo, Y. Zhou, W. Zhao, L. Yang, L. Feng, F. Yang, J. Wu, Y. Huang, C. Ma, Y. Huang, D. Jiang, J. Deng, S. Han, Y. You, B. An, Y. Guo, and J. Song, “CaveAgent: transforming LLMs into stateful runtime operators,” arXiv:2601.01569v4, June 2026.

[6] Y. Jiang, M. Del Vecchio, M. Bansal, and A. Johannsen, “Hierarchical and dynamic prompt compression for efficient zero-shot API usage,” Findings of EACL, pp.2162–2174, St. Julian’s, Malta, March 2024.

[7] Anthropic, “Introducing advanced tool use on the Claude Developer Platform,” Nov. 24, 2025. `https://www.anthropic.com/research/advanced-tool-use`, accessed Oct. 23, 2026.

[8] Y. He, Y. Zhao, J. Wang, and H. Chen, “Is progressive disclosure all you need for long-context agents?,” arXiv:2607.17598v1, July 2026.

[9] K. Zhang, S. Chundur, J.P. Owusu, M.J. Abdolhosseini Qomi, and M. Raissi, “Same simulation, different evidence: where retrieved tool output costs LLM agents accuracy,” arXiv:2610.26836v1, Oct. 2026.

[10] Z. Wang, “Matoi: selective revalidation of consequence evidence for agent authorization,” arXiv:2610.21394v1, Oct. 2026.

[11] J. Liu, “When may an agent stop? Evidence-carrying termination for tool-using LLMs,” arXiv:2608.23623v1, Aug. 2026.

[12] W. Zheng, M. Xu, K. Hu, K. Ye, and C. Xu, “AgentLoop: runtime control of slot-closed execution loops for tool-augmented LLM agents,” arXiv:2609.33315v1, Sept. 2026.

[13] S. Weinberger and A. Hozez, “Prompt-induced waste in coding agents: reasoning, effort, harness design, and end-to-end cost,” arXiv:2608.01347v6, Sept. 2026.

[14] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

English abstract and keywords

Evaluating Information Retention and Execution Control in Stateful LLM Agents

Abstract We evaluate information retention and execution control in stateful agents on four development tasks. API documentation omission, reasoning retention, and exception presentation fail prespecified adoption criteria. Completion diagnostics and pre-exception trajectory differences limit causal interpretation of observed costs. We report all conditions and unknown usage.

Keywords harness engineering, LLM agents, information retention, execution control, cost evaluation