# 推論過程を保持すると
# 仕事全体の費用はどう変わるか

# 同じ公開履歴・Python状態・予算から全８条件

既知４課題の８応答後から各１回。保持側は過去と以後の推論を全て保持。

| 課題 | 公開履歴のみ | 推論も保持 | 初回入力の増加 |
|---|---|---|---|
| 写真整理 | 8,829 | 9,120 | +291 |
| 精算 | 11,307 | 11,496 | +189 |
| 返金 | 15,786 | 16,902 | +1,116 |
| 曲情報の書出し | 13,811 | 14,172 | +361 |

各16生成・12万token・480秒、API上限と残予算通知も共通。

> 初回の入力増加だけでは、全体費用や最終品質の優劣は決まらない。

# 全８予定条件：失敗・不明費用もそのまま示す

| 課題 | 条件 | 評価 | 仕事token | 生成 | 継続API |
|---|---|---|---|---|---|
| 写真整理 | 公開履歴のみ | 成功 | 156,754 | 8 | 131 |
| 写真整理 | 推論も保持 | 成功 | 118,184 | 5 | 92 |
| 精算 | 公開履歴のみ | 未達 | 160,878 | 9 | 9 |
| 精算 | 推論も保持 | 未達 | 164,322 | 9 | 10 |
| 返金 | 公開履歴のみ | 成功 | 85,720 | 2 | 2 |
| 返金 | 推論も保持 | 成功 | 88,001 | 2 | 2 |
| 曲情報の書出し | 公開履歴のみ | 未達 | 134,971＋不明1 | 5 | 60 |
| 曲情報の書出し | 推論も保持 | 未達 | 100,425＋不明1 | 3 | 0 |

> 仕事tokenは共通前半＋継続の全入力・出力。cached inputも含む。

# 品質と仕事全体の費用を一緒に判定する

| 条件 | 成功／評価 | 仕事token合計 | 生成 | 継続API |
|---|---|---|---|---|
| 公開履歴のみ | 2/4 | 538,323＋不明1 | 24 | 202 |
| 推論も保持 | 2/4 | 470,932＋不明1 | 19 | 104 |

不明・欠測があるため、正確な仕事token合計差は未確定。

課題別の保持あり–なし：写真 -38,570／精算 +3,444／返金 +2,281／書出し 未確定 token。

全８評価・全使用量既知・少なくとも１対成功・成功喪失０・全体費用減少を要求。

> 今回の局所採用基準は未達。元の比較条件と全結果を残す。

# 保持の費用・失敗・復元まで記録して比較を閉じる

新しい生成 43回、継続 588,495＋不明2 token。
継続 306＋復元 102＝408 API。

専有推論器 2662.086秒、ロード 10.066秒。
評価subprocessの実測合計 12.876秒。推論器の停止とプロセス不在を確認。

- ４つの既知課題・各１回。統計的非劣性の検証ではない。
- 推論保持は通常対照の条件で、新提案手法ではない。

> 新提案の中核は未確立。次の主張は、この比較で支えられる範囲に限る。