状態保持型エージェントの API 説明省略における仕事全体の費用と終了手続きの診断

著者未設定

Whole-Task Costs and Completion Diagnostics of API Documentation Omission in Stateful Agents

Author DETAILS PENDING,

DOI:10.14923/transj.???????????

あらまし　状態保持型エージェントの API 説明省略と推論保持を既知 4 課題で比較し，初回入力と仕事全体費用・成否を診断する。作業状態と終了通知を分離し，通常制御の局所改善と未達・使用量不明を併記する。入力短縮だけでは全体費用の削減を判断できない。

キーワード　AI エージェント，API 説明，コンテキスト管理，費用評価

1. 目的と検証する問い

必要情報・処理と最終品質を保つ費用削減には，取得から検証までを含む評価が必要である．短い入力でも再取得や生成が増えれば費用は減らず [1], [2]，成功判定の差も実作業と終了手続きの違いを区別しない．API の一覧と引数の詳細を別々に省き，**同じ途中状態からの表示省略が仕事全体費用と成否へどう影響し，成否差を実作業の改善と解釈できるか**を調べる．Python 状態・スキーマ・原文参照を保持した既知 4 課題・2 接続の全 24 表示条件と，完了通知の介入，別条件の通常終了制御・推論保持を報告する．全結果と不明費用を残す．

2. 関連研究と本稿の範囲

圧縮と成否・費用・停止理由の反復比較 [1]，再取得費用の定式化 [2]，推論圧縮と後続の行動・全体費用の関係 [3] が既に調べられている．短縮が総費用削減を保証しないという一般論は新規性としない．CodeAct [4] のコード行動，CaveAgent [5] の持続状態，HD-Gist [6] の API 引数・値の学習表現，Tool Search Tool [7] の定義展開，同一文書での段階的開示 [8] も関連する．

同じ計算済み状態からの返却比較 [9] や，作用・方針・課題指標の分離 [10] も既出である．ECT [11] は契約と記録を検証して終了し，AgentLoop [12] は要求充足・状態変化から反復を抑える．検証費用のハーネス依存性も報告されている [13]．本稿は取得済み説明の表示と完了通知を具体的に照合する．既知要求の手書き検査を新しい終了方式や先行方式の再実装比較としない．

3. 費用の定義

仕事全体の論理トークンを

$$T_{\text{work}} = T_{\text{prefix}} + \sum_{j=1}^{n} (I_j + O_j) \tag{1}$$

とする．共通前半の実測値を各条件へ一度加え，キャッシュ入力も I_j へ含める．継続だけの値も示し，初回短縮量を全体の節約量へ，論理 token を請求額・計算量・時間へ換算しない．API，時間，実験用復元，評価，推論器のロード・常駐は別記し，重なる時間を足さない．評価器単独の時間は表示比較では未計測で，稼働時間の残差からは求めない．

4. 表示比較の方法

継続点の状態を会話履歴 H，Python 名前空間 P，操作先環境 E，残予算 $\mathcal{B}$，初期公開分を含む取得済み公開スキーマの集合 V とする．登録された全公開 API の集合を $\mathcal{A}$ とし，$V \subseteq \mathcal{A}$ である．文書取得必須の接続は V，公開名接続は $\mathcal{A}$ に属する API を呼び出せる．後者でも，未取得のスキーマや具体的な引数値を追加表示するわけではない．未登録名・未知の引数名はハーネスで拒否し，型・必須引数は元の API 側で検査する．認証，予算，完了後・作用不明後の停止も共通である．

全表示 F，古い詳細のみ省略 D，同じ詳細と古い一覧を省略 B を比較する．保存した公開 API 返却と表示処理から出自を照合できる区間のみを変更し，操作コード，リテラル，混合出力，エラー，最新応答を保持する．D/B で詳細の省略集合と印をそろえ，P, E, V と原文参照経路を維持する．表示省略は保存情報の消去や呼出し権限の縮小とは異なる．

既知 4 課題の第 8 応答後から各条件を 1 回ずつ実行する．文書取得必須 G（P55）の結果を保存し，公開名 N（P71）の比較を後に固定した．P71 では全 3 条件に同じ能力説明とツール説明を与え，前半の行動と返却は変更しない．前半は元の文書取得必須条件で生成されたもので，そのときの拒否も履歴へ残す．公開名接続を適用するのは継続部分であり，初期状態からの通常実行の比較ではない．各比較内で D 対 F と D 対 B を評価する．P55 と P71 の間では説明文と実行時点も異なるため，その差を呼出し制約だけの因果効果とはしない．両比較は同じ既知課題と前半を使い，独立した 8 課題の確認評価ではない．

各条件 16 生成，継続 120,000 token，480 秒を上限と

し，全入力を計数して残予算内に出力枠を収める．初回入力はキャッシュを再利用しない．MiniMax-M3 の IQ4_XS 版と llama.cpp b11669 を用い，context 65,536，温度 1.0，top-p 0.95，最大出力 4,096 とした．seed は 50 から生成ごとに 1 増やし，順序は課題ごとに FDB，DBF，BFD，FBD とする．API 上限は前半込みで写真 160，他 80 である．使用量不明の生成は実行も再試行もせず当該条件を終了し，作用・片付け・推論器の待機を確認できた場合だけ保存状態を評価して次へ進む．不明費用，未評価，未実行を補完しない．

両比較で Python 出力，公開返却，保存ファイルを継続前に照合するが，ヒープ・乱数状態の完全複製や生成の決定性は主張しない．返金 D/B は追加で省く一覧がなく基礎入力が同じである．残時間通知と数値実装の揺らぎは残るため，そこでの差を一覧保持の効果とはしない． 会話履歴 H は公開 content・呼出し・観測であり，全表示 F を含む全条件でモデルが返した推論は再投入しない．したがって，表 2・3 の結果は推論保持を含む通常対照へ一般化できない．

4.1 対象と入力の照合

AppWorld [14] の写真整理，電気代精算，返金，曲一覧の書出を用いる．過去の失敗・入力計数を見た方式探索であり，未閲覧 12 シナリオは使わない．D/B の詳細省略は課題順に 7・2・3・7 返却で一致し，B の追加一覧省略は 1・1・0・3 返却だった．表 1 は共通の予算通知と省略印を含む初回短縮量である．

表 1　D の初回入力短縮 token（対 F）

接続	写真	精算	返金	曲書出し
文書必須	1,447	258	782	1,629
公開名	1,447	258	782	1,629

4.2 採用基準と欠測

全 12 評価・全使用量既知・監査合格の下，D が F/B 双方の成功を失わず，合計 T_{work} が F 未満・B 以下なら局所採用候補とする．一覧の価値には入力が異なる D 成功・B 失敗の対も要求し，同数成功を非劣性とはしない．不明使用量は既知分と分け，ゼロや上限で補わず，確定費用差を求めない．API 作用・復元・実行・片付け・評価・推論器版の不一致では全体を停止する．結果で seed・条件・予算を変えず，未実行の成否も補完しない．

5. 費用と成否の全結果

両接続とも全 12 条件を評価し，未評価・未実行 0 だった（表 2）．継続費用は G で既知 1,000,847 token ＋不明 1 生成，N で 950,398 token ＋不明 2 生成．D の既知費用は F より G で 43,083，N で 22,524 token 多かった．N の写真は F/B 成功・D 未達で，D の写真・書出しは生成中の時間上限により使用量不明となった．未達で早く止まる条件を効率のよい成功とはしない．

表 2　全 24 予定条件の成否・仕事 token

接続	課題	F	D	B
G	写真	未達 145,850	成功 120,935	未達 165,015
	精算	未達 163,918	未達 161,225	未達 154,720
	返金	成功 85,697	成功 117,223	成功 117,305
	書出	未達 117,100	未達 156,265+?	未達 126,734
N	写真	成功 156,754	未達 121,357+?	成功 129,261
	精算	未達 161,694	未達 162,725	未達 154,222
	返金	成功 85,975	成功 100,527	成功 100,527
	書出	未達 96,460	未達 138,798+?	未達 173,238

G：文書必須，N：公開名で継続．+? は別に使用量不明がある値．

5.1 入力短縮と仕事全体の費用

不明生成のため D 対 F/B の確定費用差は求めない．両比較とも D の既知費用が F を上回り，採用条件は未達だった．表 3 に合計を示す．G の D は初回入力が F より短いが，継続生成は 22 回から 26 回へ増えた．返金は両接続の F/D/B で成功したが，D の全体費用は F より大きかった．

表 3　全 4 課題合計の費用と実行量

指標	F	D	B
文書取得必須（P55）			
成功／評価	1/4	2/4	1/4
仕事・既知 token	512,565	555,648+?	563,774
継続・既知 token	302,185	345,268+?	353,394
継続生成／不明	22/0	26/1	29/0
継続／復元 API	173/51	162/51	122/51
公開名（P71）			
成功／評価	2/4	1/4	2/4
仕事・既知 token	500,883	523,407+?	557,248
継続・既知 token	290,503	313,027+?	346,868
継続生成／不明	21/0	25/2	27/0
継続／復元 API	204/51	138/51	148/51

継続 API は実際の送信数で，拒否や原文参照は別記する．回数減だけを不要取得削減とはしない．推論器全稼働は G で 4,112.859 秒，N で 3,724.097 秒．N の継続 490・復元 153 API のうち，説明公開前の呼出しは写真 B の公開時計 1 件だった．

6. 成否差と終了手続きの診断

G の写真 F/D は各 42 移動で非 supervisor 保存ファイルが一致したが，公式成否は未達／成功，通知は 0／1 件だった．まず G の写真 F/B を別環境で再現し，元 D と同じ空引数の完了通知なし／1 回追加の 4 条件を固定した．次に N の全 12 条件のうち，成否によらず完了 API 未送信の全 7 状態（既知 3 課題）を選び，同じ 2 条件の計 14 ケースを固定した．N の通知は

元写真 B で観測した status="success"だけとした．全ケースで送信済み公開 API の返却と介入前の全 13 保存ファイルを元状態と照合し，無介入は元の成否を再現した．

表 4　完了通知だけの介入（全 18 ケース）

再現した元状態	通知なし	通知 1 回
G 写真 F	未達	成功
G 写真 B	未達	未達
N 写真 D	未達	成功
N 精算 F	未達	未達
N 精算 D	未達	未達
N 精算 B	未達	未達
N 書出し F	未達	未達
N 書出し D	未達	未達
N 書出し B	未達	未達

G の写真 F と N の写真 D だけが未達から成功へ変わり，それぞれ元 G の D，元 N の B と最終 13 保存ファイルも一致した．非 supervisor 保存ファイルは全ケースで介入前後不変だった．残り 7 状態は通知後も未達で，完了宣言を一律に足す根拠にはならない．G の診断は 346 API・4 評価・23.927 秒（評価 8.541 秒），N は 702 再送＋7 通知＝ 709 API・14 評価・64.318 秒（評価 19.503 秒）だった．両診断とも生成 0 で，元の成否と不明費用は変更しない．N の不明 2 生成は最後の未実行応答に限り，全 API 作用が既知であることを別に照合した．同じ既知写真の事後診断であり，独立した別課題の追認ではない．G の写真では分類に必要な現在年の成功した公開時計応答がなく，通知による公式判定の変化は公開証拠だけで要求を全て検証できたことを意味しない．

7.　公開証拠による通常終了制御の追加点検

同じ既知写真を初期状態から文書必須・公開名の各接続で実行した別の対照を用いた．モデル・seed・案内・予算をそろえ，応答内の全プログラム実行後に公開記録を検査した．上限は各 80 生成・450,000 token・1,800 秒・160 API．元集合・移動前日時・現在年・移動先・名前保持が支持されれば完了 API を 1 回送る．不明時は通常継続し，追加案内・未来応答・評価器は使わない．

表 5　別条件の写真課題：全体 token

接続	通常終了	終了制御	減少率
文書取得必須	130,439	91,116	30.1%
公開名	151,664	112,233	26.0%

全 4 実行が成功し，制御では各 2 生成・4 API が少なかった．各対の最終 13 保存ファイルと制御時点までの公開 API 記録は一致したが，ID 差による要求・モデルメッセージ全文一致の事前基準は不成立だった．

制御 2 条件の全 25 生成は 203,349 token，199 API，2 評価，使用量不明 0 だった．25 回の検査と記録ダイジェスト計算は合計 0.028224 秒で，全体時間にも含めた．減少 78,754 token のうち 66,720 は cached input であり，金銭・時間の同率削減ではない．既知書出しでは通常ツール対照と終了制御を各 1 回，API 上限のみ 80 として比較し，正しい CSV 作成後の退会までを公開記録に要求した．両方 8 生成・219,126 token・80 API で未達，書出し・退会 0 回．8 検査 0.004080 秒で通知・削減 0，使用量不明 0 だった．最終 13 保存ファイルは一致し，ID 差の全文不一致は残った．この ID 差を別途点検し，固定 runtime で保存 66 入力と 3 対照を再構成した．元 batch は原文と正規化後のテンプレートの末尾改行 1 byte 差で停止したため，保存出力を事後に読み取った．写真 13・12 対，書出し 8 対の全 33 対で文章・全 token 列・生成制約が一致し，元 66 入力の実測数とも一致した．未変更と ID 変更の対照は一致，本文変更では文章・token 列が変化した．69 入力の再構成・計数を含む処理 5.543 秒，事前照合 1.859 秒，事後読取 0.254 秒で，新規生成・API・評価は 0 だった．過去の GPU・乱数器状態は復元せず，元の全文不一致判定は変更しない． これらは API の意味を信頼した既知文型の通常制御であり，表 2・3 へ合算しない．実装・固定条件・全件集計を公開する(注1)．

8.　推論履歴を保持する通常対照

同じ既知 4 課題の 8 応答後から，公開履歴のみ（P）と返却推論も全て保持（R）を各 1 回比較した．両条件は公開履歴・持続 Python・公開名接続・予算を共通にし，過去と以後の推論の投入だけを変えた．各 16 生成・120,000 token・480 秒で，最初の生成は cache を使わない．共通前半は推論を再投入せず生成しており，最初からの方針比較ではない．

推論保持比較の全 8 条件：成否・仕事 token

課題	P：公開履歴のみ	R：推論も保持
写真	成功 156,754	成功 118,184
精算	未達 160,878	未達 164,322
返金	成功 85,720	成功 88,001
書出	未達 134,971+?	未達 100,425+?
成功／評価	2/4	2/4
既知 token 合計	538,323+?	470,932+?

R の初回入力は課題順に 291・189・1,116・361 token 増えた．全 8 予定条件のうち 8 条件を評価し，使用量

(注1)：https://github.com/sophiria1225/AI-

不明は 2 生成だった．欠測を補完せず，採用判定に用いる確定費用差は求めない．課題別の R − P の仕事 token 差は，写真 -38,570 ／精算 +3,444 ／返金 +2,281 ／書出し 未確定だった．全 8 評価・全使用量既知・少なくとも 1 対成功・成功喪失 0 ・全体費用減少という局所採用条件は満たさなかった．新規継続は 43 生成・既知 588,495 token ＋使用量不明 2 生成，継続 306・復元 102 API だった．推論器全稼働 2,662.086 秒に復元・評価も含め，重複加算しない．保持は通常の比較条件であり，新規手法や一般的な非劣性の実証とはしない．表 2・3 の過去条件は変更しない．

9. 解釈の限界

同じ既知 4 課題・単一モデル・各条件 1 回の開発比較であり，診断 18 ケースも既知 3 課題 9 状態への事後介入である．seed と初回 cache をそろえても後続経路の再現性は保証しない．返金 D/B は基礎入力が同じでも後続の残時間通知等が異なり，差を一覧の効果に帰属させない．

B でも過去コード等に API 名が残る（写真 8/26 名，精算 10/26 名）．名前の理解や情報の完全消去を測るものではなく，省略対象は出自の確かな古い説明に限る．

10. 結　　論

両接続で，D の初回入力は短くても既知の仕事全体費用は F を上回った．写真の成否差と終了通知の関係，通常終了制御の局所改善と未達を示した．推論保持でも写真の費用は減ったが，失敗・不明使用量が残り，全体の採用条件は未達だった．既知 4 課題の局所結果であり，必要情報と品質を守る制御には，仕事全体費用と作業・終了手続きへの作用を対応させた検証が必要である．

文　　献

[1] R. Satish, P. Sinha, A. Kawada, and N.J. Yadwadkar, “Beyond token savings: a systematic study of context compression in LLM agents,” arXiv:2609.32961v1, Sept. 2026.

[2] S. Liu, “What does context compression cost an agent? Interaction costs unrevealed by task-completion metrics,” arXiv:2608.16370v1, Aug. 2026.

[3] M. Wang, F. Luo, B. Wang, G. Yao, Y. Guo, C. Ning, H. Chen, Y. Ma, and J. Han, “When can agents forget their reasoning? ICLR for long-horizon agent context compression,” arXiv:2609.29875v1, Sept. 2026.

[4] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[5] M. Ran, Z. Wan, C. Lin, Y. Zhang, H. Xin, H. Fan, Y. Xu, B. Luo, Y. Zhou, W. Zhao, L. Yang, L. Feng, F. Yang, J. Wu, Y. Huang, C. Ma, Y. Huang, D. Jiang, J. Deng, S. Han, Y. You, B. An, Y. Guo, and J. Song, “CaveAgent: transforming LLMs into stateful runtime operators,” arXiv:2601.01569v4, June 2026.

[6] Y. Jiang, M. Del Vecchio, M. Bansal, and A. Johannsen, “Hierarchical and dynamic prompt compression for efficient zero-shot API usage,” Findings of EACL, pp.2162–2174, St. Julian’s, Malta, March 2024.

[7] Anthropic, “Introducing advanced tool use on the Claude Developer Platform,” Nov. 24, 2025. `https://www.anthropic.com/research/advanced-tool-use`, accessed Oct. 23, 2026.

[8] Y. He, Y. Zhao, J. Wang, and H. Chen, “Is progressive disclosure all you need for long-context agents?,” arXiv:2607.17598v1, July 2026.

[9] K. Zhang, S. Chundur, J.P. Owusu, M.J. Abdolhosseini Qomi, and M. Raissi, “Same simulation, different evidence: where retrieved tool output costs LLM agents accuracy,” arXiv:2610.26836v1, Oct. 2026.

[10] Z. Wang, “Matoi: selective revalidation of consequence evidence for agent authorization,” arXiv:2610.21394v1, Oct. 2026.

[11] J. Liu, “When may an agent stop? Evidence-carrying termination for tool-using LLMs,” arXiv:2608.23623v1, Aug. 2026.

[12] W. Zheng, M. Xu, K. Hu, K. Ye, and C. Xu, “AgentLoop: runtime control of slot-closed execution loops for tool-augmented LLM agents,” arXiv:2609.33315v1, Sept. 2026.

[13] S. Weinberger and A. Hozez, “Prompt-induced waste in coding agents: reasoning, effort, harness design, and end-to-end cost,” arXiv:2608.01347v6, Sept. 2026.

[14] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

（xxxx 年 xx 月 xx 日受付）

Abstract We compare API documentation omission and reasoning retention on four known tasks, separating whole–task token cost, work state, and completion procedures. Ordinary controls yield local savings, but failures and unknown usage limit aggregate conclusions. Shorter initial inputs do not establish lower whole-task costs. Results are exploratory.

Key words AI agents, API documentation, context management, cost evaluation