# 状態保持型エージェントにおける
# API失敗通知の比較

# 失敗の伝え方を、仕事全体の成否と費用で比べる

成功時の型付き値は共通。実際のAPI例外だけを、通常の文字列またはPython例外として返す。

| 既知課題 | 事前検査入力token | 入力照合 |
| --- | --- | --- |
| 写真整理 | 3,103 | 両条件で一致 |
| 精算 | 3,092 | 両条件で一致 |
| 返金 | 3,065 | 両条件で一致 |
| 曲情報の書出し | 3,111 | 両条件で一致 |

最初から推論履歴を保持。持続Python、公開API名、予算も共通。

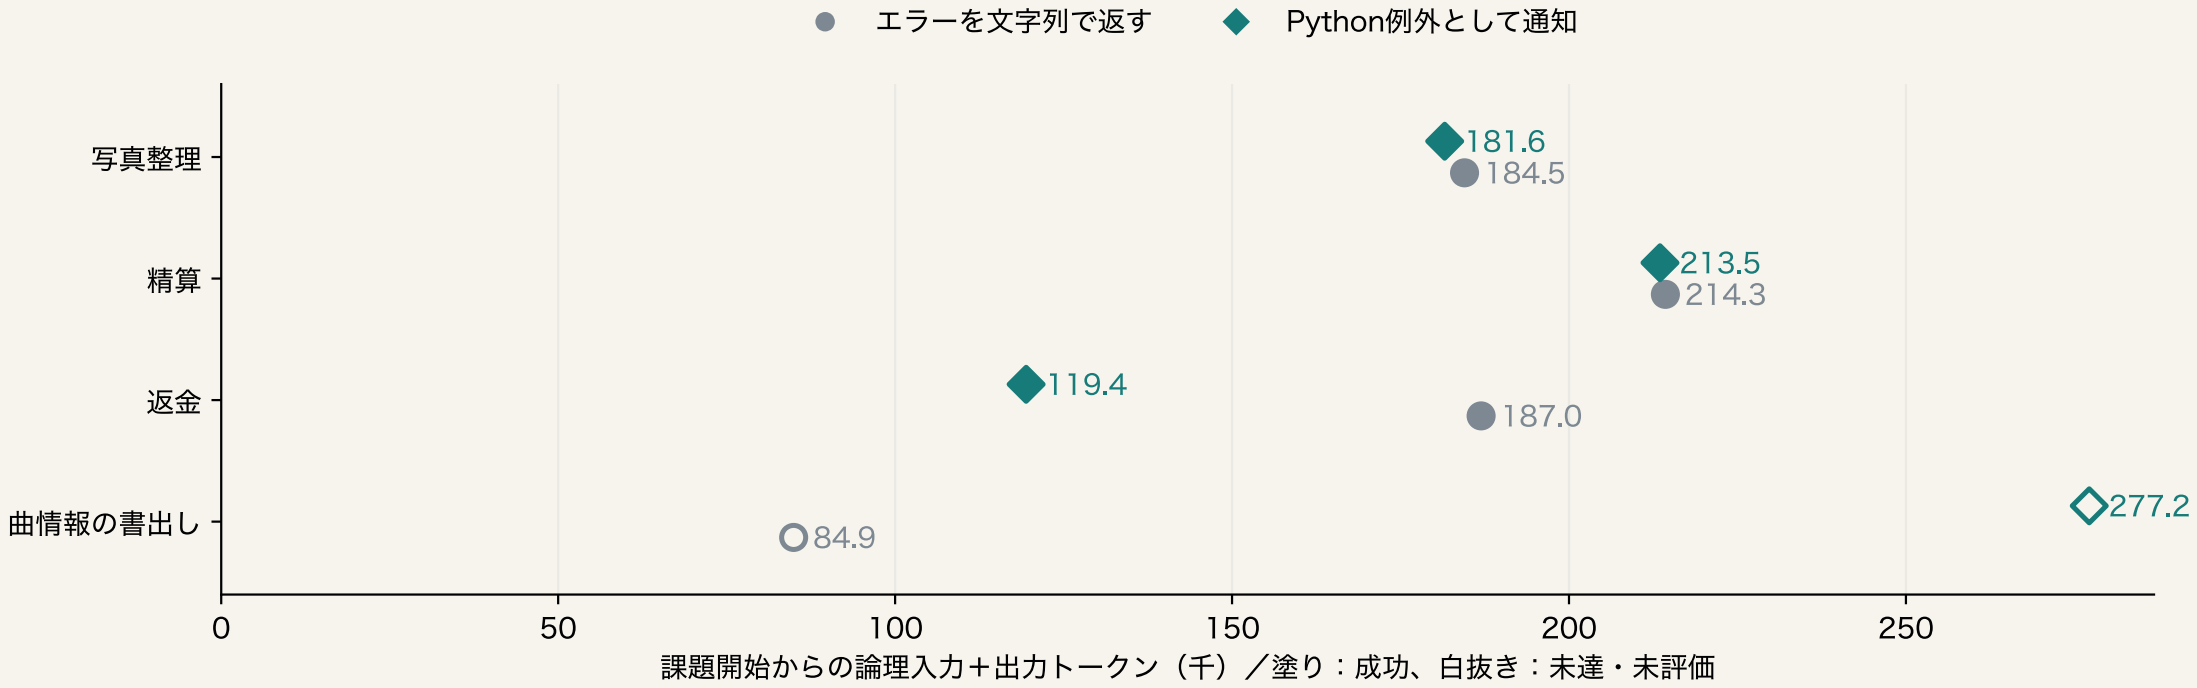
> 必要な処理と最終品質を保ち、失敗と再取得を含む総費用を減らすための診断。

# 全８予定条件を、未達と欠測も含めて示す

| 課題 | 条件 | 成否 | 全仕事token | 生成 | API | API例外 |
|---|---|---|---|---|---|---|
| 写真整理 | 文字列 | 成功 | 184,501 | 17 | 103 | 1 |
| 写真整理 | 例外 | 成功 | 181,555 | 18 | 103 | 1 |
| 精算 | 文字列 | 成功 | 214,306 | 23 | 25 | 3 |
| 精算 | 例外 | 成功 | 213,504 | 23 | 23 | 3 |
| 返金 | 文字列 | 成功 | 186,960 | 16 | 17 | 0 |
| 返金 | 例外 | 成功 | 119,442 | 10 | 17 | 0 |
| 曲情報の書出し | 文字列 | 未達 | 84,946 | 10 | 80 | 0 |
| 曲情報の書出し | 例外 | 未達 | 277,203 | 20 | 80 | 1 |

> 課題開始からの全入力・出力を計上。制御、推論、失敗、回復も含む。

# 小さな入力や短い失敗だけでは、効率化と判定しない




同じ課題の品質と全費用を併せて読む。既知部分の減少だけでは合計差は確定しない。

# 固定した品質と費用の基準で判定する

| 条件 | 成功／評価 | 全仕事token合計 | 実API例外 |
| --- | --- | --- | --- |
| エラーを文字列で返す | 3/4 | 670,713 | 4 |
| Python例外として通知 | 3/4 | 791,704 | 5 |

例外–文字列の全費用差：+120,991 token。

全８評価・使用量既知・実API例外あり・双方成功の課題あり・成功喪失なし・全体費用減少を要求。

> 既知群での局所採用基準は満たさなかった。 一般的な品質維持や新規性の証明とは区別する。

# 費用差が、失敗通知の効果とは限らない

| 課題 | 実API例外<br>文字列 / 例外 | 最初の送信要求 | 最初に差が出た<br>モデル呼出し | 差は例外より前 |
|---|---|---|---|---|
| 写真整理 | 1 / 1 | 一致 | 4 | いいえ |
| 精算 | 3 / 3 | 一致 | 4 | いいえ |
| 返金 | 0 / 0 | 一致 | 6 | はい |
| 曲情報の書出し | 0 / 1 | 一致 | 6 | はい |

参照IDだけを一貫して置換し、入力と公開出力を元の順で比較。残時間通知は保持。

> 実API例外が0の返金では、費用差を通知方法の効果とは解釈しない。

# 記録を閉じ、主張できる範囲を残す

モデル生成 137回、API 448回。
専有推論器 4,390.281秒、ロード 10.065秒。
独立評価の実測合計 13.175秒。

- 全条件の入力、予算、使用量、例外記録、独立評価を監査。
- 所有サーバー停止とプロセス不在を確認。
- 既知４課題・各１回。未開封12課題は使用しない。

> 通常の実行設計を測った結果として、情報保持と実行制御の研究へつなぐ。