状態保持型 LLM エージェントにおける情報保持と実行制御の評価

著者未設定

Evaluating Information Retention and Execution Control in Stateful LLM Agents

Author DETAILS PENDING,

DOI:10.14923/transj.???????????

あらまし　状態保持型 LLM エージェントの通知と参照表現を評価した. 既知 4 課題 24 条件で後半通知の全仕事費用改善は示せなかった. 1 保存文脈で参照 ID 差に伴う次出力差を確認した.

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1. 問題設定と関連研究

必要な情報と成果品質を保って仕事全体の費用を減らすには，取得済みの情報だけでなく，ハーネスが渡す制御情報と参照表現も検討する必要がある．実行速度で変わる残時間と，課題内容を表さない呼出し ID がモデル入力へ届く経路を調べ，入力をそろえる局所的な処理と全仕事の改善を区別する．対象は CodeAct [1] 型のコード行動と AppWorld [2] の状態を持つアプリ操作である．

時間通知と期限強制の分離 [3]，推論・道具遅延を使う時間適応 [4]，数値実行と多段経路の非決定性 [5], [7] には先行研究がある．ハーネス探索 [8]，実行形式の資源・品質への影響 [9]，同じ情報の提示方法 [10]，評価の出典記録 [6] も既出である．参照 ID の改名感度と正規化 [11]，token 削減と費用の不一致 [12]，cache と圧縮・遅延の相互作用 [13], [14] 自体を新規性とはしない．本稿の範囲は，既知課題で通知・参照表現の変化を入力，次出力，成否，全費用へ対応付ける限定した実証である．

2. 共通の履歴処理と通知

公開履歴と返却済み推論を h とする．検証済みの呼出し ID と結果 ID の対応を保ち，初出順に統一する処理を C，モデル用の表示処理を R とする．不正引数を含む呼出しでは，R が呼出し記録を文章に変換する．この後で構造化された参照欄だけを統一しても，文章内の ID は変わらない．そこで共通履歴は $R(C(h))$ とする．C は通常文，引数，コード，観測，エラー，返却推論の値を変更せず，元記録を保持する．重複・欠落・対応のない参照は拒否する．R による長い観測の先頭ページと参照先の表示は全条件で共通とする．これは通常の正規化順序の修正であり，新しい正規化アルゴリズムや，任意の文章内 ID を消す処理ではない．

元の仕事上限を $B = 1800$ 秒，生成直前の実残時間を整数秒に切り捨てた値を r とする．M は毎回 r を表示し，H は非表示を通知する．L は $2r > B$ なら H，$2r \le B$ なら M とする通常の後半表示である．整数化によって実際の半分時点より 1 秒未満早く切り替わり得る．要求には現在の通知を 1 件付け，通知自体を継続会話には蓄積しない．過去の生成内容・観測は書き換えず，進行中の生成へ通知を割り込ませない．実行可否とタイムアウトは，全条件で単調時計に基づく実期限から判定する．残 token・API 回数・生成回数の表示は共通とする．

全仕事の論理費用は $T = \sum_j (I_j + O_j)$ とし，全入力 I_j，出力 O_j，制御情報，失敗，回復，cache 入力を含める．cache を除く入力，出力，API 数，実時間は別に集計する．終端使用量の欠測は保持し，再試行や別反復で補完しない．前提を照合できる場合だけ保存数値ログから補助区間を求め，欠測を既知に変更しない．

3. 二つの比較

3.1 全仕事の通知比較

写真移動，電気代精算，返金，曲情報書出しの既知 4 課題を初期状態から M/H/L で 2 回ずつ実行する．全 24 条件は履歴処理を共通とする新しい群であり，以前の条件を対照へ流用しない．Mac Studio M3 Ultra・256 GiB メモリ上で，AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS，llama.cpp b11669 を用いる．入力枠 65,536，1 スロット，持続 Python，型付き API 返却，通常例外を共通とする．温度 1.0，top-p 0.95，環境 seed42 を固定し，モデル seed は各条件の初回 57，以後生成ごとに 1 増やす．反復 1 の課題順は MHL/HLM/LMH/LHM，反復 2 は各組の逆順である．各条件 80 生成，450,000 論理 token，1,800 作業秒，写真 160・他 80 API を上限とする．出力上限は 4,096 と残予算の小さい方で，通信待ちは 600 秒と残実時間の小さい方とする．初回は cache 再利用 0 を確認し，後続は通常の prefix cache を使う．

独立評価器で最終状態を各 1 回判定し，その基準や結果をモデルへ返さない．L の採用基準は，各反復で M/H それぞれに対し，全件評価・使用量既知・監査一致，課題ごとの成功喪失 0，共通成功 1 課題以上，全 4 課題の論理費用減を満たすことである．全 4 比較での成立を要求し，閾値探索や成功部分だけの選択を行わない．これは開発上の相対基準であり，統計的な非

表 1　全 24 条件の成否と論理入出力 token．不明生成を 0 へ置換せず，未評価・未実行も残す．

課題・反復	M	H	L
写真移動 1	成功 128,796	成功 135,628	成功 135,628
写真移動 2	未達 152,155	成功 135,628	成功 135,628
精算 1	成功 241,963	成功 211,110	成功 211,110
精算 2	成功 275,944	成功 211,110	成功 211,110
返金 1	成功 138,701	成功 102,087	成功 102,087
返金 2	成功 109,383	成功 102,087	成功 102,087
		未達 358,638	未達 348,419
曲情報の書出し 1	未達 257,266	＋不明 1	＋不明 1
		未達 358,638	未達 346,789
曲情報の書出し 2	未達 90,721	＋不明 1	＋不明 1

劣性保証ではない．

3.2　保存入力の次出力比較

以前の M/H 比較の第 2 反復全 8 条件を調べた後，書出しの第 1・第 2 反復間で最初に文章化 ID 差が現れた保存文脈を選んだ．元入力 A/B，それぞれから表示前統一した C/D，A の構造化参照だけを変えた N，診断文を追加した X の 6 入力を固定する．入力 token 列は C/D で一致し，A/N でも一致するが，A/B と A/X は異なる．X の出力まで変わるとは仮定しない．各 3 回，計 18 生成を固定順で行い，seed70，温度 1，出力上限 4,096 を保持する．全要求で入力 cache を無効化し，元の warm 状態を再現したとはしない．生成コード・環境 API・課題評価は実行しない．

各入力内の 3 対と入力間の全 15 組を照合する．全 18 件の使用量が既知で，全 6 入力が完全・非空の公開出力として安定し，C/D と A/N が一致する場合だけ，A/B の公開出力差を判定する．ここで完全とは出力上限による終了でないことであり，構文の妥当性や実行可能性ではない．途中切れ，空出力，揺れ，欠測，未実行を除外して判定可能扱いしない．公開内容・関数名・引数の照合と，返却推論を含む message 全体の hash 照合を分ける．

4.　全仕事の結果

採用基準を満たした比較は 0/4 であり，両対照を両反復で上回るという固定基準は未達だった．条件を選び直した改善や，新手法の成立として扱わない．反復 1 の固定基準は M に対し未達，H に対し未達であった．反復 2 の固定基準は M に対し未達，H に対し未達であった．反復 1 の M/H/L の成功数は 3/4，3/4，3/4 であった．反復 2 の M/H/L の成功数は 2/4，3/4，3/4 であった．全 24 条件で 426 生成，既知 4,602,713 論理 token，使用量不明 4 生成，1156 API 送信を記録した．所有推論器の稼働は 16,263.578 秒，うち読込 10.061 秒，評価 41.470 秒であった．仕事ごとの準備・作業・後片付けの合計は 16,192.106 秒であり，これらは重なりを持つため加算しない．補助的な資源区間は本稿に含めず，欠測を含む全費用差を既知分だけから推定しない． M の反復間は全 4 対中 4 対が判定可能で，そのうち全要求一致は 0 対，全公開出力一致は 0 対であった．H の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L で最初に実測残時間を通知した生成番号は反復 1/2 の順で，課題 1 は未到達/未到達，課題 2 は未到達/未到達，課題 3 は未到達/未到達，課題 4 は 16/16 であった．同条件の反復間 12 対と，反復内の条件間 24 対を全て記録した．36 対は実行を共有しており，独立標本数ではない．一致数は判定可能な対に限り，欠測側を一致扱いしない． 保存ログからの狭い条件付き区間は，H の欠測 2 生成に正の生成進捗がなく前提不成立となった．欠測 4 件は残し，以下は公開レシートと非負性だけを使った事後集計である．L − M の論理 token 差は，成功同士 5 組では −132, 765，失敗同士 2 組では ≥ +347, 221，成否不一致 1 組では −16, 527 であった．各区分は同じ 4 課題の反復を含み，独立標本ではない．成功部分の減少を全仕事へ拡張せず，M の成功喪失も保持する．L − H は両側に欠測があるため既知部分の差を全費用差へ読み替えない．片側境界は信頼区間ではなく，GPU 演算量，消費電力，課金，因果的な高速化も測っていない． 補助的な事後照合として，旧 H の 3 反復と本群 H の 2 反復を全 4 課題で比べた 24 対を残した．成功 3 課題は全要求・公開出力列が一致し，書出しの全 6 対は最初の 13 生成が一致して 14 生成目で差があった．本群 H の書出し両反復の 14 生成目は保存統一入力 C/D と要求 JSON が一致したが，課題は両方未達だった．これは時期の異なる群の記録照合であり，正規化の有無を同時に割り付けた因果比較ではない．次出力診断では cache を無効化しており，本群の warm 状態の再現でもない．

表 2　2 反復全件の L と各対照との差．下限は欠測計数の非負性だけによる．時間は実測差である．

測定	L − M	L − H
論理 token	≥ +197, 929	未確定
cache 除外入力	≥ +19, 977	未確定
出力 token	≥ +20, 204	未確定
作業秒	+1,702.316	+2.611

表 3　保存入力の全 6 条件．各 3 予定生成．公開一致は既知使用量の比較可能対だけの一致数である．

入力	試行	既知	完全非空	公開一致
A	3/3	3/3	3/3	3/3
B	3/3	3/3	3/3	3/3
C	3/3	3/3	3/3	3/3
D	3/3	3/3	3/3	3/3
N	3/3	3/3	3/3	3/3
X	3/3	3/3	3/3	3/3

5. 保存文脈の次出力

この保存文脈では元の ID 一対で公開出力が異なり、同値入力の対照は一致した．A/B の公開出力一致は 0/9 対であった．C/D の公開出力一致は 9/9 対であった．A/N の公開出力一致は 9/9 対であった．全 18 予定枠中 18 生成を試行し，既知 422,475 論理 token，使用量不明 0 生成を記録した．所有推論器の稼働は 4,386.052 秒であった．全 15 組の比較と返却 message 全体の不透明 hash 照合を補足記録に保持し，内部推論の意味内容は読まない．一致する出力が正しいことや，継続後の品質が保たれることは判定していない．

6. 解釈の範囲

独立した課題は調整に用いた既知 4 つであり，24 実行や照合対数を独立課題数へ読み替えない．保存入力も事後に選んだ 1 文脈であり，6 独立課題ではない．同じ seed でも数値実行や cache の変動が残り，ホスト負荷も排他的に固定していない．通知文の長さと情報の効果は独立に識別していない．非表示は生成コードによる独自の時刻参照を禁じず，表示開始に至らない L 条件も残す．参照表現をそろえて出力が一致しても，その正しさ，続く仕事の完成，費用削減を保証しない．過去には別の通常 API 構成で書出しを達成した記録もあり，現在の未達を予算だけで説明できない．全条件，採用しなかった結果，補助区間の前提を公開記録に残す(注1)．

7. 結　　論

後半通知は固定した全 4 採用基準を満たさず，全仕事費用の改善として採用しない．この保存文脈では元の ID 一対で公開出力が異なり、同値入力の対照は一致した．通知・参照の整合を課題成功や費用削減へ読み替えず，未達と使用量の欠測も残す．今回の既知課題と 1 保存文脈だけから，一般的な品質維持や新規な制御手法の有効性は結論できない．

(注1)：https://github.com/sophiria1225/AI-

文　　献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, “On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents,” arXiv:2610.10833v1, 2026.

[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, “Timely Machine: Awareness of Time Makes Test-Time Scaling Agentic,” Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.

[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W. Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, “Understanding and Mitigating Numerical Sources of Nondeterminism in LLM Inference,” Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.

[6] P. Pattnayak and A. Bhatia, “ReproEvalCard: A Reporting Standard for Reproducible Evaluation of LLM Pipelines,” Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.

[7] A. Yagubyan, “How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines,” arXiv:2605.28840v1, 2026.

[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, “Beyond Prompts: Measuring and Optimizing LLM Tool-Agent Harnesses,” arXiv:2609.05736v1, 2026.

[9] R. Agarwal, “Measuring Local SLM Agents as Systems: Protocol Effects on Quality and Resource Use,” preprint, 2026, doi:10.5281/zenodo.21903714.

[10] K. Zhang, S. Chundur, J. P. Owusu, M. J. Abdolhosseini Qomi, and M. Raissi, “Same Simulation, Different Evidence: Where Retrieved Tool Output Costs LLM Agents Accuracy,” arXiv:2610.26836v1, 2026.

[11] A. J. Mercado and A. Lomuscio, “Formal Verification of Agentic Systems over Operational Data,” arXiv:2608.03609v1, 2026.

[12] S. Weinberger and A. Hozez, “Token Reduction Is Not Cost Reduction,” arXiv:2607.12161v5, 2026.

[13] Y. Song, “Cache-Aware Prompt Compression: A Two-Tier Cost Model for LLM API Caching,” arXiv:2607.15516v1, 2026.

[14] E. Lumer, F. Nizar, A. Jangiti, K. Frank, A. Gulati, M. Phadate, and V. K. Subbiah, “Don’t Break the Cache: An Evaluation of Prompt Caching for Long-Horizon Agentic Tasks,” arXiv:2601.06007v2, 2026.

（xxxx 年 xx 月 xx 日受付）

Abstract We evaluated notices and references in stateful LLM agents. Late notices did not demonstrate whole-task cost improvement across 24 conditions on four known tasks. Reference-ID variants produced different next outputs in one saved context. These observations do not establish general quality preservation.

Key words LLM agents, harness engineering, state retention, time notices, cost evaluation