普通の推論予算で
コード提出は完成するか

２保存文脈 × 通常２条件 × ２反復の８生成

文脈	元入力token	元seed	推論ブロック上限
A：引数途中切れ	17,696	69	なし／2,048
B：公開操作なし	31,211	74	なし／2,048

全出力は4,096のまま。条件間の要求差は予算フィールドだけ。
全件でcacheを無効化し、各反復で条件順を逆にする。

> 対象は同じ既知CSV課題の１課題。元のwarm状態や課題全体を再現しない。

全８予定枠を欠測・未実行も含めて示す

条件	反復	入力T	出力T	終端	コード提出
A-U	1	17,696	4,096	length	JSON不正
A-H	1	17,696	2,610	tool_calls	完成
B-H	1	31,211	3,009	tool_calls	完成
B-U	1	—	—	—	不明
A-H	2	—	—	—	未実行
A-U	2	—	—	—	未実行
B-U	2	—	—	—	未実行
B-H	2	—	—	—	未実行

> Uは推論ブロック上限なし、Hは2,048。完成したコードも実行していない。

構文の完成と課題達成を分けて判断する

条件	完成／既知生成	不明・未実行	既知出力T	反復の公開出力
A-U	0/1	1	4,096	不明
A-H	1/1	1	2,610	不明
B-U	0/0	2	0	不明
B-H	1/1	1	3,009	不明

固定した条件：両文脈でUが完成０/２、Hが完成２/２。
全８使用量が既知で監査一致の場合だけ判定する。

> 全８生成の終端使用量と監査が揃わず、固定した改善条件を判定しない。

通常対照の診断費用を全て残す

測定	値
試行／計画	4/8
既知の入力＋出力token	76,318
終端使用量不明	1
入力計数要求	4
実処理／cache入力token	66,603 / 0
推論器稼働 秒	1,686.882
内・ロード／生成応答の合計 秒	10.066 / 1,661.549

> 所有推論器は停止済み。コード実行・環境API・課題評価・未見課題読取は０。