通常の推論予算を、課題全体の成果へつなげる

U：専用上限なし（−1）／H：固定2,048。全出力上限は両側とも最大4,096。

課題	U 初期入力token	H 初期入力token
写真移動	3,115	3,115
精算	3,104	3,104
返金	3,077	3,077
曲情報の書出し	3,123	3,123

新しい初期状態から各１回。初期要求差は専用予算の値だけ。

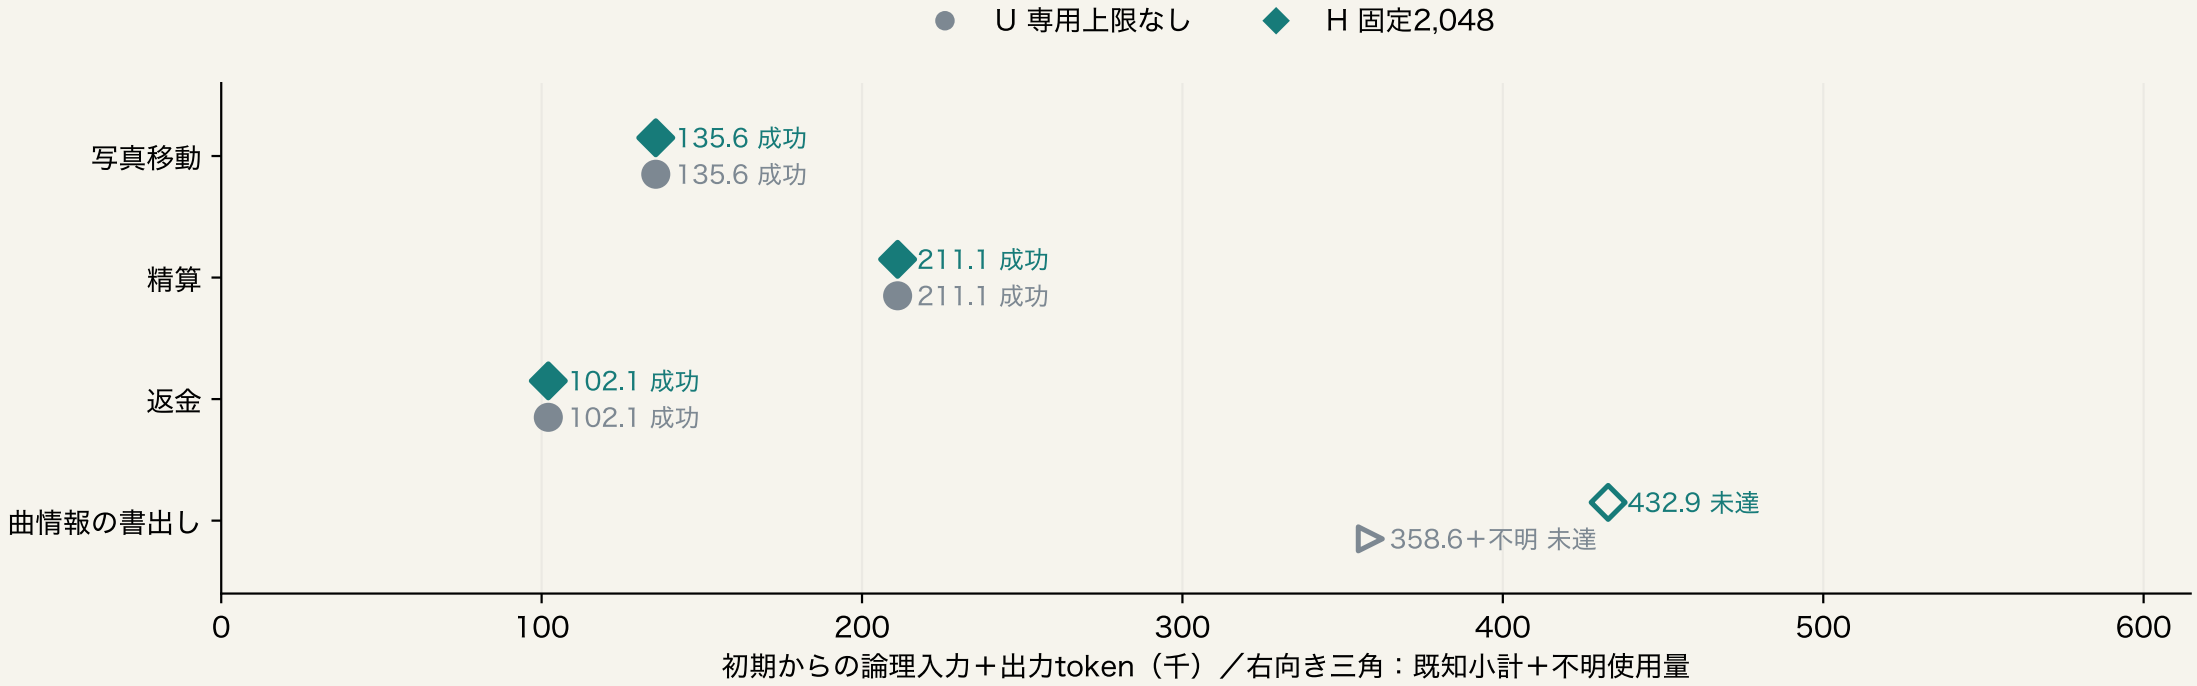
> 既知４課題の通常対照比較。P87の未実行枠を補充したものではない。

全８条件の成否と、失敗を含む費用

課題	条件	成否	全仕事token	生成	API	作業秒
写真移動	U	成功	135,628	16	99	491.1
写真移動	H	成功	135,628	16	99	490.3
精算	H	成功	211,110	24	25	349.5
精算	U	成功	211,110	24	25	349.5
返金	U	成功	102,087	13	13	321.5
返金	H	成功	102,087	13	13	321.4
曲情報の書出し	H	未達	432,872	23	72	1,713.6
曲情報の書出し	U	未達	358,638＋不明1	21	53	1,799.2

> 未評価・未実行は失敗数へ入れず、使用量不明は０で補完しない。

同じ課題で、全仕事の費用と成功を比べる



塗りは成功。三角は不明費用が残る既知小計で、確定した総費用ではない。

採否は全４課題と、課題ごとの成功喪失で決める

条件	成功／評価	既知token合計	計測済み／予定
U 専用上限なし	3/4	807,463＋不明1	4/4
H 固定2,048	3/4	881,697	4/4

全課題 H–U：未確定 token

成功喪失 0課題、成功獲得 0課題。
全８評価と使用量既知、監査一致、成功喪失０、両側成功１以上、全費用減が必要。

> 開発上の採用基準：未達。同数成功だけでは品質維持と判定しない。

成功した課題と、未達の課題の費用を分ける

成果の組合せ	課題数	H–U 全論理token
両側成功	3	未確定
両側未達	1	未確定
成否が異なる	0	未確定
片側以上が未評価	0	未確定

全４対の成否・費用差はCSVにも保存。欠測時は全体の寄与を未確定とする。

> 成功部分だけの削減と、失敗を含めた全仕事の削減を区別する。

cache、出力、呼出しを別の費用として残す

計測対象	U 専用上限なし	H 固定2,048
既知の全入力token	773,785	849,976
既知入力のcache再利用	673,826	747,123
既知のcache除外入力	99,959	102,853
既知の出力token	33,678	31,721
生成試行	74	76
API要求	190	209
使用量不明の生成	1	0

> 既知小計は不明生成の使用量を含まない。tokenを金額や計算時間へ換算しない。

ロードから終了まで、所有推論器の費用も残す

計測対象	実測値
推論器稼働秒	5,902.45
モデルロード秒（稼働時間に含む）	10.07
全条件の初期化・作業・後片付け秒	5,860.09
独立評価秒（稼働時間に含む）	13.17
推論器の最大実測RSS GiB	220.22
最大システムswap GiB	0.00

> 所有推論器の停止とPID不在を確認。重なる時間を二重加算しない。