状態保持型 LLM エージェントにおける情報保持と実行制御の評価

著者未設定

Evaluating Information Retention and Execution Control in Stateful LLM Agents

Author DETAILS PENDING,

DOI:10.14923/transj.???????????

あらまし　状態保持型 LLM エージェントの全 24 実行を解析した. 同一の公開出力が形式拒否された 14 生成と，構文が異なっても同じ API 要求列となった 4 課題 37 生成を確認した. 表示，実操作，最終成果を区別する必要性を示す.

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1. 問題設定と関連研究

状態保持型 LLM エージェントの費用を減らすには，操作と最終成果を損なわない制御が必要である．しかし，入力表現をそろえて出力が安定しても，有効な操作を提出できたとは限らない．CodeAct [1] 型のコード行動と AppWorld [2] を対象に，表現の一致と実操作の対応を調べる.

時間通知と期限強制 [3], 時間適応 [4], 数値的非決定性 [5]，ツール列・引数・出力の反復照合 [7]，ハーネス探索 [8]，実行形式 [9] と情報提示 [10]，出典記録 [6], ID 改名と正規化 [11] は既に扱われている．論理 token と実費用 [12]，cache と圧縮・遅延 [13], [14] も区別が必要である.

本稿は，不正呼出しの文章化で通信参照が通常文へ移る経路，保存 1 文脈の全 18 出力の実行，既知 4 課題 24 実行の全 426 生成の記録解析を結び付ける．一致した出力の形式拒否と，異なる構文から同じ実 API 要求列が生じる例を示す．正規化の新方式や一般的な高速化を提案するものではない.

2. 共通の履歴処理と通知

公開履歴と返却済み推論を h，呼出し ID と結果 ID の対応を保って初出順に統一する処理を C，表示処理を R とする．不正引数の呼出しを R が文章化した後では，構造上の参照欄だけの統一は文章内 ID を変更できない．共通履歴を $R(C(h))$ とし，通常文，引数，コード，観測，エラー，返却推論は変えず元記録を保持する．重複・欠落・孤立参照は拒否する．長い観測の先頭ページと参照先の表示も全条件で共通とする．これは通常の正規化順序の修正であり，品質維持の保証ではない.

仕事上限 $B = 1800$ 秒と，生成直前の実残時間を整数秒にした r を用いる．M は毎回 r を表示，H は非表示を通知，L は $2r > B$ なら H，それ以外は M とする．整数化により半分時点より 1 秒未満早く切り替わり得る．現在の通知だけを要求へ付け，履歴に蓄積せず，過去内容や進行中の生成は変更しない．実期限は全条件で単調時計から強制する．残 token・API・生成回数の表示は共通である.

全仕事の論理費用 $T = \sum_j (I_j + O_j)$ は全入力，出力，制御，失敗，回復，cache 入力を含む．cache 除外入力，出力，API 数，実時間は別に集計し，終端使用量の不明を 0 や別反復で補わない.

3. 比較の手順

3.1 通知比較と保存文脈の実行

写真移動，電気代精算，返金，曲情報書出しの既知 4 課題を M/H/L で 2 回ずつ初期化して実行する．全 24 条件で履歴処理は共通である．Mac Studio M3 Ultra・256 GiB，AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS，llama.cpp b11669 を用いる．入力枠 65,536，1 スロット，持続 Python，型付き API 返却，通常例外とし，温度 1.0，top-p 0.95，環境 seed42，モデル seed57 から生成ごとに 1 増やす．反復 1 の課題別順序は MHL/HLM/LMH/LHM，反復 2 は各組の逆順とする.

各条件 80 生成，450,000 論理 token，1,800 作業秒，写真 160・他 80 API を上限とする．出力上限は 4,096 と残予算の小さい方，通信待ちは 600 秒と残時間の小さい方である．初回は cache 再利用 0 を確認し，以後は通常の prefix cache を使う．最終状態を独立評価器で各 1 回判定し，基準・結果をモデルへ返さない．L の固定採用基準は，各反復で M/H それぞれに対し全件評価・使用量既知・監査一致，成功喪失 0，共通成功 1 課題以上，全 4 課題の論理費用減を満たすこととする．全 4 比較で成立を要求し，閾値探索や成功部分だけの選択はしない.

以前の M/H 反復を見た後，書出しで文章化 ID 差が初めて現れた保存文脈を選んだ．元入力 A/B，表示前統一 C/D，A の構造化参照だけを改名した N，診断文を足した X を固定する．token 列は C/D と A/N で一致し，A/B と A/X で異なる．各 3 回計 18 生成を seed70，温度 1，出力上限 4,096 で固定順に測る．全要求を cold 入力とし，元の warm 状態は再現しない．空出力，途中切れ，揺れ，欠測を除いて安定と判定し

表 1　全 24 条件の成否と論理入出力 token．不明生成を 0 へ置換せず，未評価・未実行も残す．

課題・反復	M	H	L
写真 1	成功 128,796	成功 135,628	成功 135,628
写真 2	未達 152,155	成功 135,628	成功 135,628
精算 1	成功 241,963	成功 211,110	成功 211,110
精算 2	成功 275,944	成功 211,110	成功 211,110
返金 1	成功 138,701	成功 102,087	成功 102,087
返金 2	成功 109,383	成功 102,087	成功 102,087
		未達 358,638	未達 348,419
書出し 1	未達 257,266	＋不明 1	＋不明 1
		未達 358,638	未達 346,789
書出し 2	未達 90,721	＋不明 1	＋不明 1

ない．

全 18 出力は新規環境で各 1 回，先行 12 コード・28 API の実要求・返答・標準出力・例外・schema を保存記録と照合後，通常実行口へ渡す．保存返答による代用や本文からのコード救済をしない．不一致・不明時は停止し補充しない．双方の提出と実行がなければ，空 API 列同士を有効操作の一致としない．元の DB・プロセス全体の復元ではない．

3.2　閉じた全 24 条件の記録解析

上の 24 実行の全生成を事後解析する．各課題 6 実行の全 15 組，計 60 組を生成序数で対応付け，片側終了後も残す．公開出力は本文・関数名・引数・終了理由，構文は位置情報だけを外した AST，実 API 列は送信 receipt を持つ全要求の名前・引数を比較する．認証値も保持し，JSON object のキー順・整形だけを統一する．全 Python 内 API 記録を外側の実行記録へ一度だけ対応付け，元監査の費用・欠測を照合する．生成前の API 要求・返答・例外・schema 列が同じ範囲も別集計するが，Python 変数や DB 全体の一致とはしない．両方空の API 列は非空要求の一致へ数えず，記録を読み直すだけでモデル・API・コード・評価を再実行しない．

4.　全仕事の結果

採用基準を満たした比較は 0/4 であり，両対照を両反復で上回るという固定基準は未達だった．条件を選び直した改善や，新手法の成立として扱わない．反復 1 の固定基準は M に対し未達，H に対し未達であった．反復 2 の固定基準は M に対し未達，H に対し未達であった．反復 1 の M/H/L の成功数は 3/4，3/4，3/4 であった．反復 2 の M/H/L の成功数は 2/4，3/4，3/4 であった．全 24 条件で 426 生成，既知 4,602,713 論理 token，使用量不明 4 生成，1156 API 送信を記録した．

表 2　2 反復全件の L と各対照との差．下限は欠測計数の非負性だけによる．時間は実測差である．

測定	L − M	L − H
論理 token	$\geq +197,929$	未確定
cache 除外入力	$\geq +19,977$	未確定
出力 token	$\geq +20,204$	未確定
作業秒	+1,702.316	+2.611

所有推論器の稼働は 16,263.578 秒，うち読込 10.061 秒，評価 41.470 秒であった．仕事ごとの準備・作業・後片付けの合計は 16,192.106 秒であり，これらは重なりを持つため加算しない．補助的な資源区間は本稿に含めず，欠測を含む全費用差を既知分だけから推定しない． M の反復間は全 4 対中 4 対が判定可能で，そのうち全要求一致は 0 対，全公開出力一致は 0 対であった．H の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L で最初に実測残時間を通知した生成番号は反復 1/2 の順で，課題 1 は未到達/未到達，課題 2 は未到達/未到達，課題 3 は未到達/未到達，課題 4 は 16/16 であった．同条件の反復間 12 対と，反復内の条件間 24 対を全て記録した．36 対は実行を共有しており，独立標本数ではない．一致数は判定可能な対に限り，欠測側を一致扱いしない． 保存ログからの狭い条件付き区間は，H の欠測 2 生成に正の生成進捗がなく前提不成立となった．欠測 4 件は残し，以下は公開レシートと非負性だけを使った事後集計である．L − M の論理 token 差は，成功同士 5 組では $-132,765$，失敗同士 2 組では $\geq +347,221$，成否不一致 1 組では $-16,527$ であった．各区分は同じ 4 課題の反復を含み，独立標本ではない．成功部分の減少を全仕事へ拡張せず，M の成功喪失も保持する．L − H は両側に欠測があるため既知部分の差を全費用差へ読み替えない．片側境界は信頼区間ではなく，GPU 演算量，消費電力，課金，因果的な高速化も測っていない． 補助的な事後照合として，旧 H の 3 反復と本群 H の 2 反復を全 4 課題で比べた 24 対を残した．成功 3 課題は全要求・公開出力列が一致し，書出しの全 6 対は最初の 13 生成が一致して 14 生成目で差があった．本群 H の書出し両反復の 14 生成目は保存統一入力 C/D と要求 JSON が一致したが，課題は両方未達だった．これは時期の異なる群の記録照合であり，正規化の有無を同時に割り付けた因果比較ではない．次出力診断では cache を無効化

表 3　一致数／比較可能対数．各 9 対は 3 出力ずつの組合せで，独立 9 課題ではない．—は双方ツール提出なし．

入力対	公開出力	コード構文	API 要求列	実行結果
A/B	0/9	0/9	0/9	0/9
A/N	9/9	9/9	9/9	9/9
A/X	0/9	0/9	9/9	0/9
C/D	9/9	—	—	—

表 4　構文が異なるが非空 API 列が同じ比較位置．右列は生成前の API 履歴も同じ範囲．組数は独立標本ではない．

課題	全対応	前史一致
写真移動	21	16
電気代精算	1	0
返金	10	2
曲情報書出し	1	1
全体	33	19

しており，本群の warm 状態の再現でもない．

5. 保存文脈の出力と実操作

全 6 入力で各 3 出力が完全・非空で安定し，全 18 生成は既知 422,475 論理 token，使用量不明 0，推論器稼働 4,386.052 秒だった．全 15 入力間比較と返却 message の不透明 hash を保持し，内部推論の意味内容は読まない．全 18 条件で先行履歴の照合が成立した．A/N/X の次操作はログインと曲・アルバム・プレイリスト一覧の各 4 API，B はログインと曲一覧の各 2 API だった．C/D の 6 出力は本文だけでツール提出がなく，通常の実行口は形式エラーを返した．A/B の構文差は実 API 要求の差を伴った．一方，A/X は構文が違っても引数を含む API 要求列は同じで，標準出力は各 521 文字と 488 文字だった．構文差は API 差と同義でなく，本文の一致も有効な操作の一致とは限らない．実行診断は再構成 504 ＋次 42 ＝ 546 API，228 コード，64.561853 秒を要した．追加生成・評価は 0，全所有資源を終了した．この再構成費を除いて削減率を作らず，局所操作の比較を課題成功へ広げない．

6. 全生成における表示と実要求

全 426 生成では，提出した全ツールの実行記録あり 397，提出なし 21，構造化提出後の未完了 4，出力不明 4 だった．397 には Python 通常例外を含み，課題成功数ではない．全 1,132 対応枠は両側記録 998，片側終了後 134 であった．公開出力は 992 比較中 441 一致，構文は 932 中 441 一致，非空 API 列は 861 中 446 一致だった．分母の違う一致率を指標の優劣にしない．同じ公開出力でも形式拒否された比較位置は 19 組で，全て CSV の 4 実行・14 生成に対応した．10 生成は提出なし，4 生成は引数 JSON が不正だった．全 19 組で生成前の API 履歴も同じだった．異なる構文・同じ非空 API 列の 33 組は，4 課題 16 実行 37 生成に対応した．前史も同じ 19 組は 3 課題 9 実行 26 生成だった．37 生成中 30 生成は Python 正常終了，7 生成は通常例外であり，同じ要求列を送信したことと正常完了を区別する．API 履歴の一致には初回の空 prefix も含む．全記録の解析は 2.940039 秒，追加生成・API・コード実行・評価 0 だった．

7. 考察と適用範囲

出力一致には実行口で拒否された生成が含まれ，構文差だけでは実 API 要求の差を判定できなかった．公開出力や構文の比較には，提出・実行状態と実要求を添える必要がある．API 列の一致自体も正常完了や正解を保証しない．既存研究が区別する行動再現性指標を新方式とせず，本実装での対応と失敗の具体的なデータとして位置付ける．

独立した課題は調整に用いた既知 4 つで，24 実行，60 組，生成数を独立課題数へ読み替えない．保存文脈は事後に選んだ 1 つで，全群解析もその観察後の二次解析である．入力・API 履歴の一致は完全な実行状態の復元でなく，同じ seed にも数値実行，cache，ホスト負荷の変動が残る．通知文の長さと情報の効果は分離していない．非表示は生成コードの時刻参照を禁じず，表示開始に至らない L も残す．参照統一は全条件共通なので，その因果的な品質効果は識別できない．局所 API 差を全仕事の削減にせず，未達・欠測と再構成費を残す．全条件と出典を公開する(注1)．

8. 結　　論

状態保持型 LLM エージェントの表現と実操作を，保存文脈の実行と全 24 実行の記録から評価した．公開出力が同じでも形式拒否された 14 生成と，構文が異なっても実 API 列が同じだった 4 課題 37 生成を確認した．通知比較の全 4 採用基準は未達だった．出力や構文の一致だけを有効操作や費用改善の代理にせず，実行状態，最終成果，失敗を含む総費用を分けて報告する必要がある．他課題への広がりと一般的な品質・費用改善，新方式の成立は未検証である．

文　　献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

(注1)：https://github.com/sophiria1225/AI-

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.
[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, “On the Clock: towards punctual and productive time-budgeted AI agents,” arXiv:2610.10833v1, 2026.
[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, “Timely Machine: awareness of time makes test-time scaling agentic,” Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.
[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W. Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, “Understanding and mitigating numerical sources of nondeterminism in LLM inference,” Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.
[6] P. Pattnayak and A. Bhatia, “ReproEvalCard: a reporting standard for reproducible evaluation of LLM pipelines,” Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.
[7] A. Yagubyan, “How consistent are LLM agents? Measuring behavioral reproducibility in multi-step tool-calling pipelines,” arXiv:2605.28840v1, 2026.
[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, “Beyond prompts: measuring and optimizing LLM tool-agent harnesses,” arXiv:2609.05736v1, 2026.
[9] R. Agarwal, “Measuring local SLM agents as systems: protocol effects on quality and resource use,” preprint, 2026, doi:10.5281/zenodo.21903714.
[10] K. Zhang, S. Chundur, J.P. Owusu, M.J. Abdolhosseini Qomi, and M. Raissi, “Same simulation, different evidence: where retrieved tool output costs LLM agents accuracy,” arXiv:2610.26836v1, 2026.
[11] A.J. Mercado and A. Lomuscio, “Formal verification of agentic systems over operational data,” arXiv:2608.03609v1, 2026.
[12] S. Weinberger and A. Hozez, “Token reduction is not cost reduction,” arXiv:2607.12161v5, 2026.
[13] Y. Song, “Cache-aware prompt compression: a two-tier cost model for LLM API caching,” arXiv:2607.15516v1, 2026.
[14] E. Lumer, F. Nizar, A. Jangiti, K. Frank, A. Gulati, M. Phadate, and V.K. Subbiah, “Don’t break the cache: an evaluation of prompt caching for long-horizon agentic tasks,” arXiv:2601.06007v2, 2026.

（xxxx 年 xx 月 xx 日受付）

Abstract We analyzed 24 recorded runs of a stateful LLM agent. Matching public outputs included 14 rejected generations; different syntax produced identical API requests in 37 generations across four known tasks. These observations distinguish output agreement, actual execution, and task outcomes without establishing general quality or cost improvements.

Key words LLM agents, harness engineering, state retention, time notices, cost evaluation