通常の提出設定を、課題全体の成果へつなげる

A：任意提出auto／R：必須提出required。推論専用上限−1、全出力上限は共通。

課題	A 初期入力token	R 初期入力token
写真移動	3,115	3,115
精算	3,104	3,104
返金	3,077	3,077
曲情報の書出し	3,123	3,123

新しい初期状態から各１回。初期要求差はtool_choiceの値だけ。入力長の差も実測する。

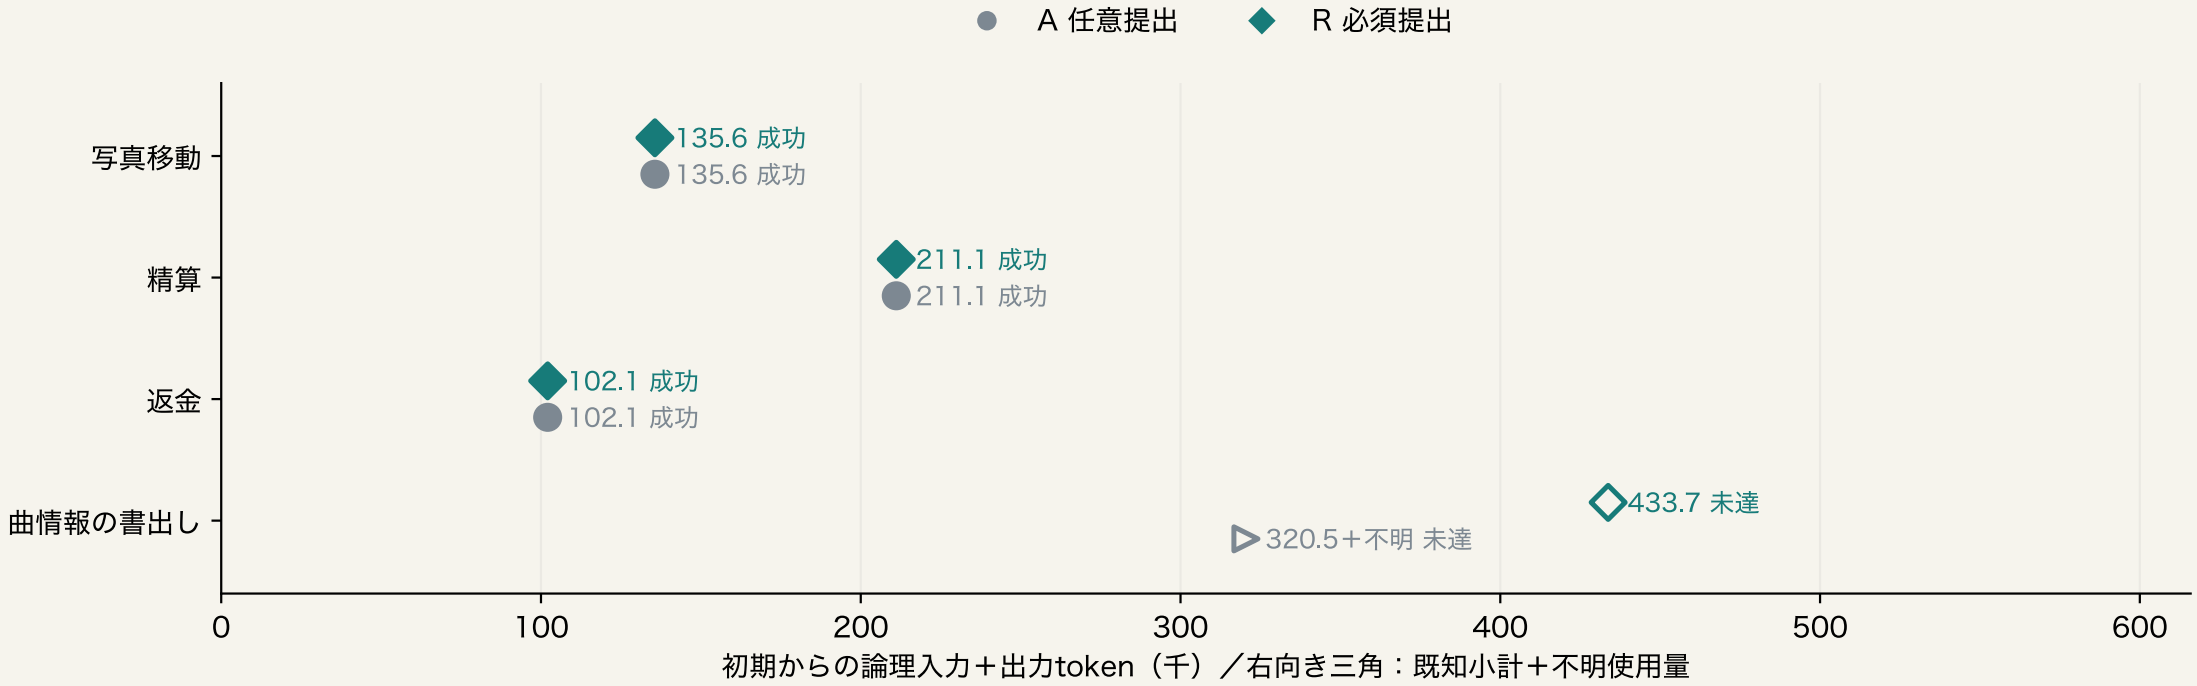
> 既知４課題の通常対照比較。過去の不明・未実行枠を補充したものではない。

全８条件の成否と、失敗を含む費用

課題	条件	成否	全仕事token	生成	API	作業秒
写真移動	A	成功	135,628	16	99	498.4
写真移動	R	成功	135,628	16	99	496.3
精算	R	成功	211,110	24	25	353.7
精算	A	成功	211,110	24	25	354.2
返金	A	成功	102,087	13	13	323.9
返金	R	成功	102,087	13	13	325.5
曲情報の書出し	R	未達	433,732	22	60	1,522.6
曲情報の書出し	A	未達	320,456＋不明1	20	42	1,799.8

> 未評価・未実行は失敗数へ入れず、使用量不明は０で補完しない。

同じ課題で、全仕事の費用と成功を比べる



> 塗りは成功。三角は不明費用が残る既知小計で、確定した総費用ではない。

採否は全４課題と、課題ごとの成功喪失で決める

条件	成功／評価	既知token合計	計測済み／予定
A 任意提出	3/4	769,281＋不明1	4/4
R 必須提出	3/4	882,557	4/4

全課題 R−A：未確定 token

成功喪失 0課題、成功獲得 0課題。

全８評価と使用量既知、監査一致、成功喪失０、両側成功１以上、全費用減が必要。

> 開発上の採用基準：未達。同数成功だけでは品質維持と判定しない。

成功した課題と、未達の課題の費用を分ける

成果の組合せ	課題数	R–A 全論理token
両側成功	3	未確定
両側未達	1	未確定
成否が異なる	0	未確定
片側以上が未評価	0	未確定

全４対の成否・費用差はCSVにも保存。欠測時は全体の寄与を未確定とする。

> 成功部分だけの削減と、失敗を含めた全仕事の削減を区別する。

cache、出力、呼出しを別の費用として残す

計測対象	A 任意提出	R 必須提出
既知の全入力token	737,825	853,963
既知入力のcache再利用	640,804	750,939
既知のcache除外入力	97,021	103,024
既知の出力token	31,456	28,594
生成試行	73	75
API要求	179	197
使用量不明の生成	1	0

> 既知小計は不明生成の使用量を含まない。tokenを金額や計算時間へ換算しない。

提出形式と実操作を、最終成果から区別する

計測対象	A 任意提出	R 必須提出
終端応答が既知の生成	72	75
終端応答が不明の生成	1	0
既知応答でツール提出なし	3	1
既知応答で出力上限に到達	2	2
実行口の形式拒否記録	4	2
Pythonの実行例外記録	11	12
提出後の未実行記録	0	0

> 形式が改善しても課題達成は未確認。全８条件の成否で判断する。

ロードから終了まで、所有推論器の費用も残す

計測対象	実測値
推論器稼働秒	5,739.32
モデルロード秒（稼働時間に含む）	10.06
全条件の初期化・作業・後片付け秒	5,698.73
独立評価秒（稼働時間に含む）	13.86
推論器の最大実測RSS GiB	220.29
最大システムswap GiB	0.00

> 所有推論器の停止とPID不在を確認。重なる時間を二重加算しない。