状態保持型 LLM エージェントにおける情報保持と実行制御の評価

著者未設定

Evaluating Information Retention and Execution Control in Stateful LLM Agents

Author DETAILS PENDING,

DOI:10.14923/transj.???????????

あらまし　状態保持型 LLM エージェントの残時間通知を既知 4 課題で比較する．欠測を保持した 3 反復では，非表示の論理 token 合計が条件付きで減る一方，cache を除く入力と出力は増えた．成否と指標別費用を全条件で評価する必要性を示す．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1. 問題設定と関連研究

必要な情報と最終品質を保って仕事全体の費用を減らすには，ハーネスがモデルへ渡す情報の役割を検証する必要がある．残時間のような制御情報は，同じ課題状態でも処理速度によって変わるため，同じ seed と実行上限だけでは判断入力が一致しない．本稿は，**実期限を共通にした残時間表示／非表示で，最終成否，失敗を含む全仕事費用，反復経路がどう変わるか**を調べる．

CodeAct [1] と AppWorld [2] を背景とし，ツール行動の反復一致 [7]，ハーネスの選択と費用 [8] にも先行研究がある．On the Clock [3] は時間通知と期限強制，予算遵守と生産的な時間使用を分け，Timely Machine [4] は推論・ツール遅延を考慮した適応を学習する．数値計算による非決定性 [5]，評価の記録要件 [6]，入力形式とライフサイクルによる品質・資源測定の変化 [9] も既出である．同じ計算結果の提示比較 [10] や，不透明な業務 ID の改名への感度と正規文脈を用いる構成 [11] も報告されている．本稿は通知，入力正規化，保存入力の対照比較を新アルゴリズムとはせず，局所反応と全仕事の指標差を区別した限定的な実証を対象とする．

2. 全仕事比較の方法

表示条件 M は実測残時間を整数秒で通知し，非表示条件 H は値を除いて非表示である旨を明示する．H は虚偽の時刻に置き換えず，token，API，生成回数の通知は共通とする．実行可否とタイムアウトは両側とも単調時計で判定し，表示の変更で期限を延長しない．

既知の写真移動，電気代精算，返金，曲情報書出しの 4 課題を，初期状態から M/H 各 3 回比較する．初回の全 8 条件 P80 を確認後，追加 16 条件 P81 を固定した．3 反復を初めから同時に事前登録した比較ではない．課題は過去の方式探索で閲覧・実行した開発課題であり，未調整群ではない．AppWorld 0.1.3.post1，MiniMax-M3 の IQ4_XS 量子化版，llama.cpp b11669 を使用した．推論有効，温度 1.0，top-p 0.95，型付き API 返却，通常 Python 例外，持続 Python，公開 API 名，初回からの返却推論保持を共通にする．環境 seed42 を固定し，モデル seed は初回 57 から生成ごとに 1 増やす．初回は課題順に M/H，H/M，M/H，H/M，2 回目は各組の逆順，3 回目は初回と同順とした．各条件 80 生成，450,000 論理 token，1,800 作業秒，API 上限は写真 160，他 80 とする．出力上限は 4,096 token と残予算の小さい方，通信待ちは 600 秒と残時間の小さい方である．各条件の初回は cold cache を実測確認し，後続は通常の prefix cache を使う．

構造上の tool-call/result ID は初出順に付け直し，対応を検査して入力を計数する．通常文，API 引数・返却，返却推論は置換せず，元履歴も保存する．ただし不正引数の呼出しを文章へ戻す経路内の ID は，この実験の正規化対象外であり，H でも入力差が残り得る．この対象は通信上の参照であり，業務 ID 全体の正規化 [11] とは異なる．

最終成否は独立評価器で各 1 回判定し，隠れた基準や評価結果をモデルへ返さない．全論理費用 $T = \sum_j (I_j + O_j)$ は初期からの入力 I_j と出力 O_j を加え，推論，制御情報，失敗，回復，cache 入力を含む．併せて cache を除く入力 $U = \sum_j (I_j - K_j)$，出力 $O = \sum_j O_j$，API，実時間を分けて示す．K_j は cache 入力であり，$U + O$ を GPU 計算量とはしない．送信後の使用量不明は未確認応答を実行せず，再試行もせずに保持する．期限後に使用量が届いた場合も計上し，期限外のコード実行は認めない．H の開発上の採用基準は全 8 条件の評価・全使用量既知・監査一致，課題ごとの成功喪失 0，全課題合計 T の減少とした．統計的な非劣性判定ではない．

3. 全条件の成否と費用

反復 1 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理 token は順に 787,092，780,394+?$_1$ だった．全費用差は使用量不明または未実行のため未確定である．開発上の採用基準は未達で，作業時間合計は M 1,897.7 秒，H 2,975.3 秒だった．反復 2 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理

表 1　全 24 条件の論理 token と成否．成：成功，否：未達．+?$_n$ は別に使用量不明が n 生成あることを示す．M：残時間表示，H：非表示．

課題	条件	反復 1（P80）	反復 2	反復 3
写真	M	177,373 成	210,357 成	164,024 成
写真	H	135,628 成	135,628 成	135,628 成
精算	M	284,294 成	215,182 成	263,695 成
精算	H	211,110 成	211,110 成	211,110 成
返金	M	216,854 成	138,701 成	73,670 成
返金	H	102,087 成	102,087 成	102,087 成
書出し	M	108,571 否	134,352 否	439,709 否
書出し	H	331,569+?$_1$ 否	319,348 否	324,014+?$_1$ 否

表 2　全 4 課題の H − M 費用差（論理 token）．反復 2 以外は順序対応と固定推論器の計数に基づく区間であり，統計的信頼区間ではない．元の不明生成は残す．

集計	H − M
反復 1	+32,959〜+34,925
反復 2	+69,581
反復 3	-127,288〜-123,560
合計	-24,748〜-19,054

token は順に 698,592，768,173 だった．H − M の合計差は +69,581 token である．開発上の採用基準は未達で，作業時間合計は M 1,991.5 秒，H 2,691.4 秒だった．反復 3 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理 token は順に 941,098，772,839+?$_1$ だった．全費用差は使用量不明または未実行のため未確定である．開発上の採用基準は未達で，作業時間合計は M 2,645.3 秒，H 2,975.6 秒だった．追加 P81 の推論器滞在は 10,405.1 秒，この内の評価時間は 26.82 秒だった．時間は重なるため合算しない．H の初回入力は全課題で M より 12 token 多い．全生成，API，cache，準備・作業・後片付けと評価の全件表を公開記録へ保存する． 事後の補助解析では，P80 と P81 の所有推論器の完全な直列ログを全 429 生成へ順序対応させた．既知 427 件すべてで，入力処理数＝終端入力 − cache 入力，生成数＝終端出力，送信前計数＝終端入力が一致した．不明要求 j について，同一送信の入力計数を $\widehat{I}_j$，ログに残った最大生成進捗を g_j，要求の出力上限を B_j とすると，固定推論器の計数・停止実装を前提に

$$\widehat{I}_j + g_j \le T_j \le \widehat{I}_j + B_j \qquad (1)$$

を得る．生成数は入力処理完了後に増加し，要求上限で停止する．全保存要求の hash と上限を照合し，別名による上書きがないことを確認した．不明 2 件の区間は順に 39,657〜41,623，40,971〜44,699 token である．この順序対応は既知 427 件の一致で裏付けられるが，要求 hash とサーバ task ID を暗号学的に結合したものではない．記録外の生成がないこと，入力計数と生成が同じ messages/tools を使うこと，固定実装どおりに処理されることを前提とする．終端使用量の補完ではなく，cache 入力と取消し後の処理を含む論理 token の範囲である．GPU 演算量，投機生成の未受理作業，料金や実時間の区間ではない． 3 反復合計では H が条件付きで 19,054〜24,748 token，約 0.79〜1.02% 少ない．ただし両条件で成功した 3 課題の減少 397,675 token に対し，両条件で失敗した書出し課題は 372,927〜378,621 token 増えている．反復ごとの全費用差も増加・増加・減少であり，安定した改善とはいえない．第 3 反復の書出し費用差は双方の未達で停止した差であり，完成に必要な費用の削減ではない．元の不明 2 件と採用基準未達は保持する． 論理 token の条件付き合計が H で小さくても，cache を除く入力と出力は既知分だけで M の完全合計を上回る．増加はそれぞれ少なくとも 7.09%，39.30% で，作業時間は実測 32.26% 長かった．入力処理と出力生成は異なる計算であり，token 数を FLOPs，電力量，料金へ換算しない．時間にはモデル待ち，通知，計数，API 等が含まれ，純粋な GPU 処理時間ではない．ホスト負荷と実行経路も異なるため，時間差を通知方式の因果的な速度差とはしない．両側成功部分では cache を除く入力が 24,280，出力が 9,537 token 減り，作業時間も 866.1 秒短かった．一方，失敗部分は既知分だけでそれぞれ 43,884，35,485 token 増え，作業時間は 2973.9 秒長く，成功部分の減少を上回った．P80/P81 の別セッションの推論器滞在は計 15,340.7 秒，ロード 20.12 秒，評価 40.42 秒だった．これらは重なる測定値であり合算しない．共通時間を M/H へ割り付けず，全件表に残す．

表 3　全 24 条件の資源・時間指標．H の token 欄は終端既知分の下限であり，不明 2 生成を 0 に補完していない．時間は実測合計．

指標	M	H
cache を除く入力	276,458	≥296,062
出力 token	66,022	≥91,970
作業時間（秒）	6,534.5	8,642.3
準備・後片付け込（秒）	6,570.7	8,679.0

4. 経路の照合と保存入力の診断

全 8 条件の 3 反復から得る全 24 対を照合した．返却された内部推論は hash のみ比較し，意味内容を解析していない．最初の要求差で現在の時計欄だけをそろえた照合は事後の診断であり，実際に同じ token 列を与えた証明ではない．要求列または公開出力列の完

表 4　全 8 条件の対比較．既知は両実行の全使用量が既知の対数／3．要求・出力は一致対数／判定対数．時計は最初の要求差が現在の時計欄だけだった観測対数．

課題	条件	既知	要求	公開出力	時計
写真	M	3/3	0/3	0/3	3
写真	H	3/3	3/3	3/3	0
精算	M	3/3	0/3	0/3	3
精算	H	3/3	3/3	3/3	0
返金	M	3/3	0/3	0/3	3
返金	H	3/3	3/3	3/3	0
書出し	M	3/3	0/3	0/3	3
書出し	H	0/3	未確定	未確定	0

全一致は，全使用量が既知で比較できた対について示す．不明生成を含む対の全体一致は未確定とし，判定できた接頭部だけを全体へ広げない．時計欄以外をそろえた照合は観測された最初の要求差だけに関する結果であり，出力変化や全仕事費用の原因を単独で決める証拠ではない．

先行する失敗通知比較で，介入前に実測残時間 1 秒だけが異なった 2 入力を選定した．各入力の他の項目を固定し，元値と＋1 秒を各 3 回，計 12 回 cold 生成したところ，同じ通知内は一致し，通知間では両入力の公開出力が異なった．不明使用量 0，99,966 論理 token で，生成コードの実行・課題評価は 0 だった．局所反応の確認であり，元の warm 状態や全仕事の因果効果は再現していない．

別の補助読取では，文章化参照の露出は全 429 要求の 20 要求で，H の書出し 3 反復だけ，各 14 生成目からだった．同じ履歴の再提示を含むため 20 独立事例ではない．露出のない M の書出し 3 反復も失敗しており，失敗全体の原因とはいえない．P80 と第 2 反復の該当 2 保存入力を固定テンプレートで再構成すると 22,669 対 22,667 token で，文章化前に参照を統一すると双方 22,650 となり全 token 列が一致した．通常の構造上の ID のみを変える対照も含む全 6 再構成を保存した．新しいモデル生成は 0 であり，次出力や品質・全費用への効果とは区別する．

5. 解釈と限界

M/H は初回から通知文が異なり，H は全課題で 12 token 長い．生成コードによる独自の時刻参照は禁止していない．同じ seed でも GPU 演算・cache 状態の変動は残り，最初の時計欄の差だけで後続の原因全体を決められない．独立した課題は既知 4 つで，24 条件を 24 課題とは扱わず，同じ実行を共有する対も独立標本とはしない．同じホストで編集と軽量解析を行っており，負荷を排他的に固定した速度比較ではない．出力列の一致は意味的同値や将来の再現保証ではなく，他課題・モデル・予算の品質維持や平均削減も主張しない．

同じ書出しには，過去の直接 API 型で 75 API, 370,343 token，1,075.6 秒の成功記録がある．設定と時期が異なるため同時対照ではないが，現在の未達を上限だけで説明したり，安い未達を必要品質の維持としたりはできない．本比較では，成功部分の費用減を失敗部分が相殺し，論理 token と cache を除く入力・出力・時間の方向も異なった．表示情報，実際の上限，最終成否と指標別の全仕事費用を対応させ，非表示を常に望ましい設計と結論しない．全条件と探索段階の先行結果を公開記録に残す(注1)．

文　献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, “On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents,” arXiv:2610.10833v1, 2026.

[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, “Timely Machine: Awareness of Time Makes Test-Time Scaling Agentic,” Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.

[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W. Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, “Understanding and Mitigating Numerical Sources of Nondeterminism in LLM Inference,” Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.

[6] P. Pattnayak and A. Bhatia, “ReproEvalCard: A Reporting Standard for Reproducible Evaluation of LLM Pipelines,” Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.

[7] A. Yagubyan, “How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines,” arXiv:2605.28840v1, 2026.

[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, “Beyond Prompts: Measuring and Optimizing LLM Tool-Agent Harnesses,” arXiv:2609.05736v1, 2026.

[9] R. Agarwal, “Measuring Local SLM Agents as Systems: Protocol Effects on Quality and Resource Use,” preprint, 2026, doi:10.5281/zenodo.21903714.

[10] K. Zhang, S. Chundur, J. P. Owusu, M. J. Abdolhosseini Qomi,

(注1)：https://github.com/sophiria1225/AI-

and M. Raissi, “Same Simulation, Different Evidence: Where Retrieved Tool Output Costs LLM Agents Accuracy,” arXiv:2610.26836v1, 2026.

[11] A. J. Mercado and A. Lomuscio, “Formal Verification of Agentic Systems over Operational Data,” arXiv:2608.03609v1, 2026.

（xxxx 年 xx 月 xx 日受付）

Abstract Across three repetitions of four known tasks, hiding remaining time slightly reduces conditional logical–token totals, while known uncached input and output increase and elapsed work takes longer. Retaining failed tasks and missing usage exposes disagreement among cost measures; these results do not establish a general efficiency improvement.

Key words LLM agents, harness engineering, state retention, remaining time feedback, cost evaluation