状態保持型エージェントの API 説明省略における仕事全体の費用と終了手続きの診断

検討用原稿・著者情報未設定

2026 年 10 月 23 日

あらまし　状態保持型エージェントの説明省略を既知４課題・２接続で比較し、入力短縮と総費用・成否の不一致を示す。完了通知による成否変化を診断した。別条件の通常終了制御は写真課題で成功を保ち費用を減らしたが、書出し課題では未達・削減なしだった。

キーワード　AI エージェント，API 説明，コンテキスト管理，費用評価

1　目的と検証する問い

AI エージェントの費用削減には，必要情報・処理と最終品質を保ち，取得・生成・実行・検証を含む全体を制御する必要がある．短い入力でも再取得や生成が増えれば費用は減らない [1, 2]．成功判定の差も，実作業の改善と終了手続きの違いを区別しない．本稿では，API の一覧と引数の詳細を別々に履歴から省き，**同じ途中状態からの表示省略が仕事全体費用と成否へどう影響し，成否差を実作業の改善と解釈できるか**を調べる．Python 状態・公開スキーマ・原文参照を保持するため，情報の完全消去とは異なる．同じ既知 4 課題・2 接続の全 24 表示条件と，保存状態への完了通知の介入を報告する．別条件の通常終了制御も点検し，全結果と不明費用を残す．

2　関連研究と本稿の範囲

Beyond Token Savings[1] は圧縮と成否・費用・停止理由を反復比較し，Liu[2] は再取得費用を分け，成否から相互作用費用を識別できない点も定式化する．短縮が総費用削減を保証しないという一般論は既出である．CodeAct[3] のコード行動，CaveAgent[4] の持続状態，HD-Gist[5] の API 引数・値の学習表現，Tool Search Tool[6] の定義展開，同一文書での段階的開示 [7] も関連する．

Zhang ら [8] は同じ科学計算済み状態から返却方式を変え，Matoi[9] は作用・方針・課題指標を分ける．状態を固定した段階別診断自体は既出である．ECT[10] は契約と記録を検証して終了し，AgentLoop[11] は要求充足・状態変化から反復を抑える．検証費用のハーネス依存性も報告されている [12]．本稿は取得済み説明の表示と，作業状態を変えない完了通知を具体的に照合する．手書きの既知要求による追加点検を新しい終了方式とせず，先行方式の再実装比較とも区別する．

3　費用の定義

仕事全体の論理トークンを

$$T_{\mathrm{work}} = T_{\mathrm{prefix}} + \sum_{j=1}^{n} (I_j + O_j) \tag{1}$$

とする．共通前半の実測値を条件ごとに一度加え，キャッシュ入力も I_j へ含める．継続だけの値も併記し，初回入力の削減量を全体の節約量へ転記しない．論理 token を請求額・計算量・時間へ換算しない．API，時間，実験用復元，評価，推論器のロード・常駐は別記する．評価器単独の時間は表示比較では未計測，完了診断では計測した．推論器の全稼働時間から継続・復元時間を引いた差は評価器の時間と同一ではない．

4　表示比較の方法

継続点の状態を会話履歴 H，Python 名前空間 P，操作先環境 E，残予算 $\mathcal{B}$，初期公開分を含む取得済み公開スキーマの集合 V とする．登録された全公開 API の集合を $\mathcal{A}$ とし，$V \subseteq \mathcal{A}$ である．文書取得必須の接続は V，公開名接続は $\mathcal{A}$ に属する API を呼び出せる．後者でも，未取得のスキーマや具体的な引数値を追加表示するわけではない．未登録名・未知の引数名はハーネスで拒否し，型・必須引数は元の API 側で検査する．認証，予算，完了後・作用不明後の停止も共通である．

全表示 F，古い詳細のみ省略 D，同じ詳細と古い一覧を省略 B を比較する．保存した公開 API 返却と表示処理から出自を照合できる区間のみを変更し，操作コード，リテラル，混合出力，エラー，最新応答を保持する．D/B で詳細の省略集合と印をそろえ，P, E, V と原文参照経路を維持する．表示省略は保存情報の消去や呼出し権限の縮小とは異なる．

既知 4 課題の第 8 応答後から各条件を 1 回ずつ実行す

る．文書取得必須 G（P55）の結果を保存し，公開名 N（P71）の比較を後に固定した．P71 では全 3 条件に同じ能力説明とツール説明を与え，前半の行動と返却は変更しない．前半は元の文書取得必須条件で生成されたもので，そのときの拒否も履歴へ残す．公開名接続を適用するのは継続部分であり，初期状態からの通常実行の比較ではない．各比較内で D 対 F と D 対 B を評価する．P55 と P71 の間では説明文と実行時点も異なるため，その差を呼出し制約だけの因果効果とはしない．両比較は同じ既知課題と前半を使い，独立した 8 課題の確認評価ではない．

各条件 16 生成，継続 120,000 token，480 秒を上限とし，全入力を計数して残予算内に出力枠を収める．初回入力はキャッシュを再利用しない．MiniMax-M3 の IQ4_XS 版と llama.cpp b11669 を用い, context 65,536, 温度 1.0，top-p 0.95，最大出力 4,096 とした．seed は 50 から生成ごとに 1 増やし，順序は課題ごとに FDB, DBF，BFD，FBD とする．API 上限は前半込みで写真 160，他 80 である．使用量不明の生成は実行も再試行もせず当該条件を終了し，作用・片付け・推論器の待機を確認できた場合だけ保存状態を評価して次へ進む．不明費用，未評価，未実行を補完しない．

両比較で Python 出力，公開返却，保存ファイルを継続前に照合するが，ヒープ・乱数状態の完全複製や生成の決定性は主張しない．返金 D/B は追加で省く一覧がなく基礎入力が同じである．残時間通知と数値実装の揺らぎは残るため，そこでの差を一覧保持の効果とはしない．

4.1 対象と入力の照合

AppWorld[13] の写真整理，電気代精算，返金，曲一覧の書出を用いる．過去の失敗と入力計数を見た後の方式探索であり，独立の確認評価ではない．未閲覧の 12 シナリオは使わず，有利な課題への交換もしない．D/B で詳細の省略対象は課題順に 7・2・3・7 返却と一致し，B が追加で省く一覧は 1・1・0・3 返却だった．表 1 に，共通の予算通知と省略印を含む初回入力の短縮量を示す．

表 1　D の初回入力短縮 token（対 F）

接続	写真	精算	返金	曲書出し
文書必須	1,447	258	782	1,629
公開名	1,447	258	782	1,629

4.2 採用基準と欠測

各接続の全 12 条件を評価し使用量が既知で監査に合格した場合に限り，D が F/B 双方の成功を失わず，合計 T_{work} が F より小さく B 以下なら，開発上の採用候補とする．一覧の追加価値を支持するには，入力の異なる課題で D 成功・B 失敗の対も必要とする．同数成功を統計的な非劣性とはみなさない．使用量不明はゼロや上限で埋めず，既知分と不明生成数を示す．不明がある対の正確な費用差は求めず，観測された既知分だけで判断できる範囲を記す．API 作用，復元，実行，片付け，評価，推論器版の不一致は全体を停止する．結果を見て seed・条件・予算を変更せず，未実行を成功や失敗に補完しない．

5　費用と成否の全結果

両接続とも全 12 条件を評価し，未評価・未実行は 0 だった．継続費用は G で既知 1,000,847 token ＋不明 1 生成，N で既知 950,398 token ＋不明 2 生成だった．G の D は既知分だけで F より 43,083 token 多かった．表 2 に両接続の全予定条件を示す．未達で早く止まった条件を効率のよい成功とは数えない．N の D は既知分だけでも F を 22,524 token 上回り，写真では F/B 成功に対し D が未達だった．D の写真・書出しは生成中の時間上限で使用量不明となった．

表 2　全 24 予定条件の成否・仕事 token

接続	課題	F	D	B
G	写真	未達 145,850	成功 120,935	未達 165,015
	精算	未達 163,918	未達 161,225	未達 154,720
	返金	成功 85,697	成功 117,223	成功 117,305
	書出	未達 117,100	未達 156,265+?	未達 126,734
N	写真	成功 156,754	未達 121,357+?	成功 129,261
	精算	未達 161,694	未達 162,725	未達 154,222
	返金	成功 85,975	成功 100,527	成功 100,527
	書出	未達 96,460	未達 138,798+?	未達 173,238

G：文書必須，N：公開名で継続．+? は別に使用量不明がある値．

5.1 入力短縮と仕事全体の費用

不明生成のため D 対 F/B の確定費用差は求めない．両比較とも D の既知費用が F を上回り，採用条件は未達だった．表 3 に合計を示す．G の D は初回入力が F より短いが，継続生成は 22 回から 26 回へ増えた．返金は両接続の F/D/B で成功したが，D の全体費用は F より大きかった．

表 3　全 4 課題合計の費用と実行量

指標	F	D	B
文書取得必須（P55）			
成功／評価	1/4	2/4	1/4
仕事・既知 token	512,565	555,648+?	563,774
継続・既知 token	302,185	345,268+?	353,394
継続生成／不明	22/0	26/1	29/0
継続／復元 API	173/51	162/51	122/51
公開名（P71）			
成功／評価	2/4	1/4	2/4
仕事・既知 token	500,883	523,407+?	557,248
継続・既知 token	290,503	313,027+?	346,868
継続生成／不明	21/0	25/2	27/0
継続／復元 API	204/51	138/51	148/51

継続 API は実際に送信した要求数であり，拒否され送信しなかった要求や原文参照は別に記録する．API 回数の減少だけで不要取得の削減とは判断せず，完了した処理と合わせて読む．G の推論器稼働全体は 4,112.859 秒だった．N は 3,724.097 秒で，継続 490・復元 153 API を送信した．説明公開前の呼出しは写真 B の公開時計 1 件だった．

6　成否差と終了手続きの診断

G の写真 F/D は各 42 移動で非 supervisor 保存ファイルが一致したが，公式成否は未達／成功，通知は 0／1 件だった．まず G の写真 F/B を別環境で再現し，元 D と同じ空引数の完了通知なし／1 回追加の 4 条件を固定した．次に N の全 12 条件のうち，成否によらず完了 API 未送信の全 7 状態（既知 3 課題）を選び，同じ 2 条件の計 14 ケースを固定した．N の通知は元写真 B で観測した `status="success"`だけとした．全ケースで送信済み公開 API の返却と介入前の全 13 保存ファイルを元状態と照合し，無介入は元の成否を再現した．

表 4　完了通知だけの介入（全 18 ケース）

再現した元状態	通知なし	通知 1 回
G 写真 F	未達	成功
G 写真 B	未達	未達
N 写真 D	未達	成功
N 精算 F	未達	未達
N 精算 D	未達	未達
N 精算 B	未達	未達
N 書出し F	未達	未達
N 書出し D	未達	未達
N 書出し B	未達	未達

G の写真 F と N の写真 D だけが未達から成功へ変わり，それぞれ元 G の D，元 N の B と最終 13 保存ファイルも一致した．非 supervisor 保存ファイルは全ケースで介入前後不変だった．残り 7 状態は通知後も未達で，完了宣言を一律に足す根拠にはならない．G の診断は 346 API・4 評価・23.927 秒（評価 8.541 秒），N は 702 再送＋7 通知＝ 709 API・14 評価・64.318 秒（評価 19.503 秒）だった．両診断とも生成 0 で，元の成否と不明費用は変更しない．N の不明 2 生成は最後の未実行応答に限り，全 API 作用が既知であることを別に照合した．同じ既知写真の事後診断であり，独立した別課題の追認ではない．G の写真では分類に必要な現在年の成功した公開時計応答がなく，通知による公式判定の変化は公開証拠だけで要求を全て検証できたことを意味しない．

7　公開証拠による通常終了制御の追加点検

同じ既知写真課題を初期状態から実行した別の通常対照を用いた．文書取得必須と，説明取得前も公開名を呼べる接続の各 1 条件である．各対照と同じモデル，seed，入力案内，予算から再実行し，生成応答内の全プログラムの実行後に，その時点までの公開記録を検査した．各 80 生成・450,000 token・1,800 秒・160 API を上限とし，検査結果の追加案内は与えない．元集合・移動前の日時・現在年・移動先・名前保持が全て支持されれば，通常の完了 API を 1 回送り終了する．不明時は通常継続し，未来応答や評価器は参照しない．

表 5　別条件の写真課題：全体 token

接続	通常終了	終了制御	減少率
文書取得必須	130,439	91,116	30.1%
公開名	151,664	112,233	26.0%

4 実行は全て公式成功で，制御条件では各 2 生成・4 API が少なかった．両接続とも対応する対照と最終 13 保存ファイルが同一で，制御時点までの公開 API 記録も一致した．ただし呼出し ID が異なり，要求・モデルメッセージ全文の一致という事前基準は不成立だった．

制御 2 条件の全 25 生成は 203,349 token，199 API，2 評価，使用量不明 0 だった．25 回の検査と記録ダイジェスト計算は合計 0.028224 秒で，全体時間にも含めた．減少 78,754 token のうち 66,720 は cached input であり，金銭・時間の同率削減ではない．別の既知書出し課題では，新しい通常ツール対照と同じ接続の終了制御を各 1 回比較した．各 80 生成・450,000 token・1,800 秒・80 API で，正しい CSV 作成後の退会までを公開記録に要求した．両条件とも 8 生成・219,126 token・80 API で上限に達し未達，書出し・退会は 0 回だった．制御の 8 検査は計 0.004080 秒で完了通知 0 回，費用削減も 0 だった．使用量不明 0，最終 13 保存ファイルは一致したが，呼出し ID による全文不一致は残った．これらは API の意味を信頼した既知文型の通常制御であり，

表 2・3 へ合算しない．実装・固定条件・全件集計を公開する[*1]．

8 解釈の限界

同じ既知 4 課題，単一モデル，各接続・表示条件 1 回の開発比較であり，追加診断は既知 3 課題の 9 状態への事後介入である．診断 18 ケースを独立 18 課題として数えない．seed と初回キャッシュ条件をそろえても，後続の実行経路の再現性は保証されない．返金 D/B の基礎入力は同じだが，後続の残時間通知などが異なるため，差を一覧の効果に帰属させない．

B でも過去コード等に API 名が残る（写真 8/26 名，精算 10/26 名）．名前の理解や情報の完全消去を測るものではなく，省略対象は出自の確かな古い説明に限る．

9 結論

両接続で，D の初回入力は短くても既知の仕事全体費用は F を上回った．写真の成否差と終了通知の関係，通常終了制御の写真での改善と書出しでの未達を示した．既知 4 課題の局所結果であり，必要情報と品質を守る制御には，仕事全体費用と作業・終了手続きへの作用を対応させた検証が必要である．

参考文献

[1] R. Satish, P. Sinha, A. Kawada, and N.J. Yadwadkar, “Beyond token savings: a systematic study of context compression in LLM agents,” arXiv:2609.32961v1, Sept. 2026.

[2] S. Liu, “What does context compression cost an agent? Interaction costs unrevealed by task-completion metrics,” arXiv:2608.16370v1, Aug. 2026.

[3] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[4] M. Ran, Z. Wan, C. Lin, Y. Zhang, H. Xin, H. Fan, Y. Xu, B. Luo, Y. Zhou, W. Zhao, L. Yang, L. Feng, F. Yang, J. Wu, Y. Huang, C. Ma, Y. Huang, D. Jiang, J. Deng, S. Han, Y. You, B. An, Y. Guo, and J. Song, “CaveAgent: transforming LLMs into stateful runtime operators,” arXiv:2601.01569v4, June 2026.

[5] Y. Jiang, M. Del Vecchio, M. Bansal, and A. Johannsen, “Hierarchical and dynamic prompt compression for efficient zero-shot API usage,” Findings of EACL, pp.2162–2174, St. Julian’s, Malta, March 2024.

[6] Anthropic, “Introducing advanced tool use on the Claude Developer Platform,” Nov. 24, 2025. https://www.anthropic.com/research/advanced-tool-use, accessed Oct. 23, 2026.

[7] Y. He, Y. Zhao, J. Wang, and H. Chen, “Is progressive disclosure all you need for long-context agents?,” arXiv:2607.17598v1, July 2026.

[8] K. Zhang, S. Chundur, J.P. Owusu, M.J. Abdolhosseini Qomi, and M. Raissi, “Same simulation, different evidence: where retrieved tool output costs LLM agents accuracy,” arXiv:2610.26836v1, Oct. 2026.

[9] Z. Wang, “Matoi: selective revalidation of consequence evidence for agent authorization,” arXiv:2610.21394v1, Oct. 2026.

[10] J. Liu, “When may an agent stop? Evidence-carrying termination for tool-using LLMs,” arXiv:2608.23623v1, Aug. 2026.

[11] W. Zheng, M. Xu, K. Hu, K. Ye, and C. Xu, “AgentLoop: runtime control of slot-closed execution loops for tool-augmented LLM agents,” arXiv:2609.33315v1, Sept. 2026.

[12] S. Weinberger and A. Hozez, “Prompt-induced waste in coding agents: reasoning, effort, harness design, and end-to-end cost,” arXiv:2608.01347v6, Sept. 2026.

[13] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[*1] https://github.com/sophiria1225/AI-

English abstract and keywords

Whole-Task Costs and Completion Diagnostics of API Documentation Omission in Stateful Agents

Abstract We compare API documentation omission on four known tasks under two continuation interfaces and diagnose whole-task costs and completion outcomes. In separate comparisons, public-evidence completion control reduces token use while preserving success on a photo task, but yields neither success nor savings on an export task. Results are exploratory.

Keywords AI agents, API documentation, context management, cost evaluation