状態保持型エージェントの API 説明省略における仕事全体の費用と終了手続きの診断

検討用原稿・著者情報未設定

2026 年 10 月 23 日

あらまし　状態保持型エージェントの説明省略を既知 4 課題・2 接続で比較し、入力短縮と総費用・成否の不一致を示す。完了通知による成否変化を診断した。別条件の通常終了制御は写真課題で成功を保ち費用を減らしたが、書出し課題では未達・削減なしだった。

キーワード　AI エージェント，API 説明，コンテキスト管理，費用評価

1　目的と検証する問い

AI エージェントの費用削減には，必要情報・処理と最終品質を保ち，取得・生成・実行・検証を含む全体を制御する必要がある．短い入力でも再取得や生成が増えれば費用は減らない [1, 2]．成功判定の差も，実作業の改善と終了手続きの違いを区別しない．本稿では，API の一覧と引数の詳細を別々に履歴から省き，**同じ途中状態からの表示省略が仕事全体費用と成否へどう影響し，成否差を実作業の改善と解釈できるか**を調べる．Python 状態・公開スキーマ・原文参照を保持するため，情報の完全消去とは異なる．同じ既知 4 課題・2 接続の全 24 表示条件と，写真の保存状態への完了通知の介入を報告する．別条件の通常終了制御も点検し，全結果と不明費用を残す．

2　関連研究と本稿の範囲

Beyond Token Savings[1] は圧縮と成否・費用・停止理由を反復比較し，Liu[2] は再取得費用を分け，成否から相互作用費用を識別できない点も定式化する．短縮が総費用削減を保証しないという一般論は既出である．CodeAct[3] のコード行動，CaveAgent[4] の持続状態，HD-Gist[5] の API 引数・値の学習表現，Tool Search Tool[6] の定義展開，同一文書での段階的開示 [7] も関連する．

Zhang ら [8] は同じ科学計算済み状態から返却方式を変え，Matoi[9] は作用・方針・課題指標を分ける．状態を固定した段階別診断自体は既出である．ECT[10] は契約と記録を検証して終了し，AgentLoop[11] は要求充足・状態変化から反復を抑える．検証費用のハーネス依存性も報告されている [12]．本稿は取得済み説明の表示と，作業状態を変えない完了通知を具体的に照合する．手書きの既知要求による追加点検を新しい終了方式とせず，先行方式の再実装比較とも区別する．

3　費用の定義

仕事全体の論理トークンを

$$T_{\mathrm{work}} = T_{\mathrm{prefix}} + \sum_{j=1}^{n} (I_j + O_j) \tag{1}$$

とする．共通前半の実測値を条件ごとに一度加え，キャッシュ入力も I_j へ含める．継続だけの値も併記し，初回入力の削減量を全体の節約量へ転記しない．論理 token を請求額・計算量・時間へ換算しない．API，時間，実験用復元，評価，推論器のロード・常駐は別記する．評価器単独の時間は表示比較では未計測，完了診断では計測した．推論器の全稼働時間から継続・復元時間を引いた差は評価器の時間と同一ではない．

4　表示比較の方法

継続点の状態を会話履歴 H，Python 名前空間 P，操作先環境 E，残予算 $\mathcal{B}$，初期公開分を含む取得済み公開スキーマの集合 V とする．登録された全公開 API の集合を $\mathcal{A}$ とし，$V \subseteq \mathcal{A}$ である．文書取得必須の接続は V，公開名接続は $\mathcal{A}$ に属する API を呼び出せる．後者でも，未取得のスキーマや具体的な引数値を追加表示するわけではない．未登録名・未知の引数名はハーネスで拒否し，型・必須引数は元の API 側で検査する．認証，予算，完了後・作用不明後の停止も共通である．

全表示 F，古い詳細のみ省略 D，同じ詳細と古い一覧を省略 B を比較する．保存した公開 API 返却と表示処理から出自を照合できる区間のみを変更し，操作コード，リテラル，混合出力，エラー，最新応答を保持する．D/B で詳細の省略集合と印をそろえ，P, E, V と原文参照経路を維持する．表示省略は保存情報の消去や呼出し権限の縮小とは異なる．

既知 4 課題の第 8 応答後から各条件を 1 回ずつ実行する．文書取得必須 G（P55）の結果を保存し，公開名 N（P71）の比較を後に固定した．P71 では全 3 条件に同じ能力説明とツール説明を与え，前半の行動と返却は変更しない．前半は元の文書取得必須条件で生成されたもので，そのときの拒否も履歴へ残す．公開名接続を適用するのは継続部分であり，初期状態からの通常実行の比較ではない．各比較内で D 対 F と D 対 B を評価する．P55 と P71 の間では説明文と実行時点も異なるため，その差を呼出し制約だけの因果効果とはしない．両比較は同じ既知課題と前半を使い，独立した 8 課題の確認評価ではない．

各条件 16 生成，継続 120,000 token，480 秒を上限とし，全入力を計数して残予算内に出力枠を収める．初回入力はキャッシュを再利用しない．MiniMax-M3 の IQ4_XS 版と llama.cpp b11669 を用い, context 65,536, 温度 1.0，top-p 0.95，最大出力 4,096 とした．seed は 50 から生成ごとに 1 増やし，順序は課題ごとに FDB, DBF，BFD，FBD とする．API 上限は前半込みで写真 160，他 80 である．使用量不明の生成は実行も再試行もせず当該条件を終了し，作用・片付け・推論器の待機を確認できた場合だけ保存状態を評価して次へ進む．不明費用，未評価，未実行を補完しない．

両比較で Python 出力，公開返却，保存ファイルを継続前に照合するが，ヒープ・乱数状態の完全複製や生成の決定性は主張しない．返金 D/B は追加で省く一覧がなく基礎入力が同じである．残時間通知と数値実装の揺らぎは残るため，そこでの差を一覧保持の効果とはしない．

4.1 対象と入力の照合

AppWorld[13] の写真整理，電気代精算，返金，曲一覧の書出を用いる．過去の失敗と入力計数を見た後の方式探索であり，独立の確認評価ではない．未閲覧の 12 シナリオは使わず，有利な課題への交換もしない．D/B で詳細の省略対象は課題順に 7・2・3・7 返却と一致し，B が追加で省く一覧は 1・1・0・3 返却だった．表 1 に，共通の予算通知と省略印を含む初回入力の短縮量を示す．

表 1　D の初回入力短縮 token（対 F）

接続	写真	精算	返金	曲書出し
文書必須	1,447	258	782	1,629
公開名	1,447	258	782	1,629

4.2 採用基準と欠測

各接続の全 12 条件を評価し使用量が既知で監査に合格した場合に限り，D が F/B 双方の成功を失わず，合計 T_{work} が F より小さく B 以下なら，開発上の採用候補とする．一覧の追加価値を支持するには，入力の異なる課題で D 成功・B 失敗の対も必要とする．同数成功を統計的な非劣性とはみなさない．使用量不明はゼロや上限で埋めず，既知分と不明生成数を示す．不明がある対の正確な費用差は求めず，観測された既知分だけで判断できる範囲を記す．API 作用，復元，実行，片付け，評価，推論器版の不一致は全体を停止する．結果を見て seed・条件・予算を変更せず，未実行を成功や失敗に補完しない．

5　費用と成否の全結果

両接続とも全 12 条件を評価し，未評価・未実行は 0 だった．継続費用は G で既知 1,000,847 token ＋不明 1 生成，N で既知 950,398 token ＋不明 2 生成だった．G の D は既知分だけで F より 43,083 token 多かった．表 2 に両接続の全予定条件を示す．未達で早く止まった条件を効率のよい成功とは数えない．N の D は既知分だけでも F を 22,524 token 上回り，写真では F/B 成功に対し D が未達だった．D の写真・書出しは生成中の時間上限で使用量不明となった．

表 2　全 24 予定条件の成否・仕事 token

接続	課題	F	D	B
G	写真	未達 145,850	成功 120,935	未達 165,015
	精算	未達 163,918	未達 161,225	未達 154,720
	返金	成功 85,697	成功 117,223	成功 117,305
	書出	未達 117,100	未達 156,265+?	未達 126,734
N	写真	成功 156,754	未達 121,357+?	成功 129,261
	精算	未達 161,694	未達 162,725	未達 154,222
	返金	成功 85,975	成功 100,527	成功 100,527
	書出	未達 96,460	未達 138,798+?	未達 173,238

G：文書必須，N：公開名で継続．+? は別に使用量不明がある値．

5.1 入力短縮と仕事全体の費用

不明生成のため D 対 F/B の確定費用差は求めない．両比較とも D の既知費用が F を上回り，採用条件は未達だった．表 3 に合計を示す．G の D は初回入力が F より短いが，継続生成は 22 回から 26 回へ増えた．返金は両接続の F/D/B で成功したが，D の全体費用は F より大きかった．

表 3　全 4 課題合計の費用と実行量

指標	F	D	B
文書取得必須（P55）			
成功／評価	1/4	2/4	1/4
仕事・既知 token	512,565	555,648+?	563,774
継続・既知 token	302,185	345,268+?	353,394
継続生成／不明	22/0	26/1	29/0
継続／復元 API	173/51	162/51	122/51
公開名（P71）			
成功／評価	2/4	1/4	2/4
仕事・既知 token	500,883	523,407+?	557,248
継続・既知 token	290,503	313,027+?	346,868
継続生成／不明	21/0	25/2	27/0
継続／復元 API	204/51	138/51	148/51

継続 API は実際に送信した要求数であり，拒否され送信しなかった要求や原文参照は別に記録する．API 回数の減少だけで不要取得の削減とは判断せず，完了した処理と合わせて読む．G の推論器稼働全体は 4,112.859 秒だった．N は 3,724.097 秒で，継続 490・復元 153 API を送信した．説明公開前の呼出しは写真 B の公開時計 1 件だった．

6　成否差と終了手続きの診断

G の写真整理の F/D は各 42 件の移動要求を送り，非 supervisor アプリの全保存ファイルが一致した．しかし公式成否は未達／成功で，完了通知の要求は 0 ／ 1 件だった．

完了通知だけを変えた追加診断．上の保存状態照合後，F/B の 2 状態を新しい模擬環境で再現し，完了 API のなし／1 回追加を固定 4 条件で比較した．送信済みの公開 API の返却と介入前 13 保存ファイルを全て照合し，既存 D と同じ空引数の通知だけを加えた．表 4 のとおり F は未達から成功へ変わり，その最終保存ファイルは元 D と全て一致した．B は通知後も未達だった．非 supervisor の保存ファイルは全条件で介入前後不変だった．

表 4　別環境の再現における終了手続きの介入

元状態	完了 API 追加	公式成否
F	なし	未達
F	1 回追加	成功
B	なし	未達
B	1 回追加	未達

再現 344 と介入 2 の計 346 API，独立評価 4 回，生成 0 で，全体 23.927 秒（評価 8.541 秒を含む）だった．これは既知 1 課題の事後診断であり，元の P55 成否・未知費用は変更しない．自動で完了を宣言してよい条件や，新たな自律エージェントの成功率は検証していない．この診断で，写真 F/D の成否差を写真整理そのものの改善と解釈する根拠はなくなる．一方，B は通知だけでは成功せず，完了宣言を一律に足せばよいともいえない．自動で通知を送るには，要求した仕事が済んだと判断する別の公開条件が必要である．実際，写真の F/D では 42 件の移動と名前保持を公開返却から照合できた一方，分類に必要な現在年の成功した時計応答は得られていなかった．完了通知による公式成否の変化は，公開証拠だけで要求を全て検証できたことを意味しない．

N の写真 D/B も非 supervisor 保存ファイルが一致し，通知 0 ／ 1 ，成否は未達／成功だった．N では通知追加の介入は行っていない．同じ既知写真課題での観測であり，独立した別課題の追認ではない．

7　公開証拠による通常終了制御の追加点検

同じ既知写真課題を初期状態から実行した別の通常対照を用いた．文書取得必須と，説明取得前も公開名を呼べる接続の各 1 条件である．各対照と同じモデル, seed, 入力案内，予算から再実行し，生成応答内の全プログラムの実行後に，その時点までの公開記録を検査した．各 80 生成・450,000 token・1,800 秒・160 API を上限とし，検査結果の追加案内は与えない．元集合・移動前の日時・現在年・移動先・名前保持が全て支持されれば，通常の完了 API を 1 回送り終了する．不明時は通常継続し，未来応答や評価器は参照しない．

表 5　別条件の写真課題：全体 token

接続	通常終了	終了制御	減少率
文書取得必須	130,439	91,116	30.1%
公開名	151,664	112,233	26.0%

4 実行は全て公式成功で，制御条件では各 2 生成・4 API が少なかった．両接続とも対応する対照と最終 13 保存ファイルが同一で，制御時点までの公開 API 記録も一致した．ただし呼出し ID が異なり，要求・モデルメッセージ全文の一致という事前基準は不成立だった．

制御 2 条件の全 25 生成は 203,349 token，199 API，2 評価，使用量不明 0 だった．25 回の検査と記録ダイジェスト計算は合計 0.028224 秒で，全体時間にも含めた．減少 78,754 token のうち 66,720 は cached input であり，金銭・時間の同率削減ではない．別の既知書出し課題では，新しい通常ツール対照と同じ接続の終了制御を各 1 回比較した．各 80 生成・450,000 token・1,800 秒・80 API で，正しい CSV 作成後の退会までを公開記録に要求した．両条件とも 8 生成・219,126 token・80 API で上限に達し未達，書出し・退会は 0 回だった．制御の 8 検査は計 0.004080 秒で完了通知 0 回，費用削減も 0 だった．使用量不明 0 ，最終 13 保存ファイルは一

致したが，呼出し ID による全文不一致は残った．これらは API の意味を信頼した既知文型の通常制御であり，表 2・3 へ合算しない．実装・固定条件・全件集計を公開する[*1]．

8 解釈の限界

同じ既知 4 課題，単一モデル，各接続・表示条件 1 回の開発比較であり，追加診断は同じ写真課題の事後介入である．診断 4 条件を独立 4 課題として数えない．seed と初回キャッシュ条件をそろえても，後続の実行経路の再現性は保証されない．返金 D/B の基礎入力は同じだが，後続の残時間通知などが異なるため，差を一覧の効果に帰属させない．

B でも過去コード等に API 名が残る（写真 8/26 名，精算 10/26 名）．名前の理解や情報の完全消去を測るものではなく，省略対象は出自の確かな古い説明に限る．

9 結論

両接続で，D の初回入力は短くても既知の仕事全体費用は F を上回った．写真の成否差と終了通知の関係，通常終了制御の写真での改善と書出しでの未達を示した．既知 4 課題の局所結果であり，必要情報と品質を守る制御には，仕事全体費用と作業・終了手続きへの作用を対応させた検証が必要である．

参考文献

[1] R. Satish, P. Sinha, A. Kawada, and N.J. Yadwadkar, “Beyond token savings: a systematic study of context compression in LLM agents,” arXiv:2609.32961v1, Sept. 2026.

[2] S. Liu, “What does context compression cost an agent? Interaction costs unrevealed by task-completion metrics,” arXiv:2608.16370v1, Aug. 2026.

[3] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[4] M. Ran, Z. Wan, C. Lin, Y. Zhang, H. Xin, H. Fan, Y. Xu, B. Luo, Y. Zhou, W. Zhao, L. Yang, L. Feng, F. Yang, J. Wu, Y. Huang, C. Ma, Y. Huang, D. Jiang, J. Deng, S. Han, Y. You, B. An, Y. Guo, and J. Song, “CaveAgent: transforming LLMs into stateful runtime operators,” arXiv:2601.01569v4, June 2026.

[5] Y. Jiang, M. Del Vecchio, M. Bansal, and A. Johannsen, “Hierarchical and dynamic prompt compression for efficient zero-shot API usage,” Findings of EACL, pp.2162–2174, St. Julian’s, Malta, March 2024.

[6] Anthropic, “Introducing advanced tool use on the Claude Developer Platform,” Nov. 24, 2025. https://www.anthropic.com/research/advanced-tool-use, accessed Oct. 23, 2026.

[7] Y. He, Y. Zhao, J. Wang, and H. Chen, “Is progressive disclosure all you need for long-context agents?,” arXiv:2607.17598v1, July 2026.

[8] K. Zhang, S. Chundur, J.P. Owusu, M.J. Abdolhosseini Qomi, and M. Raissi, “Same simulation, different evidence: where retrieved tool output costs LLM agents accuracy,” arXiv:2610.26836v1, Oct. 2026.

[9] Z. Wang, “Matoi: selective revalidation of consequence evidence for agent authorization,” arXiv:2610.21394v1, Oct. 2026.

[10] J. Liu, “When may an agent stop? Evidence-carrying termination for tool-using LLMs,” arXiv:2608.23623v1, Aug. 2026.

[11] W. Zheng, M. Xu, K. Hu, K. Ye, and C. Xu, “AgentLoop: runtime control of slot-closed execution loops for tool-augmented LLM agents,” arXiv:2609.33315v1, Sept. 2026.

[12] S. Weinberger and A. Hozez, “Prompt-induced waste in coding agents: reasoning, effort, harness design, and end-to-end cost,” arXiv:2608.01347v6, Sept. 2026.

[13] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[*1] https://github.com/sophiria1225/AI-

English abstract and keywords

Whole-Task Costs and Completion Diagnostics of API Documentation Omission in Stateful Agents

Abstract We compare API documentation omission on four known tasks under two continuation interfaces and diagnose whole-task costs and completion outcomes. In separate comparisons, public-evidence completion control reduces token use while preserving success on a photo task, but yields neither success nor savings on an export task. Results are exploratory.

Keywords AI agents, API documentation, context management, cost evaluation