持続する実行状態と入力省略の費用
AI ハーネスの開発比較から投稿の問いを絞る

検討用原稿・著者情報未設定

2026 年 10 月 22 日

原稿の位置づけ．本稿は監査済みの開発結果をつなぐ検討用原稿である．新しい制御方式の有効性，独立した研究上の貢献，公式書式への適合は未確定であり，このまま投稿できる完成稿ではない．

あらまし案．実行状態を残す出力省略を 4 開発課題で比較した．初回入力の短縮に対して継続総トークンが増える例を観測し，最終成否，停止理由，修復の適用範囲を分けて示す．

1　目的と投稿へ向けた問い

AI オーケストレーションでは，モデルへ渡す情報だけでなく，情報取得，生成，実行，検証を含む仕事全体を制御する必要がある．本研究の最終目標は，必要な情報と処理を残し，要求を満たす最終成果の品質を維持しながら，不要な取得・共有・AI 呼出し・実行・検証を減らすハーネス制御である．短い入力や少ない API 回数は，この目標の部分的な指標にすぎない．

今回の検討対象は単一作業役の継続である．同じ途中状態から表示だけを変えたとき，初回の短縮が終了までの費用へ届くか，届かない場合にどの費用と処理が残るかを調べる．複数担当間の通信削減や再編の効果を測ったものではない．また，過去に失敗した条件だけを除くことや，成功まで上限を増やすことは行わない．

2　関連研究と未確定の差

文献 [1] は圧縮の方式・時点・量を分け，総費用や時間，課題別成否を調べる．文献 [2] は状態の再取得と実行を分け，保持内容の介入も行う．したがって，圧縮後の費用増や同数成功だけでは不十分という一般論は，本研究の新しい発見として扱わない．

コードの状態を保持することも既存の機能である [3, 4]．本稿で区別するのは，会話中の表示，Python 内で利用可能な値，外部環境への作用という三つの層である．ただし層を分けただけでは独自の方式や知見は成立しない．投稿の中心にできるかは，既存の説明では足りない条件や効果を，適切な対照によって新たに確かめられるかに依存する．

3　費用と保持状態の定義

途中状態を，会話履歴 H，実行名前空間 P，操作先環境 E，残予算 B で記す．表示省略は H の一部を変える．P に値が残っていることと，モデルがその値の存在・用途を把握して使えることは同じではない．一方，使われた記録がないという理由だけで，その情報を不要とは判定しない．

継続の論理トークンを

$$T = \sum_{j=1}^{n} (I_j + O_j) \tag{1}$$

とする．キャッシュされた入力も I_j へ含む．実処理入力，出力，API，時間，制御・準備費用を別に記録する．共通前半は仕事全体の費用へ必要だが，分岐後の差とは分ける．実験のための状態復元を，運用時の AI 生成費用へ混ぜない．

4　同じ途中状態からの開発比較

AppWorld[6] の既知 4 課題について，持続 Python 基準の第 8 応答後を共通の分岐点とした．課題は写真整理，共有・依頼，返金，曲一覧の書出である．元の要求・返却，保存された境界，環境とプログラムの対応を照合し，状態復元費用を別記した．Python プロセスのヒープや乱数状態を丸ごと複製したという主張ではない．保留している 12 シナリオの要求文は，方式選定のために閲覧していない．

4.1　出力省略の比較（P33）

全表示 F，古い成功出力の省略 M，省略に変数・API 一覧を加える I を比較した．省略は分岐点で一度だけ行い，最新の完全な応答組，操作コード，エラー，停止・完了の記録を保つ．以後は通常どおり追記する．原記録は全条件で読み返せる．一覧は名前，基本型，長さ，公開 API 名を提示し，引数値の要約や未来の関連性判定を行わない．

同じモデル MiniMax-M3 IQ4_XS と継続 seed を用い，課題順に 3 条件の実行順を回転させた．継続上限は 16 生成，120,000 token，480 秒で，API 枠は共通前半を含めた元課題の上限とした．全 12 条件，各 1 試行の開発比較である．この実験は，後に導入した初回キャッシュ不使用の統一より前であり，同じ seed だけで生成経路の再現性を保証しない．

表 1　P33 の全 4 課題合計

指標	全表示	省略	一覧付
成功	2/4	2/4	2/4
初回入力	48,485	21,893	25,092
継続総 token	242,640	377,272	327,269
AI 呼出し	18	39	29
継続 API	162	133	150
実験用復元 API	51	51	51
処理入力 token	57,548	43,326	50,702
出力 token	8,752	11,138	11,686
継続時間 (s)	1,025.8	1,043.4	1,136.3

4.2　仕様表示と拒否返信の比較（P47）

P33 後の診断を受け，保存された表示処理と API 返却・出力全体の由来が一致する，古い仕様部分だけを選択表示の対象にした．全表示＋詳細契約 F，選択表示＋引数名 N，選択表示＋詳細契約 S の 3 条件を設けた．詳細契約を全表示側にも与え，片側だけの修復情報の追加を省略効果にしない．

返信対象は既公開 API で未知引数のため送信前に拒否された要求である．元の契約を改変せず返し，自動の引数修正や再送は行わない．未公開 API，送信済み，作用不明の要求は対象外とする．後続の生成・実行・修復も費用に含む．残予算通知，残量に応じた出力枠，初回キャッシュ不使用を全条件へそろえた．上限は P33 と同じだが，制御と表示規則が異なるため，P33 との結果の差を単一処理の因果効果へ変換しない．

4.3　品質と欠測の扱い

最終環境に対する独立評価で課題ごとの成否を記録する．開発上の採用基準は，対照の成功を失わず，既知の継続総 token を減らすこととした．少数で同数成功となっても統計的な非劣性ではない．使用量不明はゼロで補わず，事前規則で停止した場合は未評価と未実行を残す．安い未完了を効率のよい成功とは数えない．

5　全予定条件の結果

5.1　P33：初回入力と終了までの費用

全 12 条件を評価し，使用量不明は 0 だった．初回入力は短くなったが，継続総 token は M で 55.5%，I で 34.9% 増えた．全条件で同じ 2 課題が成功し，成功課題の入替えはなかった．一方，書出課題の F は API 上限，M と I は token 予約上限で終了しており，合計値だけで全表示が優れると一般化できない．

表 2　P33 の全 12 条件

課題	条件・成否	token	AI
写真整理	F・成功	66,851	5
	M・成功	63,575	6
	I・成功	87,160	8
共有・依頼	F・未達	110,922	9
	M・未達	110,906	12
	I・未達	109,531	9
返金	F・成功	31,680	2
	M・成功	98,106	12
	I・成功	27,808	4
曲一覧書出	F・未達	33,187	2
	M・未達	104,685	9
	I・未達	102,770	8

返金では F の 2 API に対し，M は仕様説明・相手の探索等を含む 8 API，I は 4 API だった．写真整理では M は F より低 token，I は高 token となった．一つの成功例や各課題の最良条件を，運用時に選べる制御規則とはみなさない．全体の API 減少にも，書出の未完了経路の違いが含まれる．

5.2　P47：契約返信を加えた比較

9 条件を評価した．書出 F の最後の生成が時間上限で使用量不明となり，事前規則に従って残る 2 条件を実行しなかった．全 66 生成の既知使用量 834,705 token に不明 1 呼出しが残る．継続 325 API と実験用復元 117 API を区別した．この結果を全 4 課題の完全な削減率へ変換しない．

表 3　P47 の全 12 予定条件

課題	条件・成否	token	AI
写真整理	F・成功	77,478	6
	N・未達	103,158	9
	S・未達	113,762	10
共有・依頼	F・未達	115,851	9
	N・未達	106,952	9
	S・未達	106,092	9
返金	F・成功	32,145	2
	N・成功	63,118	4
	S・成功	47,185	3
曲一覧書出	F・未評価	68,964+?	5
	N・未実行	—	—
	S・未実行	—	—

写真整理は F で成功し，N と S で未達だった．返金は 3 条件で成功したが，S も F より 15,040 token 多かった．全体で付加した 6 返信は次のモデル入力に存在し，次のプログラムで同じ API が送信された．ただし写真 S では適用対象の拒否がなく，契約返信は 0 件だった．返信の存在，同じ API の後続送信，最終成功を区別する必要がある．

6　制御規則へつなげる際の限界

6.1　費用の内訳は独立した介入効果ではない

初回入力を I，$G = \sum_j (I_j - I)$ とすると，$T = nI + G + \sum_j O_j$ である．初回入力の差，生成回数の差，後続入力の増減，出力の差へ恒等的に分けられるが，各項は独立した因果効果でも，そのまま回収できる節約量でもない．P33 の API 減少を再取得の解消と解釈することも，P47 の詳細返信後の生成を全て削減可能な修復費用とすることもできない．

6.2　小さい修復入力が適用できる範囲

P47 の 10 形式拒否を保存記録で点検した．値と既存引数を保持する部品では，空契約の通常正規化が 3 件，型上の完全な名前対応が 1 件，完全対応なしが 2 件，未公開 API が 4 件だった．介入前の P24 全 6 と P29 全 4 実行でも点検したところ，前者に形式拒否はなく，後者の 6 拒否に型上の名前対応 2 件があった．両群の課題は異なり，インターフェース間の因果比較ではない．

追加の 2 件はログイン API で，型上の行先が各 1 つだった．したがって全拒否を別 LLM へ送る前に，通常の正規化や決定的な対応付けを対照へ含める必要がある．唯一の型候補でも意味的な正解とは限らない．契約・拒否要求・エラーから API を限定して修復する通常方式 [5] との差を明確にし，辞退，通常継続への復帰，合流後の最終品質まで測る必要がある．これらの点検は生成・実行を伴わず，節約実績を示していない．

6.3　投稿の中心へ進むために必要な比較

本稿の開発結果は，実行状態を残した入力省略にも費用と品質の確認が必要であることを示す．しかし，既に知られた圧縮の注意点を超える貢献が確立したとは言えない．次の比較には，(i) 通常方式でも残る具体的な費用，(ii) 実行時に使える情報だけで必要処理を保つ判断規則，(iii) 同じ情報と予算を持つ強い対照，(iv) 規則が不要・有害となる条件をそろえる必要がある．

特に，状態が失われたための再取得と，保持された状態の利用方法を決める生成，新たに必要な情報取得を混同しない．確認群は機構・比較・予算・評価を固定してから使用する．12 シナリオで悪化 0 件を観測しても，一般的な品質維持の証明にはならない．単一モデル・既知 4 課題・各 1 回，P33 の初回推論状態，P47 の欠測，自作接続への依存は主張を制限する．

7　現在の結論

本検討では，品質を維持した総費用削減として採用できる出力省略方式は得られなかった．初回入力，総 token，API，時間，最終成否，停止理由を分けた全件記録を，次の具体的な制御規則と対照を選ぶ根拠にする．投稿の主張とあらましを確定する前に，独自の追加価値が残る比較が必要である．

参考文献

[1] R. Satish et al., “Beyond Token Savings: A Systematic Study of Context Compression in LLM Agents,” arXiv:2609.32961v1, 2026.

[2] S. Liu, “What Does Context Compression Cost an Agent? Interaction Costs Unrevealed by Task-Completion Metrics,” arXiv:2608.16370v1, 2026.

[3] X. Wang et al., “Executable Code Actions Elicit Better LLM Agents,” ICML, PMLR 235, pp.50208–50232, 2024.

[4] M. Ran et al., “CaveAgent: Transforming LLMs into Stateful Runtime Operators,” arXiv:2601.01569v4, 2026.

[5] A. Chattopadhyay et al., “Robust Function Calling for LLM Agents Under Interface Drift,” arXiv:2610.23342v1, 2026.

[6] H. Trivedi et al., “AppWorld: A Controllable World of Apps and People for Benchmarking Interactive Coding Agents,” ACL, pp.16022–16076, 2024.