状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの通知と参照表現を評価した．既知 4 課題 24 条件で全仕事費用の改善は示せなかった．保存 18 出力の実行検査では，公開出力，コード構文，API 要求の一致を区別する必要が確認された．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1　問題設定と関連研究

必要な情報と成果品質を保って仕事全体の費用を減らすには，取得済みの情報だけでなく，ハーネスが渡す制御情報と参照表現も検討する必要がある．実行速度で変わる残時間と，課題内容を表さない呼出し ID がモデル入力へ届く経路を調べ，入力をそろえる局所的な処理と全仕事の改善を区別する．対象は CodeAct[1] 型のコード行動と AppWorld[2] の状態を持つアプリ操作である．

時間通知と期限強制の分離 [3]，推論・道具遅延を使う時間適応 [4]，数値実行と多段経路の非決定性 [5, 7] には先行研究がある．ハーネス探索 [8]，実行形式の資源・品質への影響 [9]，同じ情報の提示方法 [10]，評価の出典記録 [6] も既出である．参照 ID の改名感度と正規化 [11]，token 削減と費用の不一致 [12]，cache と圧縮・遅延の相互作用 [13, 14] 自体を新規性とはしない．本稿の範囲は，既知課題で通知・参照表現の変化を入力，次出力，成否，全費用へ対応付ける限定した実証である．

2　共通の履歴処理と通知

公開履歴と返却済み推論を h とする．検証済みの呼出し ID と結果 ID の対応を保ち，初出順に統一する処理を C，モデル用の表示処理を R とする．不正引数を含む呼出しでは，R が呼出し記録を文章に変換する．この後で構造化された参照欄だけを統一しても，文章内の ID は変わらない．そこで共通履歴は $R(C(h))$ とする．C は通常文，引数，コード，観測，エラー，返却推論の値を変更せず，元記録を保持する．重複・欠落・対応のない参照は拒否する．R による長い観測の先頭ページと参照先の表示は全条件で共通とする．これは通常の正規化順序の修正であり，新しい正規化アルゴリズムや，任意の文章内 ID を消す処理ではない．

元の仕事上限を $B = 1800$ 秒，生成直前の実残時間を整数秒に切り捨てた値を r とする．M は毎回 r を表示し，H は非表示を通知する．L は $2r > B$ なら H，$2r \leq B$ なら M とする通常の後半表示である．整数化によって実際の半分時点より 1 秒未満早く切り替わり得る．要求には現在の通知を 1 件付け，通知自体を継続会話には蓄積しない．過去の生成内容・観測は書き換えず，進行中の生成へ通知を割り込ませない．実行可否とタイムアウトは，全条件で単調時計に基づく実期限から判定する．残 token・API 回数・生成回数の表示は共通とする．

全仕事の論理費用は $T = \sum_j (I_j + O_j)$ とし，全入力 I_j，出力 O_j，制御情報，失敗，回復，cache 入力を含める．cache を除く入力，出力，API 数，実時間は別に集計する．終端使用量の欠測は保持し，再試行や別反復で補完しない．前提を照合できる場合だけ保存数値ログから補助区間を求め，欠測を既知に変更しない．

3　比較の手順

3.1　全仕事の通知比較

写真移動，電気代精算，返金，曲情報書出しの既知 4 課題を初期状態から M/H/L で 2 回ずつ実行する．全 24 条件は履歴処理を共通とする新しい群であり，以前の条件を対照へ流用しない．Mac Studio M3 Ultra・256 GiB メモリ上で，AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS，llama.cpp b11669 を用いる．入力枠 65,536，1 スロット，持続 Python，型付き API 返却，通常例外を共通とする．温度 1.0，top-p 0.95，環境 seed42 を固定し，モデル seed は各条件の初回 57，以後生成ごとに 1 増やす．反復 1 の課題順は MHL/HLM/LMH/LHM，反復 2 は各組の逆順である．各条件 80 生成，450,000 論理 token，1,800 作業秒，写真 160・他 80 API を上限とする．出力上限は 4,096 と残予算の小さい方で，通信待ちは 600 秒と残実時間の小さい方とする．初回は cache 再利用 0 を確認し，後続は通常の prefix cache を使う．

独立評価器で最終状態を各 1 回判定し，その基準や結果をモデルへ返さない．L の採用基準は，各反復で M/H それぞれに対し，全件評価・使用量既知・監査一致，課題ごとの成功喪失 0，共通成功 1 課題以上，全 4 課題の論理費用減を満たすことである．全 4 比較での成立を要求し，閾値探索や成功部分だけの選択を行わない．これは開発上の相対基準であり，統計的な非劣性保証ではない．

3.2 保存入力の次出力比較

以前の M/H 比較の第 2 反復全 8 条件を調べた後，書出しの第 1・第 2 反復間で最初に文章化 ID 差が現れた保存文脈を選んだ．元入力 A/B，それぞれから表示前統一した C/D，A の構造化参照だけを変えた N，診断文を追加した X の 6 入力を固定する．入力 token 列は C/D で一致し，A/N でも一致するが，A/B と A/X は異なる．X の出力まで変わるとは仮定しない．各 3 回，計 18 生成を固定順で行い，seed70，温度 1，出力上限 4,096 を保持する．全要求で入力 cache を無効化し，元の warm 状態を再現したとはしない．この生成時にはコード・環境 API・課題評価を実行しない．

各入力内の 3 対と入力間の全 15 組を照合する．全 18 件の使用量が既知で，全 6 入力が完全・非空の公開出力として安定し，C/D と A/N が一致する場合だけ，A/B の公開出力差を判定する．ここで完全とは出力上限による終了でないことであり，構文の妥当性や実行可能性ではない．途中切れ，空出力，揺れ，欠測，未実行を除外して判定可能扱いしない．公開内容・関数名・引数の照合と，返却推論を含む message 全体の hash 照合を分ける．

3.3 保存出力の実行照合

全 18 出力を新規初期化した環境で各 1 回検査する．毎条件で先行 12 コードを同順に実行し，28 API の要求・実返答とコードの標準出力・例外を保存記録に照合する．保存返答による代用は行わず，不一致・結果不明時は停止し補充しない．照合後，保存した次出力を通常の実行口へ渡す．本文からコードを取り出す救済は行わない．公開出力，JSON 整形と位置情報を除いたコード構文，実 API 要求列，公開実行結果を区別する．API 列・実行結果の比較には双方のツール提出と実行を必要とし，空列同士を有効な操作一致としない．元の DB・プロセス全体の保存像はないため，同じ公開履歴を作った新規状態での局所比較である．

4 全仕事の結果

採用基準を満たした比較は 0/4 であり，両対照を両反復で上回るという固定基準は未達だった．条件を選び直した改善や，新手法の成立として扱わない．反復 1 の固定基準は M に対し未達，H に対し未達であった．反復 2 の固定基準は M に対し未達，H に対し未達であった．反復 1 の M/H/L の成功数は 3/4，3/4，3/4 であった．反復 2 の M/H/L の成功数は 2/4，3/4，3/4 であった．全 24 条件で 426 生成，既知 4,602,713 論理 token，使用量不明 4 生成，1156 API 送信を記録した．所有推論器の稼働は 16,263.578 秒，うち読込 10.061 秒，評価 41.470 秒であった．仕事ごとの準備・作業・後片付けの合計は 16,192.106 秒であり，これらは重なりを持つため加算しない．補助的な資源区間は本稿に含めず，欠測を含む全費用差を既知分だけから推定しない． M の反復間は全 4 対中 4 対が判定可能で，そのうち全要求一致は 0 対，全公開出力一致は 0 対であった．H の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L の反復間は全 4 対中 3 対が判定可能で，そのうち全要求一致は 3 対，全公開出力一致は 3 対であった．L で最初に実測残時間を通知した生成番号は反復 1/2 の順で，課題 1 は未到達/未到達，課題 2 は未到達/未到達，課題 3 は未到達/未到達，課題 4 は 16/16 であった．同条件の反復間 12 対と，反復内の条件間 24 対を全て記録した．36 対は実行を共有しており，独立標本数ではない．一致数は判定可能な対に限り，欠測側を一致扱いしない． 保存ログからの狭い条件付き区間は，H の欠測 2 生成に正の生成進捗がなく前提不成立となった．欠測 4 件は残し，以下は公開レシートと非負性だけを使った事後集計である．L − M の論理 token 差は，成功同士 5 組では $-132,765$，失敗同士 2 組では $\geq +347,221$，成否不一致 1 組では $-16,527$ で

表 1　全 24 条件の成否と論理入出力 token．不明生成を 0 へ置換せず，未評価・未実行も残す．

課題・反復	M	H	L
写真移動 1	成功 128,796	成功 135,628	成功 135,628
写真移動 2	未達 152,155	成功 135,628	成功 135,628
精算 1	成功 241,963	成功 211,110	成功 211,110
精算 2	成功 275,944	成功 211,110	成功 211,110
返金 1	成功 138,701	成功 102,087	成功 102,087
返金 2	成功 109,383	成功 102,087	成功 102,087
		未達 358,638	未達 348,419
曲情報の書出し 1	未達 257,266	＋不明 1	＋不明 1
		未達 358,638	未達 346,789
曲情報の書出し 2	未達 90,721	＋不明 1	＋不明 1

表 2　2 反復全件の L と各対照との差．下限は欠測計数の非負性だけによる．時間は実測差である．

測定	L − M	L − H
論理 token	$\geq +197,929$	未確定
cache 除外入力	$\geq +19,977$	未確定
出力 token	$\geq +20,204$	未確定
作業秒	+1,702.316	+2.611

表 3　一致数／比較可能対数．各 9 対は 3 出力ずつの組合せで，独立 9 課題ではない．—は双方ツール提出なし．

入力対	公開出力	コード構文	API 要求列	実行結果
A/B	0/9	0/9	0/9	0/9
A/N	9/9	9/9	9/9	9/9
A/X	0/9	0/9	9/9	0/9
C/D	9/9	—	—	—

あった．各区分は同じ 4 課題の反復を含み，独立標本ではない．成功部分の減少を全仕事へ拡張せず，M の成功喪失も保持する．L − H は両側に欠測があるため既知部分の差を全費用差へ読み替えない．片側境界は信頼区間ではなく，GPU 演算量，消費電力，課金，因果的な高速化も測っていない． 補助的な事後照合として，旧 H の 3 反復と本群 H の 2 反復を全 4 課題で比べた 24 対を残した．成功 3 課題は全要求・公開出力列が一致し，書出しの全 6 対は最初の 13 生成が一致して 14 生成目で差があった．本群 H の書出し両反復の 14 生成目は保存統一入力 C/D と要求 JSON が一致したが，課題は両方未達だった．これは時期の異なる群の記録照合であり，正規化の有無を同時に割り付けた因果比較ではない．次出力診断では cache を無効化しており，本群の warm 状態の再現でもない．

5　保存文脈の出力と実操作

全 6 入力で各 3 出力が完全・非空で安定し，全 18 生成は既知 422,475 論理 token，使用量不明 0，推論器稼働 4,386.052 秒だった．全 15 入力間比較と返却 message の不透明 hash を保持し，内部推論の意味内容は読まない．全 18 条件で先行履歴の照合が成立した．A/N/X の次操作はログインと曲・アルバム・プレイリスト一覧の各 4 API，B はログインと曲一覧の各 2 API だった．C/D の 6 出力は本文だけでツール提出がなく，通常の実行口は形式エラーを返した．A/B の構文差は実 API 要求の差を伴った．一方，A/X は構文が違っても引数を含む API 要求列は同じで，標準出力は各 521 文字と 488 文字だった．構文差は API 差と同義でなく，本文の一致も有効な操作の一致とは限らない．実行診断は再構成 504 ＋次 42 ＝ 546 API，228 コード，64.561853 秒を要した．追加生成・評価は 0，全所有資源を終了した．この再構成費を除いて削減率を作らず，局所操作の比較を課題成功へ広げない．

6　解釈の範囲

独立した課題は調整に用いた既知 4 つであり，24 実行や照合対数を独立課題数へ読み替えない．保存入力も事後に選んだ 1 文脈であり，6 独立課題ではない．同じ seed でも数値実行や cache の変動が残り，ホスト負荷も排他的に固定していない．通知文の長さと情報の効果は独立に識別していない．非表示は生成コードによる独自の時刻参照を禁じず，表示開始に至らない L 条件も残す．公開履歴の一致は元の完全状態・cache・残時間の復元ではない．次操作の 4 対 2 API を全仕事の削減とせず，追加の独立課題評価も行っていない．過去には別の通常 API 構成で書出しを達成した記録もあり，現在の未達を予算だけで説明できない．全条件，採用しなかった結果，補助区間の前提を公開記録に残す[*1]．

7　結論

後半通知は全 4 採用基準未達で，全仕事費用の改善として採用しない．1 保存文脈の診断では，統一入力の同一本文がツール提出を伴わず，異なる構文から同じ API 要求列が実行される場合もあった．出力・構文・実操作・課題成否を分けて評価する必要がある．既知 4 課題と 1 保存文脈から，一般的な品質維持や新規手法の有効性は結論できない．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, “On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents,” arXiv:2610.10833v1, 2026.

[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, “Timely Machine: Awareness of Time Makes Test-Time Scaling Agentic,” Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.

[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W.

[*1] https://github.com/sophiria1225/AI-

Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, "Understanding and Mitigating Numerical Sources of Nondeterminism in LLM Inference," Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.

[6] P. Pattnayak and A. Bhatia, "ReproEvalCard: A Reporting Standard for Reproducible Evaluation of LLM Pipelines," Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.

[7] A. Yagubyan, "How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines," arXiv:2605.28840v1, 2026.

[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, "Beyond Prompts: Measuring and Optimizing LLM Tool-Agent Harnesses," arXiv:2609.05736v1, 2026.

[9] R. Agarwal, "Measuring Local SLM Agents as Systems: Protocol Effects on Quality and Resource Use," preprint, 2026, doi:10.5281/zenodo.21903714.

[10] K. Zhang, S. Chundur, J. P. Owusu, M. J. Abdolhosseini Qomi, and M. Raissi, "Same Simulation, Different Evidence: Where Retrieved Tool Output Costs LLM Agents Accuracy," arXiv:2610.26836v1, 2026.

[11] A. J. Mercado and A. Lomuscio, "Formal Verification of Agentic Systems over Operational Data," arXiv:2608.03609v1, 2026.

[12] S. Weinberger and A. Hozez, "Token Reduction Is Not Cost Reduction," arXiv:2607.12161v5, 2026.

[13] Y. Song, "Cache-Aware Prompt Compression: A Two-Tier Cost Model for LLM API Caching," arXiv:2607.15516v1, 2026.

[14] E. Lumer, F. Nizar, A. Jangiti, K. Frank, A. Gulati, M. Phadate, and V. K. Subbiah, "Don't Break the Cache: An Evaluation of Prompt Caching for Long-Horizon Agentic Tasks," arXiv:2601.06007v2, 2026.

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Keywords LLM agents, harness engineering, state retention, time notices, cost evaluation

Summary draft We evaluated notices and references in stateful LLM agents. Late notices did not demonstrate whole-task cost improvement across 24 conditions. Testing saved outputs after matched public prefixes distinguished text agreement, code syntax, and API requests. Text agreement alone did not establish valid action agreement or task quality.