状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの全 24 実行を解析した．同一の公開出力が形式拒否された 14 生成と，構文が異なっても同じ API 要求列となった 4 課題 37 生成を確認した．表示，実操作，最終成果を区別する必要性を示す．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，実行再現性，費用評価

1　問題設定と関連研究

状態保持型 LLM エージェントのハーネスを評価する際，出力の安定性は実操作の再現性をどこまで表すか．必要な操作と最終成果を残した費用削減のため，CodeAct[1] 型のコード行動と AppWorld[2] で，公開出力，実行口での受理，実 API 列の対応を調べる．

時間制御 [3, 4]，数値的非決定性 [5]，行動段階別の反復照合 [7]，ハーネス探索 [8]，実行形式 [9]，情報提示 [10]，出典記録 [6]，ID 正規化 [11] には先行研究がある．論理 token と実費用 [12]，cache と圧縮・遅延 [13, 14] も同一ではない．

公開実装 smolagents にも接続 ID を履歴本文へ含む経路があり [15]，ID 欠落・重複による実行欠落や，ID 順と呼出し順の違いを扱う既存修正がある [16]．本稿ではこれらを新方式とせず，保存 1 文脈の全 18 出力の実行と，既知 4 課題 24 実行の全 426 生成の事後解析を結び付ける．一致出力の形式拒否と，異なる構文から同じ実 API 要求が生じる事例を示し，通常の提出設定による全仕事比較も併記する．

2　共通の履歴処理と通知

公開履歴と返却済み推論を h，呼出し ID と結果 ID の対応を保って初出順に統一する処理を C，表示処理を R とする．不正引数の呼出しを R が文章化した後では，構造上の参照欄だけの統一は文章内 ID を変更できない．共通履歴を $R(C(h))$ とし，通常文，引数，コード，観測，エラー，返却推論は変えず元記録を保持する．重複・欠落・孤立参照は拒否する．長い観測の先頭ページと参照先の表示も全条件で共通とする．これは通常の正規化順序の修正であり，品質維持の保証ではない．

仕事上限 $B = 1800$ 秒と，生成直前の実残時間を整数秒にした r を用いる．M は毎回 r を表示，H は非表示を通知，L は $2r > B$ なら H，それ以外は M とする．整数化により半分時点より 1 秒未満早く切り替わり得る．現在の通知だけを要求へ付け，履歴に蓄積せず，過去内容や進行中の生成は変更しない．実期限は全条件で単調時計から強制する．残 token・API・生成回数の表示は共通である．

全仕事の論理費用 $T = \sum_j (I_j + O_j)$ は全入力，出力，制御，失敗，回復，cache 入力を含む．cache 除外入力，出力，API 数，実時間は別に集計し，終端使用量の不明を 0 や別反復で補わない．

3　比較の手順

3.1　通知比較と保存文脈の実行

写真移動，電気代精算，返金，曲情報書出しの既知 4 課題を M/H/L で各 2 回実行する．Mac Studio M3 Ultra・256 GiB, AppWorld 0.1.3.post1, MiniMax-M3 IQ4_XS, llama.cpp b11669 を用いる．入力枠 65,536，1 スロット，持続 Python，型付き API 返却，温度 1.0，top-p 0.95，環境 seed42，モデル seed57 から生成ごとに 1 増加とする．課題別順序は反復 1 が MHL/HLM/LMH/LHM，反復 2 がその逆順である．

各条件 80 生成，450,000 論理 token，1,800 作業秒，写真 160・他 80 API を上限とする．出力上限は 4,096 と残予算，通信待ちは 600 秒と残時間の小さい方である．初回 cache 再利用 0 を確認し，以後は通常の prefix cache を使う．最終状態を独立評価器で各 1 回判定し，基準・結果をモデルへ返さない．L の採用には，両反復で M/H の各対照に対し全件評価・使用量既知・監査一致，成功喪失 0，共通成功 1 課題以上，全 4 課題の論理費用減を要求する．全 4 比較の成立を条件とし，成功部分だけを選ばない．

以前の M/H 反復を見た後，書出しで文章化 ID 差が初めて現れた保存文脈を選んだ．元入力 A/B，表示前統一 C/D，A の構造化参照だけを改名した N，診断文を

表 1　全 24 条件の成否と論理入出力 token．不明生成を 0 へ置換せず，未評価・未実行も残す．

課題・反復	M	H	L
写真移動 1	成功 128,796	成功 135,628	成功 135,628
写真移動 2	未達 152,155	成功 135,628	成功 135,628
精算 1	成功 241,963	成功 211,110	成功 211,110
精算 2	成功 275,944	成功 211,110	成功 211,110
返金 1	成功 138,701	成功 102,087	成功 102,087
返金 2	成功 109,383	成功 102,087	成功 102,087
		未達 358,638	未達 348,419
曲情報の書出し 1	未達 257,266	＋不明 1	＋不明 1
		未達 358,638	未達 346,789
曲情報の書出し 2	未達 90,721	＋不明 1	＋不明 1

足した X を固定した．token 列は C/D と A/N で同じ，A/B と A/X で異なる．各 3 回計 18 生成を seed70，温度 1，出力上限 4,096 の固定順で測る．全要求 cold 入力で元の warm 状態は再現しない．空出力，途中切れ，揺れ，欠測を除いて安定と判定しない．

全 18 出力を新規環境で各 1 回，先行 12 コード・28 API の実要求・返答・標準出力・例外・schema を照合後，通常実行口へ渡す．保存返答による代用や本文からのコード救済をしない．不一致・不明時は停止し補充しない．双方の提出・実行がなければ空 API 列同士を有効操作の一致としない．元の DB・プロセス全体の復元ではない．

3.2　全 24 条件の記録解析と通常設定の対照

全 426 生成を事後解析する．各課題 6 実行の全 15 組，計 60 組を生成序数で対応付け，片側終了後も残す．公開出力は本文・関数名・引数・終了理由，構文は位置情報だけを外した AST，実 API 列は送信 receipt がある全要求の名前・引数を比較する．認証値は保持し，JSON object のキー順・整形だけを統一する．Python 内 API を外側の実行記録へ一度だけ対応付け，費用・欠測を元監査と照合する．生成前の API 要求・返答・例外・schema 列が同じ範囲も別集計する．両方空の API 列を非空要求の一致に含めず，再生成・再実行・再評価はしない．

補助対照では同じ既知 4 課題を通常の `tool_choice=auto/required` で各 1 回，計 8 条件実行した．初期履歴，推論設定，seed，予算と評価をそろえ，課題順は同じで，設定順は auto/required，逆順，順方向，逆順とした．表示設定は H，反復回復通知は付けない．条件・順序・採用基準を生成前に固定し，全 4 課題の成功喪失なく論理費用が減ることを求めた．保存文脈の次出力だけの介入とは別の全仕事比較である．

表 2　2 反復全件の L と各対照との差．下限は欠測計数の非負性だけによる．時間は実測差である．

測定	L − M	L − H
論理 token	$\geq +197,929$	未確定
cache 除外入力	$\geq +19,977$	未確定
出力 token	$\geq +20,204$	未確定
作業秒	+1,702.316	+2.611

表 3　一致数／比較可能対数．各 9 対は 3 出力ずつの組合せで，独立 9 課題ではない．—は双方ツール提出なし．

入力対	公開出力	コード構文	API 要求列	実行結果
A/B	0/9	0/9	0/9	0/9
A/N	9/9	9/9	9/9	9/9
A/X	0/9	0/9	9/9	0/9
C/D	9/9	—	—	—

4　全仕事の結果

採用基準を満たした比較は 0/4 であり，両対照を両反復で上回るという固定基準は未達だった．条件を選び直した改善や，新手法の成立として扱わない．反復 1 の固定基準は M に対し未達，H に対し未達であった．反復 2 の固定基準は M に対し未達，H に対し未達であった．反復 1 の M/H/L の成功数は 3/4，3/4，3/4 であった．反復 2 の M/H/L の成功数は 2/4，3/4，3/4 であった．全 24 条件で 426 生成，既知 4,602,713 論理 token，使用量不明 4 生成，1156 API 送信を記録した．所有推論器の稼働は 16,263.578 秒，うち読込 10.061 秒，評価 41.470 秒であった．仕事ごとの準備・作業・後片付けの合計は 16,192.106 秒であり，これらは重なりを持つため加算しない．補助的な資源区間は本稿に含めず，欠測を含む全費用差を既知分だけから推定しない． 保存ログからの狭い条件付き区間は，H の欠測 2 生成に正の生成進捗がなく前提不成立となった．欠測 4 件は残し，以下は公開レシートと非負性だけを使った事後集計である．L − M の論理 token 差は，成功同士 5 組では $-132,765$，失敗同士 2 組では $\geq +347,221$，成否不一致 1 組では $-16,527$ であった．各区分は同じ 4 課題の反復を含み，独立標本ではない．成功部分の減少を全仕事へ拡張せず，M の成功喪失も保持する．L − H は両側に欠測があるため既知部分の差を全費用差へ読み替えない．片側境界は信頼区間ではなく，GPU 演算量，消費電力，課金，因果的な高速化も測っていない．

5　保存文脈の出力と実操作

全 6 入力で各 3 出力が完全・非空で安定し，全 18 生成は既知 422,475 論理 token，使用量不明 0，推論器稼働 4,386.052 秒だった．全 15 入力間比較と返却 message

表 4　構文が異なるが非空 API 列が同じ比較位置．右列は生成前の API 履歴も同じ範囲．組数は独立標本ではない．

課題	全対応	前史一致
写真移動	21	16
電気代精算	1	0
返金	10	2
曲情報書出し	1	1
全体	33	19

の不透明 hash を保持し，内部推論の意味内容は読まない．全 18 条件で先行履歴の照合が成立した．A/N/X の次操作はログインと曲・アルバム・プレイリスト一覧の各 4 API，B はログインと曲一覧の各 2 API だった．C/D の 6 出力は本文だけでツール提出がなく，通常の実行口は形式エラーを返した．A/B の構文差は実 API 要求の差を伴った．一方，A/X は構文が違っても引数を含む API 要求列は同じで，標準出力は各 521 文字と 488 文字だった．構文差は API 差と同義でなく，本文の一致も有効な操作の一致とは限らない．実行診断は再構成 504 ＋次 42 ＝ 546 API，228 コード，64.561853 秒を要した．追加生成・評価は 0，全所有資源を終了した．この再構成費を除いて削減率を作らず，局所操作の比較を課題成功へ広げない．

6　全生成における表示と実要求

全 426 生成では，提出した全ツールの実行記録あり 397，提出なし 21，構造化提出後の未完了 4，出力不明 4 だった．397 には Python 通常例外を含み，課題成功数ではない．全 1,132 対応枠は両側記録 998，片側終了後 134 であった．公開出力は 992 比較中 441 一致，構文は 932 中 441 一致，非空 API 列は 861 中 446 一致だった．分母の違う一致率を指標の優劣にしない．同じ公開出力でも形式拒否された比較位置は 19 組で，全て CSV の 4 実行・14 生成に対応した．10 生成は提出なし，4 生成は引数 JSON が不正だった．全 19 組で生成前の API 履歴も同じだった．異なる構文・同じ非空 API 列の 33 組は，4 課題 16 実行 37 生成に対応した．前史も同じ 19 組は 3 課題 9 実行 26 生成だった．37 生成中 30 生成は Python 正常終了，7 生成は通常例外であり，同じ要求列を送信したことと正常完了を区別する．API 履歴の一致には初回の空 prefix も含む．全記録の解析は 2.940039 秒，追加生成・API・コード実行・評価 0 だった．

7　通常の提出設定による全仕事比較

成功した写真・精算・返金の各対は費用差 0 で，両設定とも合計 448,825 論理 token だった．書出しは両方

表 5　通常設定の全 4 課題．全 8 条件を評価済み．+? は既知小計に使用量不明 1 生成が残ることを示す．

設定	成功	論理 token	生成試行	API
auto	3/4	769,281+?	73	179
required	3/4	882,557	75	197

未達で，auto は作業期限中の生成に使用量不明 1 件，required は token 予約上限で停止した．全仕事費用差は未確定，採用基準は未達である．全 148 生成試行，既知 1,651,838 論理 token，376 API，8 評価を残した．作業秒は auto 2,976.265，required 2,698.152，所有推論器 5,739.315 秒，条件の準備・作業・後片付け 5,698.734 秒だった．重なる時間は加算せず，未達の早い終了を品質維持や高速化とはしない．

8　考察と適用範囲

出力一致には形式拒否が含まれ，構文差だけでは実 API 要求の差を判定できなかった．提出・実行状態と実要求を添えることが有用だが，API 列一致自体も正常完了や正解を保証しない．通常の必須提出も今回の CSV 課題を成功させなかった．ただし異なる軌跡を持つ全仕事比較から，個々の形式拒否を必須提出が必ず防げる／防げないとはいえない．

独立した課題は調整に用いた既知 4 つで，追加対照も同じ課題である．24 実行，60 組，生成数を独立課題数に読み替えない．保存文脈は事後選定した 1 つ，全群解析も二次解析である．API 履歴一致は全状態の復元でなく，同じ seed にも数値実行，cache，ホスト負荷の変動が残る．通知の長さと情報効果は分離していない．H はコードの時刻参照を禁じず，表示開始に至らない L も残す．参照統一は全条件共通で，その品質効果は識別できない．外部公開コードは経路と既存修正の読取確認で，外部モデルの性能追試ではない．全条件・補助的な反復照合・資源記録・固定版の出典を公開する[*1]．

9　結論

状態保持型 LLM エージェントの保存文脈と全 24 実行から，公開出力が同じでも形式拒否された 14 生成と，構文が異なっても実 API 列が同じだった 4 課題 37 生成を確認した．通常設定の追加 8 条件でも成功獲得はなく，全仕事費用の改善は確認できなかった．出力・構文の一致に実行状態と実要求を添え，最終成果と失敗を含む総費用を分けて評価する．未知課題への広がり，新手法，一般的な品質・費用改善は未確立である．

[*1] https://github.com/sophiria1225/AI-

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, "Executable code actions elicit better LLM agents," Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, "AppWorld: a controllable world of apps and people for benchmarking interactive coding agents," Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, "On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents," arXiv:2610.10833v1, 2026.

[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, "Timely Machine: Awareness of Time Makes Test-Time Scaling Agentic," Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.

[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W. Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, "Understanding and Mitigating Numerical Sources of Nondeterminism in LLM Inference," Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.

[6] P. Pattnayak and A. Bhatia, "ReproEvalCard: A Reporting Standard for Reproducible Evaluation of LLM Pipelines," Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.

[7] A. Yagubyan, "How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines," arXiv:2605.28840v1, 2026.

[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, "Beyond Prompts: Measuring and Optimizing LLM Tool-Agent Harnesses," arXiv:2609.05736v1, 2026.

[9] R. Agarwal, "Measuring Local SLM Agents as Systems: Protocol Effects on Quality and Resource Use," preprint, 2026, doi:10.5281/zenodo.21903714.

[10] K. Zhang, S. Chundur, J. P. Owusu, M. J. Abdolhosseini Qomi, and M. Raissi, "Same Simulation, Different Evidence: Where Retrieved Tool Output Costs LLM Agents Accuracy," arXiv:2610.26836v1, 2026.

[11] A. J. Mercado and A. Lomuscio, "Formal Verification of Agentic Systems over Operational Data," arXiv:2608.03609v1, 2026.

[12] S. Weinberger and A. Hozez, "Token Reduction Is Not Cost Reduction," arXiv:2607.12161v5, 2026.

[13] Y. Song, "Cache-Aware Prompt Compression: A Two-Tier Cost Model for LLM API Caching," arXiv:2607.15516v1, 2026.

[14] E. Lumer, F. Nizar, A. Jangiti, K. Frank, A. Gulati, M. Phadate, and V. K. Subbiah, "Don't Break the Cache: An Evaluation of Prompt Caching for Long-Horizon Agentic Tasks," arXiv:2601.06007v2, 2026.

[15] Hugging Face, "smolagents, memory.py," source commit 96f33fa, 2026. `https://github.com/huggingface/smolagents/blob/96f33faaf028479119ec8d34507b47694cf14e34/src/smolagents/memory.py`

[16] smolagents contributors, "Tool-call ID and ordering fixes," pull requests 2684 and 2999, heads bd00a93 and c410924, inspected Oct. 24, 2026. `https://github.com/huggingface/smolagents/pull/2684`; `https://github.com/huggingface/smolagents/pull/2999`

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Keywords LLM agents, harness engineering, state retention, execution reproducibility, cost evaluation

Summary draft We analyzed 24 recorded runs of a stateful LLM agent. Matching public outputs included 14 rejected generations; different syntax produced identical API requests in 37 generations across four known tasks. These observations distinguish output agreement, actual execution, and task outcomes without establishing general quality or cost improvements.