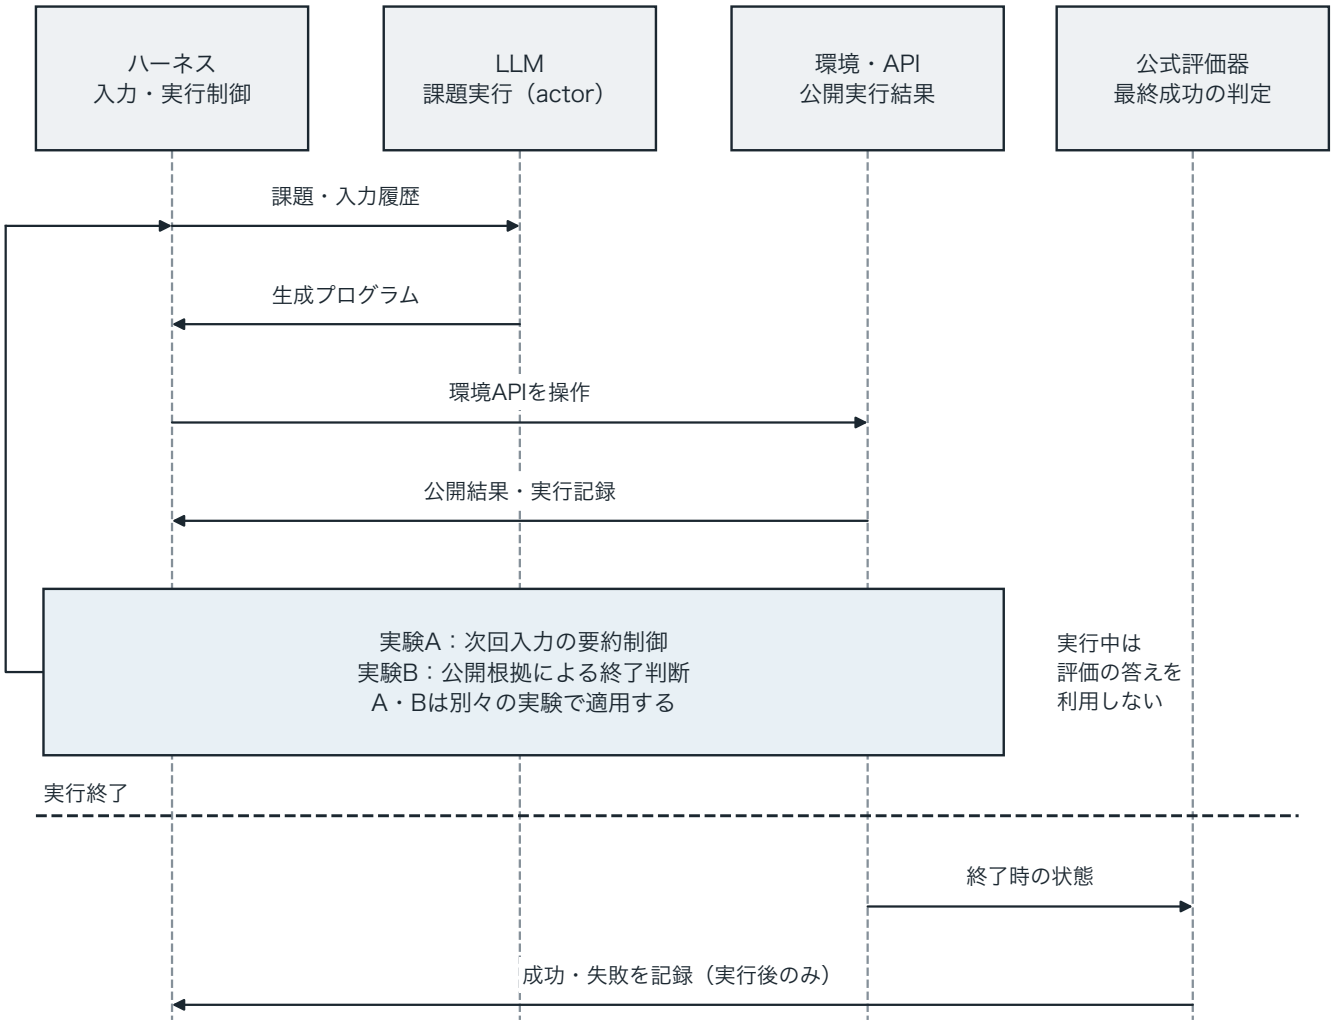
実行中の制御と、実行後の評価を分離
ハーネス
入力・実行制御
LLM
課題実行（actor）
環境・API
公開実行結果
公式評価器
最終成功の判定
課題・入力履歴
生成プログラム
環境APIを操作
公開結果・実行記録
実験A：次回入力の要約制御
実験B：公開根拠による終了判断
A・Bは別々の実験で適用する
実行中は
評価の答えを
利用しない
実行終了
終了時の状態
成功・失敗を記録（実行後のみ）
費用は全モデル呼出しを集計。公式評価器からLLMへ向かう経路は設けない。