LLM エージェントの履歴要約と終了制御による実行費用の評価

著者未設定

Evaluating Execution Cost of History Summarization and Termination Control for LLM Agents

Author details pending

所属・会員種別・連絡先：未設定

あらまし　LLM エージェントの通常ハーネス制御を評価した．既知 4 課題の成功を保ち，別呼出し反復要約は単発より 12.07%減となった．別実験の写真課題 2 条件では証拠付き終了で 26–30%減を観測した．全呼出し費用と強い対照から，適用範囲を検討する．

キーワード　LLM エージェント，ハーネス，履歴要約，終了制御，費用評価

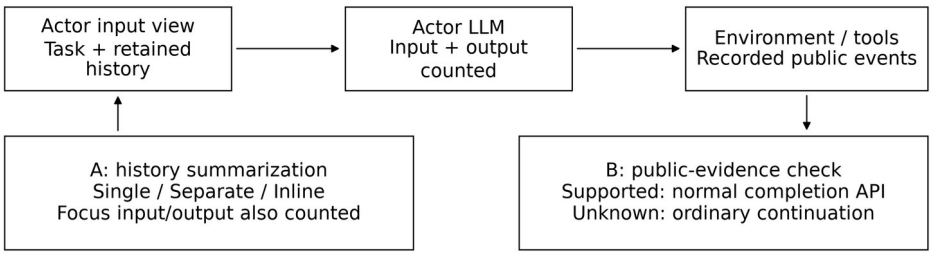
1. まえがき

大規模言語モデル（LLM）によるエージェントは，推論と行動を繰り返し[1]，生成したコードで外部環境を操作する[2]．この実行を支えるハーネスは，どの履歴をモデルに提示し，いつ要約し，いつ次の生成を止めるかを決める．蓄積した履歴の再入力や，必要な作業を終えた後の継続は，最終成果を増やさずに費用を増やす可能性がある．

本稿では，新しいモデルを学習せずに使える通常の制御を対象に，課題の最終成功と全仕事の論理入出力を評価する．第一の実験は，単発要約，別呼出しによる反復要約，行動生成と同時に行う反復要約の比較である．第二の実験は，公開 API 記録から必要な作業の完了を確認して通常の終了通知を送る制御と，モデルに継続させる制御の比較である．

長文では関連情報の位置も性能に影響する[3]．LLMLingua[4]と LLMLingua-2[5]はトークンの選別，LongLLMLingua[6]は長文入力の圧縮を扱う．長期エージェントの圧縮方針[7]やキャッシュを考慮する文脈管理[8]も，全実行の費用と関係する．また，Generative Agents[9]は経験の記憶・抽象化・検索，Reflexion[10]は言語的フィードバックを後続試行に利用する．

本稿はこれらの圧縮・記憶原理を新規に提案するものではなく，要約の呼出し配置と終了判断の効果を調べる．要約を作る費用や失敗時の費用を除かず，強い通常対照を残して最終成功と比較する．既知 4 課題では別呼出し反復が単発より 12.07%少なく，同時反復は別呼出し反復より 6.53%多かった．別の終了制御実験でも，同じ写真課題の 2 条件で成功を保つ削減を観測した．これらは別々の開発実験の結果として報告する．



Separate studies, not a combined controller; all outcomes retained.

図 1　入力履歴と次の生成の要否を制御する二つの作用点．実験 A，B は別々に実行する．

Two control points for input history and further generation, evaluated in separate studies.

2. 制御と評価指標

2.1　ハーネスの二つの作用点

図 1 に制御の作用点を示す．第一の実験は，課題実行を担う actor への入力履歴を変える．要約専用の focus 呼出しで古い履歴を圧縮し，採用済み要約と残存履歴を次の actor へ渡す．完全な履歴はホストに保存する．別呼出し反復は必要に応じて要約を更新し，同時反復は actor が行動と要約候補を同じ応答に出す．

後者が focus 呼出しを使わないことだけでは，総費用が小さくなるとは限らない．

終了指示や外部の完了判定による早期終了にも先行研究がある[11]．第二の実験は，生成応答内の全プログラムを実行した後，次の生成に進む前の終了判断を変える．公開記録の根拠が揃えば，ホストが通常の完了 API を 1 回送る．未知・未対応・矛盾があれば通常継続し，モデルの完了応答や評価器の答えを捏造しない．二つの制御を組み合わせた実験ではなく，各作用点を別々に比較する．

2.2　全呼出しを含む費用と最終成功

条件pのモデル呼出し集合をC_pとし，実際の入力I_cと出力O_cから

$$T_p = \sum_{c \in C_p} \left(I_c + O_c \right) \quad (1)$$

を求める．actor と focus，不採用要約，失敗時の既知使用量も含め，cached input を控除しない．論理トークン数は金銭課金や実行時間そのものではない[8]．圧縮役を含む費用評価は ACON[7]にも存在し，会計方法自体を新規技術とはしない．局所的な入力削減と，生成全体の費用削減も区別する．

品質は，課題終了後の状態に対する AppWorld[12]の公式評価器の成功・失敗で測る．評価の正解や詳細を実行中のモデルへ返さない．成功数の一致だけでなく，同じ課題の成功を失っていないかを確認する．不明使用量がある場合は既知小計と件数を残し，0 へ補完しない．異なる実験の費用や課題数は合算しない．

3. 実験 A：要約の呼出し配置

3.1　条件

写真操作，精算，返金，CSV 処理の既知 4 課題に対し，単発別要約（Single），別呼出し反復（Separate），同時反復（Inline）を各 1 回，計 12 条件実行した．全条件は同じ MiniMax-M3（GGUF，IQ4_XS），llama.cpp b11669，文脈長 65,536 を用いた．model seed の基点は 57，world seed は 42 で，呼出しの役割・順序に従い seed を増分した．

要約機会の入力長閾値は 16,384 トークン，直近 2 ターンを保持し，反復では新規完了ターン 3 以上を要求する．単発の最大機会数は 1，反復は 3 である．要約は合計 8,192 文字以下とし，次の actor 入力全体が短くなる場合に採用する．単発と別呼出し反復は focus 出力上限 4,096 で，focus 費用も式(1)へ含める．

各条件の上限は 80 モデル要求，450,000 トークン，作業 1,800 秒で，環境 API は写真 160，他 3 課題 80 要求とした．actor 温度 1.0，focus 温度 0.7，並列実行数 1，KV cache q8_0，計算機は Apple M3 Ultra・メモリ 256 GiB である．実装と全条件の記録を公開する[1]．

3.2　全 4 課題の結果

表 1 に全 12 条件の費用を示す．全方式が 4/4 成功し，使用量不明は 0 だった．Separate は Single より 107,873 トークン（12.07%）少なかった．この差は全て CSV の 440,461 から 332,588 への減少であり，他 3 課題は同値である．要約採用回数も，CSV は Single の 1 回に対して両反復方式が 2 回，写真は全方式 1 回，精算・返金は 0 回だった．したがって，全 4 課題で一様に改善した結果ではない．

Inline は Single より 6.34%少なかったが，強い Separate 対照より 51,266 トークン（6.53%）多かった．写真だけでは Inline が 10,497 少ない一方，CSV では Separate より 61,763 多く，この増加が上回った．専用要約呼出しを無くすことと，全仕事を安くすることは同義ではない．図 2（a）は CSV 以外の 3 課題と CSV を分けてこの内訳を示す．

表 1　実験 A の全 12 条件の論理入出力．全セル公式成功，使用量不明 0．
Logical input/output for all 12 conditions in study A; all succeed with known usage.

課題	Single	Separate	Inline
写真操作	139,871	139,871	129,374
精算	211,110	211,110	211,110
返金	102,087	102,087	102,087
CSV 処理	440,461	332,588	394,351
全 4 課題	893,529	785,656	836,922

1 https://github.com/sophiria1225/AI-

表 2　実験 B の全 4 観測．同じ写真 1 課題で，全観測公式成功，使用量不明 0．
All four observations in study B concern one photo task and succeed with known usage.

Interface	制御	論理入出力	モデル呼出し	API 要求
文書取得必須	通常継続	130,439	15	104
	証拠付き終了	91,116	13	100
公開名アクセス	通常継続	151,664	14	103
	証拠付き終了	112,233	12	99

4. 実験 B：公開証拠に基づく終了

4.1　条件

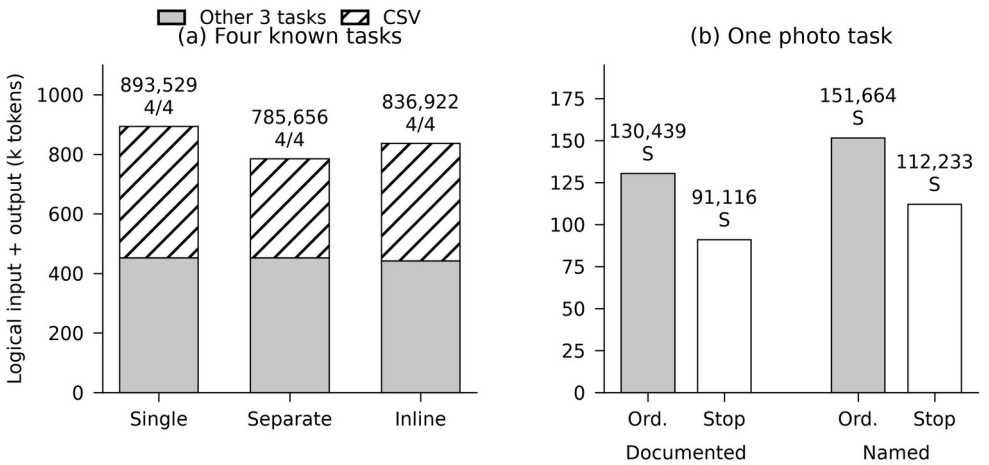
同じ既知写真課題について，API 文書取得を必須とする interface と，公開 API 名からのアクセスを許す interface の 2 条件を比較した．各 interface で，既に閉鎖した通常継続を対照に，同じ初期状態・モデル・seed・案内・予算から新たに終了制御を各 1 回実行した．seed の基点は 42 であり，実験 A とは別の履歴・設定である．同じ MiniMax-M3 IQ4_XS と llama.cpp b11669 を用い，上限は 80 要求，450,000 トークン，作業 1,800 秒，API160 要求である．

制御は既知 1 要求文型の手書き検査である．完全な元集合，移動前の日時，公開時計，対象全件の移動先，名前保持などの公開根拠を検査する．支持が揃った最初の生成境界で，通常の完了通知を 1 回だけ送る．未知作用や不確定な集合を完了扱いにせず，未来の応答・正解を利用しない．判定，保存，通知を含む実行時間と，通知 API を計上する．

4.2　成功を保った局所的な削減

表 2 と図 2（b）に全 4 観測を示す．文書取得必須では 130,439 から 91,116 へ 30.15%，公開名アクセスでは 151,664 から 112,233 へ 26.00%減った．両対照・両制御とも公式成功，使用量不明 0 で，各条件 2 生成・4API 要求が少なかった．完了通知は省かず，対象の移動後に続いていた 4 回の確認 API と，それに伴う生成を実行しなかった．

実行した公開 API 等の前半記録は対照と一致し，最終 13 データベースの hash も全て一致した．ただし，要求・モデル応答全文の strict prefix 一致は不成立であり，その事前基準を変更しない．手書きの既知要求文型による各 1 回の比較であって，平均因果効果や汎用の終了保証ではない．



S: official success. Different y-axis scales; studies are not pooled.
Cached input included. No unknown usage in these two studies.

図 2　別々の実験における費用．（a）全 4 課題は各方式 4/4 成功，（b）同じ写真課題の全 4 観測は成功．二つの縦軸と集計範囲は異なる．
Costs in separate studies. All conditions succeed; the axes and aggregation scopes differ.

5. 考察と限界

二つの実験では，履歴再入力や完了後の継続を制御した既知条件で，成功を保った費用削減を観測した．Inline も Single より低費用だが，Separate より高費用であり，専用呼出し数だけで方式を選べない．後続の表示・状態更新方式では，通常対照への追加改善は確立していない．これらを正例へ合算せず，未達・使用量不明を含む条件と不採用理由を公開記録・補足資料に残す．

本稿は閉鎖済み開発実験から，正例と直接対照を事後に整理した評価である．既知課題，単一モデル量子化，少数の seed と反復，手書き完了規則に限定され，未見課題への独立確認ではない．12.07%と 26–30%を同じ母集団の平均にせず，一般的な品質維持，統計的非劣性，新しい圧縮・終了原理の成立は主張しない．今後は具体的な候補と対照を固定して，適用範囲と失敗を含む全件を別に検証する必要がある．

6. むすび

通常のハーネス制御を全仕事の論理入出力と最終成功で評価した．既知 4 課題では別呼出し反復要約が単発より 12.07%少なく，別実験の既知写真課題 2 条件では証拠付き終了が 26–30%少なかった．同時要約が別呼出し反復より高費用だった対照も含め，専用要約呼出しの削減と全仕事の費用削減を区別した．既知条件での結果は，履歴更新と完了後継続の制御を最終成功と合わせて評価する必要性を示す．

文　献

[1] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “ReAct: Synergizing reasoning and acting in language models,” Proc. ICLR, May 2023.

[2] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, July 2024.

[3] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, “Lost in the middle: How language models use long contexts,” Trans. ACL, vol.12, pp.157–173, 2024. doi: 10.1162/tacl_a_00638.

[4] H. Jiang, Q. Wu, C.-Y. Lin, Y. Yang, and L. Qiu, “LLMLingua: Compressing prompts for accelerated inference of large language models,” Proc. EMNLP, pp.13358–13376, Dec. 2023. doi: 10.18653/v1/2023.emnlp-main.825.

[5] Z. Pan, Q. Wu, H. Jiang, M. Xia, X. Luo, J. Zhang, Q. Lin, V. Rühle, Y. Yang, C.-Y. Lin, H. V. Zhao, L. Qiu, and D. Zhang, “LLMLingua-2: Data distillation for efficient and faithful task-agnostic prompt compression,” Findings of ACL: ACL 2024, pp.963–981, Aug. 2024. doi: 10.18653/v1/2024.findings-acl.57.

[6] H. Jiang, Q. Wu, X. Luo, D. Li, C.-Y. Lin, Y. Yang, and L. Qiu, “LongLLMLingua: Accelerating and enhancing LLMs in long context scenarios via prompt compression,” Proc. ACL, vol.1, pp.1658–1677, Aug. 2024. doi: 10.18653/v1/2024.acl-long.91.

[7] M. Kang, W.-N. Chen, D. Han, H. A. Inan, L. Wutschitz, Y. Chen, R. Sim, and S. Rajmohan, “ACON: Optimizing context compression for long-horizon LLM agents,” Proc. ICML, PMLR, vol.306, pp.55321–55375, July 2026.

[8] B. Xu, Z. Xue, D. Chen, C. Fu, C. Wu, C. Huang, C. Jiang, J. Fang, X. Deng, Y. Chen, Y. Yao, X. Wang, J. Shang, H. Chen, and N. Zhang, “TokenPilot: Cache-efficient context management for LLM agents,” Findings of ACL: EMNLP 2026, pp.19034–19049, Oct. 2026.

[9] J. S. Park, J. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” Proc. ACM UIST, article 2, pp.1–22, Oct. 2023. doi: 10.1145/3586183.3606763.

[10] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” Advances in Neural Information Processing Systems, vol.36, pp.8634–8652, 2023. doi: 10.52202/075280-0377.

[11] Q. Lu, L. Ding, S. Cao, X. Liu, K. Zhang, J. Zhang, and D. Tao, “Runaway is ashamed, but helpful: On the early-exit behavior of large language model-based agents in embodied environments,” Findings of ACL: EMNLP 2025, pp.24014–24027, Nov. 2025. doi: 10.18653/v1/2025.findings-emnlp.1304.

[12] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: A controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Aug. 2024. doi: 10.18653/v1/2024.acl-long.850.

Abstract
We evaluate ordinary harness controls by total logical token use. Repeated separate-call summarization saves 12.07% over one-shot summarization, retaining success on four known tasks. A separate photo study observes 26–30% reductions with evidence-based termination. Strong baselines and contradictory findings limit generalization.
Key words: LLM agents, harness, history summarization, termination control, cost evaluation