実験A：要約呼出しの配置を比較

課題実行とAPI操作を繰り返し、入力履歴が閾値に達すると要約機会を設ける

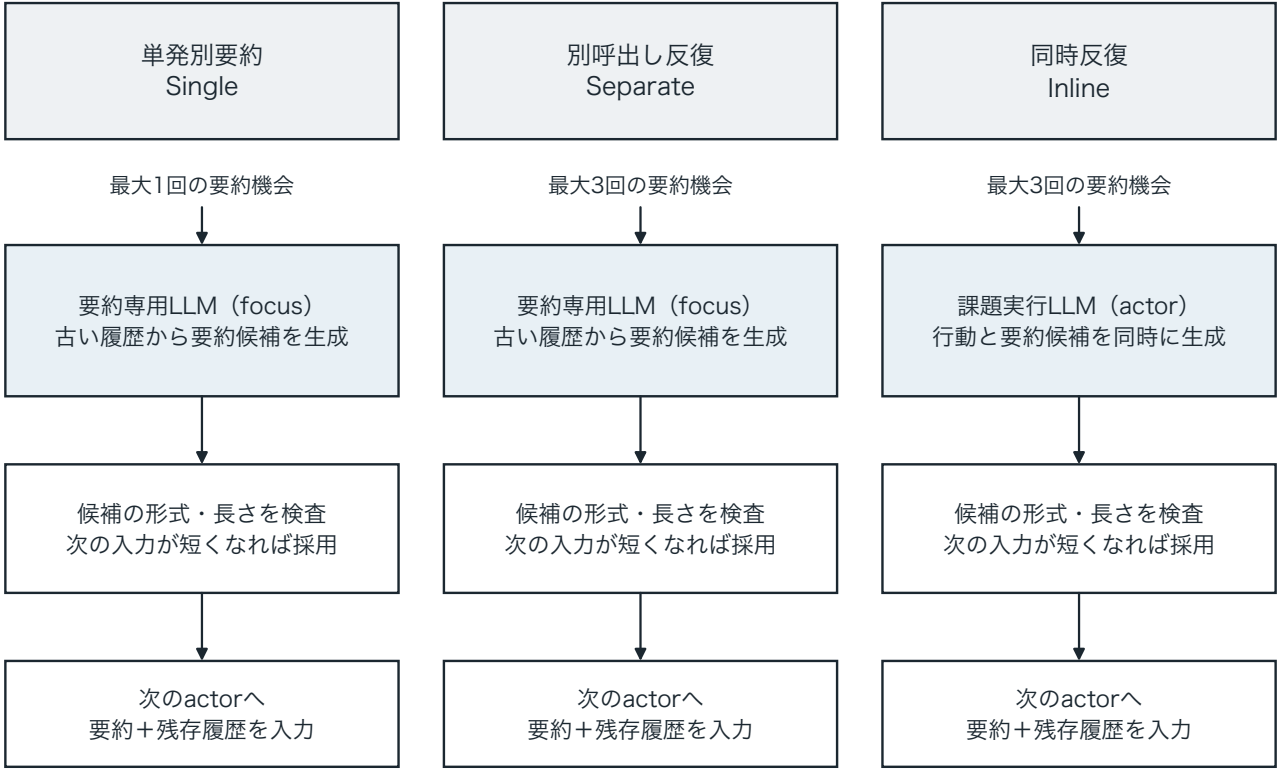

生成コードは通常どおり実行。要約用呼出しを含む総トークン数と最終成功で比較。