# LLM エージェントの履歴要約と終了制御による実行費用の評価

著者未設定

Evaluating Execution Cost of History Summarization and Termination Control for LLM Agents

Author details pending

所属・会員種別・連絡先：未設定

あらまし　LLM エージェントの履歴要約と終了制御を独立に評価した．要約生成を含む全モデル呼出しを計測し，反復要約と API 実行記録に基づく完了判定により，既知課題の成功を保ちながら総トークン数を削減できることを示した．

キーワード　LLM エージェント，ハーネス，履歴要約，終了制御，費用評価

## 1. はじめに

日常業務のデータ整理や事務処理の負担を軽減するため，大規模言語モデル（LLM）による作業支援が研究されている．文章の回答生成に加え，外部アプリケーションを操作する複数手順の実行も対象となる．例えば写真の整理や精算では，対象の検索，状態の変更，結果の確認を連続して行う必要がある．推論と行動を繰り返す ReAct[1]や，コードを行動として実行する CodeAct[2]は，このような対話的処理を支える技術である．

一方，実行が長くなると，過去の操作と観測を次の生成へ繰り返し入力する費用が増える．また，作業が終わった後も確認や生成を続ければ，成果を増やさずに資源を消費し得る．履歴を短くするだけでは必要な情報を失うおそれがあり，早く止めるだけでは未完了となり得るため，最終成功と実行全体の費用を同時に調べる必要がある．

本稿では，モデルを再学習せずに実行を管理するハーネスについて，履歴要約と終了判断の二つの制御を評価する．履歴要約では，要約を生成する呼出しの配置を比較する．終了判断では，実行中に取得できる API 応答の記録（以下，API 実行記録）に基づく制御を通常継続と比較する．両者を独立した実験として実行し，要約生成を含む全モデル呼出しの総トークン数と，課題の最終成功を調べる．

## 2. 関連研究

入力圧縮では，長文中の情報の位置が性能に影響すること[3]を踏まえ，LLMLingua[4]は予算制御とトークン選別，LLMLingua-2[5]は蒸留データによるトークン分類，LongLLMLingua[6]は長文の重要情報を残す圧縮を扱う．

長期実行では，ACON[7]は観測・履歴の圧縮方針，TokenPilot[8]は入力圧縮とキャッシュ継続性を扱う．Generative Agents[9]は経験の記憶・抽象化・検索，Reflexion[10]は言語的フィードバックを後続試行に利用する．本稿では，要約専用の呼出しで反復要約を行う方式と，行動生成と同時に要約を行う方式を比較し，要約生成も含む課題全体のトークン使用量を評価する．

終了制御では，Runaway[11]が終了指示と外部の完了検証を検討している．本稿では，既知の要求文型について API 実行記録から完了条件を検査する．通常継続との比較では，最終成功，API 要求数，総トークン数を評価する．

## 3. 制御と評価指標

### 3.1 履歴要約と終了判断

図 1 に二つの制御を示す．実験 A では全履歴をホストに保存し，行動生成を担うモデル呼出しを actor と呼ぶ．actor へ提示する履歴は，要約採用前には未要約の履歴，採用後には要約と未要約の履歴とする．要約専用のモデル呼出しを focus と呼ぶ．Single は focus による要約機会を 1 回に限り，Separate は必要に応じて繰り返す．Inline は行動と要約候補を actor の同じ応答に出力する．候補の検査と採用はホストで行う．

実験 B では，モデル応答に含まれる全プログラムを実行した後，次の生成へ進む前に API 実行記録を確認する．完了条件を満たす場合は完了 API を 1 回呼び出し，未対応の操作や不確定・矛盾する情報があれば継続する．実験 A との組合せは評価しない．

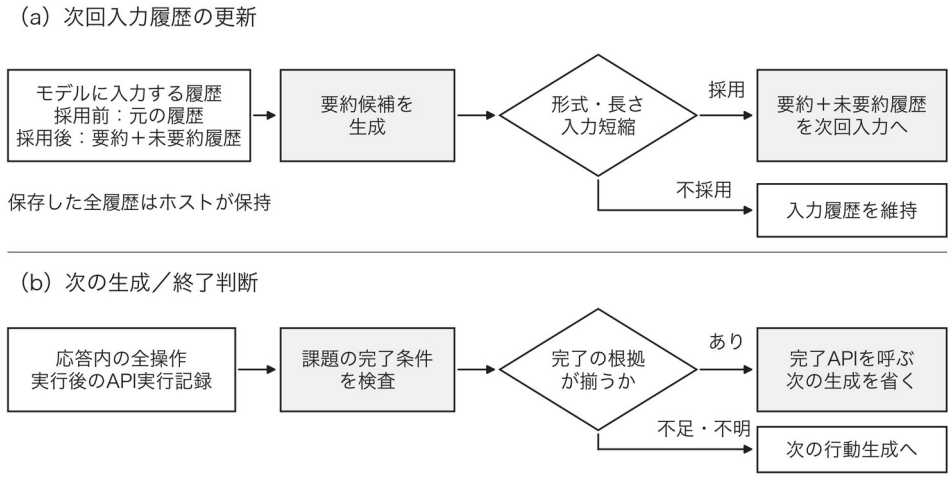



図 1　独立に評価する二つの制御．(a) 履歴要約による次回入力の更新．(b) API 実行記録に基づく終了判断．両制御の組合せは評価しない．成功は実行終了後の公式評価器で判定する．

Two independently evaluated controls: history summarization (a) and termination based on API execution records (b). Success is evaluated after execution; their combination is not tested.

### 3.2　総トークン数と最終成功

条件 $p$ で実行したモデル呼出しの集合を $\mathcal{C}_p$ とする．各呼出し $c$ の入力トークン数を $I_c$，出力トークン数を $O_c$ とし，実行全体の総トークン数 $T_p$ を式(1)で求める．

$$T_p = \sum_{c \in C_p} \left( I_c + O_c \right) \tag{1}$$

集計には actor と focus の両方を含め，不採用となった要約の生成や失敗時の呼出しについても，取得できた使用量を計上する．使用量が不明な場合は 0 とせず，既知分の小計と不明件数を記録する．

課題の成功は，実行終了後の状態に対する AppWorld[12]の公式評価器で判定する．評価器の正解や詳細は実行中のモデルへ返さない．方式間では成功数と，各課題の成功の維持を確認する．

本指標はキャッシュされた入力も含む論理トークン数であり，金銭課金や実行時間を直接表すものではない[8]．要約生成を含む費用評価は ACON[7]にも用いられている．実験 A と B は独立に集計する．

## 4. 実験 A：要約の呼出し配置

### 4.1　条件

写真操作，精算，返金，CSV 処理の既知 4 課題に対し，Single，Separate，Inline の各方式を各課題で 1 回ずつ実行した（4 課題×3 方式，計 12 実行）．全条件は同じ MiniMax-M3（GGUF，IQ4_XS），llama.cpp b11669，文脈長 65,536 を用いた．モデル生成の seed の基点は 57，環境の seed は 42 で，生成側は呼出しの役割・順序に従い seed を増分した．

要約機会の入力長閾値は 16,384 トークンとし，要約時には直近 2 ターンを原文のまま保持する．反復では，前回の要約機会の終了（採否を問わない）から新たに 3 ターン以上が完了することを要求する．初回の起点は課題開始である．要約機会の上限は Single が 1 回，Separate と Inline が 3 回である．要約は合計 8,192 文字以下とし，次の actor 入力全体が短くなる場合に採用する．Single と Separate の focus 出力上限は 4,096 トークンで，focus の使用量も式(1)へ含める．

各実行の上限はモデル呼出し 80 回，総トークン数 450,000，作業時間 1,800 秒とし，環境 API は写真 160，他 3 課題 80 要求とした．actor 温度 1.0，focus 温度 0.7，並列実行数 1，KV cache q8_0，計算機は Apple M3 Ultra・メモリ 256 GiB である．実装と全条件の記録を公開する[1]．

### 4.2　全 4 課題の結果

全 4 課題の成功を保ち，反復要約の Separate は単回要約の Single より総トークン数を 107,873（12.07%）削減した（表 1）．全 12 実行で使用量の欠測はなく要約生成を含む課題全体で削減を得た．この差は CSV 処理の 440,461 から 332,588 への減少によるもので，他の 3 課題は同じ値だった．

CSV 処理での要約採用回数は Single が 1 回，Separate と Inline が各 2 回だった．写真操作は全方式で 1 回，精算と返金は 0 回だった．

1 https://github.com/sophiria1225/AI-

表 1　実験 A の課題別総トークン数
Total tokens by task in study A.

| 課題 | Single | Separate | Inline |
|---|---|---|---|
| 写真操作 | 139,871 | 139,871 | 129,374 |
| 精算 | 211,110 | 211,110 | 211,110 |
| 返金 | 102,087 | 102,087 | 102,087 |
| CSV 処理 | 440,461 | 332,588 | 394,351 |
| 合計 | 893,529 | 785,656 | 836,922 |

各方式は 4 課題すべてで成功した．全 12 実行でトークン使用量の欠測はなかった．

Inline は Single より 6.34%少なかったが，Separate より 51,266 トークン（6.53%）多かった．Separate との比較では，写真操作で 10,497 トークン少ない一方，CSV 処理で 61,763 トークン多かった．要約生成を含む 4 課題の合計では，Separate が 3 方式中で最少となった．図 2 に CSV 処理とその他 3 課題の内訳を示す

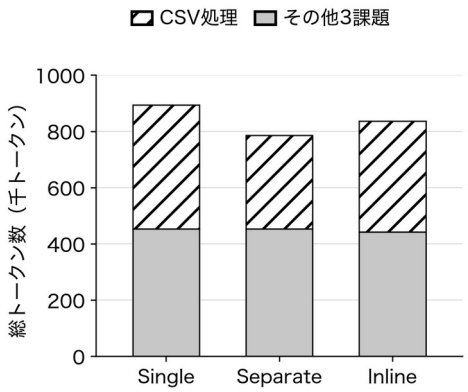



図 2　実験 A の総トークン数．各方式で全 4 課題が成功した．
Total tokens in study A. All four tasks succeed with each method.

## 5. 実験 B：API 実行記録に基づく終了

### 5.1　条件

同じ写真課題について，API 文書の取得を必須とする条件（文書必須）と，公開 API 名からのアクセスを許す条件（名前参照）を設けた．各 API アクセス条件で，通常継続と API 実行記録に基づく終了制御（完了判定）を比較した．完了判定は，事前に実行・保存した通常継続と同じ初期状態，モデル，seed，モデルへの指示とツール説明，予算を用いて各 1 回実行した．

seed の基点は 42 であり，実験 A とは別の履歴・設定である．同じ MiniMax-M3 IQ4_XS と llama.cpp b11669 を用い，各実行の予算はモデル呼出し 80 回，450,000 トークン，1,800 秒，API160 要求とした．

終了判定には，既知の 1 要求文型に対応する手書きの検査規則を用いた．操作前の対象集合，移動前の日時，API から取得できる時刻，対象全件の移動先，名前の保持を確認する．完了の根拠が初めて揃った，次の生成へ進む前の時点で，完了 API を 1 回呼び出す．未対応の操作や不確定・矛盾する情報がある場合は継続する．未来の応答や正解を利用しない．

判定，記録保存，完了通知を含む実行時間を記録し，完了通知を API 要求数に含めた．記録先と集計項目は補足資料 EVIDENCE.md に示す．

### 5.2　成功を保った総トークン数の削減

両 API 条件で課題の成功を保ち，完了判定により総トークン数を削減した（表 2，図 3）．文書必須では 130,439 から 91,116 へ 30.15%，名前参照では 151,664 から 112,233 へ 26.00%減った．全 4 実行で公式評価器による成功を確認し，使用量の欠測はなかった．各条件でモデル呼出し 2 回と API 要求 4 回を削減した．完了通知を含めて処理を終え，対象の移動後に続いていた 4 回の確認 API と，それに伴う生成を省いた．

表 2　実験 B の総トークン数と呼出し回数
Total tokens and call counts in study B.

| API 条件 | 終了方法 | 総トークン数 | モデル呼出し数 | API 要求数 |
|---|---|---|---|---|
| 文書必須 | 通常継続 | 130,439 | 15 | 104 |
| 文書必須 | 完了判定 | 91,116 | 13 | 100 |
| 名前参照 | 通常継続 | 151,664 | 14 | 103 |
| 名前参照 | 完了判定 | 112,233 | 12 | 99 |

同じ写真課題を用いた全 4 実行が成功した．トークン使用量の欠測はなかった．
文書必須：API 文書の取得が必須．名前参照：公開 API 名からのアクセスを許可．完了判定：API 実行記録に基づく終了制御．

実行した API 操作などの前半の記録と，実行終了時の 13 個のデータベースのハッシュ値は対照と一致し，最終状態を保った削減を確認した．要求・モデル応答の全文が通常継続側の先頭部分と完全に一致する事前基準は満たさなかったため，結果は既知の要求文型に対する各 1 回の比較として扱う．平均的な因果効果や汎用的な終了保証を示す評価ではない．

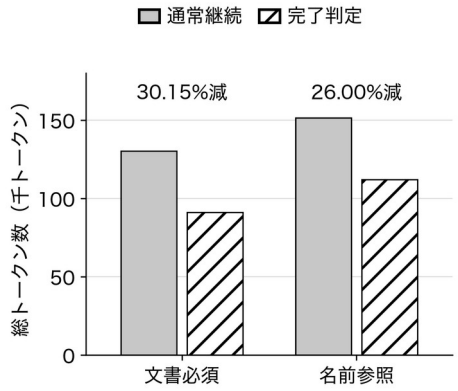



図 3　実験 B の総トークン数．同じ写真課題を用いた全 4 実行が成功した．

Total tokens in study B. All four runs of the same photo task succeed.

## 6. むすび

既知 4 課題では，反復要約の Separate により全課題の成功を保ち，Single に比べて総トークン数を 12.07% 削減した．同じ写真課題の 2 つの API 条件では，API 実行記録に基づく完了判定により成功を保ち，通常継続に比べて 26.00–30.15%削減した．要約生成を含む全モデル呼出しを計測し，履歴要約と終了制御を独立に比較することで，ハーネス上の制御による実行費用の削減を確認した．

本稿は，既知課題と単一モデル・量子化設定における少数の seed・試行による開発実験を事後に整理した評価である．未見課題の品質維持や統計的非劣性は評価していない．追加条件の採否理由は EVIDENCE.md に示した．補足の supplemental_results.pdf と P144R1_all_conditions.csv には全 12 実行を収録した．

## 文　献

[1] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “ReAct: Synergizing reasoning and acting in language models,” Proc. ICLR, May 2023.

[2] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, July 2024.

[3] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, “Lost in the middle: How language models use long contexts,” Trans. ACL, vol.12, pp.157–173, 2024. doi: 10.1162/tacl_a_00638.

[4] H. Jiang, Q. Wu, C.-Y. Lin, Y. Yang, and L. Qiu, “LLMLingua: Compressing prompts for accelerated inference of large language models,” Proc. EMNLP, pp.13358–13376, Dec. 2023. doi: 10.18653/v1/2023.emnlp-main.825.

[5] Z. Pan, Q. Wu, H. Jiang, M. Xia, X. Luo, J. Zhang, Q. Lin, V. Rühle, Y. Yang, C.-Y. Lin, H. V. Zhao, L. Qiu, and D. Zhang, “LLMLingua-2: Data distillation for efficient and faithful task-agnostic prompt compression,” Findings of ACL: ACL 2024, pp.963–981, Aug. 2024. doi: 10.18653/v1/2024.findings-acl.57.

[6] H. Jiang, Q. Wu, X. Luo, D. Li, C.-Y. Lin, Y. Yang, and L. Qiu, “LongLLMLingua: Accelerating and enhancing LLMs in long context scenarios via prompt compression,” Proc. ACL, vol.1, pp.1658–1677, Aug. 2024. doi: 10.18653/v1/2024.acl-long.91.

[7] M. Kang, W.-N. Chen, D. Han, H. A. Inan, L. Wutschitz, Y. Chen, R. Sim, and S. Rajmohan, “ACON: Optimizing context compression for long-horizon LLM agents,” Proc. ICML, PMLR, vol.306, pp.55321–55375, July 2026.

[8] B. Xu, Z. Xue, D. Chen, C. Fu, C. Wu, C. Huang, C. Jiang, J. Fang, X. Deng, Y. Chen, Y. Yao, X. Wang, J. Shang, H. Chen, and N. Zhang, “TokenPilot: Cache-efficient context management for LLM agents,” Findings of ACL: EMNLP 2026, pp.19034–19049, Oct. 2026.

[9] J. S. Park, J. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” Proc. ACM UIST, article 2, pp.1–22, Oct. 2023. doi: 10.1145/3586183.3606763.

[10] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” Advances in Neural Information Processing Systems, vol.36, pp.8634–8652, 2023. doi: 10.52202/075280-0377.

[11] Q. Lu, L. Ding, S. Cao, X. Liu, K. Zhang, J. Zhang, and D. Tao, “Runaway is ashamed, but helpful: On the early-exit behavior of large language model-based agents in embodied environments,” Findings of ACL: EMNLP 2025, pp.24014–24027, Nov. 2025. doi: 10.18653/v1/2025.findings-emnlp.1304.

[12] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: A controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Aug. 2024. doi: 10.18653/v1/2024.acl-long.850.

Abstract
We independently evaluated history summarization and termination control in an LLM-agent harness. Measuring every model call, including summarization, showed that repeated summarization and completion checks based on API execution records reduced total tokens while preserving success on known tasks.
Key words: LLM agents, harness, history summarization, termination control, cost evaluation