状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの通常推論予算を既知４課題８条件で比較した．全条件を評価したが１生成の使用量が不明で，全仕事費用差は確定できなかった．一般的な品質維持は未検証である．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，推論予算，費用評価

1　問題設定

必要な情報と成果品質を保って仕事全体の費用を減らすため，ハーネスが渡す情報と生成・実行の予算を区別して検討する．コードを行動に用いる CodeAct[1] 型エージェントでは，思考が出力枠を消費した後に，実行に必要なコードを完了できるとは限らない．しかし，短い思考や構文上の完成だけでは，課題達成や失敗を含む全費用の減少を意味しない．本稿は AppWorld[2] の既知４課題を用い，通常の推論ブロック上限指定が課題全体の成否と費用へ与える効果を，固定した８条件で調べる限定的な開発比較である．

思考終了の制御 [3]，予算情報を用いた複数ターンの資源配分の学習 [4] には先行研究がある．後者は予算内成功と自然な予算遵守を区別し，１方策につき１資源の予算を扱い，token 費用は生成分である．本稿は学習せず，既存 backend の設定 [5] を比較する．全論理入力と出力を主費用とするが，token 削減と他の費用の不一致 [6] 自体を独自性とはしない．新しい予算配分アルゴリズム，学習方式より優れた性能，一般的品質保証を主張する比較ではない．

2　共通の実行系と比較

2.1　出力枠と履歴

１生成の全出力上限を最大 4,096 とし，推論ブロック専用上限なしを U，固定 2,048 指定を H とする．U も全出力・全仕事・実時間の上限を持つ．固定 backend は推論終了タグを使ってブロックを閉じるため，2,048 は操作へ必ず半分を残す予約ではない．終了タグ，UTF-8 境界の待機，新たな推論ブロックの開始があり，ブロック内の正確な生成 token 配分を本比較では別計測していない．全仕事の残 token により全出力枠が縮む場合も，専用指定 2,048 は変更しない．

両側とも全返却推論，持続 Python，型付き API 返却，通常の Python 例外を保持する．呼出しと返答の通信参照は構造化された段階で統一してからモデル向けに文章化し，一般本文や業務 ID は変更しない．参照改名感度と正規化には先行研究 [7] があり，本処理を新規手法とはしない．残実時間は非表示と明示する一方，実行可否は単調時計の期限で強制する．残 token・API・生成回数の通知は共通とし，過去の通知を会話へ蓄積しない．

2.2　固定した課題と上限

写真移動，電気代精算，返金，曲情報書出しを新しい初期状態から各条件１回実行する．課題順はこの順，条件順は U/H，H/U，U/H，H/U である．世界 seed42，モデル seed は初回 57 で以後生成ごとに１増やす．Mac Studio M3 Ultra・256 GiB 上で AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS, llama.cpp b11669 を用いる．温度 1.0，top-p 0.95，入力枠 65,536，１スロットを共通とする．初回の cache 再利用０を確認し，後続は通常の prefix cache を使う．初期８入力を計数し，課題ごとの要求が専用予算のフィールド以外一致することを確認してから生成を始める．

各条件は 80 生成，450,000 論理 token，作業 1,800 秒，写真 160・他 80 API を上限とする．１生成の待機は 600 秒と残作業時間の小さい方である．全体は８条件，640 生成，3,600,000 予約 token，所有推論器 21,600 秒を上限とする．公開の要求と API 仕様を用い，保留 12 課題は閲覧しない．先行する保存文脈の局所診断では予定８生成中４件目で停止し，３件既知・１件不明・４件未実行だった．その後に本開発比較を固定しており，未見確認ではない．局所診断の不足枠を補充せず，専用値・seed を探索しない．

3　計測と採用条件

全仕事の論理費用は $T = \sum_j (I_j + O_j)$ とし，cache 分を含む全入力 I_j，出力 O_j，通知，失敗，回復，再取得を含める．cache 除外入力，出力，API 回数，作業・準備・

表 1　予定した全 8 条件．+? は既知小計に使用量不明の生成が残ることを表す．

課題	条件	成果	論理 token	生成	API
写真	U	成功	135,628	16	99
写真	H	成功	135,628	16	99
精算	H	成功	211,110	24	25
精算	U	成功	211,110	24	25
返金	U	成功	102,087	13	13
返金	H	成功	102,087	13	13
書出し	H	未達	432,872	23	72
書出し	U	未達	358,638+?	21	53

表 2　全課題の費用寄与．全件既知でないときは全体の寄与を確定しない．

成否の組合せ	課題数	H − U token
両側成功	3	未確定
両側未達	1	未確定
成否が異なる	0	未確定
片側以上が未評価	0	未確定

評価・推論器稼働時間を別に記録し，金額や計算量へ換算しない．各最終状態を独立評価器で一度だけ判定し，正解や評価結果をモデルへ返さない．未知の生成使用量が出た場合はその条件を終了し，応答の実行・再試行をしない．API 作用と後片付けが既知で，同じ推論器の idle を確認できた場合のみ評価して固定順を続ける．未知の API 作用や実行環境・評価の異常は全体を止める．

H の採用には全 8 評価・全終端使用量・監査一致，課題ごとの成功喪失 0，両側成功 1 課題以上，全 4 課題の論理費用が U より小さいことを要求する．同数成功だけで品質維持とせず，両側成功・両側未達・成否不一致の費用寄与を分ける．これは開発上の相対基準であり，統計的非劣性の証明ではない．途中は運用状態と使用量だけを確認し，成否と出力比較は全条件終了後，所有推論器停止と PID 不在の確認後に行う．

4　全件結果

成功／評価は U が 3/4，H が 3/4 であった．課題ごとの成功喪失は 0，成功獲得は 0 である．U の全仕事 token は 807,463+?，H は 881,697 であった．成功した 3 課題では，各対の論理 token 差は 0 であった．全 8 条件を評価したが，U の書出し 1 生成の使用量が不明であり，固定した全件比較の費用差は未確定とする．固定した開発上の採用基準は満たさなかった．表 2 は費用欠測時に全群の寄与集計を保留する固定規則による．未達の費用も残し，成功部分のみの減少を全体の改善としない．未評価・未実行は未達として補完しない． 所有推論器の稼働は 5,902.45 秒，うちロードは 10.07 秒であった．全条件の初期化・作業・後片付けは 5,860.09 秒，独立評価は 13.17 秒であり，稼働時間と重複するため加算しない．最大実測 RSS は 220.22 GiB，最大システム swap は 0.00 GiB であった．RSS を GPU 使用量全体とは解釈しない．

表 3　費用を異なる尺度で記録する．既知小計は不明生成の使用量を含まない．

計測対象	U	H
既知全入力 token	773,785	849,976
既知入力の cache 分	673,826	747,123
既知 cache 除外入力	99,959	102,853
既知出力 token	33,678	31,721
使用量不明の生成	1	0
作業秒	2,961.32	2,874.89

5　解釈の範囲

独立した課題は既知 4 つであり，8 条件や生成数を独立課題数へ読み替えない．単一モデル・専用上限 1 値・各 1 回の比較から，別課題やモデル，予算での品質維持を保証しない．同じ seed でも数値実行と cache の影響は残る．ホストでは軽量な編集と報告準備も行っており，速度の測定は排他的な負荷条件ではない．過去の直接 API 構成の品質を回復したかや，別の強い学習方式に対する優劣は調べていない．未達や欠測を残した全件の公開集計と固定版を保存する[*1]．

6　結論

全 8 条件を評価し，使用量不明の 1 生成も含めて原記録を保持した．全件比較の費用差は確定せず，通常の固定予算による全仕事改善は未確立である．課題の正しさと，局所的な出力完成，論理 token，cache，時間を区別し，一般的な品質維持は今後の独立した確認を要する．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] N. Muennighoff, Z. Yang, W. Shi, X. L. Li, L. Fei-Fei, H. Hajishirzi, L. Zettlemoyer, P. Liang, E. Candès, and T. Hashimoto, “s1: Simple test-time scaling,” arXiv:2501.19393v3, 2025.

[4] T. A. Lamb, A. Golinski, E. Gualdoni, S. Williamson, and M. Kirchhof, “Rewards for

[*1] https://github.com/sophiria1225/AI-

Budget-Aware Multi-Turn Agents That Adapt to Arbitrary Test-Time Constraints," arXiv:2610.28409v1, 2026.

[5] ggml-org, "llama.cpp: reasoning budget," commit 620d2225cc436ab0b001e3200e590e3b286ef9ab, `https://github.com/ggml-org/llama.cpp/blob/620d2225cc436ab0b001e3200e590e3b286ef9ab/common/reasoning-budget.cpp`, accessed Oct. 24, 2026.

[6] S. Weinberger and A. Hozez, "Token Reduction Is Not Cost Reduction," arXiv:2607.12161v5, 2026.

[7] A. J. Mercado and A. Lomuscio, "Formal Verification of Agentic Systems over Operational Data," arXiv:2608.03609v1, 2026.

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Keywords LLM agents, harness engineering, state retention, reasoning budget, cost evaluation

Summary draft We compared ordinary reasoning budgets across eight conditions on four known tasks in a stateful LLM agent. All conditions were evaluated, but missing usage for one generation prevented identifying the complete cost difference. These development results do not establish general quality preservation.