状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの通常回復通知を既知 4 課題 12 条件で比較した．欠測または未評価が残り，全件の費用差は確定できなかった．検出対象は 1 課題で，一般的な品質維持は未検証である．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，回復通知，費用評価

1　問題設定と関連研究

状態保持型 LLM エージェントでは，取得済みの値を処理する計算と，同じ情報の再取得が同時に起こり得る．必要な情報と最終成果を残して費用を減らすには，再観測の検出と，その後の行動・完了・全費用を分けて評価する必要がある．本稿では CodeAct[1] 型の持続 Python と AppWorld[2] を用い，通常の回復通知を初期状態から比較する．

AgentLoop[3] は要求の充足と根拠不足をモデル補助で確認し，安定性などの信号から継続・回答・停止を選ぶ．Failure-Aware Observability[4] は反復や情報増分を診断し，警告による探索方針の変更も試行している．警告を完了保証へ置き換える方式ではなく，介入評価の限界も述べている．したがって反復検出，見直し通知，状態に応じた終了という一般形を本稿の新手法とはしない．

本稿の問いは，同じ観測値を再び受け取った事実を通知すると，普通の見直し指示に比べて最終成果と全仕事費用がどう変わるかである．成功条件だけを選ばず，未達・欠測を残す．論理 token，cache，実時間の違い [5] も区別する．

2　再観測の検出と通知

開発用の保存 8 実行・399 API 要求を事後に調べ，固定した Spotify 読取 72 件で，過去の同じ要求と完全な返答値が一致したものは 7 件だった．認証引数を除いて照合すると 34 件となり，成功 login 要求の由来群を用いた照合も同じ 34 件だった．2 つの判定に差がないため，単純な認証引数除外を使用する．これは同じ CSV 課題の 2 実行から得た開発情報であり，独立 2 課題や改善の実証とはしない．

対象は曲・アルバム・プレイリストの一覧と詳細の 6 API に限定する．最も直近の同じ非認証引数の要求と，今回実際に返された値を比較する．監視対象読取が 1 件以上あり，全件が以前のモデル境界で得た同じ値で，それ以外の送信は同じ Spotify login 要求の再成功だけ，という境界が 2 回続いた時点を候補とする．同じ境界内だけの重複は数えない．空の境界，新しい値，例外，他 API で連続を切り，効果不明後は通知しない．保存枠 512 件，比較値 64 KiB を固定する．

N は通知なし，G は残る要求と既存 Python 変数を見直す一般通知，F は再観測の事実と限界を添えて G と同じ見直し文を送る条件である．最初の候補の次入力へ最大 1 回追加し，永続履歴には追加しない．N も同じ監視・記録を行い，完全一致と login 由来群の判定も全条件で保存する．通知文の長さはそろえず，実際の入力費用を計上する．

API を省略せず，返却値の置換，認証値の再利用，変数の変更，追加モデルによる判断を行わない．同じ値を得たことは，ローカル計算の進捗がないこと，現在の権限，将来の値，課題の完了を保証しない．モデルは全ての通常ツールを引き続き使用できる．

3　比較の手順

既知の写真移動，電気代精算，返金，曲情報書出しの 4 課題を各条件 1 回，計 12 条件で計画した．課題順と条件順は N/G/F，G/F/N，F/N/G，N/G/F に固定する．過去の実行を対照へ流用せず，毎回初期状態から開始する．初期 12 入力を事前計数し，同じ課題の 3 条件が同じ要求で始まることを確認する．

Mac Studio M3 Ultra・256 GiB 上で AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS，llama.cpp b11669 を用いる．context は 65,536，出力上限 4,096，1 スロット，温度 1，top-p 0.95，環境 seed42，モデル seed は初回 57 から呼出しごとに 1 増加する．`reasoning_budget_tokens=-1`，返却推論を含む履歴，型付き API を共通とし，実残時間はモデルへ表示し

表 1　固定した全 12 条件．+? は既知小計に使用量不明の生成が残ることを示す．

課題	条件	成果	論理 token	生成	API
写真	N	成功	135,628	16	99
写真	G	成功	135,628	16	99
写真	F	成功	135,628	16	99
精算	G	成功	211,110	24	25
精算	F	成功	211,110	24	25
精算	N	成功	211,110	24	25
返金	F	成功	102,087	13	13
返金	N	成功	102,087	13	13
返金	G	成功	102,087	13	13
書出し	N	未達	320,456+?	20	42
書出し	G	未達	348,819+?	21	79
書出し	F	未達	423,816	23	79

ない．初回の cache 再利用 0 を確認し，以後は通常の prefix cache を用いる．

各条件は 80 生成，450,000 論理 token，1,800 作業秒を上限とし，API は写真 160・他 80，1 生成の待機は 600 秒と実残時間の小さい方である．準備 120 秒，後片付け 180 秒，idle 回復 60 秒，独立評価 180 秒も有限とする．全 12 条件の予約は 960 生成，5,400,000 token，1,200 API，所有サーバ上限 32,400 秒で，使用実績とは別に扱う．

各実行の最終状態を 1 回評価し，評価内容をモデルへ返さない．使用量不明の生成は実行・再試行せずセルを終了する．API 効果と後片付けが確定した場合だけ独立評価を行い，同じ idle サーバで次条件へ進む．効果不明・片付け未確認等では batch を停止し，残る枠を補充しない．

主費用は全入力と全出力の和で，cache 入力，通知，失敗，回復を含める．G − N，F − N，F − G について，全 12 評価・使用量既知・監査正常，課題ごとの成功喪失なし，共通成功 1 件以上，全 4 課題の論理 token 合計の厳密な減少を固定基準とする．F の便益候補には F − N と F − G の両基準に加え，G/F の通知前履歴と予算の hash が同じ送信試行を 1 課題以上要求する．閾値・文面・seed の探索はしない．

4　全仕事の結果

各条件の成功／評価は N が 3/4，G が 3/4，F が 3/4 であった．CSV の最終結果は N が未達，G が未達，F が未達であった．G/F の通知前の入力と予算が一致し，両側で送信を試行した課題数は 1 であった．事実通知の便益候補の固定基準は未達だった．これは新手法の優位性や統計的な非劣性の判定ではない．未達を安く終えた差を，完了した仕事の効率改善に読み替えない．未実行・未評価を未達で補完せず，欠測は残した．

表 2　全 4 課題を含む 3 対照．欠測時は既知分だけで全費用差を確定しない．

比較	課題別成功	全論理 token 差	固定基準
G − N	喪失なし	未確定	未達
F − N	喪失なし	未確定	未達
F − G	喪失なし	未確定	未達

表 3　失敗を含む費用寄与．全 12 条件の使用量が確定したときだけ全体差を分解する．

比較	成否の組合せ	課題数	論理 token 差
G − N	両成功	3	未確定
G − N	両未達	1	未確定
G − N	成否差	0	未確定
G − N	未評価あり	0	未確定
F − N	両成功	3	未確定
F − N	両未達	1	未確定
F − N	成否差	0	未確定
F − N	未評価あり	0	未確定
F − G	両成功	3	未確定
F − G	両未達	1	未確定
F − G	成否差	0	未確定
F − G	未評価あり	0	未確定

表 4　全 12 枠の候補と送信試行．E は完全一致，S は認証引数除外，O は login 要求の由来群．

課題	条件	候補境界 E/S/O	通知の送信試行
写真	N	0/0/0	なし
写真	G	0/0/0	なし
写真	F	0/0/0	なし
精算	G	0/0/0	なし
精算	F	0/0/0	なし
精算	N	0/0/0	なし
返金	F	0/0/0	なし
返金	N	0/0/0	なし
返金	G	0/0/0	なし
書出し	N	0/1/1	なし
書出し	G	0/1/1	009
書出し	F	0/1/1	009

表 5　通知・失敗・回復を含む既知小計．不明使用量を 0 とはしない．

計測	N	G	F
既知論理 token	769,281	797,644	872,641
既知 cache 入力	640,804	666,850	739,068
既知 cache 除外入力	97,021	98,424	102,100
既知出力 token	31,456	32,370	31,473
使用量不明生成	1	1	0
生成試行	73	74	76
API 送信	179	216	216

5　検出・通知と資源

入力計数だけを行って予算で拒否された通知は送信試行へ数えない．試行したという記録と，推論器が返答を完了したことも区別する．観測処理の小計は保存・通知構成を含む全制御費用ではない． 所有推論器は 8,959.431 秒稼働し，うちロード 10.063 秒，独立評価

20.919 秒だった．計測済みセルの準備・作業・後片付けは 8,907.739 秒，未計測セルは 0 件だった．推論器の最大実測 RSS は 220.16 GiB，最大システム swap は 0.00 GiB であった．重なる時間を二重加算せず，論理 token や RSS を FLOPs・料金・GPU 全体の使用量へ換算しない．

6 解釈の範囲

独立した課題は調整に用いた既知 4 つで，検出対象の API を含むのは CSV の 1 つだけである．他の 3 課題を誤検出率の陰性例として数えない．各 1 回の比較から，一般的な平均効果や品質の非劣性は推定しない．同じ seed でも実装・数値・実行時の揺らぎが残る．軽量な資料作成を並行したため，速度の排他的な計測でもない．

F/G は長さを合わせた文章ではなく，意味情報と文量の効果を独立に識別しない．監視対象に属さない API やローカル計算を含む反復は本検出器の対象外である．検出器のない無計測基準との監視費用の差，近接手法の完全再実装との性能差も測っていない．全件監査・通知台帳と固定文面は公開リポジトリ[*1]へ残す．

7 結論

再観測の事実を用いる通知を，通知なし・一般的な見直し通知と比較する全 12 条件を計画し，12 条件の独立評価を得た．全予定枠を残し，全仕事の成否・費用，成功と未達の寄与，検出候補と送信試行を区別した．事実通知の便益候補の固定基準は未達だった．通常対照の結果を新手法の成立へ置き換えず，既知 4 課題の結果を他課題の品質保証へ一般化しない．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] W. Zheng, M. Xu, K. Hu, K. Ye, and C. Xu, “AgentLoop: Runtime Control of Slot-closed Execution Loops for Tool-augmented LLM Agents,” arXiv:2609.33315v1, 2026.

[4] X. Li, W. Yan, Y. Wu, P. Liang, M. Yuan, J. Liu, and J. Yang, “Early Diagnosis of Wasted Computation in Multi-Agent LLM Systems via Failure-Aware Observability,” arXiv:2606.01365v2, 2026.

[5] S. Weinberger and A. Hozez, “Token Reduction Is Not Cost Reduction,” arXiv:2607.12161v5, 2026.

[*1] https://github.com/sophiria1225/AI-

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Keywords LLM agents, harness engineering, state retention, recovery notices, cost evaluation

Summary draft We compared ordinary recovery notices across twelve conditions on four known tasks in a stateful LLM agent. Missing usage or evaluations prevented a complete cost comparison. Only one task contained monitored APIs; general quality preservation remains untested.