状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの時間通知を評価する．実時間上限を共通にし, 残時間の表示有無を比較する．保存入力の１秒差による経路変化と課題全体の成否, 全入出力費用を分けて検証する．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1　問題設定

必要な情報と最終品質を保って仕事全体の費用を減らすには，ハーネスがモデルへ渡す情報の必要性を検証する必要がある．環境の観測に加え，残 token，API 回数，残時間などの制御情報も次の行動へ入力される．このうち残時間は同じ課題状態でも推論速度や処理時間によって変わる．従って，同じ seed と実行上限を指定したことだけでは，同じ判断入力を与えたことにならない．

本稿の問いは，**実際の期限を共通にしても，現在の残時間をモデルへ表示するかどうかが，最終成否と全仕事費用へどう現れるか**である．残時間の非表示を常に望ましいとは仮定せず，通知の役割と強制的な停止の役割を分けて評価する．

2　関連研究と本稿の範囲

コードを行動とする CodeAct[1] や，状態を持つアプリ操作を評価する AppWorld[2] を背景とする．On the Clock[3] は時間情報の通知とコマンドへの期限強制を区別し，予算遵守と時間の生産的利用が別の問題であることを扱う．本稿も通知と期限を分離するが，この分離そのものを独自手法とはしない．保存入力に対する局所的な応答変化と，初期状態からの課題全体の品質・費用を別の検証として扱う．通信参照の正規化も通常の比較条件整備である．

3　通知と実行上限の分離

時点 j でハーネスが持つ実資源状態を b_j，モデルへ渡す表示を v_j とする．次のモデル入力は，公開履歴と返却済み推論を含む h_j と v_j から作る．表示条件 M は b_j の実測残時間を整数秒で通知し，非表示条件 H はその値を除いて非表示である旨を明示する．H は時刻を固定値や虚偽値へ置き換えない．token，API，生成回数の通知は共通にする．実行可否とタイムアウトは両側とも実際の単調時計から判定する．表示を消したことによる期限延長はない．

通信上の tool-call ID と tool-result ID は両条件とも初出順に付け直し，対応を検査してから入力を計数する．文章，API 引数・返却，過去の推論には文字列置換を行わず，元履歴も保存する．この処理は通信識別子の表現をそろえるもので，モデル内部や GPU 演算の決定性を保証しない．同じ固定ランタイムで実施済みの別の入力診断では，ID だけを変更しても再構成 token 列は一致していた．従って，通信 JSON 上の ID 差だけからモデル入力差や挙動への影響を推定しない．

4　保存入力の局所診断

先行する失敗通知の比較では，API 例外より前に経路が分かれた 2 入力があった．通信参照を対応付けた後の最初の差は実測残時間１秒だった．この 2 入力について他の項目を共通にし，元値と＋１秒を各３回，計 12 回生成した．全回で初期 cache は０，同じ通知内では３回の公開出力が一致し，通知間では両入力とも異なった．使用量不明は０，論理入出力 99,966 token であり，生成コードの実行と課題評価は行っていない．これは小さな入力差への局所反応であり，元の warm 状態の再現，実行後の成否差，通知非表示の品質保証ではない．

5　全仕事比較の方法

既知の写真移動，電気代精算，返金，曲情報書出しの４課題について，初期状態から M/H を各１回比較する．これらは過去の方式探索で閲覧・実行した開発課題であり，未調整群ではない．AppWorld 0.1.3.post1 上で，MiniMax-M3 の IQ4_XS 量子化版と llama.cpp b11669 を用いる．推論を有効にし，温度 1.0，top-p 0.95，１生成の通信待ち上限 600 秒と残実時間の小さい方を用いる．モデル，公開初期状態，型付き API 返却，通常 Python 例外，持続 Python，公開 API 名，初回からの推

表 1　既知 4 課題の全 8 条件．M：実測残時間表示，H：非表示．費用は全論理入出力 token．

課題・条件	成否	費用	生成	API
写真 M	成功	177,373	17	100
写真 H	成功	135,628	16	99
精算 M	成功	284,294	20	26
精算 H	成功	211,110	24	25
返金 M	成功	216,854	21	25
返金 H	成功	102,087	13	13
書出し M	未達	108,571	12	80
書出し H	未達	331,569 ＋不明 1	20	69

論保持は共通とする．環境 seed42，モデル seed57 ＋呼出し番号を固定し，課題順に M/H，H/M，M/H，H/M と実行する．各条件 80 生成，450,000 論理 token，1,800 作業秒を上限とし，API 上限は写真 160，他 80 とする．出力上限は 4,096 token と残予算の小さい方である．各条件の初回は cold cache を実測確認し，後続は通常の prefix cache を使う．

最終成否は独立評価器で各 1 回判定し，評価結果や隠れた基準をモデルへ返さない．仕事費用は初期からの全論理入力 I_j と出力 O_j の和

$$T_{\mathrm{work}} = \sum_j (I_j + O_j) \tag{1}$$

で，推論，制御情報，失敗，回復と cache 入力を含む．論理 token を請求額や時間と同一視しない．API，準備，作業，後片付け，評価，推論器ロード・滞在は別に示し，重なる時間を加算しない．

生成を送信した後に使用量が不明になった場合，未確認応答を実行せず，再試行もしない．既知部分と不明試行を残し，確定合計差は求めない．期限後に応答と使用量だけが届いた場合も，その費用は計上し，期限外のコード実行は認めない．H の開発上の採用基準は全 8 条件の評価・全使用量既知・監査一致，課題ごとの成功喪失 0，合計 T_{work} の減少とする．これは統計的な非劣性判定ではない．

6　全結果

M は 4 条件中 3 成功，H は 4 条件中 3 成功だった．全論理入出力は M が 787,092，H が 780,394 ＋不明 1 である．未評価または使用量不明を含むため，全費用差は確定しない．事前の開発上の採用基準は満たさなかった．単一実行の合計差を平均的改善や一般的な品質維持とは解釈しない．作業時間の合計は M が 1,897.7 秒，H が 2,975.3 秒であり，論理 token とは別に報告する．全条件合計は 143 生成，437 API，17 API 例外である．所有推論器の滞在時間は 4,935.6 秒，この内に含まれる独立評価の時間は 13.60 秒だった．表示説明文の差により，H の初回入力は全課題で M より 12 token 多い．従って入力文の単純な短縮を評価した比較ではない．各条件の入出力，cache 入力，準備・作業・後片付け時間は全件表に保存する．

7　解釈と限界

M と H は初回から通知文が異なり，その文章長の差も処置に含む．操作はハーネスの現在の残時間欄に限り，生成コードによる独自の時刻参照を禁止するものではない．同じ API 列に到達しても，後続の入力，Python 状態，潜在計算の同一性は意味しない．同じ seed でも GPU 演算や cache 状態による変動が残るため，単一実行の費用差を安定した平均改善とは扱わない．また，既知 4 課題各 1 回で得た採用基準の成否は，他の課題・モデル・予算への一般化を支持しない．

局所診断で 1 秒差への反応が確認されても，課題全体で時間通知が不要であるとは結論できない．反対に，時間内に停止したことだけでは，必要処理と品質を保った効率化は示せない．表示情報，実行上限，実際の操作，最終成否，全仕事費用を対応付けて判断する．全条件と探索段階の先行結果を公開記録に保持する[*1]．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, “On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents,” arXiv:2610.10833v1, 2026.

[*1] https://github.com/sophiria1225/AI-

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Summary draft We evaluate wall-time observations in stateful LLM agents under a common enforced deadline. Saved-input calibration and whole-task comparisons separate local response changes from task success and total logical token cost. The study examines four known development tasks and does not establish general quality preservation.