状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの残時間通知を評価する．既知 4 課題の 3 反復で, 成功部分の費用減と失敗費用の増加を分離する．欠測を保持した費用区間と実行経路の照合により, 局所的な応答変化と全体改善の違いを示す.

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，時間通知，費用評価

1　問題設定

必要な情報と最終品質を保って仕事全体の費用を減らすには，ハーネスがモデルへ渡す情報の必要性を検証する必要がある．環境の観測に加え，残 token，API 回数，残時間などの制御情報も次の行動へ入力される．このうち残時間は同じ課題状態でも推論速度や処理時間によって変わる．従って，同じ seed と実行上限を指定したことだけでは，同じ判断入力を与えたことにならない.

本稿の問いは，**実際の期限を共通にしても，現在の残時間をモデルへ表示するかどうかが，最終成否と全仕事費用へどう現れるか**である．残時間の非表示を常に望ましいとは仮定せず，通知の役割と強制的な停止の役割を分けて評価する.

2　関連研究と本稿の範囲

コードを行動とする CodeAct[1] や，状態を持つアプリ操作を評価する AppWorld[2] を背景とする．ツール列・引数・分岐位置の反復一致は既に評価されており [7]，ハーネス探索でも費用と選択結果の信頼性が検討されている [8]．On the Clock[3] は時間情報の通知とコマンドへの期限強制を区別し，予算遵守と時間の生産的利用が別の問題であることを扱う．本稿も通知と期限を分離するが，この分離そのものを独自手法とはしない．Timely Machine[4] は推論とツールの待ち時間を含む時間予算への適応を学習し，速度や時間情報の扱いを検討する．また，数値精度や実行構成による推論の非決定性 [5] と，複数段の評価に必要な記録の報告 [6] にも先行研究がある．本稿では，保存入力の 1 秒差への局所反応と，全仕事の成否・費用・同一 seed 反復を区別し，現在時刻を含む制御入力の差と出力列の変化を照合する．時刻通知，固定 seed の限界，記録の保存そのものを新規手法とはしない．通信参照の正規化も通常の比較条件整備である．入力形式や schema 順序，サーバ運用による品質・資源測定の変化にも先行研究がある [9]．同じ計算結果から提示だけを変える再開比較も行われており [10]，保存入力の対照実験そのものを独自性とはしない.

3　通知と実行上限の分離

時点 j でハーネスが持つ実資源状態を b_j，モデルへ渡す表示を v_j とする．次のモデル入力は，公開履歴と返却済み推論を含む h_j と v_j から作る．表示条件 M は b_j の実測残時間を整数秒で通知し，非表示条件 H はその値を除いて非表示である旨を明示する．H は時刻を固定値や虚偽値へ置き換えない．token，API，生成回数の通知は共通にする．実行可否とタイムアウトは両側とも実際の単調時計から判定する．表示を消したことによる期限延長はない.

構造化された tool-call ID と tool-result ID は両条件とも初出順に付け直し，対応を検査してから入力を計数する．ただし，不正な引数の呼出しを文章として保存する経路内の ID はこの処理の対象外であり，非表示条件でも入力差が残り得る．この経路の差は元の実験を変更せず，保存された呼出しと表示処理に結び付けた補助読取で確認する．文章，API 引数・返却，過去の推論には文字列置換を行わず，元履歴も保存する．この処理は通信識別子の表現をそろえるもので，モデル内部や GPU 演算の決定性を保証しない．同じ固定ランタイムで実施済みの別の入力診断では，通常の構造化参照の ID だけを変更しても再構成 token 列は一致していた．一方，P80 と第 2 反復の H の書出しでは，14 生成目の保存要求が文章化された ID だけで異なり，入力計数は 22,669 対 22,667 だった．従って，通信 JSON 上の ID 差を一律に無視せず，実際に文章となる経路と区別する．この観測だけでは後続の成否や費用への因果効果は分からない.

4　保存入力の局所診断

先行する失敗通知の比較では，API 例外より前に経路が分かれた 2 入力があった．通信参照を対応付けた後の最初の差は実測残時間 1 秒だった．この 2 入力について他の項目を共通にし，元値と＋1 秒を各 3 回，計 12 回生成した．全回で初期 cache は 0，同じ通知内では 3 回の公開出力が一致し，通知間では両入力とも異なった．使用量不明は 0，論理入出力 99,966 token であり，生成コードの実行と課題評価は行っていない．これは小さな入力差への局所反応であり，元の warm 状態の再現，実行後の成否差，通知非表示の品質保証ではない．

5　全仕事比較の方法

既知の写真移動，電気代精算，返金，曲情報書出しの 4 課題について，初期状態から M/H を各 3 回比較する．最初の全 8 条件を P80，同じ 8 条件を 2 回追加する計画を P81 と呼ぶ．P80 を確認後に P81 の全 16 条件と順序を固定しており，3 回を初めから同時に事前登録した比較ではない．これらは過去の方式探索で閲覧・実行した開発課題であり，未調整群ではない．AppWorld 0.1.3.post1 上で，MiniMax-M3 の IQ4_XS 量子化版と llama.cpp b11669 を用いる．推論を有効にし，温度 1.0，top-p 0.95，1 生成の通信待ち上限 600 秒と残実時間の小さい方を用いる．モデル，公開初期状態，型付き API 返却，通常 Python 例外，持続 Python，公開 API 名，初回からの推論保持は共通とする．環境 seed42，モデル seed57 ＋呼出し番号を固定し，初回は課題順に M/H，H/M，M/H，H/M と実行する．2 回目は各組の順序を逆転し，3 回目は初回と同じ順序とする．課題や seed の探索ではなく，同じ条件の 3 回の安定性を調べる．各条件 80 生成，450,000 論理 token，1,800 作業秒を上限とし，API 上限は写真 160，他 80 とする．出力上限は 4,096 token と残予算の小さい方である．各条件の初回は cold cache を実測確認し，後続は通常の prefix cache を使う．

最終成否は独立評価器で各 1 回判定し，評価結果や隠れた基準をモデルへ返さない．仕事費用は初期からの全論理入力 I_j と出力 O_j の和

$$T_{\mathrm{work}} = \sum_j (I_j + O_j) \tag{1}$$

で，推論，制御情報，失敗，回復と cache 入力を含む．論理 token を請求額や時間と同一視しない．API，準備，作業，後片付け，評価，推論器ロード・滞在は別に示し，重なる時間を加算しない．

表 1　全 24 条件の論理 token と成否．成：成功，否：未達．$+?_n$ は別に使用量不明が n 生成あることを示す．M：残時間表示，H：非表示．

課題	条件	反復 1（P80）	反復 2	反復 3
写真	M	177,373 成	210,357 成	164,024 成
写真	H	135,628 成	135,628 成	135,628 成
精算	M	284,294 成	215,182 成	263,695 成
精算	H	211,110 成	211,110 成	211,110 成
返金	M	216,854 成	138,701 成	73,670 成
返金	H	102,087 成	102,087 成	102,087 成
書出し	M	108,571 否	134,352 否	439,709 否
書出し	H	331,569+$?_1$ 否	319,348 否	324,014+$?_1$ 否

生成を送信した後に使用量が不明になった場合，未確認応答を実行せず，再試行もしない．既知部分と不明試行を残し，確定合計差は求めない．期限後に応答と使用量だけが届いた場合も，その費用は計上し，期限外のコード実行は認めない．H の開発上の採用基準は全 8 条件の評価・全使用量既知・監査一致，課題ごとの成功喪失 0，合計 T_{work} の減少とする．これは統計的な非劣性判定ではない．

6　全条件の成否と費用

反復 1 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理 token は順に 787,092，780,394+$?_1$ だった．全費用差は使用量不明または未実行のため未確定である．開発上の採用基準は未達で，作業時間合計は M 1,897.7 秒，H 2,975.3 秒だった．反復 2 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理 token は順に 698,592，768,173 だった．H − M の合計差は +69,581 token である．開発上の採用基準は未達で，作業時間合計は M 1,991.5 秒，H 2,691.4 秒だった．反復 3 は M が 4 評価中 3 成功，H が 4 評価中 3 成功で，全論理 token は順に 941,098，772,839+$?_1$ だった．全費用差は使用量不明または未実行のため未確定である．開発上の採用基準は未達で，作業時間合計は M 2,645.3 秒，H 2,975.6 秒だった．追加 P81 の推論器滞在は 10,405.1 秒，この内の評価時間は 26.82 秒だった．時間は重なるため合算しない．H の初回入力は全課題で M より 12 token 多い．全生成，API，cache，準備・作業・後片付けと評価の全件表を公開記録へ保存する．

7　欠測を保持した補助的な費用区間

事後の補助解析では，P80 と P81 の所有推論器の完全な直列ログを全 429 生成へ順序対応させた．既知 427 件すべてで，入力処理数＝終端入力 − cache 入力，生成数＝終端出力，送信前計数＝終端入力が一致した．不明要求 j について，同一送信の入力計数を $\widehat{I}_j$，ログに残っ

表 2　全 4 課題の H − M 費用差（論理 token）．反復 2 以外は順序対応と固定推論器の計数に基づく区間であり，統計的信頼区間ではない．元の不明生成は残す．

集計	H − M
反復 1	+32,959〜+34,925
反復 2	+69,581
反復 3	-127,288〜-123,560
合計	-24,748〜-19,054

た最大生成進捗を g_j，要求の出力上限を B_j とすると，固定推論器の計数・停止実装を前提に

$$\widehat{I}_j + g_j \le T_j \le \widehat{I}_j + B_j \tag{2}$$

を得る．生成数は入力処理完了後に増加し，要求上限で停止する．全保存要求の hash と上限を照合し，別名による上書きがないことを確認した．不明 2 件の区間は順に 39,657〜41,623，40,971〜44,699 token である．この順序対応は既知 427 件の一致で裏付けられるが，要求 hash とサーバ task ID を暗号学的に結合したものではない．記録外の生成がないこと，入力計数と生成が同じ messages/tools を使うこと，固定実装どおりに処理されることを前提とする．終端使用量の補完ではなく，cache 入力と取消し後の処理を含む論理 token の範囲である．GPU 演算量，投機生成の未受理作業，料金や実時間の区間ではない．3 反復合計では H が条件付きで 19,054〜24,748 token，約 0.79〜1.02% 少ない．ただし両条件で成功した 3 課題の減少 397,675 token に対し，両条件で失敗した書出し課題は 372,927〜378,621 token 増えている．反復ごとの全費用差も増加・増加・減少であり，安定した改善とはいえない．第 3 反復の書出し費用差は双方の未達で停止した差であり，完成に必要な費用の削減ではない．元の不明 2 件と採用基準未達は保持する．

8　同じ条件の経路の照合

各条件の 3 実行から得る 3 対，計 24 対を全て比較する．公開出力と返却メッセージ全体の hash を照合し，返却された内部推論の意味内容は解析しない．最初に要求が異なる箇所では，現在の残時間欄だけをそろえた事後照合も行う．これは実際のモデル入力 token 列の同一性を確認する操作ではなく，差の所在を切り分ける読取解析である．要求列または公開出力列の完全一致は，全使用量が既知で比較できた対について示す．不明生成を含む対の全体一致は未確定とし，判定できた接頭部だけを全体へ広げない．時計欄以外をそろえた照合は観測された最初の要求差だけに関する結果であり，出力変化や全仕事費用の原因を単独で決める証拠ではない．

表 3　全 8 条件の対比較．既知は両実行の全使用量が既知の対数／3．要求・出力は一致対数／判定対数．時計は最初の要求差が現在の時計欄だけだった観測対数．

課題	条件	既知	要求	公開出力	時計
写真	M	3/3	0/3	0/3	3
写真	H	3/3	3/3	3/3	0
精算	M	3/3	0/3	0/3	3
精算	H	3/3	3/3	3/3	0
返金	M	3/3	0/3	0/3	3
返金	H	3/3	3/3	3/3	0
書出し	M	3/3	0/3	0/3	3
書出し	H	0/3	未確定	未確定	0

9　解釈と限界

M と H は初回から通知文が異なり，その文章長の差も処置に含む．操作はハーネスの現在の残時間欄に限り，生成コードによる独自の時刻参照を禁止するものではない．同じ API 列に到達しても，後続の入力，Python 状態，潜在計算の同一性は意味しない．同じ seed でも GPU 演算や cache 状態による変動が残るため，単一実行の費用差を安定した平均改善とは扱わない．また，独立した課題は既知 4 つである．24 行を 24 課題とは扱わず，24 対も同じ実行を共有するため独立標本とはしない．同じホストで編集，読取解析，軽量検査も行っており，計算機負荷を排他的に固定した比較ではない．出力列の一致は意味的な同値や将来の再現を保証せず，時計欄の差が先行したことだけで全費用差の因果効果は同定しない．この反復から他の課題・モデル・予算の一般的品質維持や平均削減は主張しない．同じ書出し課題には，過去の直接 API 型で 75 API，370,343 token，1,075.6 秒の成功記録がある．設定と実行時期が異なるため同時対照ではないが，現在の未達を上限だけで説明したり，未達を安く終えることを必要品質の維持とみなしたりはできない．

局所診断で 1 秒差への反応が確認されても，課題全体で時間通知が不要であるとは結論できない．反対に，時間内に停止したことだけでは，必要処理と品質を保った効率化は示せない．表示情報，実行上限，実際の操作，最終成否，全仕事費用を対応付けて判断する．全条件と探索段階の先行結果を公開記録に保持する[*1]．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions

[*1] https://github.com/sophiria1225/AI-

elicit better LLM agents," Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, "AppWorld: a controllable world of apps and people for benchmarking interactive coding agents," Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] A. Wang, N. Madan, V. Sobal, M. Trager, M. Kleinman, E. Mansimov, W. Xia, and S. Soatto, "On the Clock: Towards Punctual and Productive Time-Budgeted AI Agents," arXiv:2610.10833v1, 2026.

[4] Y. Ma, L. Li, Y. Chen, P. Li, X. Li, Q. Guo, D. Lin, and K. Chen, "Timely Machine: Awareness of Time Makes Test-Time Scaling Agentic," Proc. ACL, vol.1, pp.4619–4636, San Diego, USA, July 2026.

[5] J. Yuan, H. Li, X. Ding, W. Xie, Y.-J. Li, W. Zhao, K. Wan, J. Shi, X. Hu, and Z. Liu, "Understanding and Mitigating Numerical Sources of Nondeterminism in LLM Inference," Advances in Neural Information Processing Systems, vol.38, 2025, doi:10.52202/085713-5653.

[6] P. Pattnayak and A. Bhatia, "ReproEvalCard: A Reporting Standard for Reproducible Evaluation of LLM Pipelines," Proc. ACL, vol.2, pp.238–249, San Diego, USA, July 2026.

[7] A. Yagubyan, "How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines," arXiv:2605.28840v1, 2026.

[8] C. Zhao, H. Ruan, W. Chen, P.-f. Tu, U. Abbasi, and J. Hesch, "Beyond Prompts: Measuring and Optimizing LLM Tool-Agent Harnesses," arXiv:2609.05736v1, 2026.

[9] R. Agarwal, "Measuring Local SLM Agents as Systems: Protocol Effects on Quality and Resource Use," preprint, 2026, doi:10.5281/zenodo.21903714.

[10] K. Zhang, S. Chundur, J. P. Owusu, M. J. Abdolhosseini Qomi, and M. Raissi, "Same Simulation, Different Evidence: Where Retrieved Tool Output Costs LLM Agents Accuracy," arXiv:2610.26836v1, 2026.

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Summary draft Under a common deadline, we compare wall-time visibility over three repetitions of four known development tasks. Conditional token intervals retain missing usage and separate reductions on successful tasks from increases on failures. Cost directions vary across repetitions; persistent failures prevent a general efficiency claim.