状態保持型 LLM エージェントにおける情報保持と実行制御の評価

検討用別稿・著者情報未設定

あらまし案　状態保持型 LLM エージェントの通常ツール提出設定を既知 4 課題 8 条件で比較した．全 8 条件を評価し，両設定とも 3 課題が成功した．使用量不明の 1 生成が残り，全仕事費用差は未確定である．

キーワード　LLM エージェント，ハーネスエンジニアリング，状態保持，ツール提出，費用評価

1　問題設定と先行研究

必要な情報と最終成果を保ちながら仕事全体の費用を減らすには，出力形式，実操作，課題達成を区別する必要がある．CodeAct[1] 型の状態保持エージェントが実行コードを提出せず本文だけを返す場合，出力が安定していても有効な操作を実行できない．AppWorld[2] の既知 4 課題で得た閉じた 24 実行の全 426 生成には，構造化提出完了 397，構造化呼出し後の提出未完了 4，構造化呼出しなし 21，応答不明 4 があった．397 には Python 通常例外を含み，課題成功数ではない．この全件観測を動機として，任意提出と必須提出の通常設定を初期状態から比較する．

文法制約による構造化出力 [3] には先行研究があり，制約による生成分布の変化と文法適合性の区別 [4] も既に扱われている．本稿は制約復号や適応文法を提案せず，固定した backend[5] の既存設定が，有限予算下の全仕事の成否と費用へ与える結果を調べる．構造の完成や通常設定の比較だけを新手法の新規性とはしない．

2　実行系と固定比較

2.1　提出設定と共通条件

通常の任意提出を A，必須提出を R とする．要求の指定値はそれぞれ `auto` と `required` である．使用する MiniMax-M3 用処理では R の文法はツール部分を任意にせず，文法の遅延適用も無効にする．これは有限の出力枠内での完了，正しい Python，課題達成を保証するものではない．両側で推論を有効にし，推論ブロック専用上限は -1 を明示する．全出力上限 4,096 と全仕事予算は残る．

全返却推論，持続 Python，型付き API 返却，通常例外，公開 API 仕様を共通にする．呼出しと結果の構造化参照を対応を保って統一し，その後にモデル向けに文章化する．通常文，引数，業務 ID，観測は書き換えない．参照正規化には先行研究 [6] があり，共通の履歴処理を独自方式としない．残 token，API，生成回数の通知は共通で，実残時間は表示せず単調時計の期限で強制する．通知を過去履歴に蓄積せず，別の回復通知は加えない．

初期の要求差は `tool_choice` だけで，入力計数と生成に同じ指定を渡す．サーバのテンプレート，token 化，文法適用の効果は設定に含まれるため，入力 token 数の一致を要求せず，文法だけの因果効果とは呼ばない．各要求の計数と終端使用量を照合する．

2.2　課題，順序，予算

写真移動，電気代精算，返金，曲情報書出しの既知 4 課題を各条件 1 回，初期状態から実行する．順序は A/R，R/A，A/R，R/A とする．環境 seed42，モデル seed57 から生成ごとに 1 増やす．AppWorld 0.1.3.post1，MiniMax-M3 IQ4_XS，llama.cpp b11669 を Mac Studio M3 Ultra・256 GiB で使用する．温度 1.0，top-p 0.95，文脈 65,536，q8_0 の KV，1 スロットを共通とし，初回の cache 再利用 0 を確認して以後は通常の prefix cache を使う．

各条件 80 生成，450,000 論理 token，1,800 作業秒，写真 160・他 80 API，出力最大 4,096 かつ残 token に応じた予約を上限とする．1 生成は 600 秒と残作業時間の小さい方，初期化 120 秒，後片付け 180 秒，idle 確認 60 秒，独立評価 180 秒を上限とする．全 8 条件の予約は 640 生成，3,600,000 token，800 API，所有推論器 21,600 秒であり，使用量とは区別する．値，閾値，seed を探索せず，過去の失敗・不明・未実行枠を置換しない．保留 12 課題は閲覧しない．

3　計測と事前判定

一次費用は全仕事の $T = \sum_j (I_j + O_j)$ とし，cache を含む全入力，出力，返却推論，通知，失敗，回復を数える．cache 除外入力，API，実時間は別に残す．論理

表 1　予定した全 8 条件．+? は既知小計に使用量不明の生成が残ることを表す．

課題	条件	成果	論理 token	生成	API
写真	A	成功	135,628	16	99
写真	R	成功	135,628	16	99
精算	R	成功	211,110	24	25
精算	A	成功	211,110	24	25
返金	A	成功	102,087	13	13
返金	R	成功	102,087	13	13
書出し	R	未達	433,732	22	60
書出し	A	未達	320,456+?	20	42

表 2　全課題の費用寄与．全件既知でないときは全体の寄与を確定しない．

成否の組合せ	課題数	R − A token
両側成功	3	未確定
両側未達	1	未確定
成否が異なる	0	未確定
片側以上が未評価	0	未確定

token と他費用の不一致 [7] を認め，金額や FLOPs へ換算しない．一次品質は各最終状態に対する一度の独立評価であり，基準や結果をモデルへ返さない．全 8 枠と全生成を保持し，終端使用量不明時は応答を実行せず条件を終了する．API 作用と後片付けが既知で同じ推論器の idle を確認できた場合だけ，評価後に予定順を続ける．API 作用不明や環境・評価異常では全体を停止する．

R の開発上の採用には，全 8 評価と終端使用量が既知，監査一致，課題ごとの成功喪失 0，両側成功 1 課題以上，全 4 課題の論理費用が A より小さいことを要求する．同数成功だけでは通さず，成功・未達・成否不一致・未評価の費用寄与を分ける．CSV の完了も別に報告し，安く未達になった差を達成改善としない．

二次指標は，既知応答のツール提出数と出力上限到達，外側の形式拒否・Python 例外・未実行の記録数，実送信 API 数である．未知応答の形式を 0 で補完しない．出力・行動の再現性を区別する先行研究 [8] を踏まえ，形式の改善を課題達成の代替指標にしない．実行中の成否を見て条件を変更せず，全体終了と所有プロセスの不在確認後に監査する．

4　全件結果

成功／評価は A が 3/4，R が 3/4 であった．課題ごとの成功喪失は 0，成功獲得は 0 である．A の全仕事 token は 769,281+?，R は 882,557 であった．全 8 条件を評価したが，A の 1 生成で終端使用量が不明なため，全件の正確な費用差は未確定とする．固定した開発上の採用基準は満たさなかった．CSV 課題は R が未達，A が未達であった．未達の費用も残し，成功部分のみの減少を全体の改善としない．未評価・未実行は未達と

表 3　生成数と外側の実行記録数は異なる単位．不明応答を提出なしへ数えない．

観測単位	A	R
応答既知の生成	72	75
応答不明の生成	1	0
既知で提出なし	3	1
既知で上限到達	2	2
形式拒否の記録	4	2
Python 例外の記録	11	12
提出後未実行の記録	0	0

表 4　費用を異なる尺度で記録する．既知小計は不明生成の使用量を含まない．

計測対象	A	R
既知全入力 token	737,825	853,963
既知入力の cache 分	640,804	750,939
既知 cache 除外入力	97,021	103,024
既知出力 token	31,456	28,594
使用量不明の生成	1	0
作業秒	2,976.26	2,698.15

して補完しない． 出力上限到達と形式拒否は重なり得る．構造化提出に Python 例外や API 送信が含まれる場合があり，形式の改善を最終成果の代替にしない．全生成記録と全 API 送信の対応を監査した． 所有推論器の稼働は 5,739.32 秒，うちロードは 10.06 秒であった．全条件の初期化・作業・後片付けは 5,698.73 秒，独立評価は 13.86 秒であり，稼働時間と重複するため加算しない．最大実測 RSS は 220.29 GiB，最大システム swap は 0.00 GiB であった．RSS を GPU 使用量全体とは解釈しない．

5　適用範囲

独立した課題は既知 4 つであり，8 条件や生成数を独立標本数へ読み替えない．先行 24 実行の解析後に選んだ開発比較であり，未見確認や統計的な非劣性試験ではない．単一モデル，各 1 回の結果を別課題やモデルへ一般化しない．同じ seed にも数値実行，cache，ホスト負荷の変動が残る．ホストでは軽量な編集と資料準備も行い，排他的な速度測定ではない．他の文法制約方式や学習方式との優劣は測っていない．全予定条件と出典を公開する[*1]．

6　結論

全 8 条件を評価し，両設定とも 3 課題が成功した．A の 1 生成の使用量不明を保持した．全件比較の費用差は確定せず，通常の必須提出による全仕事改善は未確立である．課題の正しさと，局所的な出力完成，論理 token，

[*1] https://github.com/sophiria1225/AI-

cache，時間を区別し，一般的な品質維持は今後の独立した確認を要する．

参考文献

[1] X. Wang, Y. Chen, L. Yuan, Y. Zhang, Y. Li, H. Peng, and H. Ji, “Executable code actions elicit better LLM agents,” Proc. ICML, PMLR, vol.235, pp.50208–50232, Vienna, Austria, July 2024.

[2] H. Trivedi, T. Khot, M. Hartmann, R. Manku, V. Dong, E. Li, S. Gupta, A. Sabharwal, and N. Balasubramanian, “AppWorld: a controllable world of apps and people for benchmarking interactive coding agents,” Proc. ACL, vol.1, pp.16022–16076, Bangkok, Thailand, Aug. 2024.

[3] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” Proc. EMNLP, pp.10932–10952, Singapore, Dec. 2023, doi:10.18653/v1/2023.emnlp-main.674.

[4] K. Park, J. Wang, T. Berg-Kirkpatrick, N. Polikarpova, and L. D’Antoni, “Grammar-aligned decoding,” Advances in Neural Information Processing Systems, vol.37, 2024, doi:10.52202/079017-0774.

[5] ggml-org, “llama.cpp: MiniMax-M3 parser,” commit 620d2225cc436ab0b001e3200e590e3b286ef9ab, `https://github.com/ggml-org/llama.cpp/blob/620d2225cc436ab0b001e3200e590e3b286ef9ab/common/parsers/minimax-m3.cpp`, accessed Oct. 24, 2026.

[6] A. J. Mercado and A. Lomuscio, “Formal Verification of Agentic Systems over Operational Data,” arXiv:2608.03609v1, 2026.

[7] S. Weinberger and A. Hozez, “Token Reduction Is Not Cost Reduction,” arXiv:2607.12161v5, 2026.

[8] A. Yagubyan, “How Consistent Are LLM Agents? Measuring Behavioral Reproducibility in Multi-Step Tool-Calling Pipelines,” arXiv:2605.28840v1, 2026.

Title Evaluating Information Retention and Execution Control in Stateful LLM Agents

Authors 未設定

Keywords LLM agents, harness engineering, state retention, tool submission, cost evaluation

Summary draft We compared ordinary tool-choice settings across eight evaluated conditions on four known tasks. Both settings succeeded on three tasks. One generation had unknown token usage, preventing an exact whole-task cost comparison. General quality preservation remains untested.